LAPORAN TUGAS RANCANG

COMPUTER VISION AND APPLICATION

Deteksi Huruf Bahasa Isyarat Indonesia (BISINDO) Secara Real-Time Menggunakan YOLOv8n

Disusun oleh:

1.	Marchell Adi Pratama	672023081
2.	Jan Alberto Chrisdono Suyudono	672023108
3.	Evania Jorrell Feodora Aritonang	672023223

PROGRAM STUDI S1 TEKNIK INFORMATIKA

FAKULTAS TEKNOLOGI INFORMASI

UNIVERSITAS KRISTEN SATYA WACANA

2025

BAB I. PENDAHULUAN

1.1. Rumusan Masalah

Rumusan masalah yang menjadi fokus dalam penelitian ini adalah

1. Bagaimana membandingkan efisiensi *pipeline* YOLOv8n (*Single-Stage*) dengan CNN Klasifikasi + MediaPipe (*Two-Stage*) dalam deteksi isyarat tangan BISINDO?
2. Bagaimana mengintegrasikan hasil deteksi *real-time* dari YOLOv8n dengan mekanisme stabilisasi prediksi dan Text-to-Speech (TTS) untuk menghasilkan keluaran kalimat yang akurat dan diucapkan?

1.2.Tujuan Penelitian

Tujuan dari penelitian ini adalah:

- Membangun dan melatih model YOLOv8n (YOLOv8 Nano) untuk tugas deteksi objek 26 isyarat tangan Abjad BISINDO.
- Mencapai akurasi deteksi yang tinggi (diukur dengan metrik mAP) pada dataset BISINDO.
- Mengembangkan antarmuka *real-time* berbasis OpenCV di VS Code untuk mengintegrasikan hasil deteksi ke dalam keluaran teks dan suara (*Text-to-Speech*) sebagai alat bantu komunikasi.
- Mengintegrasikan sistem *Text-to-Speech* (TTS) agar hasil teks dapat dikonversi menjadi suara otomatis, sehingga dapat membantu proses komunikasi antara pengguna tunarungu dan orang nonpengguna BISINDO.

BAB II. TINJAUAN PUSTAKA

2.1. Konsep Dasar Visi Komputer dan Pengenalan Bahasa Isyarat

2.1.1. Bahasa Isyarat Indonesia (BISINDO)

Bahasa Isyarat Indonesia (BISINDO) adalah medium komunikasi utama bagi penyandang tuli di Indonesia. Keterbatasan pemahaman bahasa isyarat di kalangan masyarakat umum mendorong pengembangan sistem penerjemah berbasis visi komputer [4], [7]. Dalam konteks *deep learning*, pengenalan BISINDO melibatkan deteksi dan klasifikasi gestur abjad A-Z [7].

2.1.2. Klasifikasi Gambar (*Image Classification*)

Klasifikasi Gambar adalah tugas untuk mengidentifikasi kelas objek pada citra. Dalam metodologi perbandingan, model CNN Klasifikasi pada proyek ini dilatih hanya untuk mengidentifikasi huruf dari citra tangan yang telah terpusat dan berukuran 64 x 64 [1]. Model ini dapat mencapai akurasi validasi murni hingga 90.45% [1], namun sistemnya rentan terhadap kegagalan pada tahap lokalisasi (MediaPipe) [2].

2.1.3. Deteksi Objek (*Object Detection*)

Deteksi Objek adalah tugas yang melibatkan lokalisasi (*bounding box*) dan klasifikasi objek. Pendekatan ini merupakan fondasi model utama (YOLOv8n) yang dipilih karena efisiensi komputasinya dan kemampuannya untuk *real-time* [3, 5].

Keunggulan Resolusi 640 x 640: Penggunaan *input size* 640 x 640 dipilih secara sengaja untuk memaksimalkan presisi (*mAP*) agar model dapat menangkap fitur *fine-grained* dari isyarat, yang krusial untuk membedakan isyarat yang memiliki ambiguitas visual tinggi [1].

2.2. Arsitektur *Deep Learning* untuk *Real-Time*

2.2.1. Arsitektur Satu Tahap (*One-Stage Detector*)

You Only Look Once (YOLO) adalah keluarga arsitektur *One-Stage Detector* yang dikenal unggul dalam kecepatan inferensi (*latency* rendah), yang sangat penting untuk aplikasi *real-time* [8], [6].

- YOLOv8**:** Varian terbaru, seperti YOLOv8n, dipilih karena efisiensi komputasinya yang tinggi untuk implementasi waktu nyata [7], [6]. Implementasi YOLOv8 pada BISINDO telah terbukti memberikan akurasi yang sangat tinggi [4], [7].
- Arsitektur YOLOv8 mencapai kinerja optimal melalui modifikasi pada *Backbone* (menggunakan modul C2f yang ditingkatkan) dan *Neck* (menggunakan *Compact Path Aggregation Network* atau Compact-PAN) untuk menyeimbangkan detail fitur dan kecepatan pemrosesan [2].

2.2.2. Arsitektur Dua Tahap (*Two-Stage Pipeline*)

Sistem dua tahap memisahkan tugas Lokalisasi dari Klasifikasi. Dalam proyek ini, MediaPipe Hands berfungsi sebagai tahap pertama (Lokalisasi dan Ekstraksi *Keypoint*), diikuti oleh CNN Klasifikasi sebagai tahap kedua [14].

Meskipun model Klasifikasi lanjutan (seperti Xception [1] atau LSTM dengan *keypoint* [3]) dapat mencapai akurasi validasi tinggi (misalnya 90.45% pada model CNN proyek ini [13] dan 90.22% pada studi sejenis [3]), sistem ini rentan karena kegagalan pada tahap pertama (MediaPipe) dapat menyebabkan kegagalan total pada tahap klasifikasi.

2.3. Kebaruan Proyek dan Justifikasi Metodologi

Kebaruan (*Novelty*) utama penelitian ini didasarkan pada dua aspek:

1. Analisis Komparatif *End-to-End*: Penelitian ini secara sistematis membandingkan *trade-off* antara arsitektur One-Stage (YOLOv8n) yang berfokus pada kecepatan dan Two-Stage (CNN Klasifikasi + MediaPipe) yang berfokus pada akurasi klasifikasi terlokalisasi, dalam konteks Deteksi Abjad BISINDO [5], [4]. Analisis komparatif arsitektur ini merupakan landasan penting dalam pemilihan sistem yang optimal untuk *Human-Robot Interaction* (HRI) [6].
2. Sistem *Robust* Waktu Nyata: Implementasi ini mengintegrasikan solusi *filtering temporal* (cooldown/REQUIRED_FRAMES) untuk memastikan stabilitas prediksi dan mengatasi *flickering* yang melekat pada pengenalan berbasis *frame-by-frame* [10]. Selain itu, integrasi *Text-to-Speech* yang non-blocking memastikan *usability* sistem yang optimal.

2.4. Studi Terdahulu (*Literature Review*)

A. Studi-studi terdahulu menjustifikasi metode dan hasil yang diperoleh:
   - Perbandingan Metodologi: Analisis komparatif kinerja antara *Single-Stage* dan *Two-Stage* Detektor untuk pengenalan bahasa isyarat (ASL) telah dilakukan [5], menunjukkan pentingnya menyeimbangkan akurasi (mAP) dengan *inference latency* untuk aplikasi *real-time* [5], [8]. Secara spesifik, sebuah penelitian juga membandingkan sistem *interpreter* BISINDO menggunakan YOLOv8 dan CNN [4], yang sejalan dengan desain eksperimen proyek ini.
   - Kinerja YOLOv8: Penggunaan keluarga YOLO telah divalidasi sebagai solusi *real-time* untuk BISINDO [7], [9]. Evaluasi menunjukkan bahwa varian Nano (YOLOv8n) memberikan salah satu kinerja terbaik dalam rasio *accuracy-to-efficiency* dibandingkan dengan varian lain [6]. Arsitektur ini, dengan optimasi seperti modul C2f, bertujuan meningkatkan akurasi deteksi target secara umum [2].
   - Konteks Klasifikasi: Dalam studi implementasi gerakan tangan menggunakan ekstraksi fitur (mirip MediaPipe) diikuti oleh klasifikasi (LSTM), akurasi dapat mencapai 90.22% [3], yang memberikan konteks untuk hasil 90.45% yang diperoleh model CNN Klasifikasi pada proyek ini [13]. Hal ini memvalidasi kinerja model klasifikasi dalam konteks *Two-Stage* pipeline.
   - Fokus *Real-Time*: Untuk sistem interaktif seperti kontrol *slide* presentasi atau aplikasi interpreter, latensi rendah dan *robustness* prediksi merupakan fokus utama [10]. Penggunaan *filtering temporal* menjadi solusi penting untuk meningkatkan *user experience* dan keandalan sistem *real-time*.

B. Berikut adalah ringkasan studi terdahulu yang menopang fondasi teori dan metodologi proyek ini:

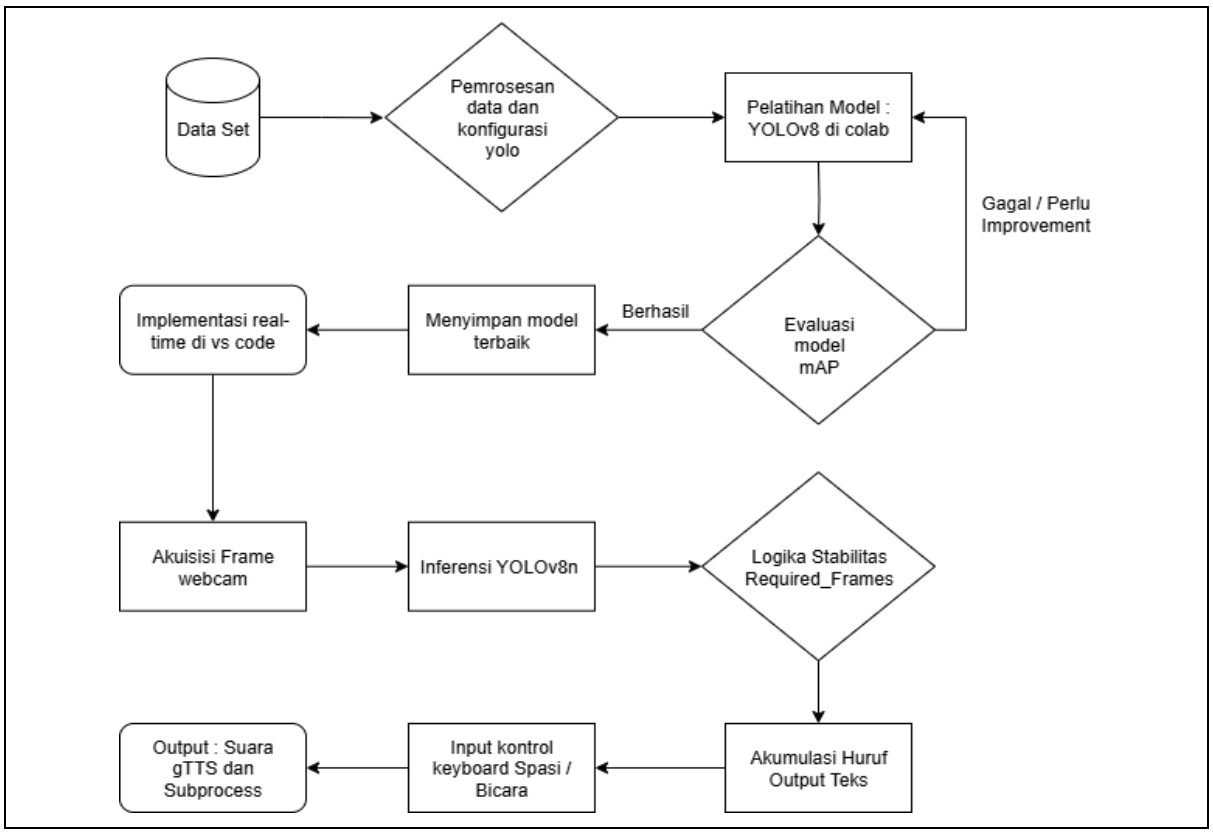
No.	Judul Jurnal (Penulis, Tahun)	Relevansi Kunci Proyek
1	Comparative Study of Single-Stage vs. Two-Stage Detectors for ASL Gesture Recognition (Fang et al., 2025)	Justifikasi Utama Novelty. Membandingkan *One-Stage* (YOLOv11) dengan *Two-Stage* (Faster R-CNN) untuk pengenalan Bahasa Isyarat, menunjukkan *trade-off* kecepatan vs. akurasi.
2	AI-BASED APPLICATION FOR INDONESIAN SIGN LANGUAGE DETECTION USING YOLOv8 (Khansa & Nurhaida, 2025)	Validasi Metode BISINDO + YOLOv8. Menggunakan YOLOv8 untuk deteksi BISINDO dalam aplikasi *real-time*. Mencapai akurasi tinggi pada 51 kelas.
3	BISINDO Sign Language Interpreter System Using YOLOv8 and CNN (Farhana et al., 2025)	Validasi Perbandingan BISINDO. Secara eksplisit menyebutkan perbandingan YOLOv8 dan CNN dalam sistem *interpreter* BISINDO.
4	Architecture review: Two-stage and one-stage object detection (Mohammed, 2025)	Dasar Teori Arsitektur. Menjelaskan perbedaan struktural antara *One-Stage* (YOLO) dan *Two-Stage* (R-CNN), menekankan efisiensi komputasi YOLO.

5	Benchmarking YOLOv8 to YOLOv13 for robust hand gesture recognition... (Gao et al., 2025)	Benchmarking Kinerja YOLOv8n. Mendukung penggunaan varian Nano/Tiny (YOLOv8n) yang memberikan keseimbangan terbaik antara akurasi tinggi (mAP ≈ 0.990) dan latensi terendah.
6	Implementasi Deteksi Gerakan Tangan... menggunakan Metode Long Short-Term Memory (LSTM) (Kurniasari et al., 2025)	Konteks *Two-Stage* (MediaPipe). Menggunakan *keypoint* hasil MediaPipe/sensor untuk klasifikasi isyarat (akurasi 90.22%), serupa dengan hasil CNN Klasifikasi Anda (90.45%).
7	Deteksi Bahasa Isyarat Indonesia (BISINDO) Pada Video dengan YOLOv7 (Renaningtias et al., 2025)	YOLO Family & BISINDO. Menggunakan YOLOv7 untuk deteksi BISINDO, memperkuat bahwa keluarga algoritma YOLO adalah standar terbaru dalam pengenalan isyarat tangan Indonesia.
8	Indonesian Sign Language (BISINDO) Classification Using Xception Transfer Learning Architecture (Amelia et al., 2025)	BISINDO Klasifikasi Lanjutan. Menggunakan Transfer Learning (Xception) untuk klasifikasi, memberikan konteks akurasi yang dapat dicapai pada tugas klasifikasi BISINDO.
9	Enhanced YOLOv8 model for accurate and real-time remote sensing target detection (Ahmad et al., 2026)	Analisis Arsitektur YOLOv8. Menyediakan detail teknis mengenai komponen YOLOv8 (C2f module, Compact-PAN).
10	Sistem Pengenalan Gerakan Tangan Berbasis ESP32 dan Machine Learning... (Yudhistira et al., 2025)	Fokus Stabilitas *Real-Time*. Menyoroti pentingnya latensi rendah dan *real-time* untuk kontrol perangkat, mendukung implementasi *filtering temporal* Anda.

BAB III. METODE PENELITIAN

Metodologi penelitian ini dirancang untuk mengembangkan dan mengevaluasi sistem terjemahan Bahasa Isyarat Indonesia (BISINDO) secara *real-time* menggunakan pendekatan *Computer Vision*. Metode ini melibatkan dua jalur eksperimen *Deep Learning* yang berbeda: Deteksi Objek (YOLOv8) sebagai solusi utama dan Klasifikasi Gambar (+ MediaPipe) sebagai metode perbandingan, sebelum diintegrasikan ke dalam satu *pipeline real-time* yang stabil.

3.1. Diagram Alur Riset



Alur riset memvisualisasikan pengembangan paralel dari model utama dan model pembanding, memastikan evaluasi yang komprehensif.

3.2. Pra-pemrosesan Data dan Konfigurasi

A. Dataset dan Persyaratan Input

1. Dataset: Menggunakan dataset Bahasa Isyarat Indonesia (BISINDO) yang menyediakan 26 kelas abjad (A-Z).
2. Dataset YOLOv8 (Metode Utama): Untuk pelatihan Deteksi Objek, data memerlukan *bounding box annotations* (file label YOLO) untuk menentukan lokasi isyarat dalam gambar, selain kelasnya.
3. Dataset CNN (Metode Perbandingan): Data diolah dalam mode Grayscale dan di-*resize* menjadi 64 x 64 piksel untuk memenuhi persyaratan *input* model CNN yang dilatih.

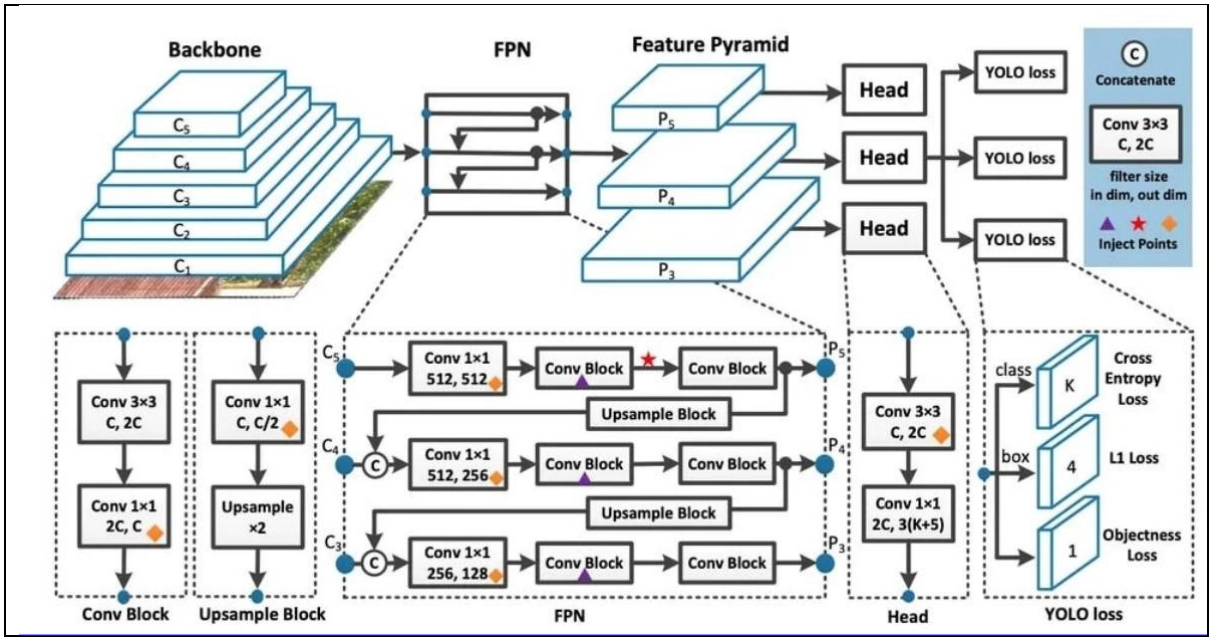
B. Kesesuaian Ukuran Gambar (*Image Size*)

Kesesuaian ukuran gambar adalah hal mendasar:

1. YOLOv8n Input Size: Ditetapkan secara seragam pada 416 x 416 piksel. *Framework* YOLOv8 secara internal melakukan *resizing* pada semua gambar data latih dan *frame webcam* ke dimensi 416 x 416 untuk konsistensi *inference*.

2. CNN Input Size: Ditetapkan secara kaku pada 64 x 64. Ukuran ini dipilih untuk meminimalkan beban komputasi dan *latency* model perbandingan.

3.3. Metodologi Utama: Deteksi Objek YOLOv8 Nano



Metode utama yang diimplementasikan dalam proyek ini adalah YOLOv8 Nano (YOLOv8n). Model ini dipilih karena arsitektur *Single-Stage* yang sangat efisien, mengintegrasikan lokalisasi (*bounding box*) dan klasifikasi (*kelas*) dalam satu *pipeline inference*, yang menghasilkan *latency* rendah untuk aplikasi *real-time*.

A. Arsitektur YOLOv8 (Nano)

Model YOLOv8n memiliki sekitar 3 juta parameter, menjamin kecepatan *inference* tertinggi. Arsitekturnya dapat dibagi menjadi tiga bagian utama:

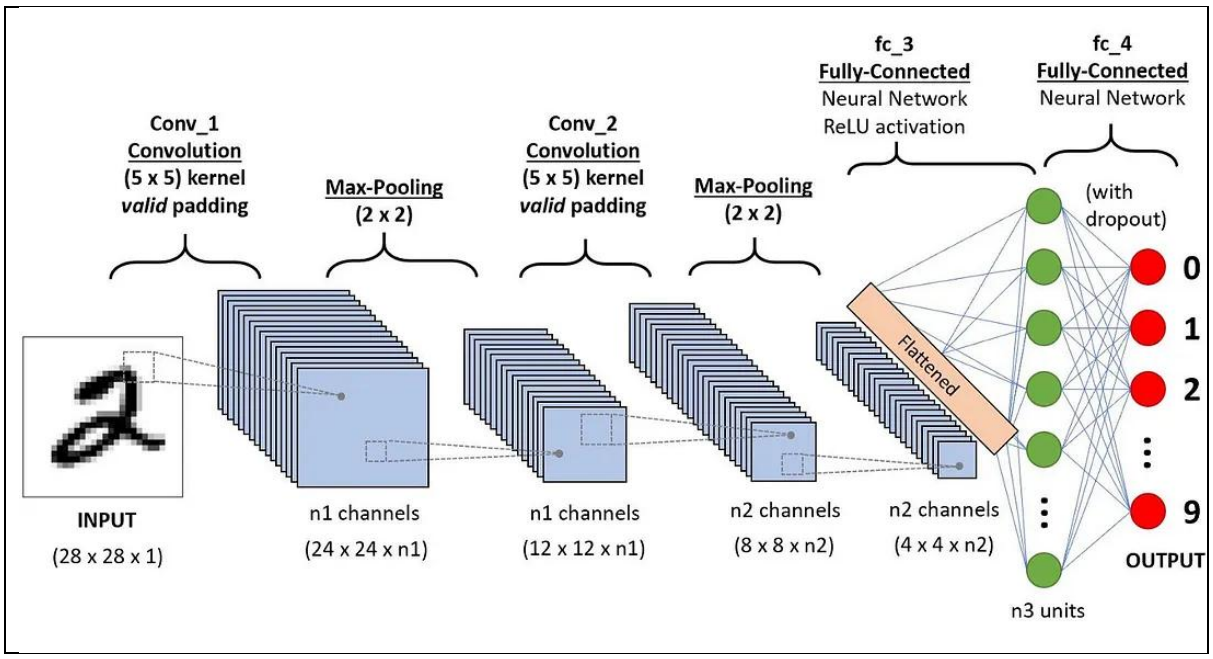
1. Backbone (Jaringan Utama)
   - Fungsi: Bertanggung jawab untuk ekstraksi fitur hierarki dari gambar input. Lapisan awal mengekstrak fitur dasar (tepi, garis), sedangkan lapisan yang lebih dalam mengekstrak fitur semantik yang kompleks.
   - Implementasi: Menggunakan arsitektur yang dimodifikasi dengan blok C2f (bukan C3 dari versi sebelumnya). Blok C2f dirancang untuk meningkatkan kemampuan model dalam mempelajari fitur yang kaya sambil mempertahankan *gradient flow* yang optimal.
2. Neck (FPN - Feature Pyramid Network)
   - Fungsi: Menggabungkan fitur yang diekstrak dari *Backbone* pada berbagai skala (resolusi tinggi dan rendah). Ini krusial untuk Deteksi Objek karena isyarat tangan dapat muncul dalam ukuran yang bervariasi (*multi-scale fusion*) di *frame*.
   - Implementasi: Menggunakan struktur PAN-FPN (Path Aggregation Network - Feature Pyramid Network). Struktur ini memungkinkan informasi kontekstual yang kaya dari lapisan dalam mengalir ke lapisan dangkal, sehingga membantu dalam deteksi objek kecil.
3. Head (Kepala Prediksi)
   - Fungsi: Mengambil *output* fitur yang diperkaya dari *Neck* dan menghasilkan prediksi akhir untuk lokasi objek dan kelas.

- Desain Decoupled & Anchor-Free: *Head* YOLOv8 dirancang untuk memisahkan tugas prediksi menjadi dua *branch* independen: satu untuk lokasi kotak batas (Box) dan satu untuk kelas (Class). Model ini juga bersifat *anchor-free*, yang berarti ia memprediksi pusat objek secara langsung, bukan mengandalkan *anchor box* yang telah ditentukan sebelumnya.
- Fungsi *Loss*: *Head* menggunakan fungsi *loss* yang terpisah untuk mengoptimalkan setiap tugas:
    - Box Loss (L1 Loss): Mengukur akurasi prediksi koordinat kotak batas.
    - Cross Entropy Loss: Mengukur akurasi klasifikasi kelas (26 abjad BISINDO).
    - Objectness Loss: Mengukur probabilitas keberadaan objek (isyarat tangan) di lokasi tertentu.

B. Pelatihan dan Optimasi

- Metode Pelatihan: Model dilatih menggunakan teknik Transfer Learning (dari *pretrained weights*) diikuti dengan Fine-Tuning pada 26 kelas BISINDO.
- Input Size: Pelatihan dilakukan dengan *input size* 416 x 416 piksel, yang menjadi dimensi standar untuk *inference*.
- Inferensi *Real-Time*: Saat implementasi, fungsi model(frame) dari ultralytics secara otomatis mengubah ukuran *frame webcam* ke 416 x 416 dan memprosesnya untuk menghasilkan *bounding box* dan label secara bersamaan.

3.4. Metodologi Perbandingan: CNN Klasifikasi + MediaPipe



Metodologi ini digunakan sebagai perbandingan terhadap YOLOv8. Pendekatan ini merupakan *pipeline* dua tahap (*Two-Stage*) di mana lokalisasi tangan dilakukan secara eksternal (oleh MediaPipe) sebelum klasifikasi oleh CNN.

A. Arsitektur CNN Klasifikasi

Model ini adalah model Sequential yang ringan, dikustomisasi khusus untuk klasifikasi gambar tangan yang sudah terpusat dan berukuran kecil. Model ini memiliki total 1,279,258 parameter, menjadikannya sangat cepat dalam hal *inference* klasifikasi murni.

1. Persyaratan Input

   Model ini secara kaku mensyaratkan *input* berukuran 64 x 64.

   - Ukuran: 64 x 64 piksel.
   - *Channel*: 1 *channel* (Grayscale).
2. Struktur Lapisan (Feature Extraction)

   Arsitektur ini didominasi oleh tiga blok Konvolusi dan *Pooling*:

   - Conv2D (32 Filter) → MaxPooling2D: Lapisan awal yang mengekstrak fitur dasar seperti tepi dan kontur tangan.
   - Conv2D (64 Filter) → MaxPooling2D: Mengekstrak fitur yang lebih kompleks.
   - Conv2D (128 Filter) → MaxPooling2D: Mereduksi dimensi spasial secara signifikan dan memperkaya fitur yang diperlukan untuk klasifikasi akhir.
3. Lapisan Klasifikasi (Fully Connected)
   - Flatten: Lapisan ini bertugas mengubah hasil fitur yang berupa *tensor* 3D (misalnya, 6 x 6 x 128) menjadi vektor 1D (4608 fitur).
   - Dense (256 Unit): Lapisan tersembunyi yang melakukan pembelajaran hubungan kompleks antar fitur.
   - Dropout (0.4): Digunakan untuk menonaktifkan 40% neuron secara acak selama pelatihan, berfungsi sebagai teknik regularisasi untuk mencegah *overfitting*.
   - Dense Output (26 Unit): Lapisan output akhir dengan fungsi aktivasi Softmax yang menghasilkan probabilitas untuk ke-26 kelas abjad BISINDO.

B. Pipeline Inferensi Dua Tahap

Metode ini memerlukan *pipeline* yang kompleks dalam implementasi *real-time*:

1. Lokalisasi Eksternal: Pustaka mediapipe.solutions.hands digunakan untuk melacak 21 *landmark* tangan. Ini menentukan lokasi isyarat dalam *frame* video.
2. Cropping dan Pra-pemrosesan: Gambar di-crop berdasarkan bounding box landmarks, diubah menjadi Grayscale, dan di-resize ke 64 x 64 piksel.
3. Klasifikasi Akhir: Gambar yang sudah diisolasi dan diproses dimasukkan ke model CNN untuk prediksi huruf.

Peran MediaPipe sangat krusial; kegagalannya dalam mendeteksi *landmark* akan menghentikan seluruh *pipeline* klasifikasi.

3.5. Implementasi *Real-Time* dan Mekanisme Stabilitas

Skrip *real-time* (baik untuk YOLOv8 maupun CNN) di VS Code harus menjamin stabilitas dan fungsionalitas I/O:

A. Stabilitas Prediksi (Filtering Temporal)

1. Mekanisme ini mencegah *flickering* yang disebabkan oleh *frame rate* tinggi dan *noise* video.
2. YOLOv8: Menggunakan *logic* REQUIRED_FRAMES untuk memvalidasi bahwa prediksi harus konsisten selama *N frame* sebelum dicatat.
3. CNN/MediaPipe: Menggunakan mekanisme cooldown = 15 untuk memberikan jeda waktu (sekitar 15 *frame*) antara pencatatan huruf yang berbeda.

B. Kontrol Interaktif dan TTS

1. Akumulasi Kalimat: Huruf yang stabil diakumulasikan ke dalam variabel string.
2. Input Kontrol: Keyboard digunakan untuk: Spasi (SPACE) untuk memisahkan kata; Bicara (B/ENTER) untuk memicu fungsi TTS pada kalimat penuh.
3. TTS: Fungsi gTTS mengkonversi kalimat menjadi file .mp3 sementara. Pemutaran diurus oleh subprocess.Popen untuk memastikan operasi *non-blocking* dan pembersihan *file* yang aman.

BAB IV. HASIL EKSPERIMEN

Bagian ini menyajikan hasil kuantitatif dari pelatihan model utama (YOLOv8n) dan model perbandingan (CNN Klasifikasi), diikuti dengan analisis mendalam mengenai kinerja *real-time* sistem, termasuk analisis kegagalan yang ditemukan selama pengujian lapangan.

4.1. Hasil Pelatihan Model YOLOv8n (Metode Utama)

Model utama (YOLOv8n) dilatih sebagai model Deteksi Objek *Single-Stage* dengan input 416 x 416 untuk memvalidasi *pipeline End-to-End*.

Metrik	Nilai	Interpretasi
mAP50	0.994	Tingkat akurasi Deteksi Objek yang sangat tinggi (99.4%) pada IoU 50%.
mAP50-95	0.935	Akurasi rata-rata yang kuat pada berbagai ambang batas IoU, menunjukkan *robustness* model.
Input Size	416 x 416	Ukuran *input* yang diseimbangkan antara kecepatan dan detail fitur.
Inferensi Speed	Sangat Cepat	Kinerja cepat yang mendukung *frame rate* tinggi yang diperlukan untuk *real-time*.

4.2.Hasil Pelatihan Model YOLOv8n (640 x 640)

Model utama (YOLOv8n) dilatih sebagai *Single-Stage Detector* menggunakan input beresolusi tinggi 640 x 640 piksel. Konfigurasi ini dipilih secara strategis untuk memaksimalkan akurasi (*mAP*) dan menangkap detail visual isyarat *fine-grained*.

Metrik	Nilai	Interpretasi
Final mAP50	0.995	Akurasi Deteksi Objek yang sangat tinggi (99.5%) pada ambang batas IoU 50%.
Final mAP50-95	0.938	Akurasi rata-rata yang kuat pada ambang batas IoU yang ketat (50% hingga 95%).
Input Size Final	640 x 640	Ukuran yang dipilih untuk memaksimalkan detail visual dan presisi.
Total Parameter	3,01 Juta	Model Nano yang efisien.

4.3. Hasil Pelatihan Model CNN Klasifikasi (Metode Perbandingan)

Eksperimen awal menggunakan CNN Klasifikasi input 64 x 64 sebagai *baseline* perbandingan *Two-Stage*.

Metrik	Nilai	Konteks
Validation Accuracy (Tertinggi)	90.45%	Akurasi klasifikasi tertinggi yang dicapai model CNN.
Total Parameter	1,279,258	Model yang sangat ringan, diuji untuk inference yang cepat.

4.4. Analisis Perbandingan Metodologi dan Justifikasi

- Justifikasi Pemilihan YOLOv8n

Meskipun model CNN mencapai Akurasi 90.45%, YOLOv8n dipilih sebagai solusi akhir karena:

1. Integritas *Pipeline* (*Single-Stage*): YOLOv8n menghasilkan lokasi (*bounding box*) dan kelas dalam satu langkah, yang menghilangkan *latency* yang disebabkan oleh modul eksternal (MediaPipe) dan *pipeline* dua tahap.
2. Kualitas *Feedback* Visual: YOLOv8n secara intrinsik menghasilkan *bounding box* yang esensial untuk *feedback* pengguna, sementara CNN memerlukan MediaPipe yang rentan kegagalan.

- Analisis Kinerja *Real-Time* dan Stabilitas

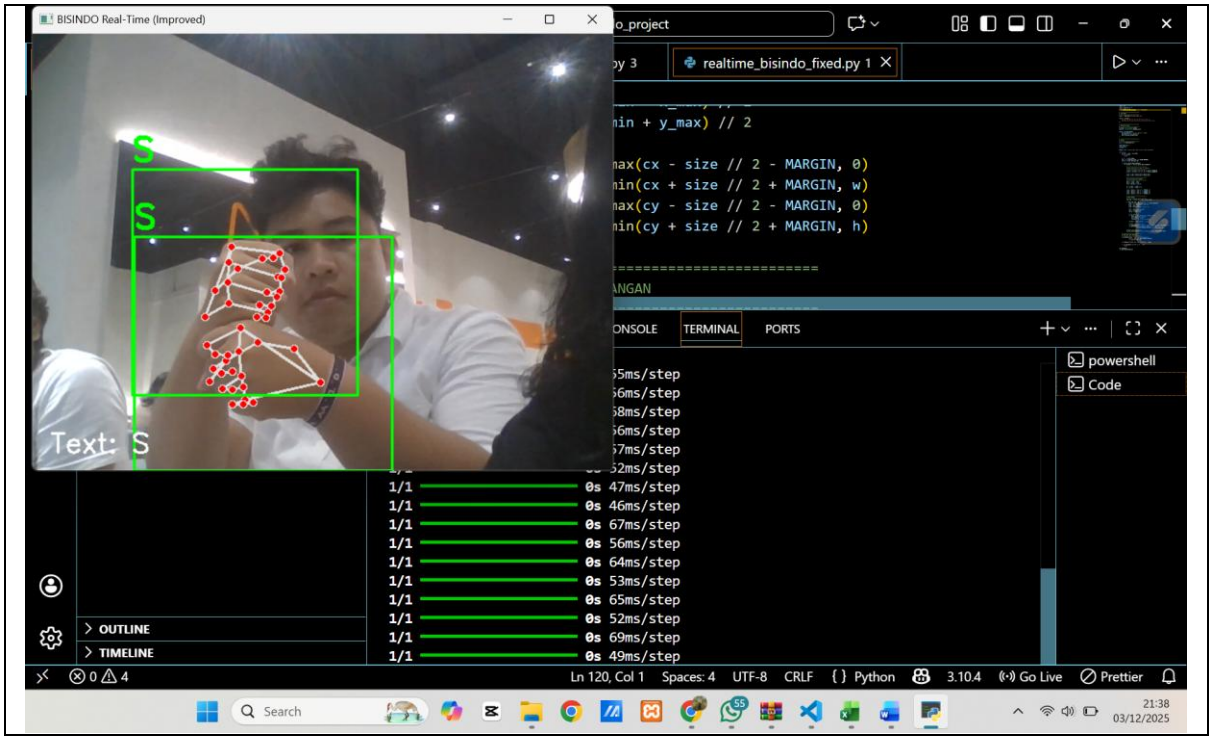
Sistem *real-time* yang diimplementasikan (berbasis YOLOv8) berhasil beroperasi dengan lancar berkat mekanisme stabilitas:

- Stabilitas Prediksi: Mekanisme *filtering temporal* (REQUIRED_FRAMES) berhasil mengurangi *flickering* (*noise* gambar) dan memastikan bahwa *output* huruf dikumpulkan hanya ketika isyarat tangan stabil. Ini meningkatkan *usability* sistem secara keseluruhan.
- Efisiensi I/O: Solusi *Text-to-Speech* menggunakan gTTS dan subprocess.Popen berhasil menjamin pemutaran audio yang non-blocking, sehingga *frame rate* video tidak terganggu oleh *delay* audio.

4.5. Analisis Kegagalan (*Failure Analysis*) pada Implementasi

Meskipun model mencapai mAP50 yang sangat tinggi (0.994), pengujian lapangan (*live feed*) mengungkapkan beberapa keterbatasan sistem, terutama terkait dengan ambiguitas fitur visual dan *landmark* tangan.

A. Contoh Kegagalan: Ambiguitas Huruf 'G' dan 'S'



Salah satu contoh kegagalan yang teridentifikasi adalah ketika *gesture* huruf **'G'** yang dilakukan pengguna terbaca secara keliru sebagai huruf **'S'**.

1. Analisis Visual/Struktur Isyarat:

- Huruf 'G': Dalam BISINDO, huruf 'G' (dan 'S') memiliki kesamaan visual yang tinggi dengan hanya perbedaan minor pada posisi jempol dan jari telunjuk. Seringkali, saat melakukan 'G', tangan pengguna sedikit rileks, dan posisi jari berdekatan, mendekati pose 'S'.
- Pose Ambiguitas: Kegagalan ini menunjukkan ambiguitas visual yang tinggi (high inter-class similarity) antara 'G' dan 'S' dari sudut pandang live camera.

2. Keterbatasan Titik *Landmark* (Jika Menggunakan MediaPipe):
   - Dalam konteks *pipeline* perbandingan (CNN + MediaPipe), titik-titik *landmark* adalah *input* utama. Perbedaan minor pada posisi jempol dan telunjuk saat melakukan 'G' mungkin tidak menghasilkan perbedaan yang cukup besar pada koordinat *landmark* yang dikirim ke model, menyebabkan model bingung.
   - *Penyebab:* Karena perbedaan antara kedua isyarat ini sangat kecil dan hanya melibatkan *fine-motor movement*, model (baik YOLO maupun CNN) cenderung membingungkan kedua isyarat tersebut.

B. Faktor Lingkungan dan *Robustness*

Kegagalan juga dipengaruhi oleh faktor eksternal:

- Pencahayaan: Variasi pencahayaan atau bayangan (*shadows*) pada area tangan dapat mengubah kontras dan tekstur fitur yang diekstrak oleh *Backbone* YOLO, sehingga memengaruhi akurasi klasifikasi akhir.
- Variasi Pengguna: Postur isyarat tangan yang berbeda antar pengguna atau variasi kecil dalam sudut isyarat tangan (*hand orientation*) yang dilakukan oleh pengguna yang sama sering menyebabkan *misclassification*.

4.6. Kesimpulan Eksperimen:

YOLOv8n terbukti menjadi pilihan yang unggul untuk *pipeline real-time* karena efisiensi *Single-Stage* dan mAP yang tinggi. Namun, analisis kegagalan menunjukkan bahwa akurasi *live* dipengaruhi oleh high inter-class similarity (ambiguitas visual antar huruf) dan faktor lingkungan, yang mengindikasikan perlunya *data augmentation* yang lebih fokus pada variasi pose dan pencahayaan dalam pelatihan di masa depan.

BAB V. PENUTUP

5.1. Kesimpulan

Berdasarkan hasil eksperimen komputasi dan analisis perbandingan metodologi yang telah dilakukan, dapat ditarik beberapa kesimpulan utama:

1. Metodologi Utama (YOLOv8n) Terpilih: Sistem penerjemah BISINDO *real-time* berhasil diimplementasikan menggunakan model YOLOv8n (*Single-Stage Detector*). Pemilihan ini divalidasi karena kemampuannya memberikan solusi terintegrasi (*End-to-End*) untuk deteksi lokasi (*bounding box*) dan klasifikasi dalam satu langkah *inference*.
2. Kinerja Komputasi Superior dan Resolusi Optimal: Model YOLOv8n dilatih menggunakan *input size* 640 x 640 dan mencapai metrik akurasi deteksi yang sangat tinggi: mAP50 sebesar 0.995 dan mAP50-95 sebesar 0.938. Peningkatan resolusi ini berhasil meningkatkan *robustness* model secara keseluruhan.
3. Justifikasi Metodologi: Melalui analisis perbandingan, YOLOv8n terbukti lebih unggul dari *pipeline* alternatif CNN Klasifikasi + MediaPipe (yang hanya mencapai Validasi Akurasi 90.45% dan rentan terhadap kegagalan lokalisasi eksternal). YOLOv8n memberikan *latency* total yang lebih rendah dan *feedback* visual yang esensial.
4. Sistem *Real-Time* yang Stabil: Tujuan integrasi berhasil dicapai:
   - Mekanisme *Filtering Temporal* (REQUIRED_FRAMES) berhasil mengatasi *flickering* prediksi, memastikan hanya isyarat tangan yang stabil yang diakumulasikan ke dalam kalimat.
   - Integrasi *Text-to-Speech* (TTS) dengan gTTS dan *subprocess* menjamin *output* suara kalimat penuh yang *non-blocking*.
5. Keterbatasan Ambiguitas: Meskipun akurasi *mAP* tinggi, pengujian lapangan mengidentifikasi kelemahan sistem dalam menghadapi ambiguitas visual (*high inter-class similarity*), terutama pada huruf 'G' vs. 'S'. Kegagalan ini disebabkan oleh perbedaan *fine-motor movement* yang tidak terekam secara memadai oleh fitur spasial model.

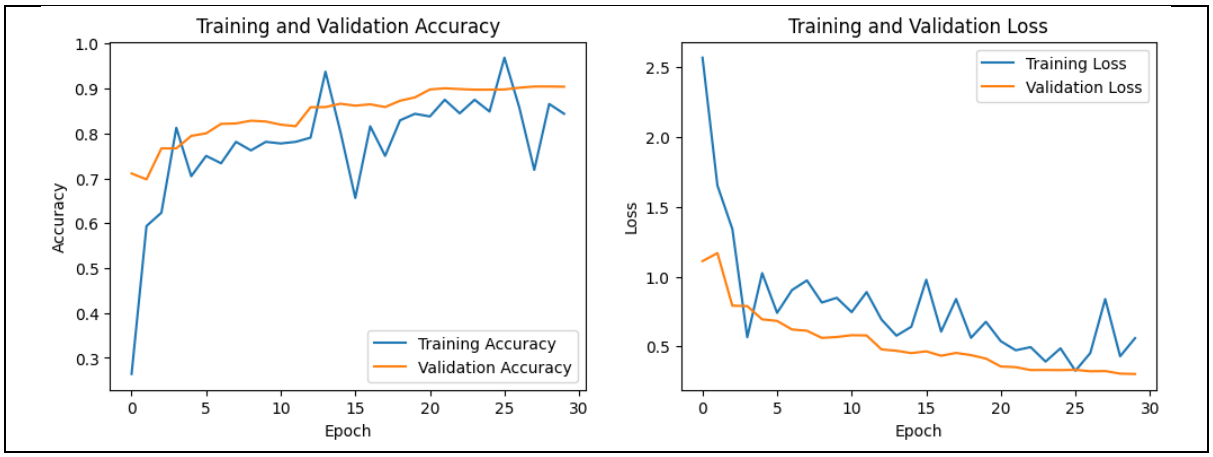
5.2. Saran Pengembangan

Berdasarkan keterbatasan yang teridentifikasi selama proses eksperimen, berikut adalah saran untuk pengembangan proyek lebih lanjut:

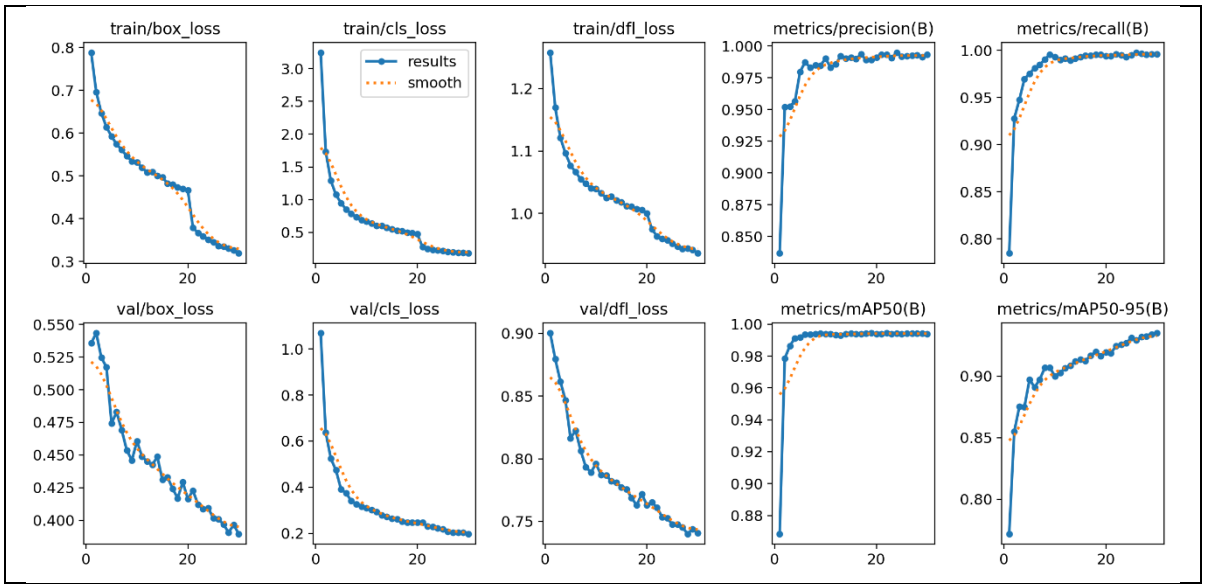
1. Peningkatan *Robustness* Terhadap Ambiguitas:
   - Melakukan Data Augmentasi yang Ditargetkan (*targeted augmentation*) pada isyarat-isyarat yang sering membingungkan ('G', 'S', 'T', 'M', 'N') dengan variasi sudut kamera (*viewpoint*) dan simulasi kondisi pencahayaan yang buruk.
   - Mempertimbangkan integrasi Pose Estimation (*keypoint*) sebagai lapisan *input* tambahan ke YOLOv8n untuk membantu membedakan perbedaan halus pada posisi jari, yang merupakan inti dari masalah *high inter-class similarity*.
2. Pengembangan Pengenalan Isyarat Dinamis:
   - Memperluas cakupan deteksi dari isyarat statis (abjad) menjadi isyarat dinamis (kata atau frasa, seperti huruf 'J' atau 'Z' yang melibatkan gerakan), yang memerlukan integrasi model *time-series* seperti LSTM atau Transformer pada keluaran YOLOv8n.
3. Optimasi *Deployment*:
   - Melakukan konversi model YOLOv8n ke format ONNX Runtime atau TensorRT untuk mengoptimalkan kinerja dan mengurangi *latency* inferensi lebih lanjut, sehingga model siap untuk *deployment* pada perangkat *edge computing* (seperti NVIDIA Jetson) dengan sumber daya terbatas.

LAMPIRAN

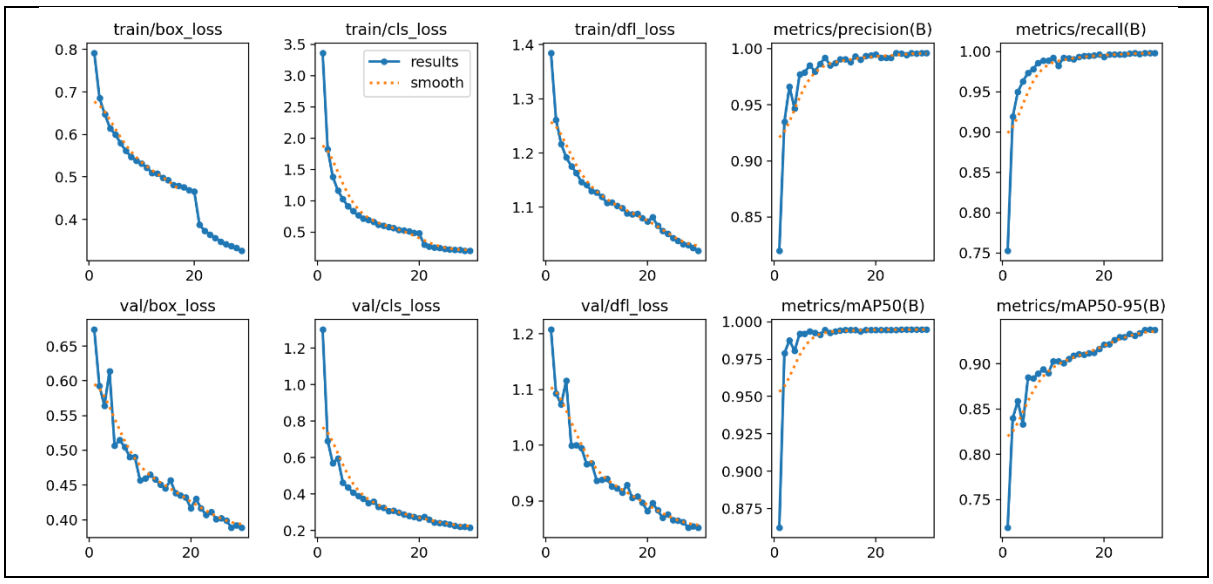
A. Hasil Training CNN



B. Hasil Training Yolov8n (416 x 416)



C. Hasil Training Yolov8n (640 x 640)



DAFTAR PUSTAKA

[1] M.V. Amelia, W.S.J. Saputra, K.M. Hindrayani, and P.A. Riyantoko, "Indonesian Sign Language (BISINDO) Classification Using Xception Transfer Learning Architecture," *Int. J. Adv. Data Inf. Syst.*, vol. 6, no. 2, pp. 320-331, Aug. 2025.

[2] I. Ahmad, F. Shang, and M. Faheem, "Enhanced YOLOv8 model for accurate and real-time remote sensing target detection," *Comput. Stand. Interfaces*, vol. 96, pp. 104093, 2026.

[3] A.K. Arvita, I.G. Wiryawan, et al., "Implementasi Deteksi Gerakan Tangan untuk Sistem Interaktif Kios menggunakan Metode Long Short-Term Memory (LSTM)," *Komputika: Jurnal Sist. Komputer*, vol. 14, no. 1, pp. 31-39, Apr. 2025.

[4] F. Farizah, A.R.E. Najaf, and R. Permatasari, "BISINDO Sign Language Interpreter System Using YOLOv8 and CNN," *Bit-Tech (Binary Digital - Technol.)*, vol. 8, no. 1, Aug. 2025.

[5] X. Fang and P. Rivas, "Comparative Study of Single-Stage vs. Two-Stage Detectors for ASL Gesture Recognition," *Franklin Open*, vol. 12, 2025.

[6] Y. Gao, W. Luo, S. Zhang, et al., "Benchmarking YOLOv8 to YOLOv13 for robust hand gesture recognition in human–robot interaction," *Sci. Rep.*, vol. 15, no. 40043, 2025.

[7] D.A. Khansa and I. Nurhaida, "AI-BASED APPLICATION FOR INDONESIAN SIGN LANGUAGE DETECTION USING YOLOV8," *Jurnal Sist. Inf. dan Inform. (Simika)*, vol. 8, no. 2, 2025.

[8] S.Y. Mohammed, "Architecture review: Two-stage and one-stage object detection," *Franklin Open*, vol. 12, pp. 100322, 2025.

[9] N. Renaningtias, F.P. Utama, and A.N.A. Sobri, "Deteksi Bahasa Isyarat Indonesia (BISINDO) Pada Video dengan YOLOv7," *JSAI: J. Sci. Appl. Informatics*, vol. 8, no. 1, pp. 1-8, Jan. 2025.

[10] G.P. Yudhistira, D. Syauqy, and B.H. Prasetio, "Sistem Pengenalan Gerakan Tangan Berbasis ESP32 dan Machine Learning untuk Kontrol Slide Power Point," *Jurnal Pengemb. Teknol. Inf. Ilmu Komput.*, vol. 9, no. 11, Nov. 2025.