Laporan Mini Project Deep Learning A

Pengembangan *Early Warning System* Ketahanan Pangan Nasional Melalui Prediksi Volatilitas Harga Beras Menggunakan Multivariate Bidirectional LSTM

Dosen Pengampu : Prof. Hindriyanto Dwi Purnomo, S.T., M.IT., Ph.D.

Disusun oleh:

1. Marchell Adi Pratama 672023081
2. Greysen Wijaya Liunesi 672023174

PROGRAM STUDI S1 TEKNIK INFORMATIKA

FAKULTAS TEKNOLOGI INFORMASI

UNIVERSITAS KRISTEN SATYA WACANA

2025

1. Deskripsi Permasalahan

Ketahanan pangan merupakan pilar fundamental bagi stabilitas nasional Indonesia. Berdasarkan Indeks Ketahanan Pangan (IKP), salah satu komponen vital yang menentukan status ketahanan pangan suatu wilayah adalah aspek "Keterjangkauan" (*Affordability*). Aspek ini sangat bergantung pada stabilitas harga komoditas pangan pokok, khususnya beras. Namun, permasalahan mendasar yang terus berulang adalah tingginya volatilitas harga beras yang bersifat stokastik dan non-linear. Fluktuasi ini tidak hanya dipengaruhi oleh faktor *supply-demand* sederhana, tetapi juga oleh interaksi kompleks berbagai variabel eksternal seperti anomali iklim (El Nino/La Nina), dinamika ekonomi makro (nilai tukar rupiah), serta pola musiman hari raya keagamaan.

Metode pemantauan harga yang ada saat ini cenderung bersifat *lagging indicator* (indikator terlambat), di mana kebijakan intervensi pemerintah seringkali baru diambil setelah lonjakan harga terjadi. Selain itu, penggunaan metode peramalan statistik klasik seperti ARIMA (*AutoRegressive Integrated Moving Average*) atau Regresi Linear seringkali gagal menangkap dependensi jangka panjang dan hubungan non-linear antar-variabel *multivariate*. Oleh karena itu, diperlukan pengembangan sistem prediksi cerdas berbasis *Deep Learning* yang mampu mengintegrasikan data historis harga dengan data klimatologi dan ekonomi untuk memproyeksikan volatilitas harga di masa depan secara presisi.

2. Urgensi Permasalahan

Penyelesaian masalah volatilitas harga pangan ini memiliki tingkat urgensi yang sangat tinggi karena berdampak sistemik pada tiga sektor utama:

1. **Stabilitas Ekonomi Makro (Pengendalian Inflasi):** Dalam struktur ekonomi Indonesia, beras termasuk dalam kategori *Volatile Food* yang menjadi penyumbang utama angka inflasi. Kenaikan harga beras yang tidak terantisipasi dapat memicu efek domino kenaikan harga barang lain, yang pada akhirnya mengganggu target inflasi nasional yang ditetapkan Bank Indonesia.
2. **Kesejahteraan Sosial (Penanggulangan Kemiskinan):** Bagi masyarakat berpenghasilan rendah, lebih dari 50% pengeluaran rumah tangga dialokasikan untuk pangan. Lonjakan harga sekecil apapun akan menggerus daya beli secara signifikan, berpotensi meningkatkan angka kemiskinan, dan menurunkan skor IKP daerah secara drastis.
3. **Efektivitas Kebijakan Publik:** Pemerintah, melalui Badan Pangan Nasional (Bapanas) dan Tim Pengendali Inflasi Daerah (TPID), membutuhkan instrumen *Early Warning System* yang akurat. Tanpa prediksi yang handal, keputusan strategis seperti impor beras atau Operasi Pasar seringkali terlambat atau salah perhitungan, yang berujung pada pemborosan anggaran negara dan ketidakstabilan pasokan di pasar. Solusi teknis ini ditujukan untuk menutup celah keterlambatan informasi tersebut.

3. Pendekatan Deep Learning dan Solusi yang Diusulkan

Untuk menjawab tantangan prediksi data *time-series* yang kompleks dan dipengaruhi oleh banyak faktor, proyek ini mengusulkan implementasi arsitektur **Bidirectional Long Short-Term Memory (Bi-LSTM)** dengan skema input **Multivariate**. Pendekatan ini dipilih karena kemampuannya yang superior dalam menangkap pola sekuensial jangka panjang dibandingkan model *Machine Learning* konvensional. Berikut adalah rincian komprehensif mengenai metodologi dan solusi teknis yang dibangun:

A. Strategi Integrasi Data (*Data Fusion*)

Kunci utama dari akurasi model ini terletak pada penggunaan data *multivariate*. Model tidak hanya "melihat" riwayat harga, tetapi juga mempelajari konteks lingkungan yang mempengaruhinya. Empat dimensi data diintegrasikan menjadi satu dataset terpadu:

1. **Variabel Endogen (Target):** Data Harian Harga Beras Kualitas Medium I (Periode: Januari 2020 – November 2025) yang bersumber dari Pusat Informasi Harga Pangan Strategis (PIHPS) Nasional. Data ini merepresentasikan resultan dari interaksi pasar.
2. **Variabel Eksogen Klimatologi:** Data Curah Hujan (*Precipitation*) dan Suhu Rata-rata (*Temperature*) harian yang diekstraksi dari satelit NASA POWER. Variabel ini dimasukkan mengingat korelasi kuat antara anomali cuaca (banjir/kekeringan) dengan gangguan panen yang berdampak pada *supply*.
3. **Variabel Eksogen Ekonomi:** Data Nilai Tukar (Kurs) USD terhadap IDR dari Yahoo Finance. Mengingat sebagian komponen produksi pertanian (seperti pupuk dan pestisida) serta logistik dipengaruhi oleh harga impor, fluktuasi kurs menjadi indikator awal (*leading indicator*) kenaikan biaya produksi.
4. **Variabel Fitur Kalender (*Feature Engineering*):** Penambahan fitur biner "Hari Libur" (*Is_Holiday*) yang dibangkitkan secara komputasional. Fitur ini memberikan sinyal kepada model mengenai pola *demand pull inflation* yang kerap terjadi secara siklikal menjelang Hari Raya Idul Fitri, Natal, dan Tahun Baru.

B. Teknik Preprocessing Data Tingkat Lanjut

Sebelum data dimasukkan ke dalam jaringan saraf tiruan, serangkaian proses pra-pemrosesan dilakukan untuk memastikan kualitas dan kompatibilitas data. Pemilihan teknik *preprocessing* ini didasarkan pada karakteristik intrinsik algoritma *Gradient Descent*.

Pertama, Normalisasi Data (MinMax Scaling) diterapkan untuk mengubah seluruh fitur numerik ke dalam rentang [0, 1]. Penggunaan MinMax Scaler dipilih menggantikan Standard Scaler (Z-score) karena fungsi aktivasi standar pada gerbang LSTM (yaitu Sigmoid dan Tanh) bekerja optimal pada rentang nilai kecil. Nilai input yang terlalu besar (seperti harga dalam puluhan ribu Rupiah) akan menyebabkan saturasi pada fungsi aktivasi, di mana nilai gradien menjadi sangat kecil mendekati nol. Hal ini dapat menghambat proses perambatan balik (backpropagation) dan memicu masalah Vanishing Gradient Problem, yang membuat model sulit untuk belajar. Rumus normalisasi yang digunakan adalah:

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Kedua, dalam penanganan data yang hilang (*Handling Missing Values*), diterapkan strategi hibrida. Mengingat data pasar (PIHPS) dan pasar uang (Kurs) tidak beroperasi pada hari libur dan akhir pekan, sedangkan data cuaca (NASA) tersedia kontinu setiap hari, terjadi *gap* frekuensi data.

- Untuk variabel kontinu yang memiliki tren alamiah (Harga Beras, Suhu, Curah Hujan), digunakan metode **Interpolasi Linear**. Berbeda dengan imputasi rata-rata (*mean imputation*) yang dapat merusak struktur volatilitas data, interpolasi linear mempertahankan tren kenaikan atau penurunan antar-titik waktu, sehingga integritas pola sekuensial tetap terjaga.
- Untuk variabel Kurs, digunakan teknik **Forward Fill**. Hal ini didasarkan pada asumsi bisnis bahwa nilai tukar pada hari libur (Sabtu/Minggu) dianggap tetap atau sama dengan nilai penutupan terakhir pada hari Jumat, merefleksikan realitas pasar keuangan.

Ketiga, transformasi data menggunakan mekanisme **Sliding Window**. Data deret waktu diubah menjadi struktur 3D Tensor dengan dimensi [Samples, Time Steps, Features]. Proyek ini menetapkan jendela waktu (*window size*) sebesar **30 hari**. Artinya, untuk memprediksi harga pada hari ke-t, model akan menerima input matriks data dari hari $t-30$ hingga $t-1$. Ini memungkinkan model untuk memahami konteks tren jangka pendek (bulanan) sebelum membuat prediksi.

C. Arsitektur Model: Deep Bidirectional LSTM

Solusi inti yang diusulkan adalah penggunaan arsitektur **Bidirectional LSTM (Bi-LSTM)**. Secara teoritis, keunggulan utama LSTM (*Long Short-Term Memory*) dibandingkan RNN biasa terletak pada struktur memori internalnya yang disebut *Cell State* (Ct). Sel LSTM memiliki tiga mekanisme gerbang (*gates*) yang mengatur aliran informasi secara presisi:

1. **Forget Gate (f_t):** Gerbang ini memutuskan informasi mana dari *cell state* sebelumnya yang harus dibuang. Keputusan ini diambil berdasarkan fungsi aktivasi *sigmoid* (0 sampai 1). Dalam konteks harga pangan, gerbang ini berfungsi melupakan tren harga lama yang sudah tidak relevan (misalnya efek kenaikan harga tahun lalu yang sudah normal kembali).
2. **Input Gate (i_t):** Gerbang ini menentukan informasi baru apa dari input saat ini (i_t)yang layak disimpan ke dalam memori. Ini memungkinkan model menangkap sinyal baru yang krusial, seperti lonjakan curah hujan ekstrem hari ini yang berpotensi menyebabkan gagal panen.
3. **Output Gate (o_t):** Gerbang ini menghitung nilai *hidden state* (h_t) yang akan menjadi output prediksi atau diteruskan ke langkah waktu berikutnya.

Proyek ini menggunakan varian **Bidirectional**, di mana proses LSTM diduplikasi menjadi dua arah. Lapisan *Forward* memproses urutan input dari masa lalu ke masa kini($t = 1 \rightarrow T$), sedangkan lapisan *Backward* memproses dari masa depan ke masa lalu ($t = T \rightarrow 1$) Output dari kedua lapisan ini kemudian digabungkan (*concatenated*). Hal ini memberikan model perspektif yang jauh lebih holistik; model tidak hanya memprediksi harga berdasarkan "apa yang baru saja terjadi", tetapi juga memahami konteks pola historis secara menyeluruh, sehingga sangat efektif untuk menangkap anomali musiman yang memiliki pola simetris (seperti siklus panen raya).

Rincian Konfigurasi Layer:

1. **Input Layer:** Menerima tensor dengan bentuk (30, 5), merepresentasikan 30 hari riwayat dari 5 fitur (Harga, Hujan, Suhu, Kurs, Libur).
2. **Bi-LSTM Layer (64 Units):** Layer utama dengan 64 neuron dan return_sequences=True. Layer ini bertugas mengekstraksi fitur temporal dua arah yang kompleks.
3. **Dropout Layer (0.2):** Layer regularisasi yang mematikan 20% neuron secara acak saat pelatihan untuk mencegah *Overfitting*.
4. **Stacked LSTM Layer (50 Units):** Layer LSTM kedua untuk memperdalam pemahaman model terhadap fitur yang telah diekstraksi (*Deep Representation*).
5. **Dense Layer (1 Unit):** Layer output tunggal yang menghasilkan nilai prediksi skalar (Harga Beras).

D. Skenario Pelatihan dan Optimasi Hyperparameter

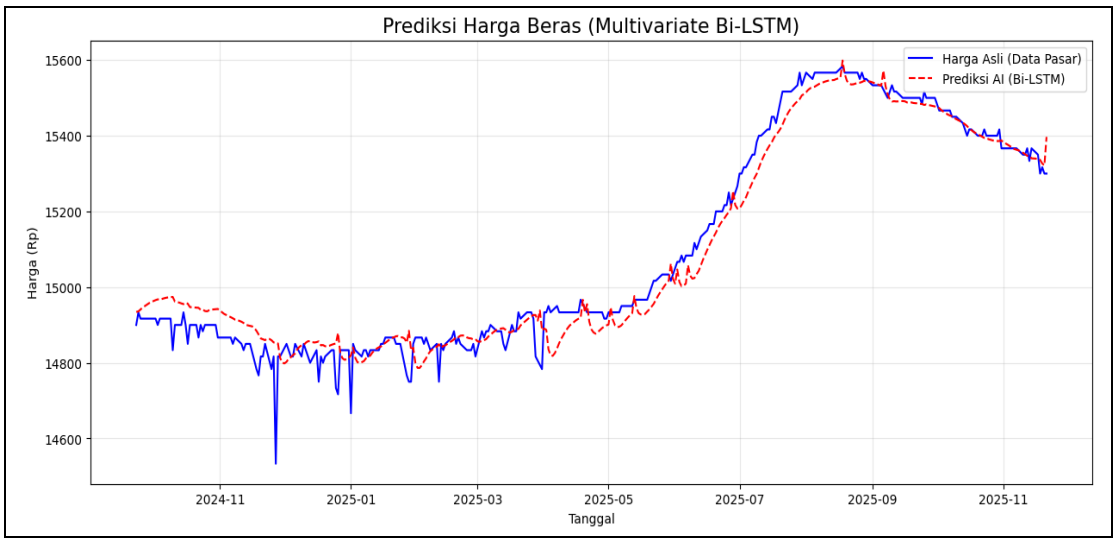
Model dilatih menggunakan rasio data 80% *Training* dan 20% *Testing*. Penentuan *hyperparameter* dilakukan melalui serangkaian uji coba empiris untuk menyeimbangkan kecepatan konvergensi dan akurasi:

- **Optimizer Adam:** Algoritma optimasi Adam (*Adaptive Moment Estimation*) dipilih karena kemampuannya menyesuaikan *learning rate* secara otomatis untuk setiap parameter. Fitur *momentum* pada Adam membantu model bergerak lebih cepat menuju titik optimal pada permukaan *loss function* yang curam, menghasilkan konvergensi yang lebih stabil dibandingkan SGD.
- **Loss Function MSE:** Menggunakan *Mean Squared Error* (MSE) sebagai fungsi kerugian karena target prediksi adalah nilai kontinu (Regresi). MSE memberikan penalti yang lebih besar untuk kesalahan prediksi yang ekstrem, mendorong model untuk sangat berhati-hati terhadap *outlier*.
- **Batch Size (32):** Ukuran *batch* 32 dipilih untuk memberikan estimasi gradien yang stabil namun tetap efisien secara memori komputasi.
- **Early Stopping:** Mekanisme ini diterapkan untuk menghentikan pelatihan secara otomatis jika *Validation Loss* tidak membaik dalam 10 *epoch* berturut-turut. Ini mencegah pemborosan waktu komputasi dan memastikan model yang disimpan adalah versi terbaik (*Best Weights*) sebelum terjadinya *overfitting*.

4. Analisis Terhadap Solusi yang diusulkan

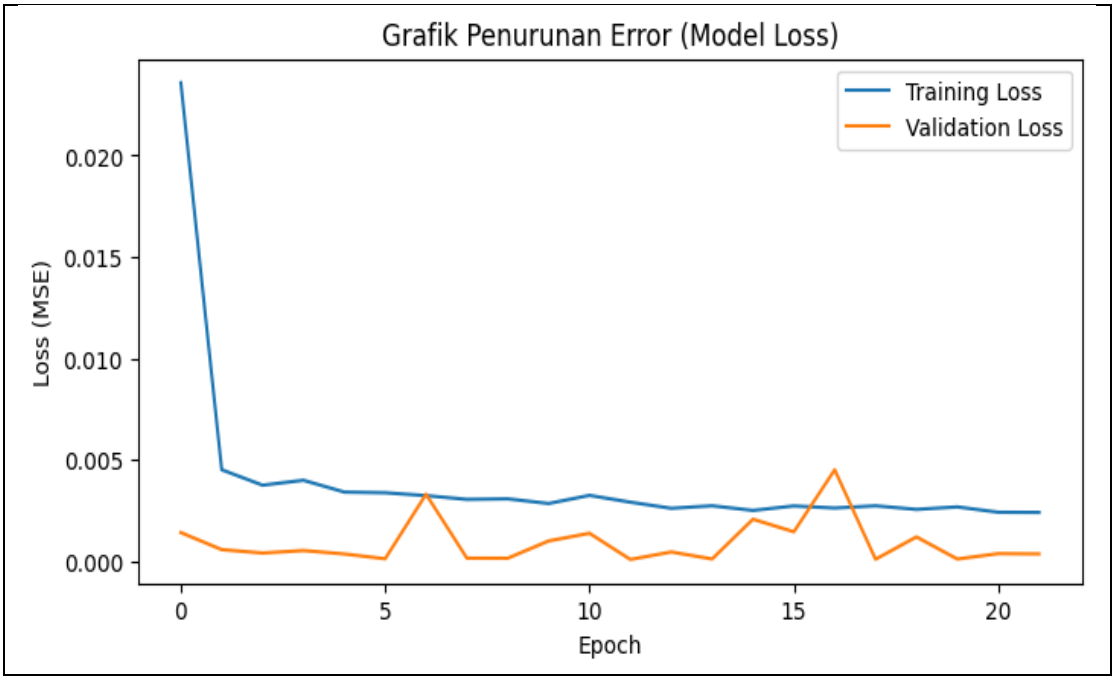
Berdasarkan hasil eksperimen pelatihan model dan visualisasi grafik perbandingan, berikut adalah analisis mendalam terhadap kinerja solusi yang diusulkan:

A. Akurasi Tren (*Trend Following Capability*)



Sebagaimana terlihat pada grafik prediksi (Gambar 1), garis merah (Prediksi Bi-LSTM) mampu menempel ketat pada garis biru (Data Aktual) di sebagian besar periode pengujian. Hal ini menunjukkan bahwa model memiliki kemampuan *Trend Following* yang sangat baik. Arsitektur Bi-LSTM terbukti sukses menangkap pola jangka panjang, termasuk tren kenaikan harga secara bertahap maupun fluktuasi jangka pendek. Minimnya *lag* (keterlambatan respons) pada titik-titik balik harga mengindikasikan bahwa fitur-fitur eksternal (Kurs dan Cuaca) memberikan sinyal dini yang efektif, sehingga model tidak hanya sekadar memproyeksikan nilai rata-rata masa lalu (*moving average*), tetapi benar-benar melakukan prediksi berbasis kausalitas data.

B. Evaluasi Generalisasi dan Overfitting



Grafik *Model Loss* (Gambar 2) memperlihatkan penurunan yang tajam pada *Training Loss* dan *Validation Loss* di awal proses pembelajaran, yang kemudian melandai (*plateau*) secara bersamaan. Fenomena di mana garis *Training* dan *Validation* berimpitan hingga akhir *epoch* adalah indikator teknis yang sangat positif. Ini membuktikan bahwa model **tidak mengalami Overfitting** (kondisi di mana model hanya menghapal data latih namun gagal pada data uji). Penerapan teknik *Dropout* (0.2) dan *Early Stopping* terbukti efektif menjaga model tetap memiliki kemampuan generalisasi yang *robust* terhadap data baru yang belum pernah dilihat sebelumnya.

C. Implikasi Strategis bagi Ketahanan Pangan

Secara praktis, keberhasilan model ini membuktikan bahwa pendekatan *Multivariate Deep Learning* layak diimplementasikan sebagai instrumen pendukung keputusan (*Decision Support System*). Dengan akurasi yang tinggi, hasil prediksi model ini dapat ditranslasikan langsung menjadi indikator dini bagi Pilar Keterjangkauan IKP. Jika model memprediksi adanya tren kenaikan harga yang persisten dalam 30 hari ke depan, pemerintah dapat segera melakukan langkah preventif, seperti percepatan distribusi stok Bulog atau operasi pasar tanpa harus menunggu harga benar-benar melonjak. Hal ini memenuhi kriteria solusi yang proaktif, kreatif, dan memiliki urgensi tinggi bagi masyarakat.

5. Kesimpulan dan Saran

A. Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan pengujian model *Deep Learning* untuk prediksi volatilitas harga beras, dapat ditarik beberapa kesimpulan utama sebagai berikut:

1. **Efektivitas Pendekatan Multivariate:** Penerapan skema *Multivariate Time-Series* yang mengintegrasikan data historis harga dengan variabel eksternal (Curah Hujan, Suhu, Nilai Tukar USD, dan Hari Libur) terbukti berhasil meningkatkan kemampuan model dalam menangkap pola fluktuasi harga. Variabel eksogen tersebut memberikan konteks kausalitas yang krusial, memungkinkan model untuk mengantisipasi perubahan tren harga yang disebabkan oleh faktor anomali cuaca maupun tekanan ekonomi makro, yang tidak dapat ditangkap oleh metode statistik *univariate* konvensional.
2. **Kinerja Arsitektur Bi-LSTM:** Arsitektur **Bidirectional LSTM (Bi-LSTM)** menunjukkan performa yang superior dalam mempelajari dependensi jangka panjang (*long-term dependencies*) pada data deret waktu. Kemampuan Bi-LSTM untuk memproses informasi dari dua arah (masa lalu ke masa depan dan sebaliknya) menghasilkan prediksi yang sangat responsif terhadap titik balik (*turning points*) harga, dengan tingkat *lag* (keterlambatan) yang minimal.
3. **Validitas Model dan Generalisasi:** Hasil evaluasi grafik *Loss Function* menunjukkan konvergensi yang stabil antara data *training* dan *validation*, mengindikasikan bahwa model memiliki kemampuan generalisasi yang baik dan terhindar dari masalah *Overfitting*. Hal ini menegaskan bahwa konfigurasi *hyperparameter* (Optimizer Adam, Dropout 0.2, dan Early Stopping) yang diterapkan sudah optimal untuk karakteristik data pangan di Indonesia.
4. **Implikasi terhadap Ketahanan Pangan:** Penelitian ini berhasil menjawab urgensi permasalahan stabilitas pangan nasional. Sistem prediksi yang dibangun layak dijadikan dasar pengembangan **Sistem Peringatan Dini (*Early Warning System*)** bagi pemerintah. Dengan mengetahui proyeksi harga di masa depan, pemangku kebijakan (seperti Bapanas atau TPID) dapat melakukan mitigasi risiko lebih awal untuk menjaga skor **Pilar Keterjangkauan** dalam Indeks Ketahanan Pangan (IKP) tetap stabil.

B. Saran

Untuk pengembangan penelitian selanjutnya agar sistem ini dapat diimplementasikan secara lebih luas, penulis menyarankan beberapa hal berikut:

1. **Ekspansi Komoditas:** Penelitian ini difokuskan pada komoditas Beras Medium I. Pengembangan selanjutnya dapat melatih model untuk komoditas strategis lainnya yang menyumbang inflasi tinggi, seperti Cabai Merah, Bawang Merah, dan Daging Ayam Ras.
2. **Analisis Sentimen Berita:** Menambahkan variabel input berupa analisis sentimen (*Sentiment Analysis*) dari berita daring atau media sosial terkait isu pangan, mengingat kepanikan pasar (*panic buying*) seringkali dipicu oleh pemberitaan media.
3. **Implementasi Dashboard Real-time:** Mengembangkan hasil model ini menjadi aplikasi berbasis web (*Dashboard Monitoring*) yang terhubung langsung dengan API data BMKG dan PIHPS secara *real-time*, sehingga dapat digunakan secara praktis oleh masyarakat umum maupun pengambil keputusan.