Metodologi Data Science

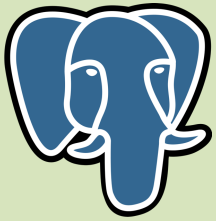
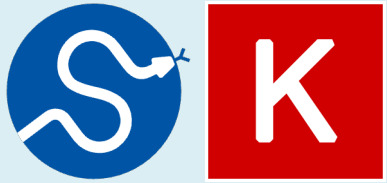
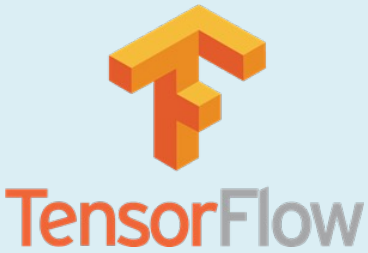


Prof. Hindriyanto Dwi Purnomo, Ph.D

Data Science Tools

- Didalam mengerjakan project Data Science, tahapan pemrosesan data akan membutuhkan porsi yang sangat besar, sehingga memerlukan waktu yang lama.
- Untuk membantu pekerjaannya, data scientist akan memerlukan tools yang bisa menghemat waktu dalam melakukan pemrosesan data, sehingga data scientist bisa mengalokasikan lebih banyak waktu untuk melakukan Analisa data.

- Ada beragam jenis alat bantu/tools yang dipakai terkait dengan data science, mulai dari aspek penyimpanan data, persiapan data, pemodelan data hingga vizualisasi data.
- Beragam alat tools tersebut dapat dilihat pada gambar berikut

Penyimpanan Data (Data storage)	Persiapan Data (Data Preparation)	Pemodelan Data (Data Modelling)	Vizualisasi Data (Data Vizualization)
			
			
			
			
			

- Kita akan membahas tools tersebut dengan lebih rinci

Penyimpanan Data

- Data mentah (raw data) yang dipergunakan dalam project data science bisa berasal dari berbagai sumber.
- Data-data ini ada yang disimpan dalam basis data (data base management system) maupun disimpanselain dalam basis data, seperti dalam bentuk text file maupun file spreadsheet (misalnya excel).

- Contoh sistem basis data yang dipergunakan untuk penyimpanan data adalah:

1. mySQL
2. PostgreSQL
3. Mongo DB
4. SQL Server









- Contoh penyimpanan data tanpa menggunakan basis data antara lain

1. CSV
2. Spreadsheet (excel)





Contoh Sistem Manajeman Basis Data (DBMS : Data Base Management System)

- mySQL :

merupakan sistem manajemen basis data yang bersifat ‘open source’ dan menggunakan perintah SQL (Structured Query Language).

mySQL termasuk dalam basis data relasional, sehingga cocok untuk menyimpan data terstruktur

Keuntungan dari my SQL antara lain :

a) memiliki komunitas yang besar, sehingga memudahkan kita dalam mencari referensi ketika mengalami permasalahan.
b) Bersifat open source, sehingga ekonomis

c) Bersifat multi user, sehingga dapat diakses oleh beberapa user secara bersamaan
d) Bersifat portable sehingga bisa dijalankan dalam berbagai platform atau sistem operasi
e) Dapat diintegrasikan dengan berbagai bahasa pemrograman, sehingga memudahkan dalam penerapannya

Keterbatasan dari my SQL antara lain :

a) Performa mySQL untuk database dengan ukuran besar belum teruji, sehingga tidak cocok untuk database dengan kapasitas besar
b) Meskipun memiliki komunitas yang besar, tetapi mySQL belum memiliki tehnical support yang memadai. Untuk mengatasi permasalahan yang dihadapi, pengguna cenderung mengandalkan ‘pengalaman’ dari pengguna lain yang dishare dalam forum-forum komunitas mySQL

- postgreSQL :

merupakan sistem manajemen basis data relasional object yang bersifat ‘open source’ serta mendukung eksekusi berbagai query kompleks

Meskipun postgre merupakan sistem basis data relasional, yang menggunakan SQL sebagai Bahasa query utamanya, tetapi postgre juga mendukung NoSQL, sehingga bisa dipakai untuk tipe data non terstruktur, seperti JSON (JavaScript Object Notation) dan XML (Extensible Markup Language).

Keuntungan dari postgre antara lain:

a) Bersifat open source, sehingga bisa dipakai secara
b) Basis data relational object, sehingga dapat dipakai juga untuk menangani data yang tidak terstruktur

c) Dapat diintegrasikan dengan berbagai Bahasa pemrograman
d) Memiliki performa yang stabil dan fitur keamanan yang tinggi
e) Mendukung pengolahan data yang kompleks, sehingga banyak dipergunakan pada aplikasi web, mobile dan analitik

Keterbatasan dari postgre antara lain:

a) Lambat : proses pencarian data dalam postgreSQL lambat, apalagi jika jumlah datanya sangat besar. Kinerja lambat ini juga disebabkan karena banyaknya fitur yang tersedia dalam postgre serta proses backup yang dilakukan terus menerus.
b) Kurang populer, sehingga komunitasnya kurang begitu besar. Hal ini menyebabkan sedikitnya forum-forum yang bisa dijadikan rujukan ketika pengguna mengalami permasalahan

- MongoDB :

merupakan sistem basis data NoSQL yang menyimpan data dalam bentuk dokumen dengan format JSON.

MongoDB banyak dipergunakan dalam aplikasi web. Popularitas MongoDB semakin meningkat seiring dengan meningkatnya kebutuhan pengelolaan data tidak terstruktur. Kebutuhan ini muncul karena meningkatnya jumlah data tidak terstruktur yang dihasilkan dan disimpan.

Keuntungan dari MongoDB antara lain:

a) Skalabilitas tinggi : MongoDB memiliki kemampuan yang baik dalam meningkatkan kapasitas penyimpanan melalui skalabilitas horisontal
b) Fleksibilitas dan adaptabilitas yang tinggi. Konfigurasi data yang disimpan dapat disesuaikan kebutuhan dengan lebih mudah
c) Kebutuhan infrastruktur yang lebih ringan
d) Dapat diintegrasikan dengan berbagai bahasa pemrograman

Keterbatasan dari MongoDB antara lain:

a) Memerlukan memori yang besar Fungsionalitas dalam MongoDB terbatas, sehingga memungkinkan adanya duplikasi data, yang memerlukan banyak memori
b) Tidak mendukung proses transaksi. Kemampuan Mongo DB dalam proses transaksi memerlukan adanya pembaharuan data secara periodik, kurang baik
c) Adanya batasan ukuran data. Ukuran setiap dokumen dibatasi sehingga data yang bisa disimpan juga terbatas

- SQL Server :

merupakan sistem manajemen basis data relasional yang dibuat oleh Microsoft.

SQL server menggunakan SQL sebagai Bahasa query nya serta memiliki arsitektur dengan konsep client-server.

Client merupakan bagian/komponen dari sistem yang meminta layanan/request dari bagian/komponen yang lainnya.

Server adalah bagian/komponen dari sistem yang memberikan layanan kepada bagian/komponen lainnya.

SQL server memiliki scalabilitas yang baik serta powerfull, sehingga banyak dipergunakan oleh perusahaan.

Keuntungan dari SQL server antara lain:

a) Pengelolaan basis data secara terpusat, sehingga meminimalkan terjadinya kesalahan pengelolaan data
b) Memiliki fitur recovery dan restore data yang baik, sehingga ketika terjadi kerusakan data, bisa dilakukan recovery dan restore data
c) Memiliki performa yang baik

Keterbatasan dari SQL server antara lain:

a) Berbayar. SQL server memiliki harga yang cukup tinggi yang diimbangi dengan kemampuan dan fitur yang disediakan
b) Hanya bisa dipergunakan untuk sistem operasi Windows
c) Tidak mensupport beragam Bahasa pemrograman. SQL server didesain untuk implementasi dengan .Net saja

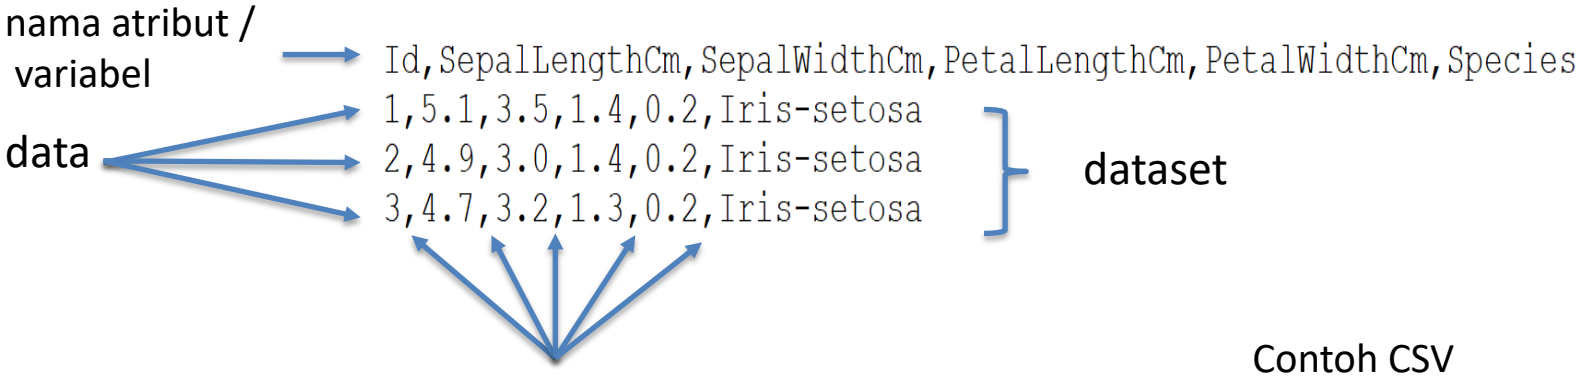
Untuk penyimpanan data non database antara lain:

1. CSV

- CSV atau Comma Separated Value adalah sebuah tipe file teks yang menyimpan informasi dengan format pemisahan oleh koma.
- Didalam sebuah file CSV, sebuah data disimpan dalam satu baris, dimana tiap-tiap attribute atau variabel yang terkandung dalam sebuah data tersebut dipisahkan dengan koma.
- Satu file CSV bisa berisi banyak data, yang sering disebut dengan dataset

Contoh CSV dapat dilihat pada gambar berikut

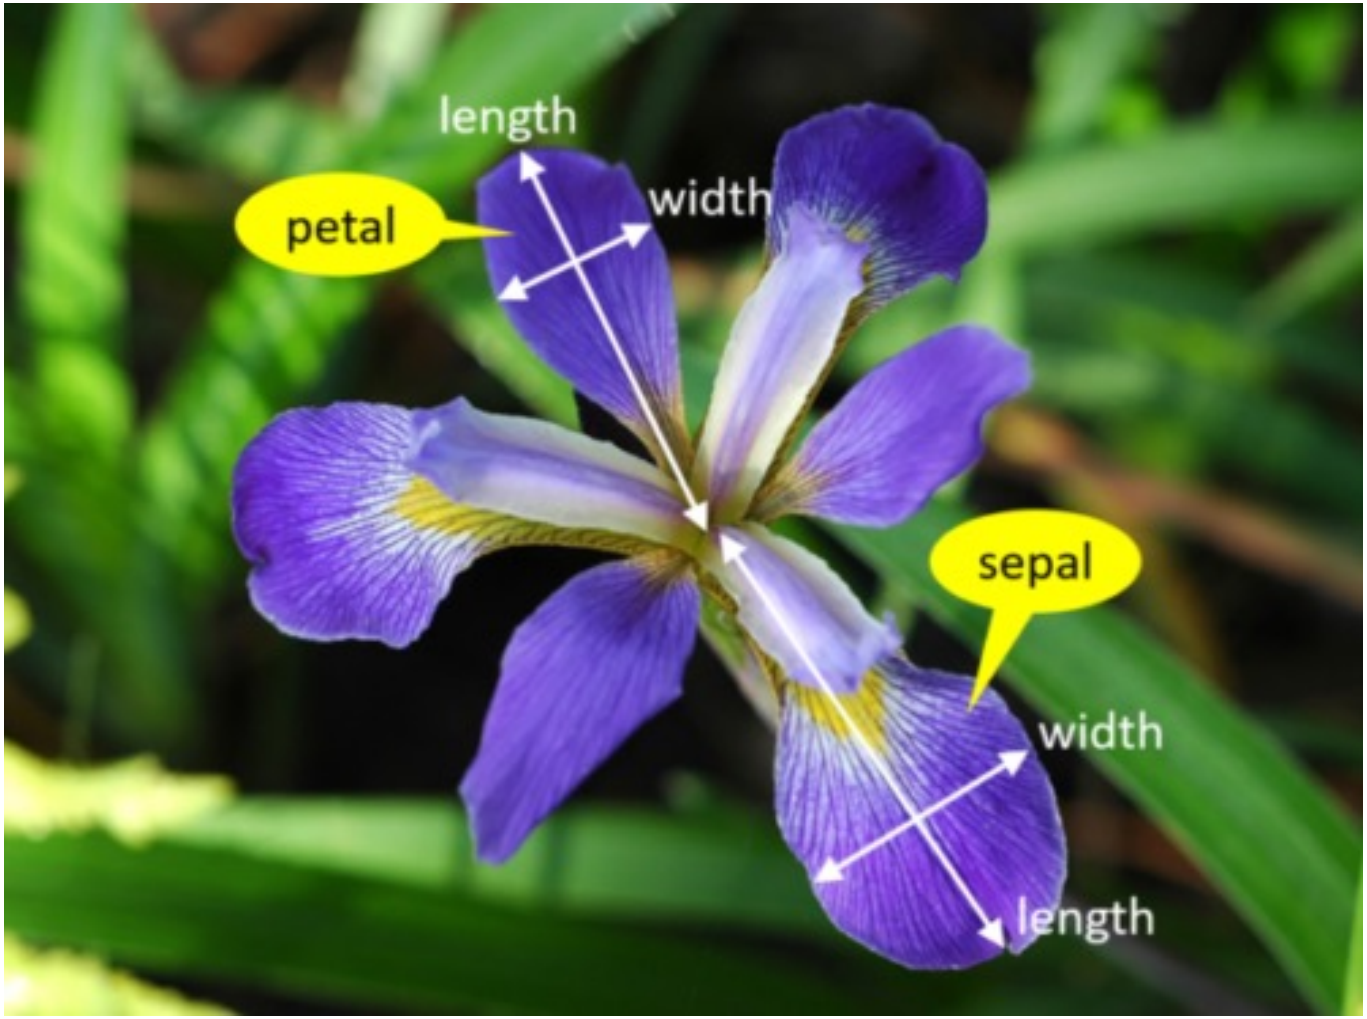
Data ini diambil dari data set IRIS, salah satu open dataset yang banyak dipakai dalam pembelajaran



Contoh CSV

Setiap data memiliki 6 attribute atau variabel, yaitu ID data (Id), Panjang Sepal (SepalLengthCm), lebar Sepal (SepalWidthCm), Panjang Petal (PetalLengthCm), lebar Petal (PetalWidthCm) dan nama Spesies bunga Iris (Species)

Sepal dan Petal bunga Iris



https://marcelofern.com/projects/iris-dataset

2. Spreadsheet

Spreadsheet adalah aplikasi yang dipergunakan untuk menyimpan, menampilkan dan mengolah data dalam bentuk baris dan kolom.

Data yang disimpan dalam spreadsheet berarti disimpan dalam format baris dan kolom.

Kolom merepresentasikan attribute / variabel dari data sedangkan baris merepresentasikan data yang disimpan.

Contoh spreadsheet yang banyak digunakan adalah excel

Contoh : dataset IRIS dalam format baris dan kolom

Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
1	5.1	3.5	1.4	0.2	Iris-setosa
2	4.9	3	1.4	0.2	Iris-setosa
3	4.7	3.2	1.3	0.2	Iris-setosa

- Data yang telah disimpan akan digunakan sebagai sumber data dalam project data science
- Ketika data yang disimpan tersebut dibutuhkan, maka data akan diambil (retrieve) dari penyimpanan.
- Data yang baru diambil dari penyimpanan ini masih berupa data mentah (raw data)
- Data mentah ini harus diolah terlebih dahulu supaya memiliki format yang bisa dipergunakan untuk pemodelan data.
- Tahapan ini disebut dengan persiapan data (data preparation), yang cenderung berfokus pada pengolahan format data (merubah bentuk data)

Data Preparation

- Data Preparation adalah proses mempersiapkan data mentah menjadi data yang siap untuk dimodelkan
- Data prepration diperlukan karena data mentah memiliki bentuk dan kualitas yang beragam, sehingga perlu untuk diolah supaya memiliki bentuk yang seragam dan kualitas yang baik.
- Data yang berkualitas sangat penting dalam pemodelan data, karena data input yang baik akan menghasilkan output pemodelan yang baik juga.

Data Preparation

- Data Preparation memiliki beberapa tahap, yaitu :

1. data cleaning atau proses pembersihan data
2. data integration : menggabungkan data dari berbagai sumber
3. data selection : memilih data yang akan dipakai untuk pemodelan
4. data transformation : merubah data supaya memiliki bentuk yang lebih baik dan lebih berkualitas

Data Preparation

- Tools yang dipergunakan untuk melakukan data preparation antara lain:

1. Python
2. Julia
3. Spark







- **Python :**

✓ merupakan bahasa pemrograman berorientasi object (OOP) yang sangat popular untuk data Science.

✓ Python bersifat ‘open source’ dan termasuk dalam bahasa pemrograman level tinggi, sehingga memiliki syntac/perintah yang mudah dipahami, karena mendekati bahasa manusia (natural language)

✓ Python termasuk dalam Bahasa interpreter, dimana code program akan di ‘terjemahkan’ ke dalam bahasa mesin per ‘statement’ atau per perintah.

✓ Hal ini berbeda dengan bahasa compiler, dimana penerjemahan ke dalam bahasa mesin dilakukan untuk keseluruhan code program sekaligus.

✓ Python memiliki banyak library yang dapat dipergunakan untuk *data preparation*, misalnya melakukan penskalaan data, menangani *missing value*, melakukan normalisasi data, dan sebagainya

- **Julia :**

✓ merupakan bahasa pemrograman dinamis level tinggi yang didesain sebagai ‘general purpose programming language’

✓ Julia bersifat open source serta memiliki performa yang sangat bagus untuk pengolahan data, khususnya pengkodean aritmatika

✓ Karena kemampuannya tersebut, Julia banyak dipergunakan untuk analisa data

✓ Julia memiliki banyak library yang bisa dipakai untuk melakukan *data preparation* misalnya melakukan penskalaan data, menangani *missing value*, melakukan normalisasi data, dan sebagainya

- **Spark :**

✓ merupakan suatu framework yang dipergunakan untuk mengakses data dari berbagai sumber yang berbeda, kemudian mengolah dan menyimpannya untuk kebutuhan analisa data

✓ Salah satu kekuatan Spark adalah kemampuannya untuk membangun jalur pemrosesan data berskala besar sehingga Spark memiliki kecepatan tinggi dalam pemrosesan data

✓ Kemampuan untuk menangani data dalam skala besar ini membuat Spark banyak dipergunakan dalam project Big Data maupun Data Science

Pemodelan Data

- Luaran Data Preparation adalah dataset yang memiliki kualitas dan bentuk yang baik, sehingga siap untuk dieksplorasi lebih lanjut

- Proses eksplorasi data untuk mendapatkan mengekstraksi informasi didalam data ini dilakukan melalui pemodelan data

- Tool yang dipakai dalam pemodelan data antara lain

1. Pandas
2. Scikitlearn
3. Keras
4. Scipy python
5. Tensorflow











- **Pandas :**



- ✓ Pandas merupakan library Python yang berfungsi untuk melakukan analisa dan manipulasi data
- ✓ Pandas banyak dipergunakan untuk memanipulasi data numerik maupun data sekuensial (time series).
- ✓ Pandas memiliki 2 tipe structure data, yaitu Series dan Data Frame
- ✓ Series merupakan struktur data yang memiliki 1 dimensi (semacam vector atau array 1 dimensi) sedangkan Data Frame merupakan struktur data yang memiliki 2 dimensi sehingga dapat menyimpan data dalam bentuk tabular (berbentuk table)
- ✓ Beberapa fitur yang terdapat dalam Pandas antara lain untuk mengubah dimensi data, melakukan pivoting data, menggabungkan data, memisahkan data (splitting data) menyisipkan data maupun menghapus data

- **Scikitlearn :**



- ✓ Scikitlearn merupakan library Machine Learning untuk Python
- ✓ Scikitlearn menyediakan berbagai algoritma Machine Learning, baik yang supervised maupun unsupervised untuk analisa dan pemodelan data
- ✓ Scikitlearn compatible dengan library lain dalam Python seperti Numpy, SciPy dan Matplotlib sehingga dapat beroperasi dengan library-library lain dengan mudah
- ✓ Beberapa fitur yang terdapat di Scikitlearn antara lain : Regresi, clustering dan klassifikasi

- **Keras :**



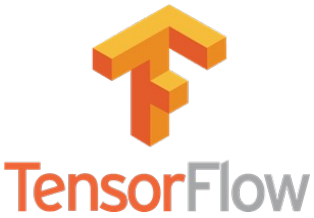
- ✓ KERAS merupakan API (Application Programming Interface) deep learning yang dibangun menggunakan Python serta bekerja diatas platform Tensorflow.
- ✓ Keras didesain untuk meminimalkan aksi yang diperlukan user dalam memanfaatkan API tersebut serta memberikan pesan kesalahan (actionable error message) yang jelas sehingga memudahkan pengguna dalam meindaklanjutinya.
- ✓ Karena kemudahan dalam penggunaannya, KERAS banyak dipergunakan oleh berbagai perusahaan sebagai API deep learningnya
- ✓ Beberapa fitur yang ada dalam KERAS antara lain: Concolutional Neural Network (CNN), Long- Short Term Memory (LSTM) mapun Recurrent Neural Network (RNN)

- **Scipy :**



- ✓ Scipy merupakan library Python yang dipergunakan untuk keperluan *Scientific Computing*
- ✓ Scipy dimanfaatkan untuk menyelesaikan permasalahan matematis, permasalahan sains maupun permasalahan teknis.
- ✓ Beberapa fitur yang terdapat dalam Scipy adalah algoritma untuk optimalisasi, integral, interpolasi, aljabar, persamaan differensial maupun statistic.

- **Tensorflow :**



- ✓ Tensorflow adalah suatu platform Machine Learning yang dikembangkan oleh Google.
- ✓ Tensorflow memiliki ekosistem yang lengkap dan fleksibel baik dari sisi tools, library maupun komunitasnya.
- ✓ Ekosistem yang lengkap akan memudahkan peneliti dalam mengembangkan riset-riset terbaru dibidang Machine Learning
- ✓ Fitur-fitur dalam Tensorflow meliputi algoritma-algoritma dalam Machine Learning maupun Deep learning, seperti regresi, clustering dan klasifikasi

Vizualisasi Data

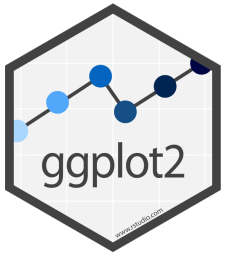
- Untuk memudahkan melakukan analisa dan interpretasi, diperlukan visualisasi data.
- Visualisasi dapat diterapkan pada data mentah maupun data yang sudah diolah dan dimodelkan.
- Visualisasi pada data mentah bertujuan untuk memahami data dengan lebih baik
- Visualisasi pada data hasil pengolahan dan pemodelan data bertujuan untuk melihat *insight/*pengetahuan dari hasil pengolahan dan pemodelan yang dilakukan

- Tools visualisasi yang banyak dipergunakan dalam data science antara lain:

1. Matplotlib
2. Seaborn
3. ggplot2
4. Tableau
5. Power BI











- **Matplotlib :**



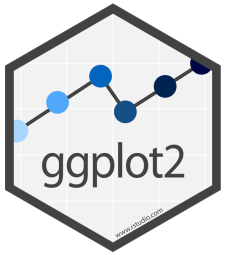
- ✓ Matplotlib adalah library Python yang banyak dipergunakan untuk melakukan visualisasi data baik yang statis maupun interaktif
- ✓ Vizualisasi yang disediakan dalam Matplotlib antara lain: bar plot, grafik batang, histogram, pie chart, box plot dan lain sebagainya

- **Seaborn :**



- ✓ Seaborn adalah library visualisasi yang dibangun diatas matplotlib.
- ✓ Seaborn memiliki fungsi visualisasi yang lebih banyak dan lebih mudah dipergunakan
- ✓ Beberapa fitur visualisasi dalam seaborn antara lain: plot kategorial, plot distribusi, plot relasi, plot regresi dan plot matriks

- **ggplot2 :**



- ✓ ggplot2 adalah suatu sistem untuk membuat grafik secara declarative berdasarkan paa The Grammar Graphic.
- ✓ The Grammar Graphic adalah suatu grammar yang dipergunakan untuk mendeskripsikan dan membuat berbagai grafik statistic
- ✓ ggplot2 dibuat menggunakan Bahasa R.
- ✓ Fitur grafik yang disediakan dalam ggplot2 antara lain : box plot, line chart, pie chart dan histogram

- Tableau :



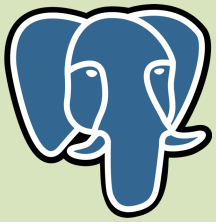
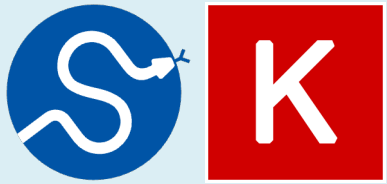
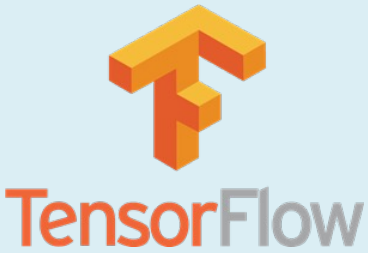
- ✓ Tableau adalah sebuah platform yang mendukung visualisasi data secara interaktif
- ✓ Tableau dapat mengimport berbagai data yang kompleks, memiliki range yang beragam serta dalam jumlah yang besar
- ✓ Tableau mampu menyajikan data dengan tampilan yang menarik sehingga data yang disajikan lebih mudah dimengerti bahkan oleh orang awam
- ✓ Fitur vizualisasi yang disediakan oleh tableau sangat lengkap, sehingga sering dipergunakan dalam membuat sebuah dasboard

- Power BI :



- ✓ Power BI adalah sebuah platform visualisasi data secara interaktif buatan Microsoft
- ✓ Power BI memiliki fitur yang lengkap untuk berbagai kebutuhan visualisasi data bisnis maupun Business Intelligence
- ✓ Power BI mampu mengambil data dari berbagai sumber serta terintegrasi dengan berbagai aplikasi pengolah data lainnya, seperti Google Analytics, Oracle, Microsoft Dynamics CRM dan lain sebagainya
- ✓ Power BI juga sering dipergunakan dalam membangun dashboard perusahaan

- Demikian tadi kita sudah membahas berbagai tools yang mendukung pekerjaan Data Science mulai dari Penyimpanan Data, Persiapan Data, Pemodelan Data dan Vizualisasi Data.
- Karena banyaknya tools yang tersedia, tentu saja masih ada beberapa tools lain yang tidak bisa kita bahas satu persatu dalam kesempatan ini. Tetapi tools-tools yang kita diskusikan kali ini sudah mencukupi untuk mengerjakan berbagai project Data Science.

Penyimpanan Data (Data storage)	Persiapan Data (Data Preparation)	Pemodelan Data (Data Modelling)	Vizualisasi Data (Data Vizualization)
			
			
			
			
			

Terima kasih