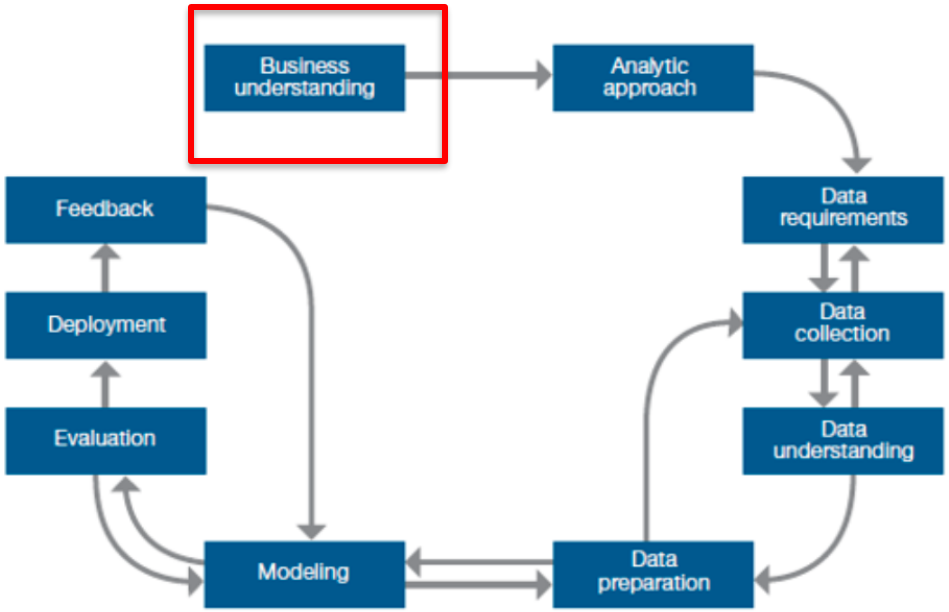
Metodologi Data Science



Prof. Hindriyanto Dwi Purnomo, Ph.D

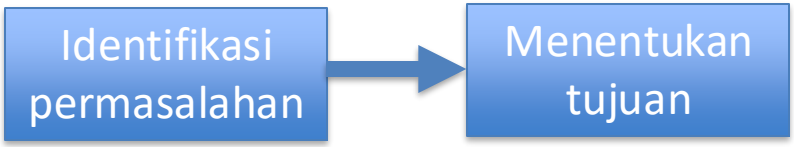
Business Understanding - Data Collection

- Pada saat ini kita akan mempelajari tahapan-tahapan dalam project data science menggunakan pendekatan IBM Data Science methodology
- Tahap pertama dalam project data science adalah business understanding



- Tujuan dari project Data Science adalah menemukan informasi implisit di dalam kumpulan data untuk membantu pengambilan keputusan dalam rangka mencapai tujuan perusahaan.
- Umumnya data science dipakai untuk mendukung keputusan-keputusan yang bersifat strategik
- Sebuah project Data science perlu berfokus pada kebutuhan bisnis yang ditanganinya sehingga mampu memberikan manfaat yang maksimal bagi kebutuhan bisnis perusahaan
- Supaya informasi yang didapatkan bisa sesuai dengan kebutuhan perusahaan, maka kita perlu memahami proses bisnis (business understanding) dengan baik

- Business understanding merupakan fase awal dalam project data science yang bertujuan untuk :
  1. mengidentifikasi permasalahan yang dihadapi
  2. menentukan tujuan dari project data science



Identifikasi masalah

- Tahapan Business understanding memerlukan pengetahuan dan pemahaman yang memadai terkait domain bisnis yang ditangani
- Untuk bisa mengidentifikasi permasalahan, kita perlu memahami proses bisnisnya, sehingga bisa memodelkan permasalahan yang ada.
- Pemodelan dilakukan karena permasalahan real umumnya sangat kompleks dengan banyak faktor yang mempengaruhinya serta tidak mudah terlihat.
- Oleh karena itu perlu dilakukan penyederhanaan dengan menambahkan berbagai asumsi maupun melakukan pendekatan praktis dengan hanya mempertimbangkan factor-factor penting saja

Identifikasi masalah

- Meskipun berupa pernyederhanaan dari permasalahan real, sebuah model harus memiliki kepresisian yang baik karena model tersebut merupakan representasi dari permasalahan real yang dihadapi sehingga solusi yang dihasilkan berdasarkan model tersebut harus dapat diimplementasikan pada permasalahan real.
- Suatu solusi yang benar akan membutuhkan pemahaman permasalahan yang benar.
- Selain memiliki pengetahuan terhadap domain bisnis, seorang data scientist diharapkan memiliki kreativitas yang tinggi, sehingga mampu merumuskan permasalahan dengan baik.

Identifikasi masalah

- Pertanyaan awal yang bisa membantu kita dalam memahami proses bisnis antara lain :

1. " Apakah tujuan dari bisnis tersebut?"
2. "Kendala apa yang dihadapi oleh bisnis tersebut?"

Sebagai contoh:

- Sebuah perusahaan investasi memiliki tujuan menginvestasikan dana yang dihimpuan dari para investor untuk mendapatkan keuntungan sebanyak mungkin.
- Kendala yang dihadapi oleh perusahaan tersebut adalah :

1. ada beragam jenis instrument investasi dengan berbagai kelebihan dan keterbatasannya masing-masing, sehingga perusahaan mengalami kesulitan untuk menentukan instrument investasi yang tepat
2. setiap instrument investasi memiliki fluktuasi yang beragam, sehingga perusahaan kesulitan untuk menentukan waktu yang tepat untuk melakukan investasi

Menentukan tujuan

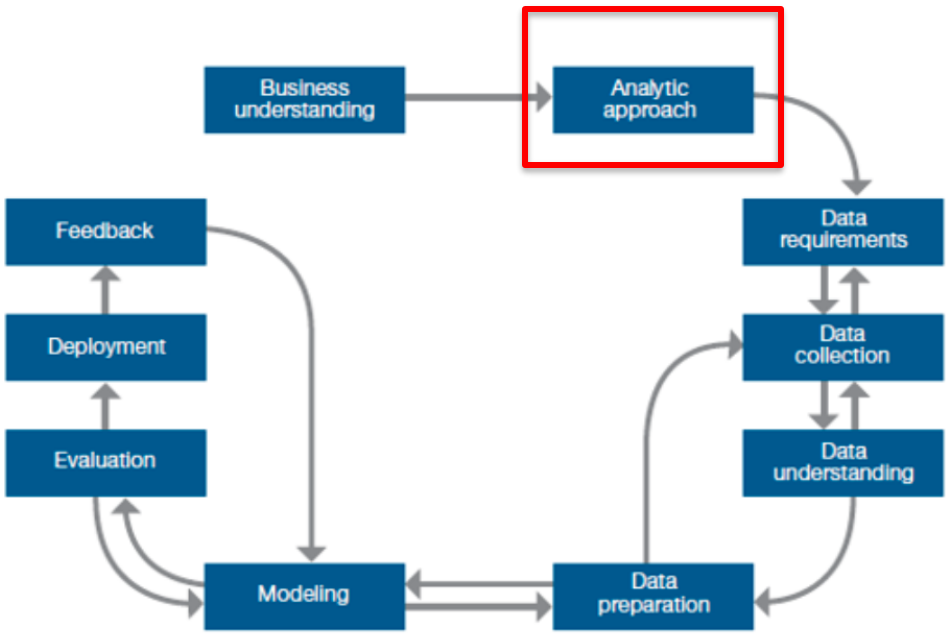
- Tidak semua permasalahan yang telah teridentifikasi bisa diselesaikan sekaligus, sehingga kita perlu menentukan fokus, permasalahan mana yang akan diselesaikan dalam sebuah project data science.

- Oleh karena itu, setelah mengidentifikasi permasalahan-permasalahan yang dihadapi, maka kita perlu memutuskan tujuan yang ingin di capai dalam project data science tersebut. Tujuan ini merupakan penyelesaian dari salah satu permasalahan yang dihadapi

- Sebagai contoh, setelah melalui berbagai pertimbangan, perusahaan investasi tersebut menetapkan tujuan dari project data science-nya adalah menyelesaikan permasalahan **penentuan waktu investasi** yang tepat untuk instrument investasi **saham dalam jangka pendek**.

Analytics approach

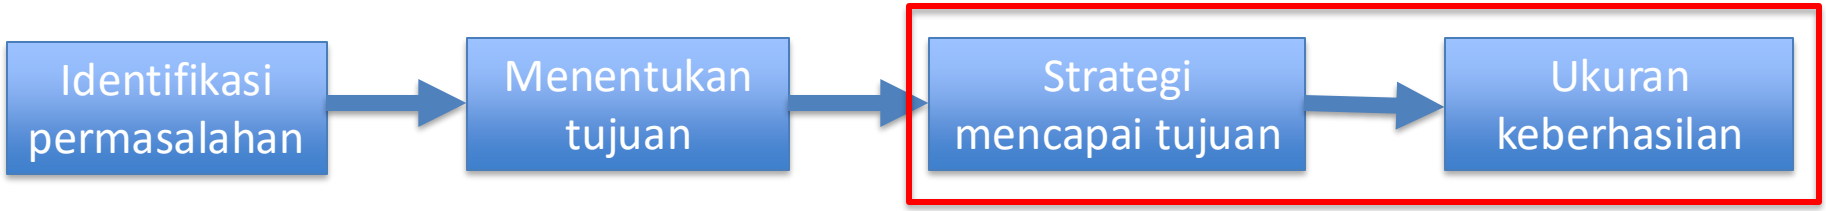
- Setelah menentukan tujuan dari suatu project data science, langkah berikutnya adalah mempersiapkan strategi untuk mencapai tujuan tersebut.
- Dalam mempersiapkan strateginya, data scientist perlu melakukan pendekatan analitik (analytics approach) untuk menyelesaikan permasalahan tersebut.



Menentukan strategi

- Tujuan dari analytics approach ini adalah :
  1. mempersiapkan strategi untuk mencapai tujuan yang ditetapkan
  2. menentukan ukuran keberhasilan

- Dalam konteks data science, pendekatan analitik ini dapat dimaknai sebagai cara memformulasikan permasalahan dari sudut pandang statistik dan machine learning sehingga perusahaan dapat memutuskan pendekatan mana yang paling tepat untuk menyelesaikan permasalahan tersebut.



Menentukan strategi

- Dalam contoh perusahaan investasi sebelumnya, salah satu strategi untuk menentukan waktu yang tepat kapan harus berinvestasi saham adalah dengan memahami fluktuasi harga saham sehingga perusahaan bisa mengetahui kapan suatu saham akan naik atau turun.
- Keuntungan investasi saham didapat dari selisih antara harga jual dan harga beli sehingga saat yang tepat untuk membeli saham adalah ketika harganya di bawah dan saat yang tepat untuk menjual saham adalah ketika harganya di puncak
- Oleh karena itu, perusahaan perlu memprediksi harga saham di masa-masa yang akan datang untuk menentukan waktu yang tepat berinvestasi saham
- Dari sudut pandang machine learning, proses prediksi ini dapat dilakukan dengan metode regresi.
- Perusahaan bisa menerapkan berbagai metode regresi untuk melakukan prediksi harga saham di masa yang akan datang seperti Regresi Linear, Regresi Non linear dan support vector regression

Menentukan ukuran keberhasilan

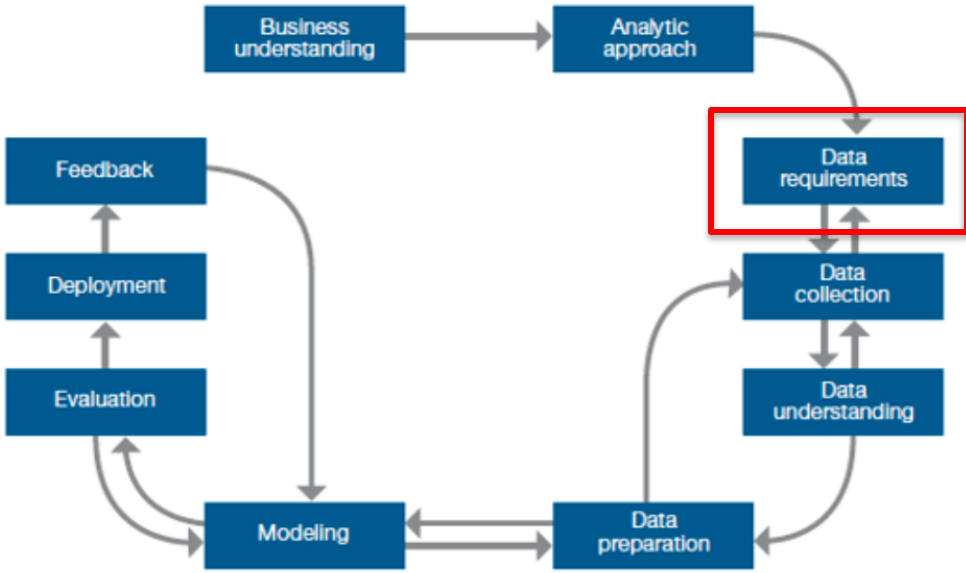
- Setelah menentukan strategi, langkah berikutnya adalah menentukan ukuran keberhasilan dari strategi yang dipilih
- Metode evaluasi yang digunakan akan sangat di pengaruhi oleh strategi yang dipilih
- Dalam contoh kasus yang kita pergunakan, perusahaan menggunakan pendekatan regresi untuk memprediksi harga saham.
- Kinerja metode regresi dapat diukur berdasarkan selisih antara harga prediksi saham dengan harga aktual saham.
- Selisih ini menyatakan error sehingga semakin kecil selisih antara harga prediksi dengan harga aktual, semakin bagus kinerja dari metode regresi yang digunakan.
- Error ini dapat dinyatakan antara lain dalam bentuk mean square error (MSE), root mean square error (RMSE), mean absolute error

Menentukan ukuran keberhasilan

- Ukuran keberhasilan untuk berbagai metode machine learning akan kita pelajari lebih lanjut pada topik Evaluasi

Identifikasi kebutuhan data

- Pemilihan metode analisa akan mempengaruhi kebutuhan data yang diperlukan
- Dalam contoh yang kita pergunakan, ada banyak faktor yang mempengaruhi pergerakan harga saham.
- Secara umum pergerakan saham bisa di analisa secara teknical dan fundamental



Identifikasi kebutuhan data

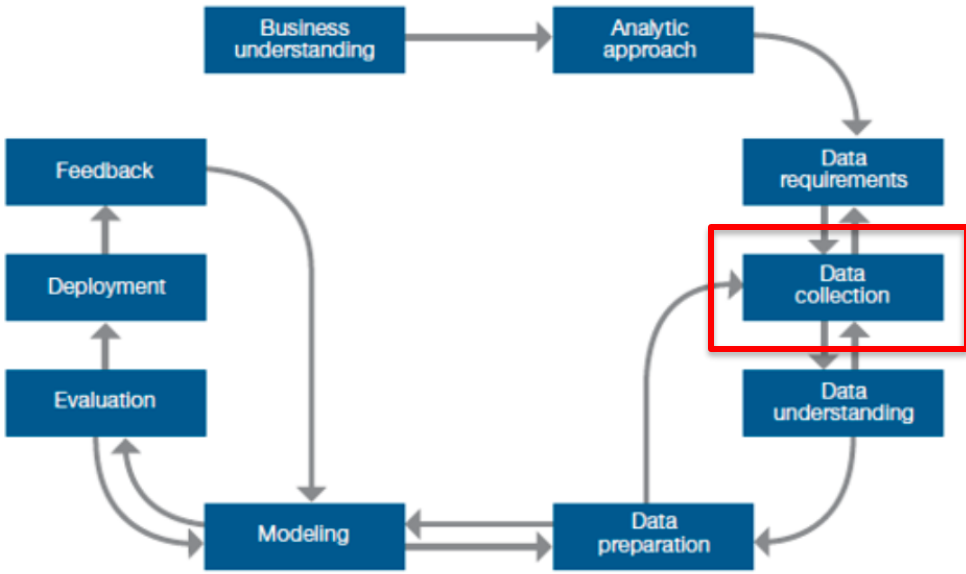
- Analisa teknikal mempergunakan informasi harga dan volume perdagangan saham yang telah terjadi di masa lalu sedangkan analisa fundamental mempergunakan informasi terkait kondisi perusahaan, seperti kinerja perusahaan, persaingan usaha serta kondisi pasar.
- Analisa teknikal cenderung dipergunakan untuk investasi jangka pendek yaitu perdagangan cepat sebagai trader sedangkan analisa fundamental cederung dipergunakan untuk investasi jangka panjang
- Karena tujuan yang ditetapkan adalah untuk investasi saham jangka pendek, maka data- data yang diperlukan adalah data-data untuk mendukung analisa teknikal, yaitu data historis perdagangan saham

Mengumpulkan data

- Setelah menentukan kebutuhan data yang diperlukan, langkah selanjutnya adalah mengidentifikasi sumber-sumber data yang tersedia serta mengumpulkan data.

- Data bisa didapatkan dari berbagai sumber, antara lain:

1. Data internal perusahaan
2. Data publik
3. Open data
4. web scraping atau web API



Mengumpulkan data

1. Data internal perusahaan :

- Data internal adalah yang bersumber dari dalam perusahaan itu sendiri misal data karyawan dan data keuangan perusahaan

2. Data publik :

- Data publik adalah informasi publik yang bisa di dapatkan dari berbagai domain publik
- Data publik tidak selalu bisa di akses misalnya untuk mengaksesnya kita perlu melakukan permohonan akses terlebih dahulu
- Data publik seringkali tidak terstruktur dan tidak terorganisasi sehingga untuk memanfaatkan data publik kita perlu mengolahnya supaya menjadi data set yang terstruktur
- Sebagai contoh: data inflasi yang dimuat dalam website pemerintah, data harga pangan dan data kasus covid harian

Mengumpulkan data

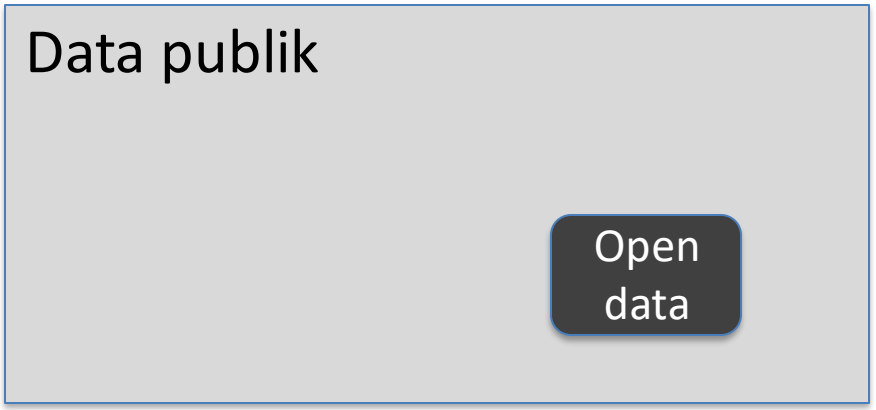
3. Open data :

- Open data adalah data yang dapat diakses dan dipergunakan secara bebas serta dapat didistribusikan ulang.
- Open data dapat di modifikasi sesuai dengan kebutuhan
- Open data umumnya sudah terstruktur, dikelola dengan baik, memiliki lisensi terbuka serta machine-readable

Mengumpulkan data

3. Open data :

- Open data merupakan bagian dari publik data
- Contoh open data misalnya data-data yang terdapat di Portal Satu Data Indonesia (https://data.go.id), open data UCI machine learning repository (https://archive.ics.uci.edu/ml/index.php), Kaggle (https://www.kaggle.com/datasets)



Mengumpulkan data

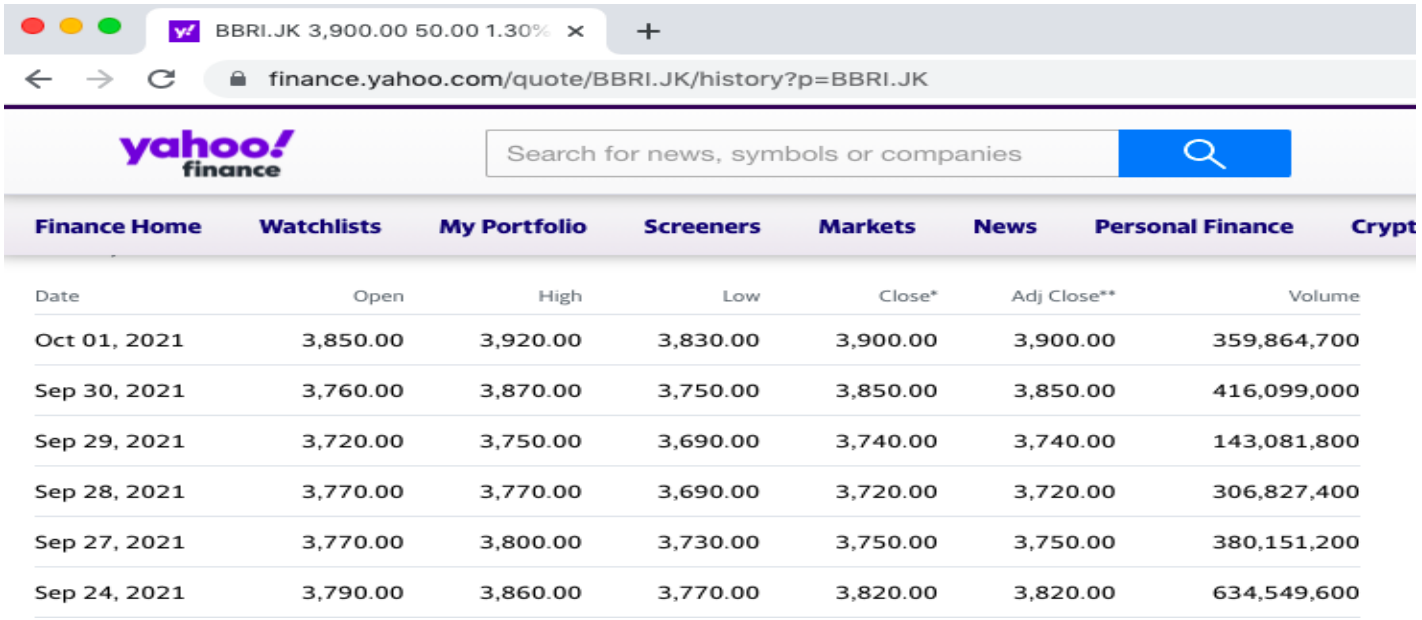
4. Web scraping dan web API

- Web scraping merupakan pengambilan data dari suatu website
- Web scraping dapat dilakukan secara manual maupun otomatis seperti copy paste, parsing HTML maupun dengan tools web scraping.
- Contoh tools web scraping adalah Google Play Scraper, yang berfungsi untuk mengambil data ulasan user dari google play store

- Sedangkan Web API merupakan media komunikasi antara pengguna dengan website sehingga pengguna bisa mengirimkan permintaan ke web API untuk mendapatkan data secara cepat
- Dengan web API, data yang dikumpulkan lebih spesifik sesuai dengan link yang diberikan
- Contoh API adalah API twitter yang befungsi untuk mengambil data dari twitter

Mengumpulkan data

Dalam contoh yang kita pergunakan, data harga saham dapat diperoleh dari berbagai sumber misalnya dari Website Bursa Efek Indonesia dan Yahoo finance API



Date	Open	High	Low	Close*	Adj Close**	Volume
Oct 01, 2021	3,850.00	3,920.00	3,830.00	3,900.00	3,900.00	359,864,700
Sep 30, 2021	3,760.00	3,870.00	3,750.00	3,850.00	3,850.00	416,099,000
Sep 29, 2021	3,720.00	3,750.00	3,690.00	3,740.00	3,740.00	143,081,800
Sep 28, 2021	3,770.00	3,770.00	3,690.00	3,720.00	3,720.00	306,827,400
Sep 27, 2021	3,770.00	3,800.00	3,730.00	3,750.00	3,750.00	380,151,200
Sep 24, 2021	3,790.00	3,860.00	3,770.00	3,820.00	3,820.00	634,549,600

Contoh data saham yang di dapatkan dari Yahoo finance

- Demikian topik kita kali ini, mulai dati business understanding sampai data collection

- Untuk lebih memahami topik ini, saudara dapat mencari contoh permasalahan lain dan menentukan point-point penting yang telah kita bahas sebelumnya yaitu:
  - mengidentifikasi permasalahan yang dihadapi
  - menentukan tujuan dari project data science
  - mempersiapkan strategi untuk mencapai tujuan yang ditetapkan
  - menentukan ukuran keberhasilan
  - mengidentifikasi jenis data yang diperlukan
  - mengumpulkan data yang diperlukan

Terima kasih