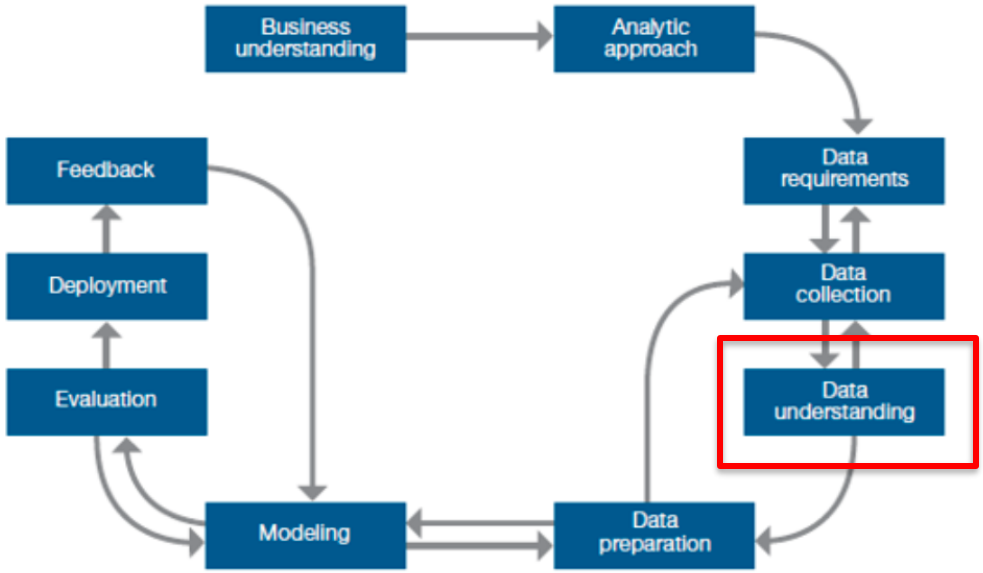
Data Science



Prof. Hindriyanto Dwi Purnomo, Ph.D

Data Understanding

- Setelah data kita kumpulkan, tahapan selanjutnya adalah memahami data yang sudah dikumpulkan.
- Pemahaman akan data yang dimiliki akan mempengaruhi proses selanjutnya yang perlu dilakukan pada data



- Data understanding membantu kita mendapatkan gambaran yang utuh atas data untuk memecahkan permasalahan bisnis yang diberikan.
- Dengan *data understanding* kita bisa:

1. memahami isi data
2. Mengevaluasi kualitas data
3. Mengevaluasi kesesuaian data dengan masalah
4. Mengetahui kekuatan dan keterbatasan penggunaan data
5. Menemukan persepsi awal terhadap data

- Secara umum, data memiliki susunan sebagai berikut:

1. Butir data/datum/field : butir data adalah satuan terkecil data. Butir data merupakan satu nilai untuk satu variabel tertentu.
2. Data : kumpulan butir data yang mendeskripsikan satu object tertentu
3. Himpunan data / dataset : kumpulan dari data
4. Metadata : data yang menjelaskan data lainnya

variabel Nama -> tipe data : nominal

deskripsi : nama mahasiswa

Mahasiswa				
NIM	Nama	Alamat	No Telp	Tanggal lahir
0001	Kurnia	Salatiga	12345678	01-01-2001
0002	Melody	Semarang		01-02-2001

- Langkah awal untuk memahami data yang sudah dikumpulkan adalah dengan mengidentifikasi variabel apa saja yang dimiliki oleh data serta tipe dan rentang nilai yang dimiliki oleh setiap variabel tersebut.

- Secara umum ada 4 tipe butir data yaitu:

1. Data nominal
2. Data ordinal
3. Data interval
4. Data rasio

1. Data nominal :

- Data nominal adalah data yang nilainya berupa kategorial dan berfungsi sebagai label
- Dalam data nominal tidak relasi diantara nilai nominalnya.
- Operasi matematika yang bisa dilakukan pada tipe data nominal adalah operasi kesamaan (equality) dan modus (nilai yang paling sering muncul)
- Contoh data nominal adalah data jenis furnitur. Data ini berisi kategorial furnitur misalnya meja, kursi dan almari.

2. Data Ordinal :

- Data ordinal adalah data yang nilainya berupa kategorial tetapi menunjukkan adanya urutan.
- Operasi matematika yang bisa dilakukan pada tipe data nominal adalah operasi kesamaan (equality), urutan (order), dan modus (nilai yang paling sering muncul) dan median (nilai tengah)
- Contoh data ordinal adalah data temperatur yang dinyatakan sebagai kategori : dingin, sedang dan panas. Dari data ini kita bisa mengetahui bahwa temperatur dingin lebih rendah daripada sedang dan temperatur sedang lebih rendah daripada panas.

3. Data interval

- Data interval adalah data numerik yang merepresentasikan suatu pengukuran
- perbedaan diantara dua nilai dalam data interval bisa diukur sehingga bisa mengetahui derajat perbedaan kedua nilai tersebut
- Operasi matematika yang bisa dilakukan pada tipe data interval adalah kesamaan (equality), urutan (order), modus, median, penjumlahan, pengurangan serta rata-rata
- Pada data interval umumnya tidak bisa diterapkan operasi perkalian dan pembagian
- Contoh data interval adalah data tahun. Misal ada 3 nilai tahun, 1990, 2010 dan 2020, maka kita bisa menentukan urutan tahunnya, mengetahui mediannya serta selisih/interval antar nilainya. Tetapi kita tidak bisa melakukan perkalian dan pembagian pada nilai-nilai diatas karena hasil perkalian dan pembagian terhadap nilai diatas tidak memiliki makna

4. Data Rasio

- Data Rasio adalah data numerik yang merepresentasikan suatu pengukuran
- Data rasio sering disebut juga data dengan nilai kontinu
- Operasi matematika yang bisa dilakukan pada tipe data rasio adalah kesamaan (equality), urutan (order), modus, median, penjumlahan, pengurangan, rata-rata, perkalian dan pembagian
- Contoh data rasio adalah panjang. Misal kita memiliki 2 data rasio yang menyatakan panjang dan lebar dari suatu bidang. Panjangnya 50 cm dan lebarnya 25 cm. Kedua nilai diatas dapat dilakukan operasi perkalian dan pembagian. Hasil perkalian diatas merepresentasikan besaran luas, sedangkan hasil pembagian menyatakan rasio antara panjang dan lebarnya.

Operasi matematika

Jenis Operasi	Nominal	Ordinal	Interval	Rasio
kesamaan	V	V	V	V
urutan		V	V	V
penjumlahan			V	V
pengurangan			V	V
perkalian				V
pembagian				V
median		V	V	V
modus	V	V	V	V
Rata-rata			V	V

- Ada dua pendekatan yang banyak dilakukan untuk memahami data. Yang pertama adalah pendekatan deskripsi statistik dan yang kedua adalah menggunakan teknik visualisasi.

Deskripsi Statistik

- Deskripsi statistik adalah cara mendeskripsikan object dengan memanfaatkan operasi statistik pada data.
- Deskrispi statistik bisa dilakukan pada data numerik
- Deskripsi statistik meliputi :

1. rata-rata /mean : rata-rata merupakan ukuran untuk merepresentasikan pusat dari suatu kumpulan data
2. Simpangan baku (standar deviasi) : merepresentasikan sebaran dari suatu kumpulan data. Dengan simpangan baku kita bisa mengetahui seberapa jauh jarak suatu nilai terhadap rata-rata dari kumpulan data tersebut
3. Jumlah data (count) : untuk menghitung jumlah data dalam suatu kumpulan data

Deskripsi Statistik

4. Akumulasi data (sum) : mberfungsi untuk menjumlahkan data yang terdapat dalam kumpulan data
5. Nilai terkecil (min) : menyatakan nilai terkecil yang terdapat dalam kumpulan data
6. Nilai terbesar (max) : menyatakan nilai terbesar yang terdapat dalam kumpulan data
7. Modus : merepresentasikan fenomena yang paling sering terjadi dengan cara menampilkan nilai data yang paling sering muncul.
8. Median : menyatakan nilai tengah dari kumpulan data setelah data tersebut diurutkan (dari nilai terkecil ke terbesar atau sebaliknya)

Deskripsi Statistik

9. Kuartil pertama (Q1) : merupakan nilai tengah antara nilai terkecil dan median dari kumpulan data. Kuartil pertama memisahkan 25% data terbawah dengan 75% data tertinggi
10. Kuartil kedua (Q2) : merupakan nilai yang membagi data menjadi 2. Kuartil kedua disebut juga median data
11. Kuartil ketiga (Q3): merupakan nilai tengah antara median dengan nilai tertinggi dalam kumpulan data. Kuartil ketiga memisahkan 25% data tertinggi dengan 75% data terbawah
12. Korelasi : merepresentasikan hubungan antar variabel dalam data

- Kita bisa menggunakan fungsi statistik pada Pandas untuk menampilkan deskripsi statistik pada data

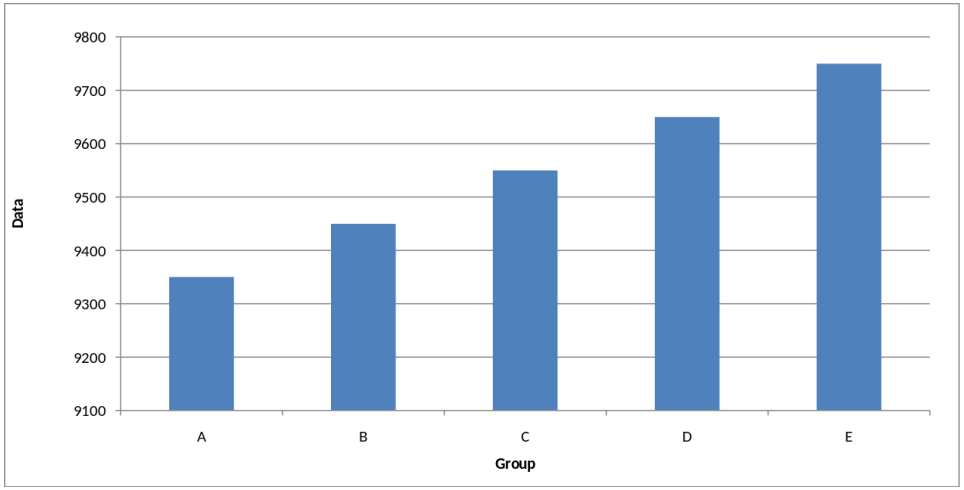
Visualisasi

- Data understanding juga dapat dilakukan dengan cara memvisualiasasi kumpulan data yang dimiliki
- Visualisasi membantu dalam mengidentifikasi karakteristik penting dari data
- Visualisasi dapat dilakukan untuk :

1. Visualisasi variabel
2. Visualisasi statistik

Visualisasi variabel antara lain:

- Bar chart : chart yang menampilkan data dalam bentuk batang. Bar chart dipergunakan untuk menampikan distribusi nilai maupun membandingkan nilai metrik dari berbagai kategori data

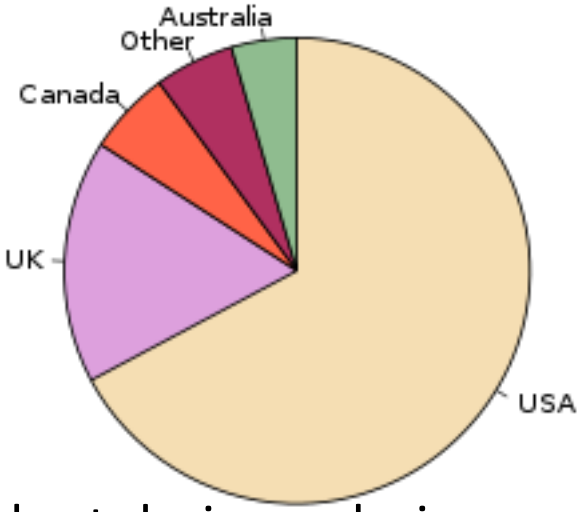


Contoh Bar chart untuk menampilkan jumlah data dari 5 group data

https://en.m.wikipedia.org/wiki/File:Bar_graph.svg

Visualisasi variabel antara lain:

- Pie chart : chart berbentuk lingkaran yang dipergunakan untuk menampilkan perbandingan proporsi antar kategori dalam kumpulan data

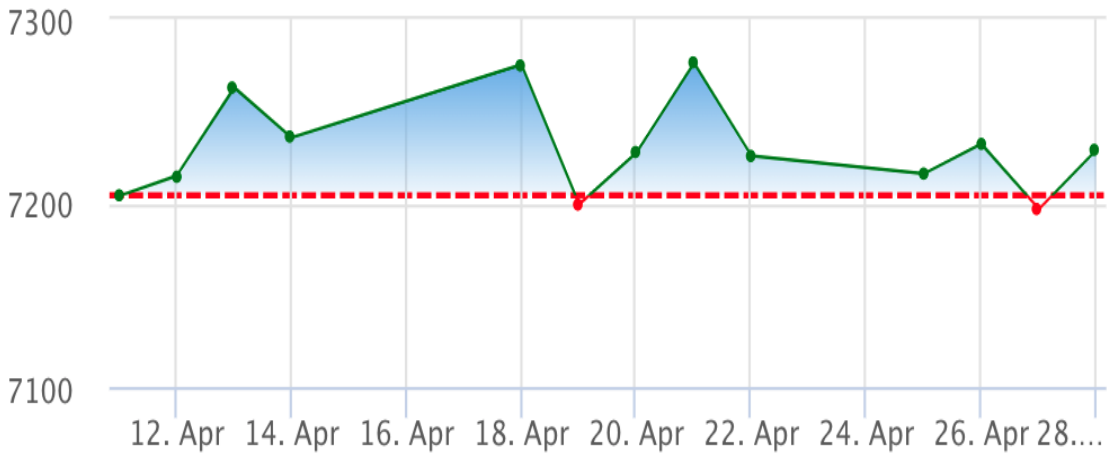


https://en.wikipedia.org/wiki/Pie_chart

- Contoh pie chart dari populasi negara dengan penutur asli bahasa Inggris (English Native Speakers)
- Kita bisa melihat proporsi populasi dari tiap-tiap negara dengan jelas

Visualisasi variabel antara lain:

- Line chart : chart berbentuk garis untuk menampilkan perubahan data seiring dengan waktu

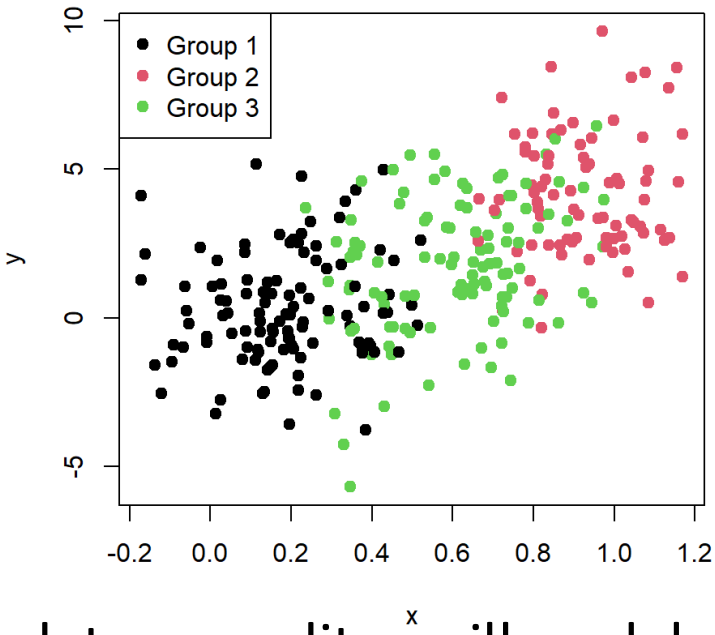


https://www.idx.co.id/

- Contoh line chart Index Harga Saham Gabungan (IHSG)
- Kita bisa melihat nilai IHSG dari hari ke hari selama periode tertentu

Visualisasi variabel antara lain:

- Scatter plot : graph untuk menampilkan data yang terdiri dari 2 variabel numerik, ke dalam bidang 2 dimensi (vertikal dan horisontal). Scatter plot dipergunakan untuk menunjukkan relasi antara kedua variabel tersebut

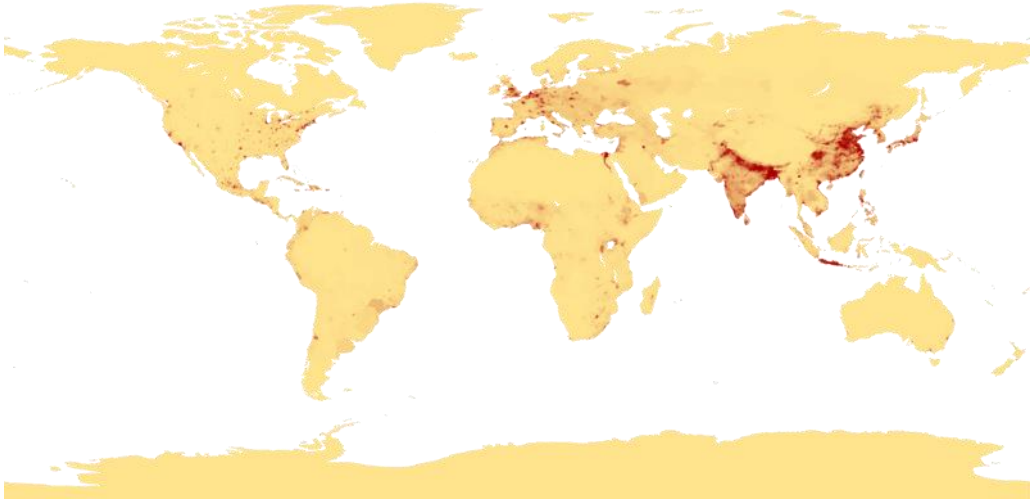


Contoh 3 group data yang ditampilkan dalam bentuk scatter plot

https://r-charts.com/correlation/scatter-plot-group/

Visualisasi variabel antara lain:

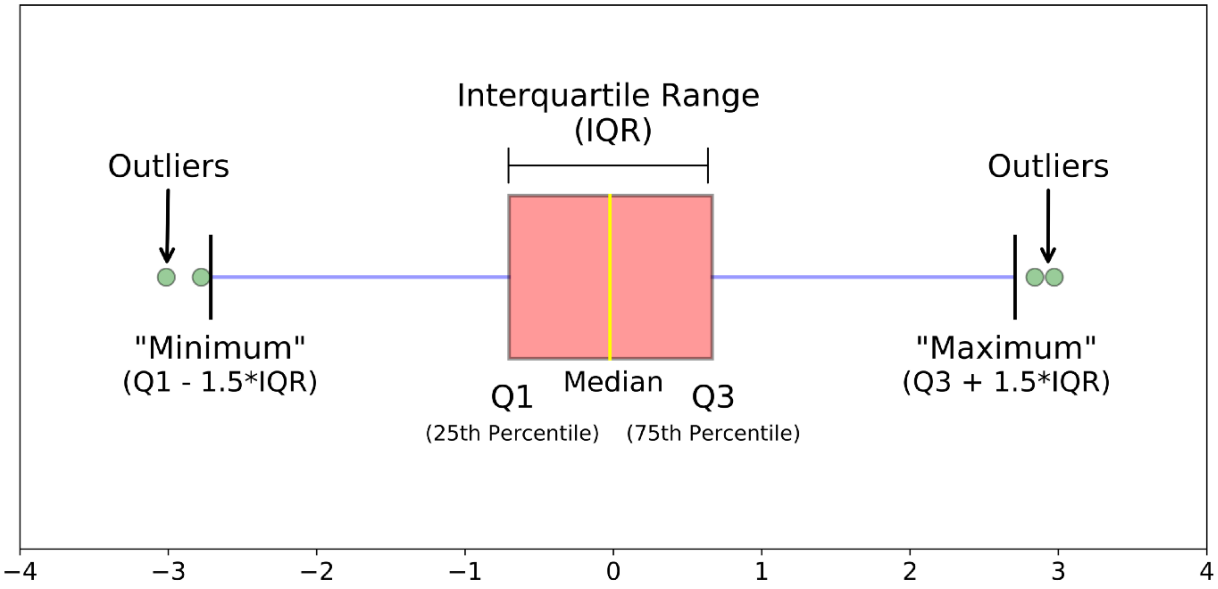
- Heatmap : representasi data dalam bentuk diagram dimana nilai data direpresentasikan sebagai warna. Heatmap memberikan rangkuman informasi dalam bentuk visual, sehingga memudahkan dalam mengidentifikasi aspek penting dari data
- Contoh heatmap untuk menunjukkan kepadata populasi penduduk. Semakin gelap warnanya, semakin tinggi kepadatan populasinya.



https://en.wikipedia.org/wiki/File:Population_density.png

Visualisasi statistik antara lain

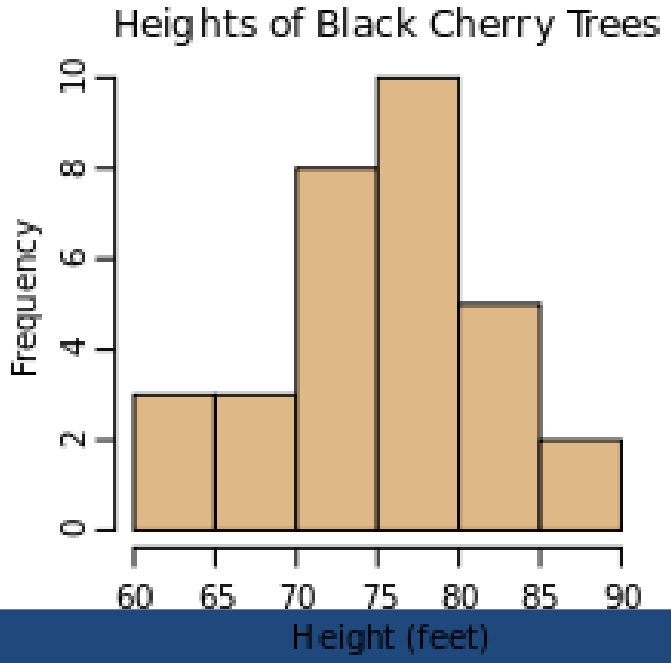
- Box plot : merupakan graph yang menampilkan distribusi data berdasarkan nilai minimum, maksimum, kuartil 1, kuartil 2, dan kuartil 3. boxplot juga bisa menunjukkan adanya outlier dalam data



https://towardsdatascience.com/understanding-boxplots-5e2df7bcbd51

Visualisasi statistik antara lain

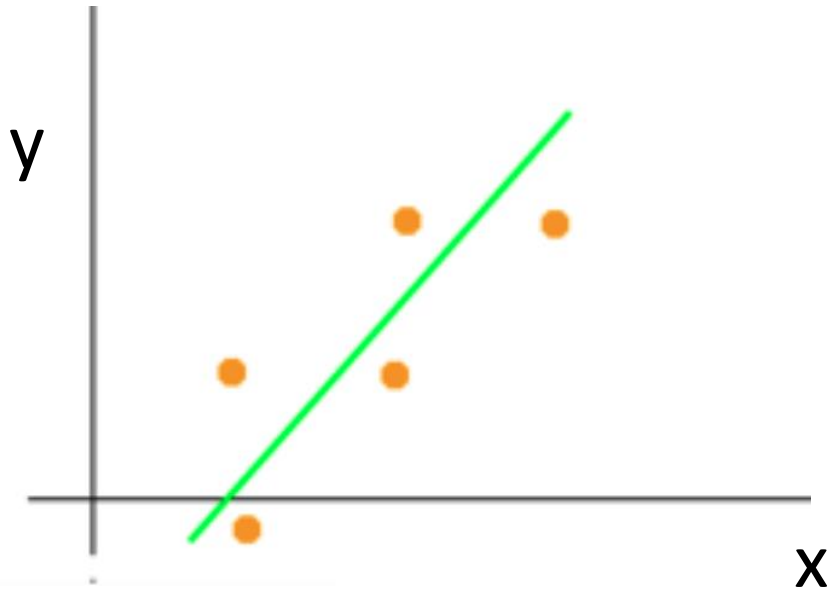
- Histogram : merupakan grafik yang menampilkan data yang dikelompokkan berdasarkan rentang nilai tertentu dalam bentuk batang.



https://id.wikipedia.org/wiki/Histogram

Visualisasi statistik antara lain

- Korelasi : merupakan grafik untuk mengukur hubungan antara dua variabel
- Contoh grafik korelasi antara x dan y



https://commons.wikimedia.org/wiki/File:Correlation_coefficient.png

Terima kasih