Data Science

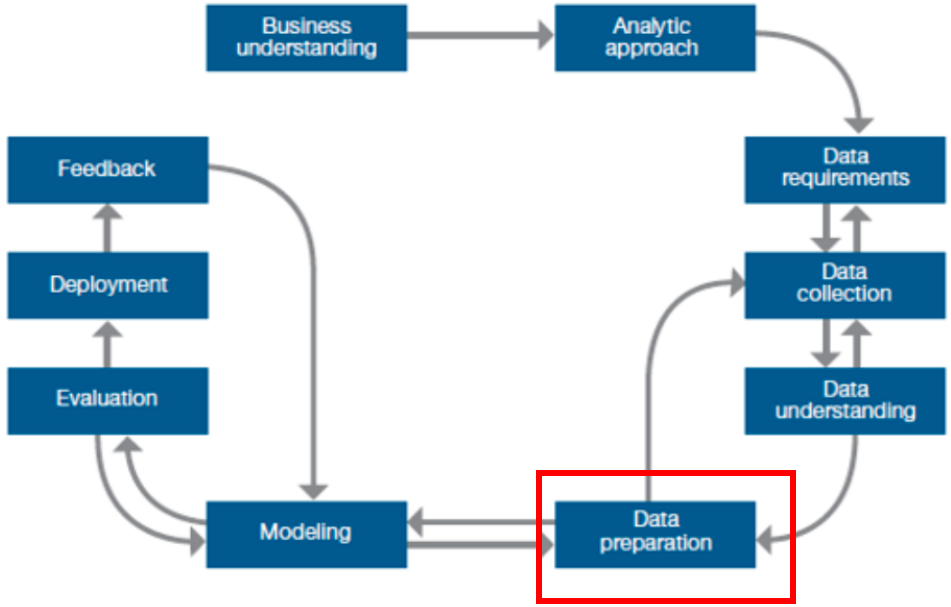


Prof. Hindriyanto Dwi Purnomo, Ph.D

Data Preparation

- Data preparation merupakan tahapan untuk mengolah data mentah menjadi dataset yang siap untuk di modelkan atau di analisa
- Mengapa Data preparation diperlukan?

1. Data preparation bertujuan untuk meningkatkan kualitas data yang akan dipergunakan untuk Analisa. Analisa yang baik hanya bisa didapatkan ketika data yang dipergunakan juga baik.
2. Data preparation mempermudah dan mempercepat proses modelling data



Data preparation meliputi:

1. Data cleaning
2. Data integration
3. Data transformation
4. Data reduction
5. Data discretization

1. Data cleaning

- Data cleaning merupakan proses untuk memperbaiki atau menghapus data yang salah, data yang memiliki format yang tidak sesuai, data yang terduplikasi, maupun data yang kurang lengkap.
- Data cleaning dapat dilakukan dengan :

a. Menghapus data yang terduplikasi. Ketika menggabungkan data dari berbagai sumber, ada kemungkinan terjadi duplikasi data, sehingga diperlukan proses untuk menghapus duplikat dari data tersebut

b. Menghapus data yang tidak relevan. Ketika menggabungkan data dari berbagai sumber, ada kemungkinan terdapat data yang tidak relevan dengan permasalahan yang dihadapi sehingga data tersebut perlu di hapus. Data yang tidak relevan bisa juga berupa outlier

c. Menangani missing data. Data yang tidak lengkap akan sangat mempengaruhi kinerja algorima yang dipergunakan, sehingga data diperlukan cara untuk menangani data yang tidak lengkap ini. Missing data bisa ditangani dengan:

   - menghapus data yang tidak lengkap
   - mengisi data yang tidak lengkap dengan cara tertentu, misalnya dengan nilai rata-rata, modus maupun suatu nilai konstan

1. Data cleaning

d. Memperbaiki struktur dan format data. Data yang dikumpulkan dari berbagai sumber bisa saja memiliki format yang berbeda-beda. Oleh karena itu, format data tersebut perlu di seragamkan sehingga memudahkan dalam proses selanjutnya

2. Data Integration

- Data integration adalah proses mengkombinasikan data yang berasal dari berbagai sumber ke dalam satu kumpulan data / dataset.
- Sumber data bisa berasal dari internal organisasi, data publik, web scraping maupun web API
- Data dari berbagai sumber yang diintegrasikan tersebut dapat menghasilkan informasi berharga yang berguna dalam memecahkan permasalahan bisnis

3. Data Transformation

- Data transformation adalah proses untuk merubah struktur, format maupun nilai data supaya sesuai dengan kebutuhan analisa data
- Trasnformasi data membantu meningkatkan kualitas data, sehingga dengan struktur dan format data yang baik akan menghasilkan Analisa yang lebih baik
- Yang termasuk dalam transformasi data antara lain:
  - Normalisasi data (Data Normalization)
  - Agregasi data (Data aggregation)
  - Generalisasi data (Data Generalization)
  - Data Smoothing

3. Data Transformation

- **Normalisasi data** adalah proses untuk merubah nilai data ke dalam rentang nilai tertentu.
- Mekanisme normalisasi yang banyak dipergunakan antara lain:

- Z normalization (standardization) : proses normalisasi dengan cara membawa rata-rata data ke nilai 0 (nol) dan standar deviasinya 1.

$$Xbaru = (Xlama - Xrata\text{-}rata) / Stdev$$

- Min-Max Normalization : proses normalisasi dengan merubah skala nilai data kedalam rentang nilai [0, 1] (nol sampai satu)

$$Xbaru = (Xlama - Xmin) / (Xmax - Xmin)$$

- simple scaling: proses normalisasi dengan cara membagi nilai tiap variabel dengan nilai maksimal pada variabel tersebut

$$Xbaru = Xlama/Xmax$$

3. Data Transformation

- **Agregasi data** adalah proses dimana data mentah dikumpulkan dan disajikan dalam bentuk ringkasan untuk keperluan Analisa
- Proses agregasi diterapkan pada suatu kelompok data sehingga organisasi bisa lebih cepat menangkap informasi dalam kelompok data tersebut
- Proses agregasi akan memerlukan Analisa statistic terhadap kelompok data yang di aggregate-kan, misalnya mencari rata-rata, nilai minimum, nilai maksimum maupun jumlah data.
- Ada 2 jenis agregasi data yaitu : time aggregation dan spatial aggregation

1. Time aggregation adalah agregasi semua titik data dari **satu sumber data** pada suatu periode waktu tertentu

2. spatial aggregation adalah agregasi semua titik data dari **sekumpulan sumber data** dalam periode waktu tertentu

- Hasil dari agregasi data adalah satu titik data (data point) yang mencerminkan sifat statistik dari kumpulan data yang di agregasikan tersebut

3. Data Transformation

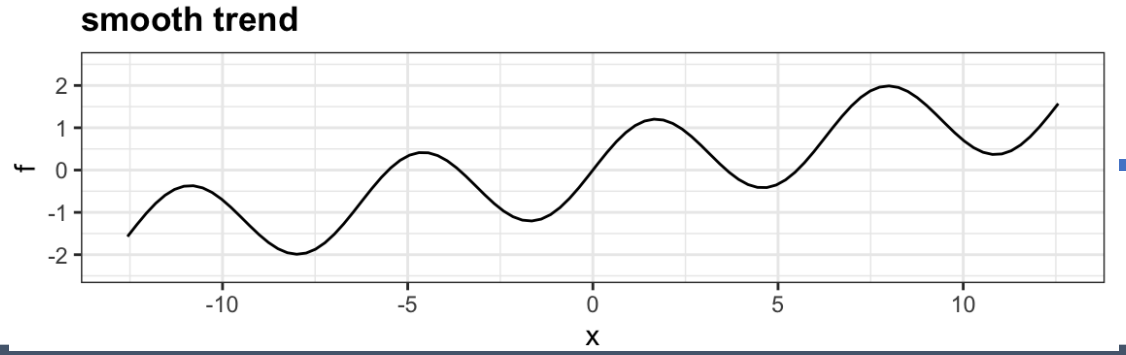
- **Generalisasi data** adalah proses untuk membuat kategori data yang lebih luas dalam kumpulan data yang dimiliki
- Dengan generalisasi data, nilai data digantikan dengan nilai lain yang lebih general. Hal ini membuat nilai data menjadi lebih tidak spesifik, oleh karena itu, Teknik ini juga sering disebut dengan blurring
- Sebagai contoh : misal kita memiliki variabel data berupa tanggal lahir. Alih-alih menyebutkan tanggalnya secara detail untuk tiap data, dengan generalisasi, data yang dimuat hanya tahun lahirnya saja.

3. Data Transformation

- **Data smoothing** adalah proses untuk mendeteksi trend yang terdapat dalam data yang memiliki noise serta trendnya belum diketahui
- Data smoothing sering disebut juga dengan istilah curve fitting
- Contoh



Data mentah, trendnya tidak terlalu terlihat karena adanya noise dalam data



Data yang sudah di smoothing, sehingga trendnya terlihat lebih jelas

4. Data Reduction

- **Data reduction** adalah proses untuk mengurangi beberapa aspek dari data tanpa mengurangi integritas data
- Data reduction dilakukan karena data yang dikumpulkan data berbagai sumber menghasilkan volume data yang sangat besar atau memiliki dimensi data yang sangat banyak, sehingga menyulitkan dalam proses analisa
- Data reduction dapat dilakukan dengan :

1. pengurangan dimensi data (dimensionality reduction)

✓ Pengurangan dimensi data berarti mengurangi jumlah attribute data yang akan dipergunakan untuk analisa

✓ Secara tidak langsung, mengurangi dimensi data akan berimbas pada pengurangan volume data

4. Data Reduction

✓ Pengurangan dimensi data dapat dilakukan antara lain dengan:

a. Seleksi atribut:

- pendekatan ini dilakukan dengan hanya menyimpan atribut yang penting dan menghapus atribut yang terduplikasi.

- Pada metode ini tidak diperlukan proses transformasi pada attributnya.

- Seleksi atribute dapat dilakukan dengan :

a) Backward elimination

b) Forward selection

b. transformasi atribut :

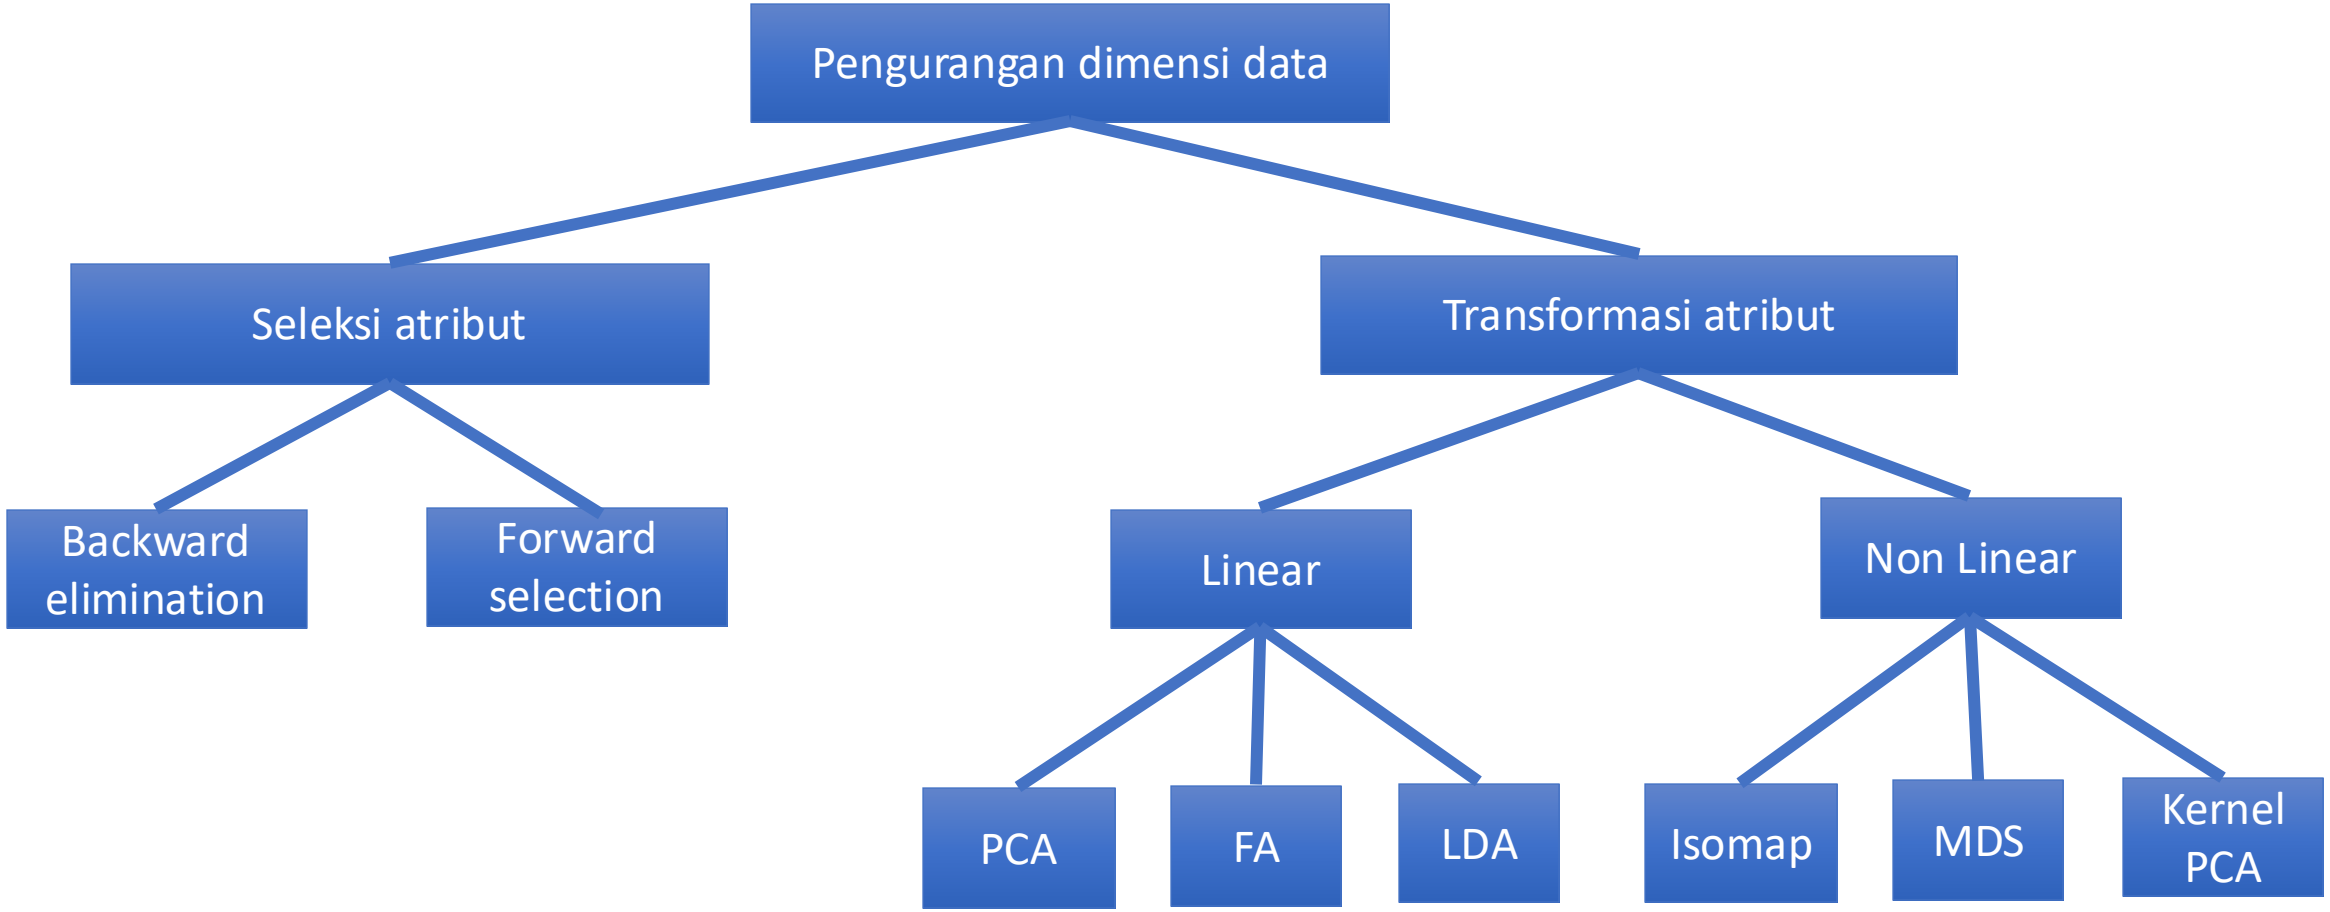
- pendekatan ini dilakukan dengan melakukan transformasi pada atribut lama untuk mendapatkan atribut baru yang merepresentasikan atribut yang lama

- metode transformasi atribute dibedakan menjadi metode linear dan metode non linear

4. Data Reduction

- Contoh metode linear adalah:
  a) Principle componen analysis (PCA)
  b) Factor Analysis (FA)
  c) Linear Discriminant Analysis (LDA)

- contoh metode non linear adalah
  a) Isometric mapping (Isomap)
  b) Multidimensional scaling (MDS)
  c) Kernel PCA


Pengurangan dimensi data
Seleksi atribut
Transformasi atribut
Backward elimination
Forward selection
Linear
Non Linear
PCA
FA
LDA
Isomap
MDS
Kernel PCA

4. Data Reduction

2. Pengurangan volume data (Numerosity reduction)

- Numerosity reduction adalah teknik reduksi data dengan cara menggantikan data asli dengan representasi data yang lebih kecil
- Numerosity reduction dapat dibagi menjadi

a. metode parametrik :

- pada metode ini, data direpresentasikan menggunakan suatu model, sehingga yang disimpan bukan data asli, tetapi model dari datanya

- contoh metode parametrik adalah :

a) Regresi : dengan cara ini, data dimodelkan sebagai fungsi regresi, seperti fungsi regresi linear dan nonlinear

b) log-linear : model log linear dapat memperkirakan probabilitas titik data dalam ruang multidimensi berdasarkan dimensi yang lebih kecil. Sehingga Log linear memungkinkan kita menyusun data dengan dimensi yang besar dari dimensi yang lebih rendah.

4. Data Reduction

b. metode non parametrik

- contoh metode numerosity reduction non parametrik adalah :

a) histogram : histogram merepresentasikan data berdasarkan frekuensinya. Histogram dapat merepresentasikan distribusi data.

b) clustering : dengan clustering, data dibagi ke dalam kelompok yang berbeda-beda. Dalam kontek reduksi data, representasi kelompok data digunakan untuk menggantikan data aslinya

c) sampling : metode ini memungkikan data yang berukuran besar diwakili oleh sample data yang dipilih dengan sampling.

4. Data Discretization

- Data discretization adalah proses merubah atribut data kontinu menjadi atribut data diskrit
- Data discretization dapat mengurang jumlah nilai dari atribut kontinu dengan membagi nilai tersebut ke dalam range interval tertentu
- Metode data discretization dapat dibedakan menjadi supervised discretization dan unsupervised discretization.
- Metode supervised discretization memanfaatkan nilai class untuk menentukan batas-batas diskretnya sementara metode unsupervised discretization tidak memiliki kelas untuk menentukan batas-batas nilai diskritnya
- Contoh metode supervised discretization adalah diskretisasi dengan teknik regresi linear dan decision tree
- Contoh metode unsupervised discretization adalah diskretisasi dengan membagi data berdasarkan rentang interval yang sama serta discretization dengan teknik clustering

Terima kasih