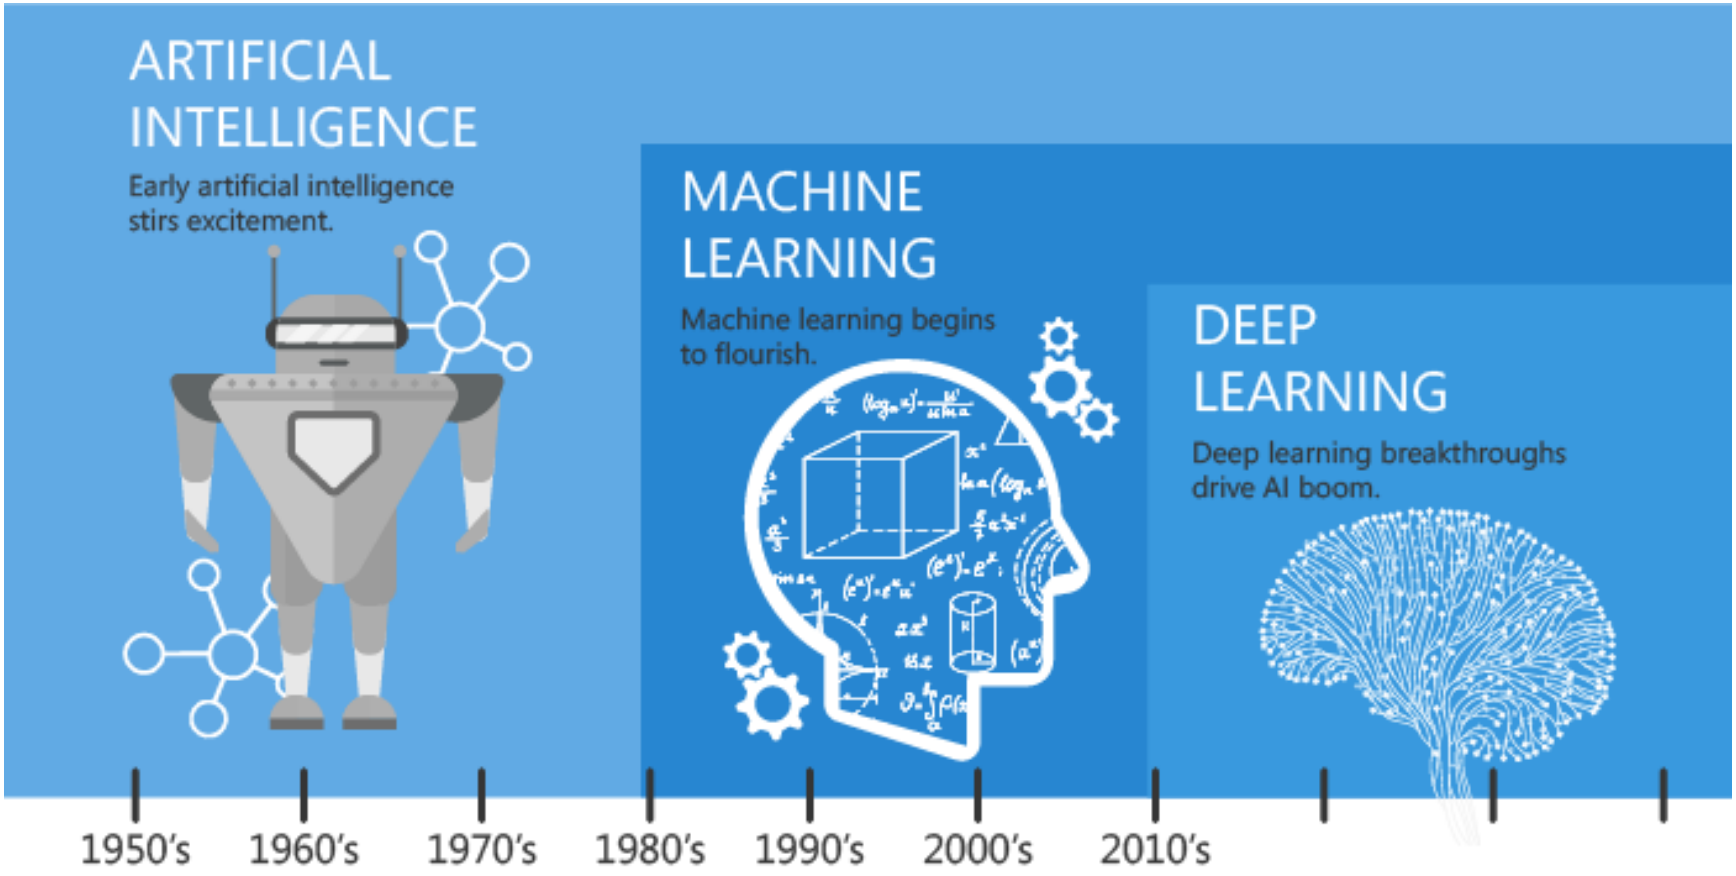
Metodologi Data Science

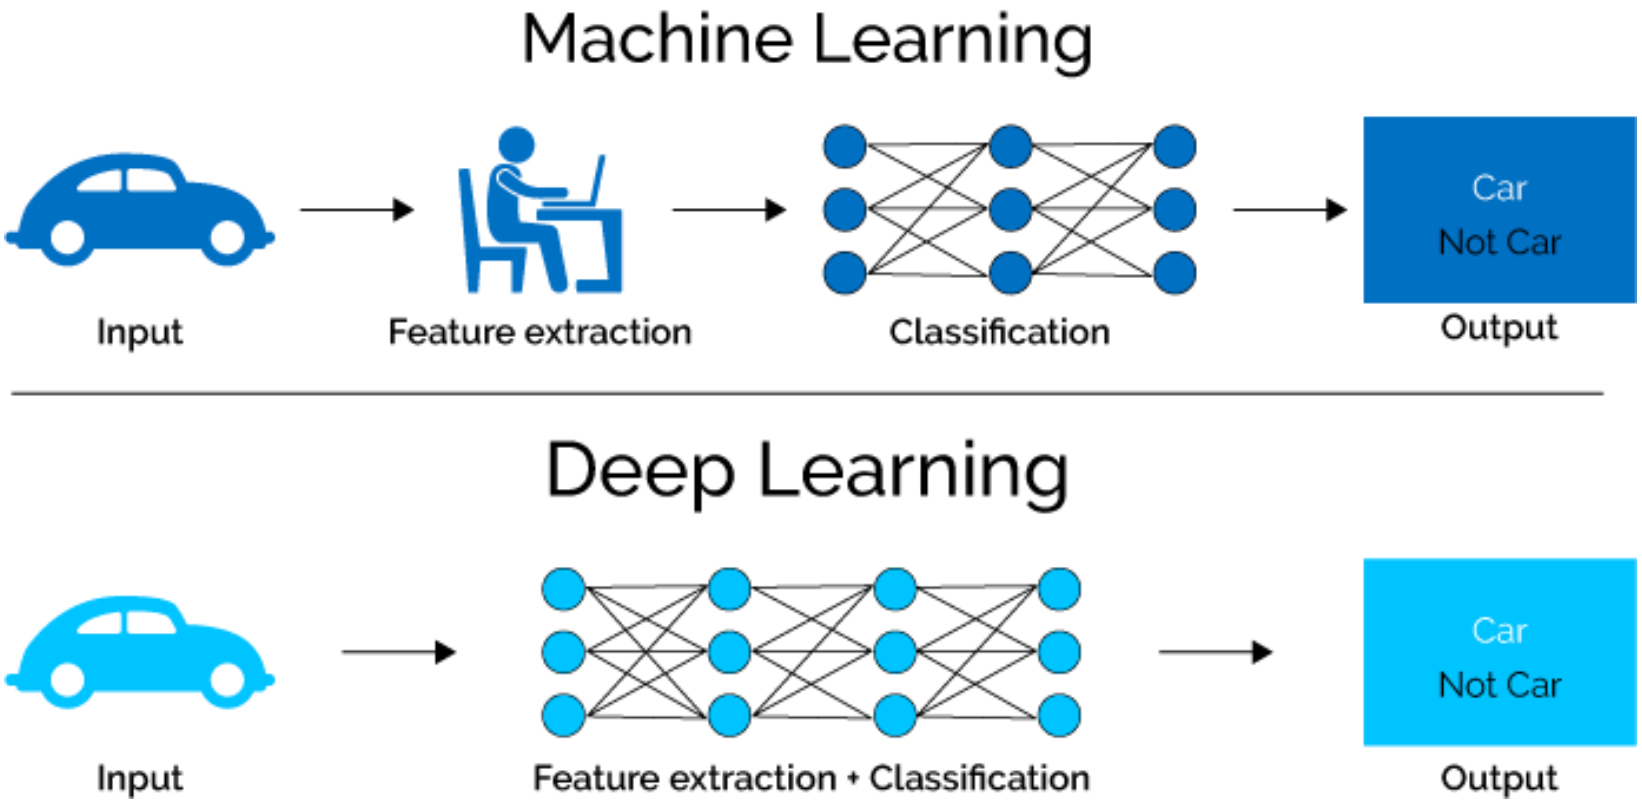


Prof. Hindriyanto Dwi Purnomo, Ph.D

AI dan Deep Learning



Machine Learning vs Deep Learning



Terminologi

Beberapa terminologi penting dalam Machine Learning :

- **Instance** : single, contoh independen dari sebuah konsep
- **Attributes** : aspek pengukur dari sebuah instance. Disebut juga feature
- **Konsep** : sesuatu yang ingin dipelajari

Instance

Outlook	Temperature	Humidity	Windy	Play
sunny	hot	high	FALSE	no
sunny	hot	high	TRUE	no
overcast	hot	high	FALSE	yes
rainy	mild	high	FALSE	yes
rainy	cool	normal	FALSE	yes
rainy	cool	normal	TRUE	no
⋮	⋮	⋮	⋮	⋮

INSTANCE$_1$

INSTANCE$_2$

Attributte

Outlook	Temperature	Humidity	Windy	Play
sunny	hot	high	FALSE	no
sunny	hot	high	TRUE	no
overcast	hot	high	FALSE	yes
rainy	mild	high	FALSE	yes
rainy	cool	normal	FALSE	yes
rainy	cool	normal	TRUE	no
⋮	⋮	⋮	⋮	⋮

ATTRIBUTE_1

ATTRIBUTE_2

Attributte

- Setiap instance di deskripsikan dengan serangkaian attribute
- Tipe-tipe attribute:
    1. nominal
    2. ordinal
    3. interval
    4. rasio

Apakah konsep itu?

Gaya pembelajaran konsep :

1. Association learning : mendeteksi keterkaitan antar feature
2. Clustering : pengelompokan instance yang sama kedalam cluster/kelompok
3. Classification learning : memprediksi kedalam kelas-kelas diskrit
4. Regression : memprediksi kuantitas numeris

Supervised vs unsupervised learning

Labeled dataset

Customer Id	Age	Edu	Years Employed	Income	Card Debt	Other Debt	Address	DebtIncomeRatio	Defaulted
1	41	2	6	19	0.124	1.073	NBA001	6.3	0
2	47	1	26	100	4.582	8.218	NBA021	12.8	0
3	33	2	10	57	6.111	5.802	NBA013	20.9	1
4	29	2	4	19	0.681	0.516	NBA009	6.3	0
5	47	1	31	253	9.308	8.908	NBA008	7.2	0
6	40	1	23	81	0.998	7.831	NBA016	10.9	1
7	38	2	4	56	0.442	0.454	NBA013	1.6	0
8	42	3	0	64	0.279	3.945	NBA009	6.6	0
9	26	1	5	18	0.575	2.215	NBA006	15.5	1
10	47	3	23	115	0.653	3.947	NBA011	4	0

Modeling



Decision Tree

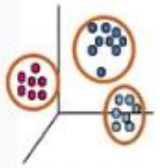
Prediction

Unlabeled dataset

Customer Id	Age	Edu	Years Employed	Income	Card Debt	Other Debt	Address	DebtIncomeRatio	Defaulted
1	41	2	6	19	0.124	1.073	NBA001	6.3	0
2	47	1	26	100	4.582	8.218	NBA021	12.8	0
3	33	2	10	57	6.111	5.802	NBA013	20.9	1
4	29	2	4	19	0.681	0.516	NBA009	6.3	0
5	47	1	31	253	9.308	8.908	NBA008	7.2	0
6	40	1	23	81	0.998	7.831	NBA016	10.9	1
7	38	2	4	56	0.442	0.454	NBA013	1.6	0
8	42	3	0	64	0.279	3.945	NBA009	6.6	0
9	26	1	5	18	0.575	2.215	NBA006	15.5	1

Modeling

Segmentation



K-Means

CLUSTERING

Outline

- Dasar-dasar clustering
- K-means clustering
- DBSCAN
- Hierachycal clustering

Dasar-dasar clustering

- Deskripsi : menemukan cluster/kel dalam data set
- Cluster : kumpulan object yang sama satu sama lain dalam satu cluster, dan berbeda dengan cluster yang lainnya
- Unsupervised learning
- Tidak ada definisi kelas secara eksplisit maupun implisit

Dasar-dasar clustering

- Clustering vs classification

Labeled dataset

Customer Id	Age	Edu	Years Employed	Income	Card Debt	Other Debt	Address	DebtIncomeRatio	Defaulted
1	41	2	6	19	0.124	1.073	NBA001	6.3	0
2	47	1	26	100	4.582	8.218	NBA021	12.8	0
3	33	2	10	57	6.111	5.802	NBA013	20.9	1
4	29	2	4	19	0.681	0.516	NBA009	6.3	0
5	47	1	31	253	9.308	8.908	NBA008	7.2	0
6	40	1	23	81	0.998	7.831	NBA016	10.9	1
7	38	2	4	56	0.442	0.454	NBA013	1.6	0
8	42	3	0	64	0.279	3.945	NBA009	6.6	0
9	26	1	5	18	0.575	2.215	NBA006	15.5	1
10	47	3	23	115	0.653	3.947	NBA011	4	0

Modeling



Decision Tree

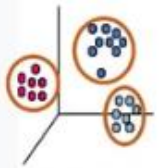
Prediction

Unlabeled dataset

Customer Id	Age	Edu	Years Employed	Income	Card Debt	Other Debt	Address	DebtIncomeRatio	Defaulted
1	41	2	6	19	0.124	1.073	NBA001	6.3	0
2	47	1	26	100	4.582	8.218	NBA021	12.8	0
3	33	2	10	57	6.111	5.802	NBA013	20.9	1
4	29	2	4	19	0.681	0.516	NBA009	6.3	0
5	47	1	31	253	9.308	8.908	NBA008	7.2	0
6	40	1	23	81	0.998	7.831	NBA016	10.9	1
7	38	2	4	56	0.442	0.454	NBA013	1.6	0
8	42	3	0	64	0.279	3.945	NBA009	6.6	0
9	26	1	5	18	0.575	2.215	NBA006	15.5	1

Modeling

Segmentation



K-Means

Dasar-dasar clustering

Aplikasi clustering

- Retails marketing : identifikasi pola pembelian konsumen, system rekomendasi pembelian
- Perbankan : fraud detection, identifikasi cluster customer (loyalitas dll)
- Asuransi : insurance risk of customer
- Lain-lain : pattern recognition, data analisis spasial, diagnose medis, dll

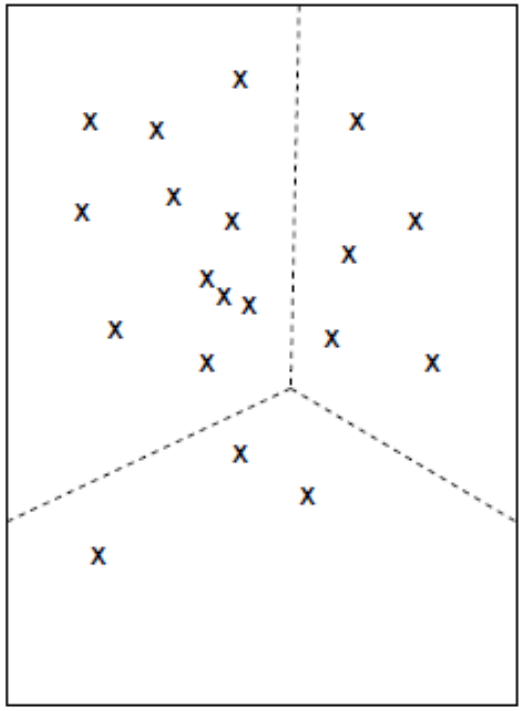
Dasar-dasar clustering

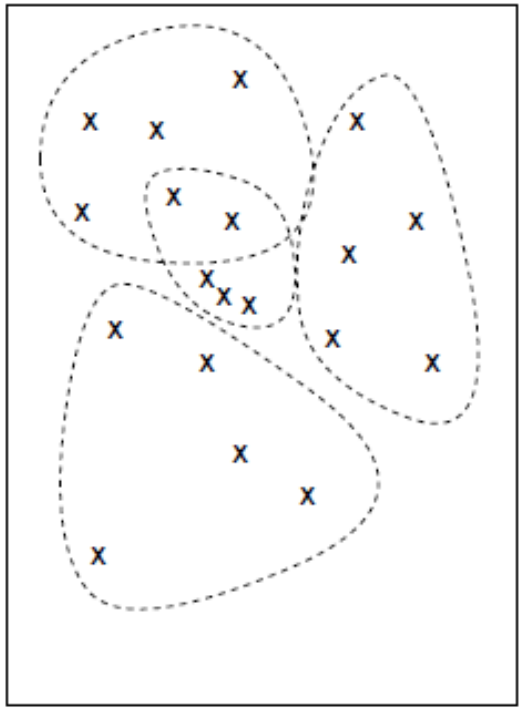
Macam-macam pengelompokan (clustering)

- Exclusive vs overlapping clustering
- Deterministic vs probabilistic clustering
- Hierarchical vs partitioning clustering
- Incremental vs batch clustering

Dasar-dasar clustering

- Exclusive vs overlapping clustering





Dasar-dasar clustering

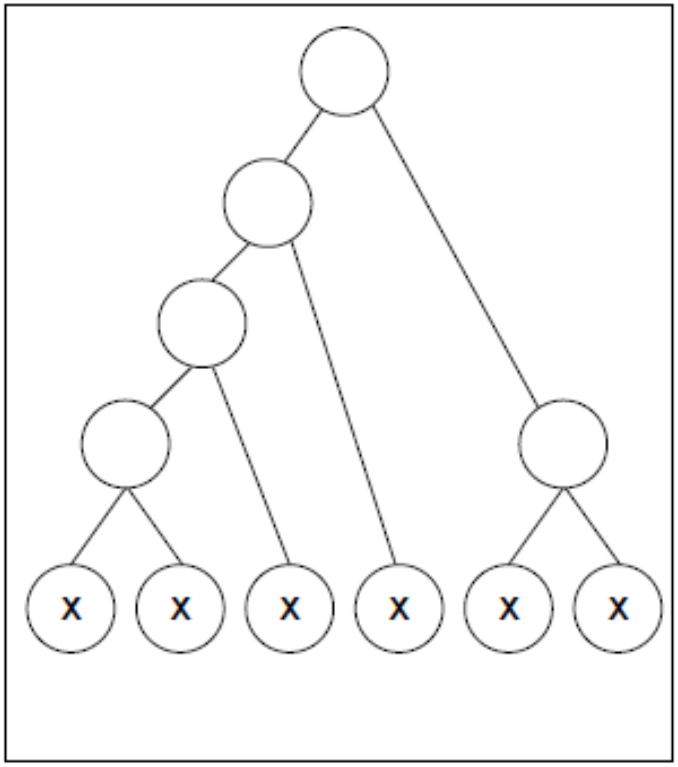
- Deterministic vs probabilistic clustering

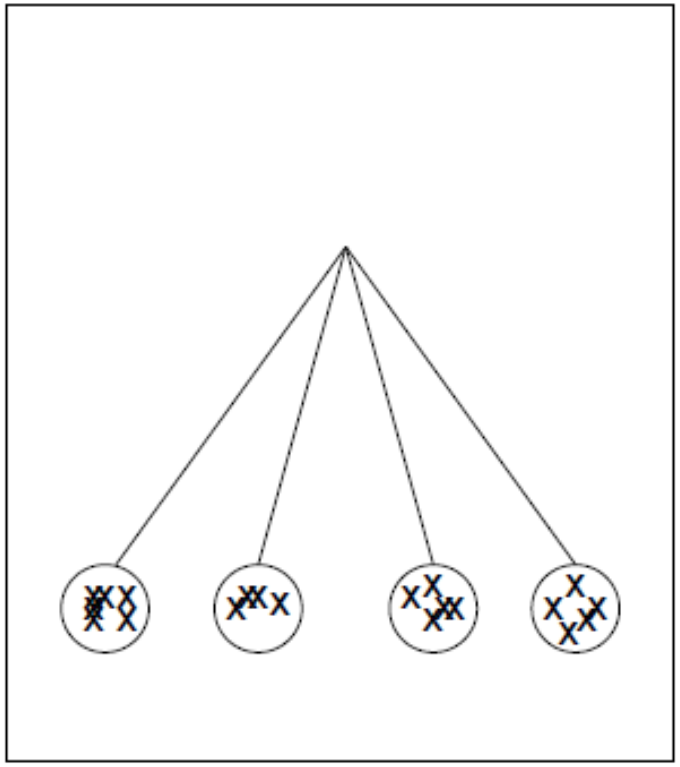
Instance	*Cluster*
1	2
2	3
3	2
4	1
5	2
6	2
7	4
⋮	⋮

Instance	*Cluster*			
	1	2	3	4
1	0.01	0.87	0.12	0.00
2	0.05	0.25	0.67	0.03
3	0.00	0.98	0.02	0.00
4	0.45	0.39	0.08	0.08
5	0.01	0.99	0.00	0.00
6	0.07	0.75	0.08	0.10
7	0.23	0.10	0.20	0.47
⋮	⋮			

Dasar-dasar clustering

- Hierarchical vs partitioning clustering





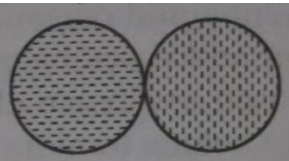
Dasar-dasar clustering

Tipe-tipe kelompok (cluster)

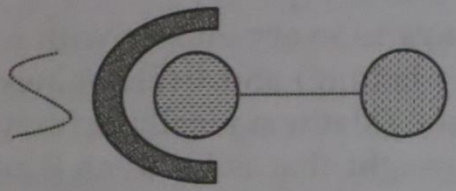
- *Well-separated cluster* : setiap objek lebih dekat dengan objek yang lainnya dalam kelompoknya
- *Center-based cluster*: setiap objek lebih dekat dengan pusat objeknya dari pada dengan pusat objek yang lain
- *Contiguity-based cluster*: setiap objek lebih dekat dengan setidaknya 1 objek dalam kelompoknya daripada dengan objek di kelompok lainnya
- *Density-based cluster* : kelompok merupakan daerah dengan densitas tinggi. Antar kelompok dipisahkan dengan daerah yang densitasnya rendah
- *Conceptual cluster*: objek-objek dalam satu kelompok memiliki sifat/karakter yang sama/mirip



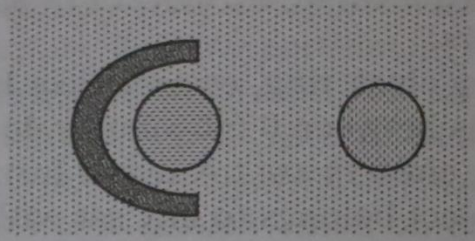
(a) Well-separated clusters. Each point is closer to all of the points in its cluster than to any point in another cluster.



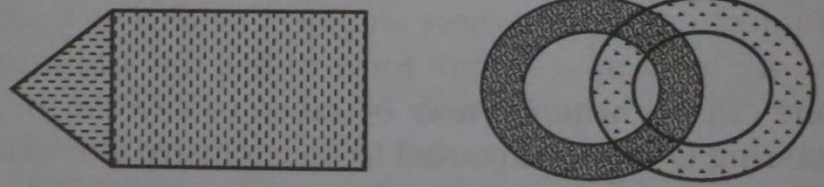
(b) Center-based clusters. Each point is closer to the center of its cluster than to the center of any other cluster.



(c) Contiguity-based clusters. Each point is closer to at least one point in its cluster than to any point in another cluster.



(d) Density-based clusters. Clusters are regions of high density separated by regions of low density.

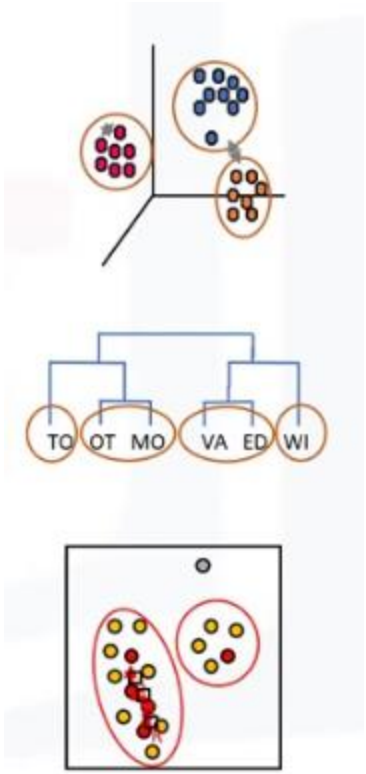


(e) Conceptual clusters. Points in a cluster share some general property that derives from the entire set of points. (Points in the intersection of the circles belong to both.)

Contoh Metode Clustering

- Partisi : Membagi data ke dalam kelompoh yang tidak saling tumpang tindih. Contohnya k-means, Density based spatial clustering algorithm with Noise (DBSCAN)

- Hierarki : pengelompokan bertingkat/hierarki. Data tunggal bisa dianggap menjadi sebuah kelompok. Dua atau lebih kelompok bisa menjadi menjadi kelompok yang lebih besar. Contohnya Agglomerative Hierarchical clustering (AHC)

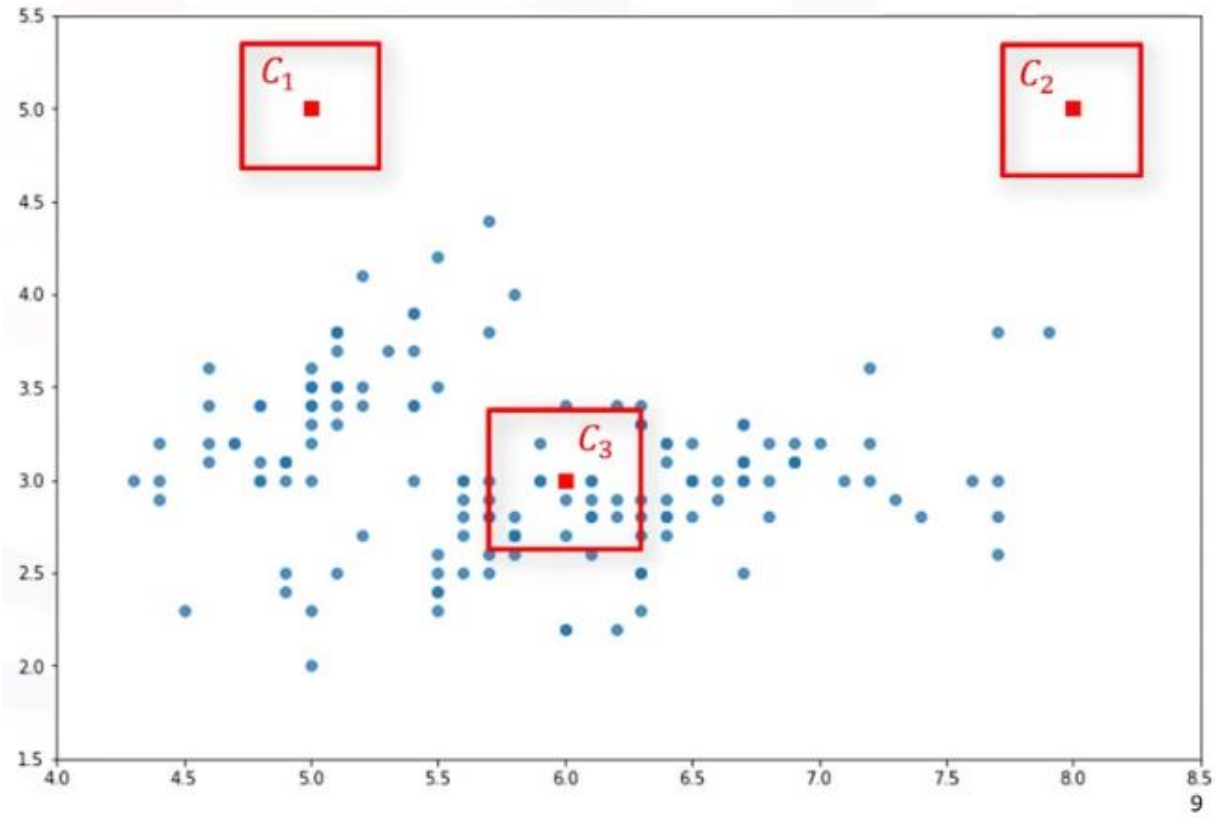


K-means clustering

1. Pilih *k* titik secara acak sebagai awal dari pusat kelompok
2. Kelompokkan tiap item ke titik pusat terdekatnya
3. Hitung ulang pusat kelompok yang baru bedasarkan rata-rata item yang masuk di kelompok tersebut
4. Ulangi tahap 2

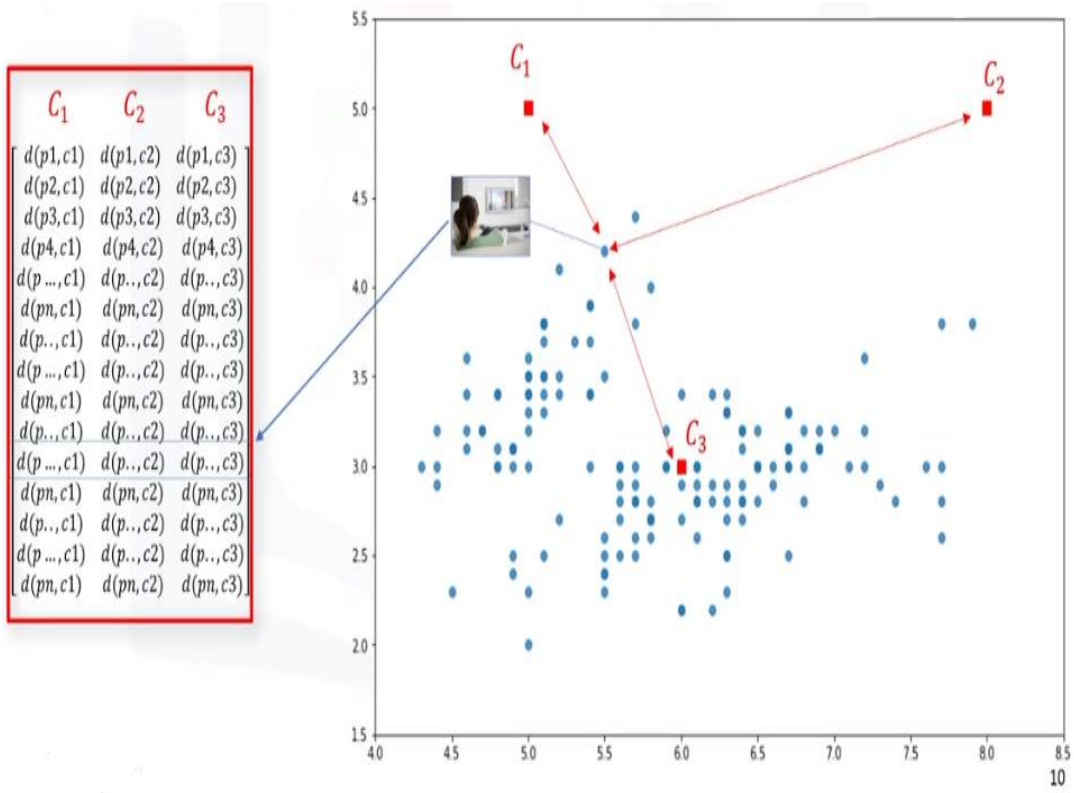
K-means clustering

1. Pilih *k* titik secara acak sebagai awal dari pusat kelompok



K-means clustering

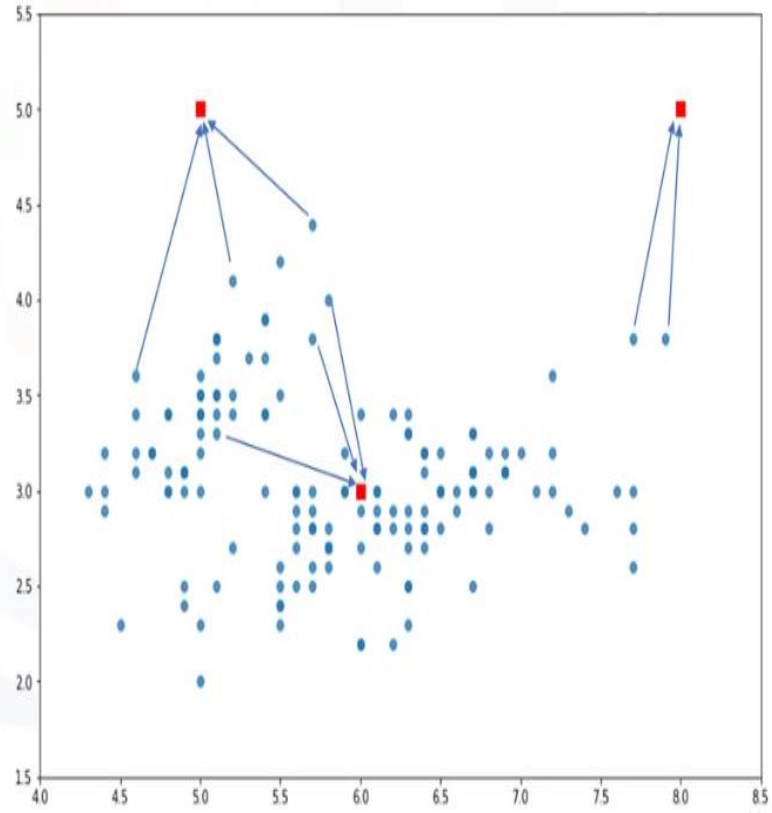
1. Hitung jarak



K-means clustering

2. Masukkan tiap titik ke cluster terdekat

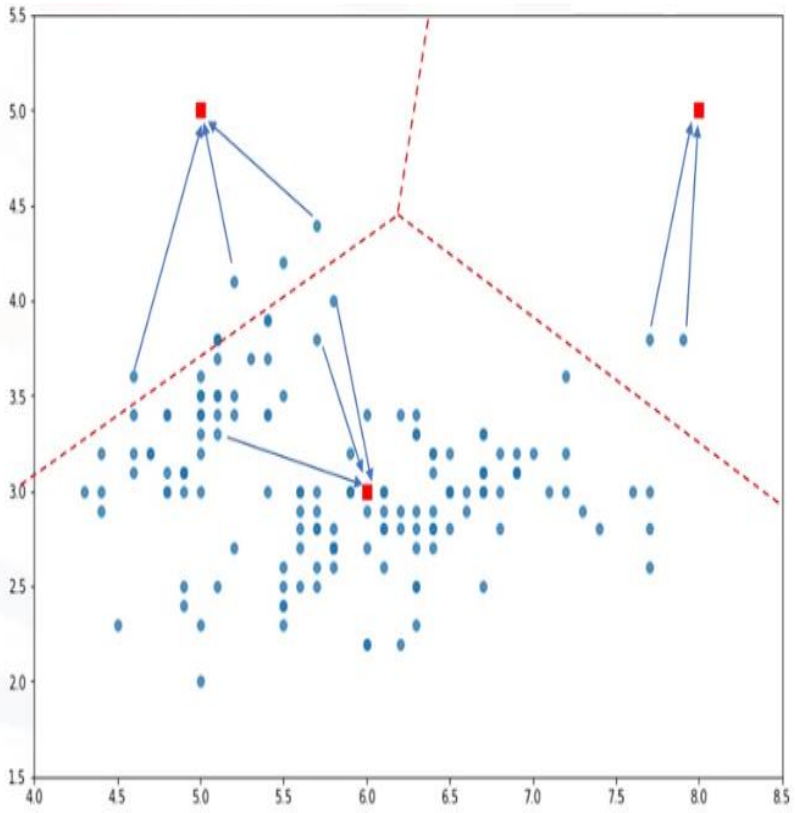
$$\begin{matrix} C_1 & C_2 & C_3 \end{matrix}$$
$$\begin{bmatrix} d(p1,c1) & d(p1,c2) & d(p1,c3) \\ d(p2,c1) & d(p2,c2) & d(p2,c3) \\ d(p3,c1) & d(p3,c2) & d(p3,c3) \\ d(p4,c1) & d(p4,c2) & d(p4,c3) \\ d(p\ldots,c1) & d(p..,c2) & d(p..,c3) \\ d(pn,c1) & d(pn,c2) & d(pn,c3) \\ d(p..,c1) & d(p..,c2) & d(p..,c3) \\ d(p\ldots,c1) & d(p..,c2) & d(p..,c3) \\ d(pn,c1) & d(pn,c2) & d(pn,c3) \\ d(p..,c1) & d(p..,c2) & d(p..,c3) \\ d(p\ldots,c1) & d(p..,c2) & d(p..,c3) \\ d(pn,c1) & d(pn,c2) & d(pn,c3) \\ d(p..,c1) & d(p..,c2) & d(p..,c3) \\ d(p\ldots,c1) & d(p..,c2) & d(p..,c3) \\ d(pn,c1) & d(pn,c2) & d(pn,c3) \end{bmatrix}$$



K-means clustering

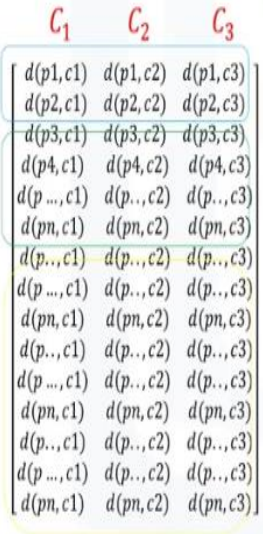
2. Masukkan tiap titik ke cluster terdekat

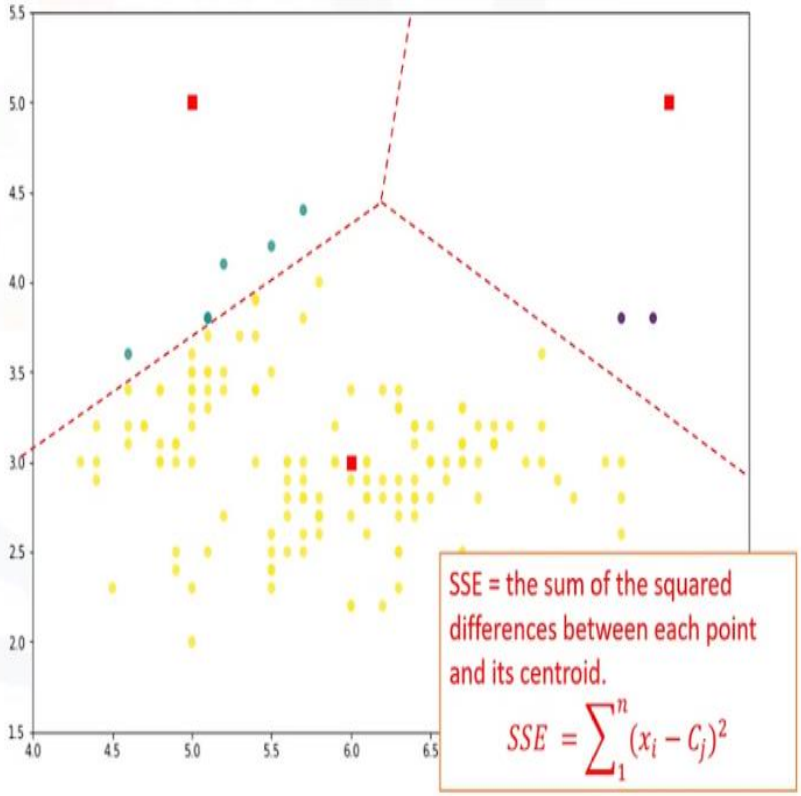
C_1	C_2	C_3
$d(p1,c1)$	$d(p1,c2)$	$d(p1,c3)$
$d(p2,c1)$	$d(p2,c2)$	$d(p2,c3)$
$d(p3,c1)$	$d(p3,c2)$	$d(p3,c3)$
$d(p4,c1)$	$d(p4,c2)$	$d(p4,c3)$
$d(p\ldots,c1)$	$d(p..,c2)$	$d(p..,c3)$
$d(pn,c1)$	$d(pn,c2)$	$d(pn,c3)$
$d(p..,c1)$	$d(p..,c2)$	$d(p..,c3)$
$d(p\ldots,c1)$	$d(p..,c2)$	$d(p..,c3)$
$d(pn,c1)$	$d(pn,c2)$	$d(pn,c3)$
$d(p..,c1)$	$d(p..,c2)$	$d(p..,c3)$
$d(p\ldots,c1)$	$d(p..,c2)$	$d(p..,c3)$
$d(pn,c1)$	$d(pn,c2)$	$d(pn,c3)$
$d(p..,c1)$	$d(p..,c2)$	$d(p..,c3)$
$d(p\ldots,c1)$	$d(p..,c2)$	$d(p..,c3)$
$d(pn,c1)$	$d(pn,c2)$	$d(pn,c3)$



K-means clustering

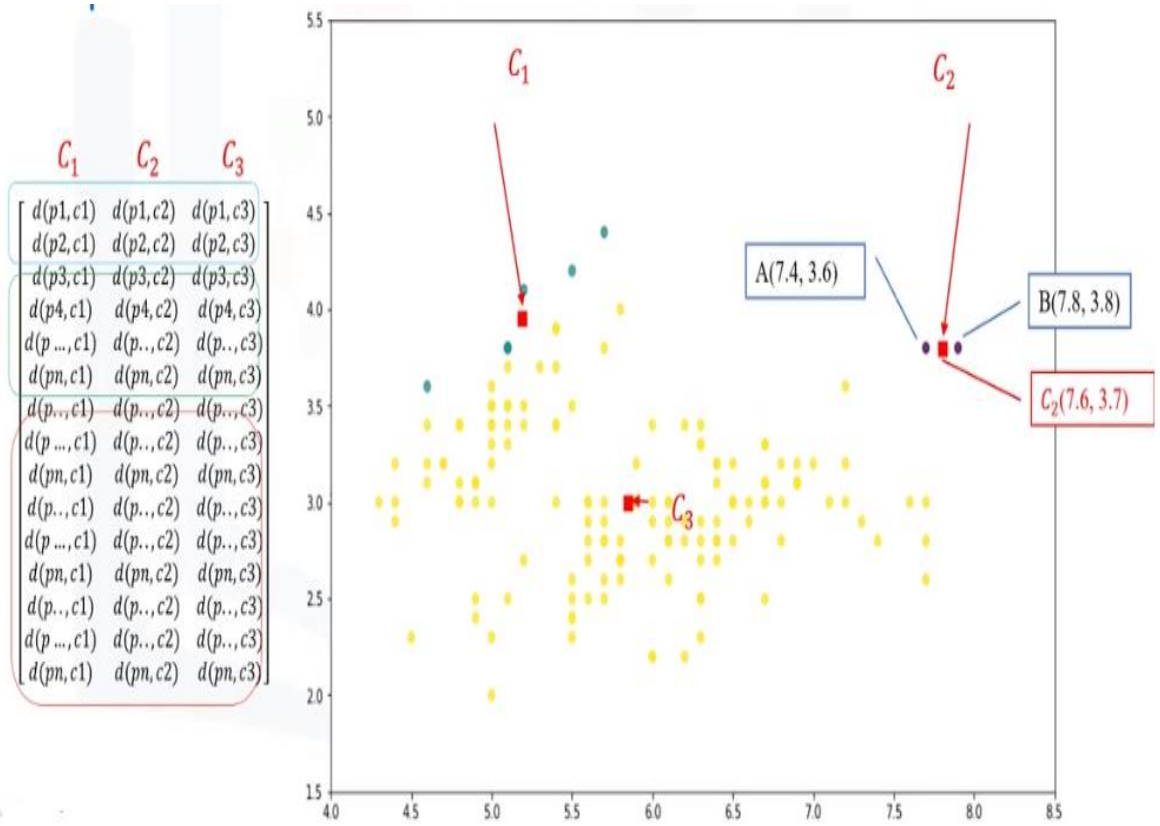
2. Masukkan tiap titik ke cluster terdekat





K-means clustering

3. Hitung titik pusat cluster



K-means clustering

4. Ulangi dari tahap 2 sampai tidak ada lagi perubahan

K-means clustering

Kelebihan (+)

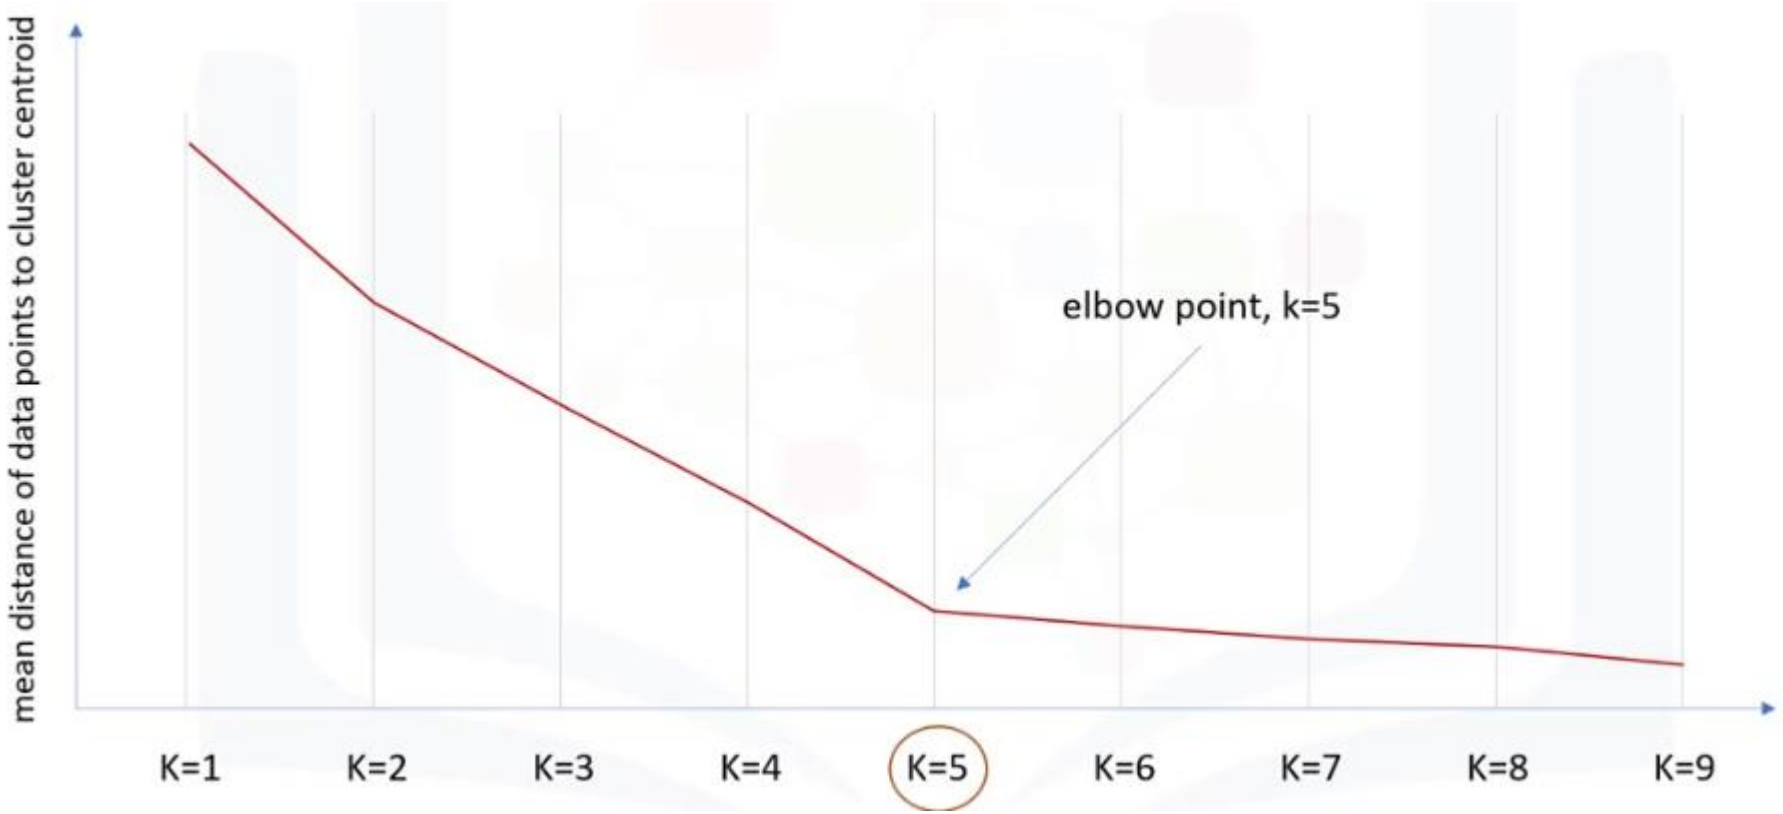
1. Efisient
2. Dapat di eksten ke hierarchical clustering

Kekurangan (-)

1. Cenderung terjebak dalam local optima
2. Perlu menspesifikasikan nilai k
3. Tidak bisa diterapkan pada data nominal

K-means clustering

Memilih nilai k



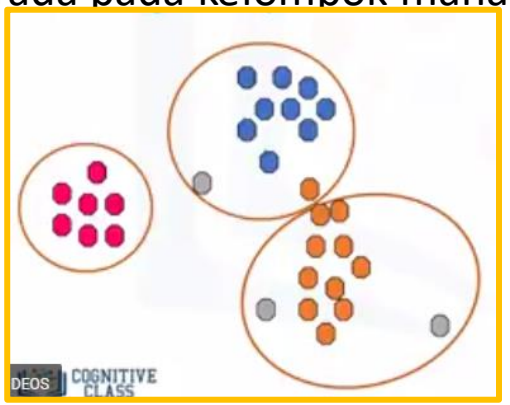
DBSCAN

- Merupakan algoritma pengelompokan yang didasarkan pada kepadatan (density) data
- Kepadatan data merupakan jumlah data dalam radius tertentu (Eps Ɛ) dari setiap data

DBSCAN VS K Means

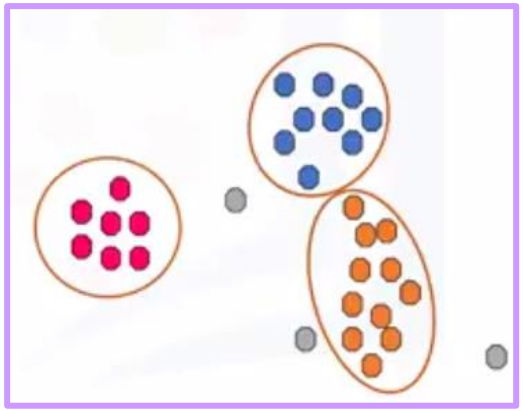
K-Means

Algoritma K-Means cenderung mengelompokan semua poin ke dalam beberapa kelompok *(cluster),* meskipun terdapat beberapa poin yang seharusnya tidak berada pada kelompok manapun.



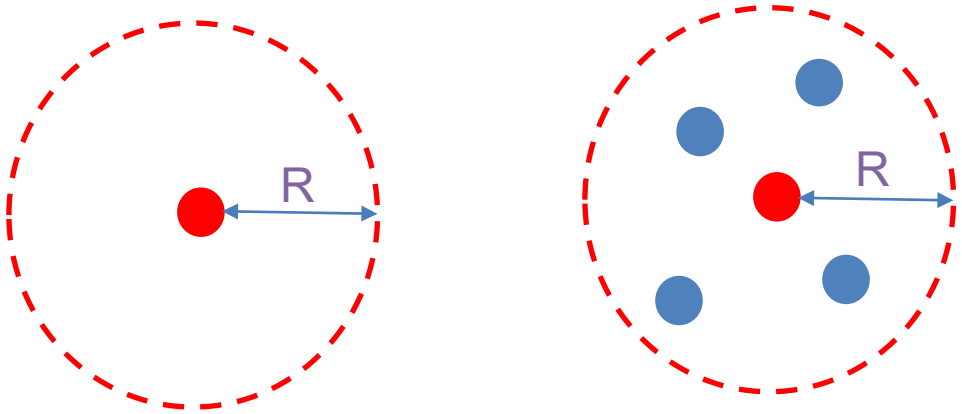
DBSCAN

Algoritma DBSCAN mengelompokan poin-poin terpilih ke dalam beberapa *cluster* dan tidak memisahkan poin-poin yang tidak terpilih ke dalam kategori outlier (pencilan).



DBSCAN

- Radius
- MinPts



- Konsep kepadatan melahirkan 3 macam status:
    1. Inti (core)
    2. batas (border)
    3. noise

DBSCAN

- Inti : jika jumlah data tetangga dan dirinya sendiri pada radius Ɛ berjumlah > MinPts
- Batas : jika jumlah jumlah tetangga dan dirinya sendiri pada radius Ɛ berjumlah < MinPts, tetapi tetangganya menjadi inti karena kehadirannya
- Noise : jika tidak memenuhi kriteria diatas

DBSCAN

- DBSCAN dapat memisahkan data berkepadatan tinggi dan data berkepadatan rendah
- Algoritma DBSCAN membutuhkan 2 parameter penting, Eps (Ɛ) dan jumlah tetangga minimal untuk membentuk kelompok (MinPts)

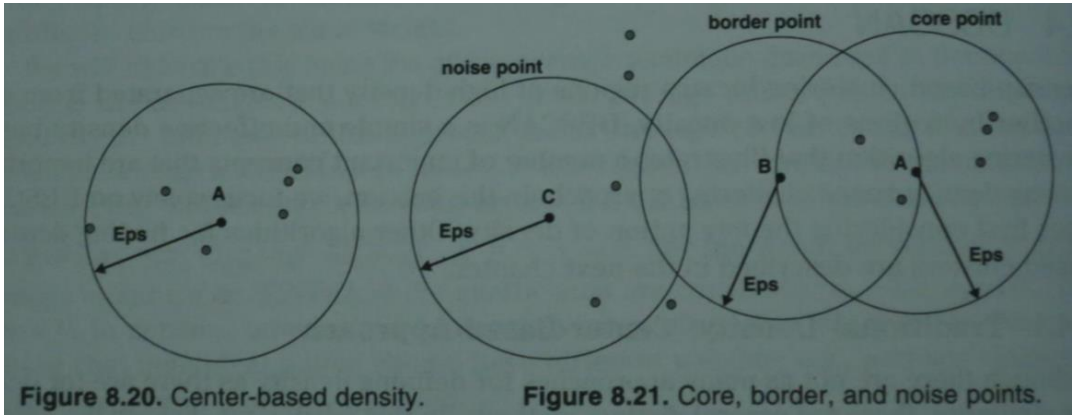


Figure 8.20. Center-based density.

Figure 8.21. Core, border, and noise points.

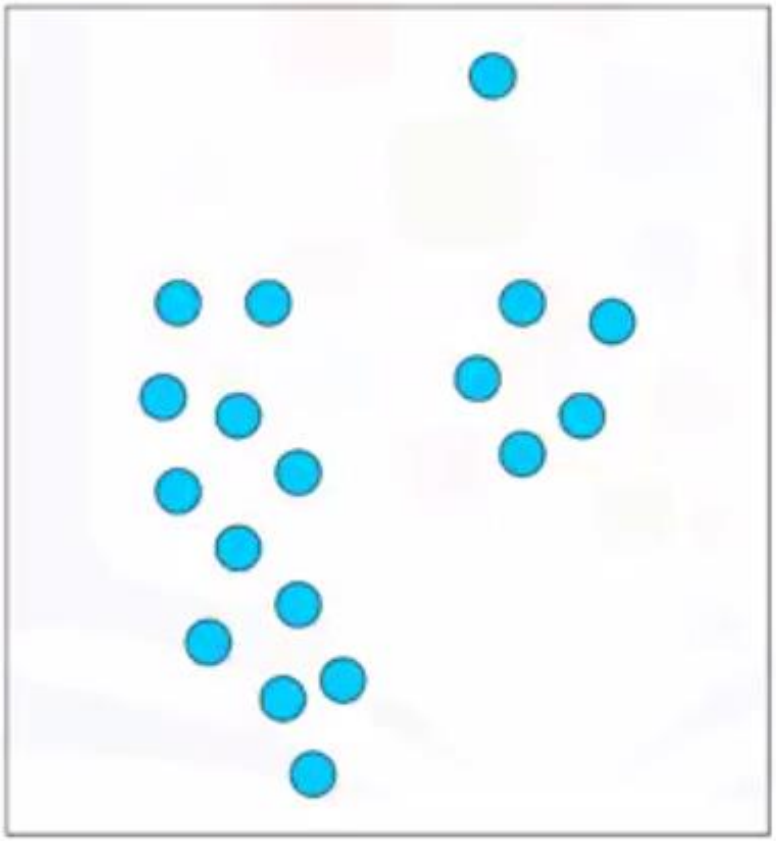
DBSCAN

1. Tentukan semua data sebagai inti, batas ataupun noise
2. Eliminasi data yang masuk dalam kategori noise
3. Letakkan batas diantara semua titik-titik inti yang berada diantara Eps
4. Titik-titik inti yang berada dalam satu group dikelompokkam menjadi cluster yang sama
5. Masukkan titik-titik batas ke dalam salah satu cluster

Contoh DBSCAN

Parameter:

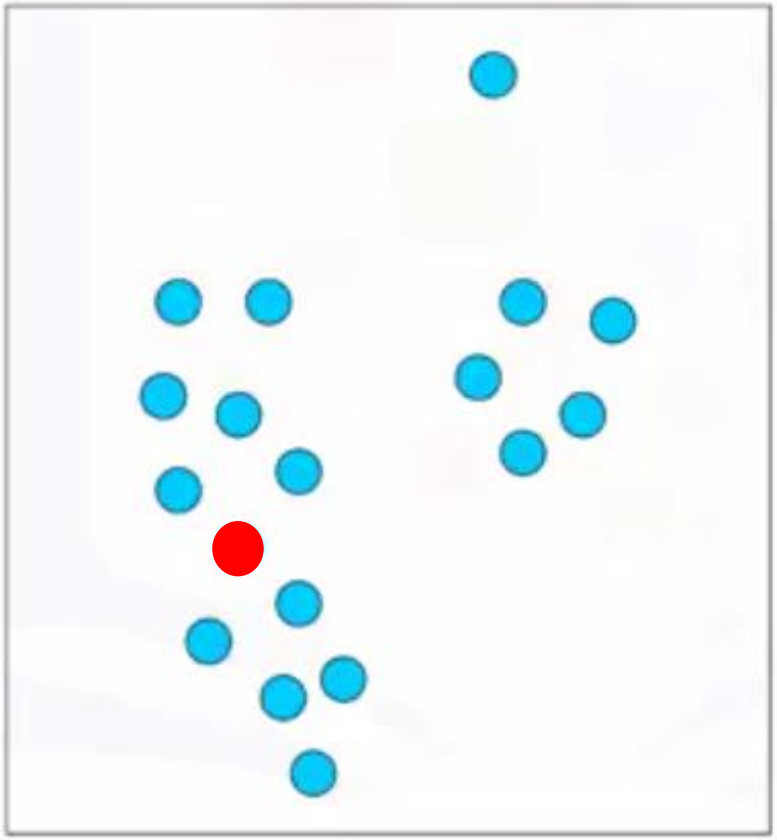
R = 2 unit dan M = 5



Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



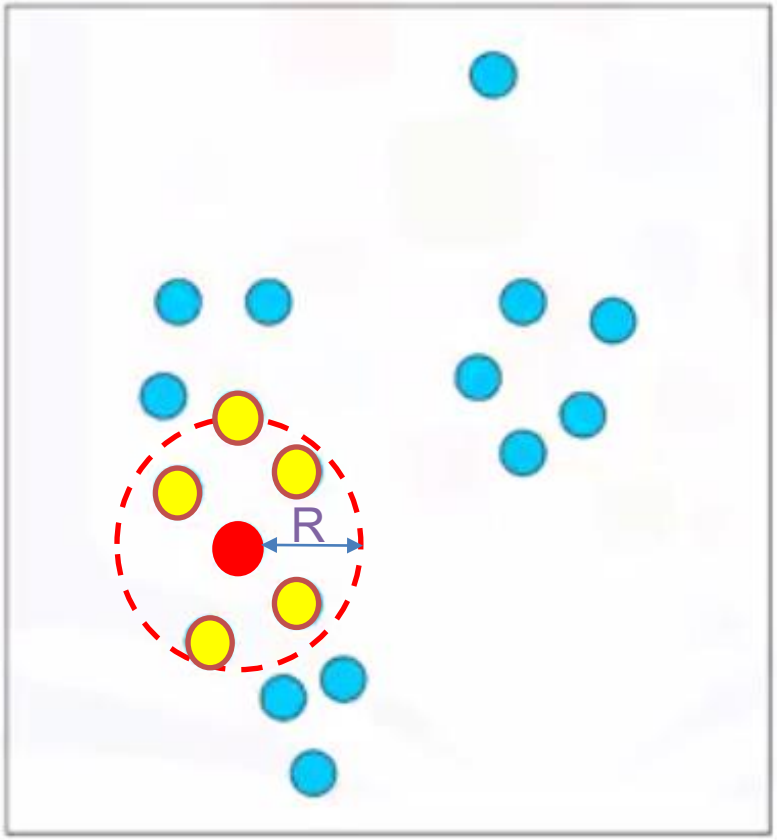
Langkah 1 :

Pilih poin secara acak

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



Langkah 2 :

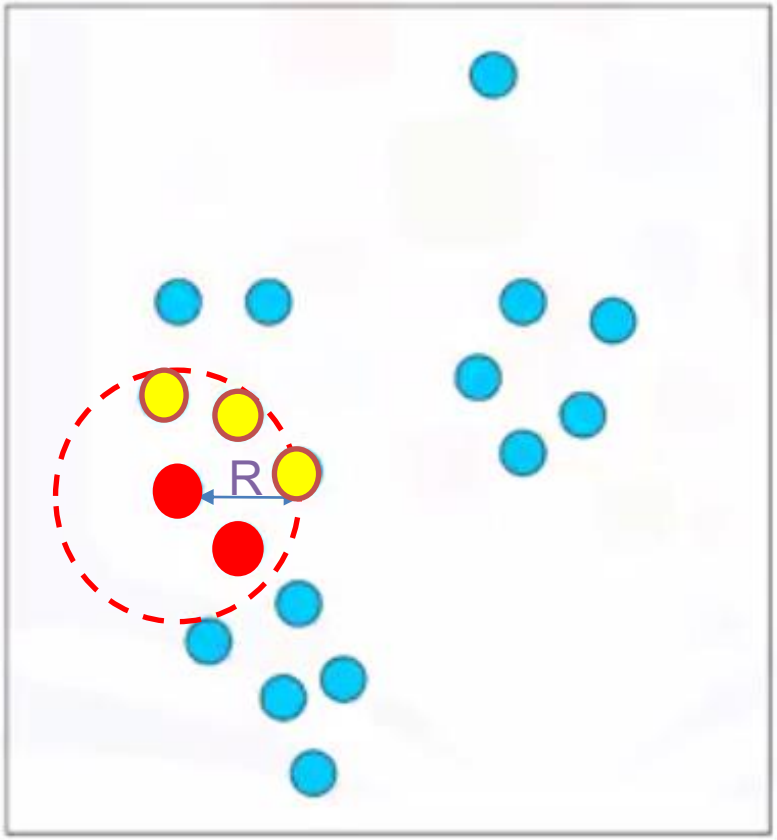
Kategorikan Poin

- Poin pertama merupakan poin inti karena dalam radius R sebesar 2 unit, terdapat 6 poin (termasuk poin pertama).

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



Langkah 3 :

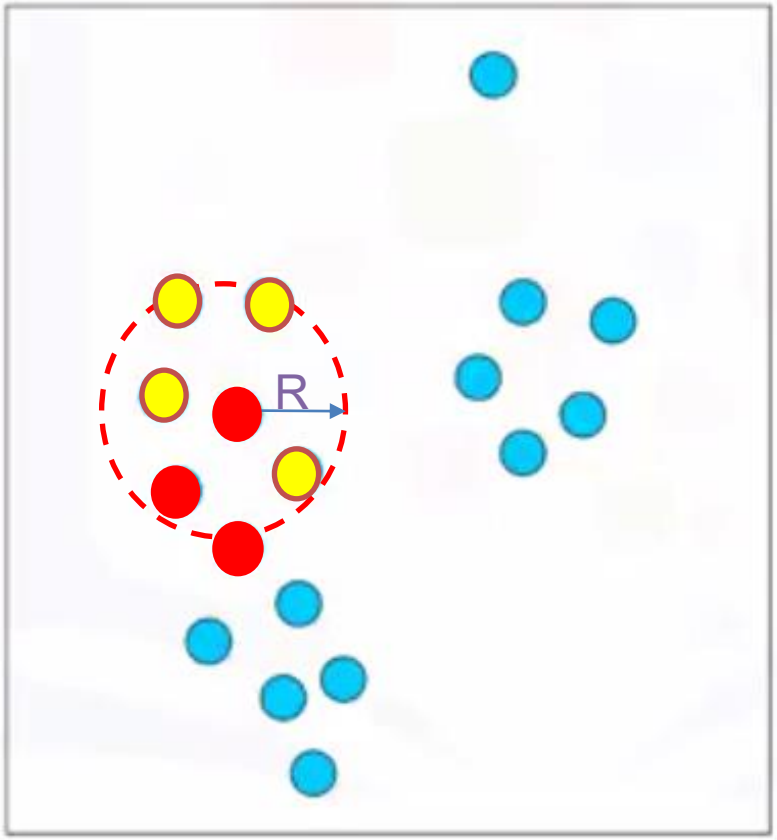
Ulangi langkah 1 dan 2 hingga semua poin sudah dikategorikan.

- Poin kedua merupakan poin inti karena dalam radius R sebesar 2 unit, terdapat 5 poin.

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



Langkah 3 :

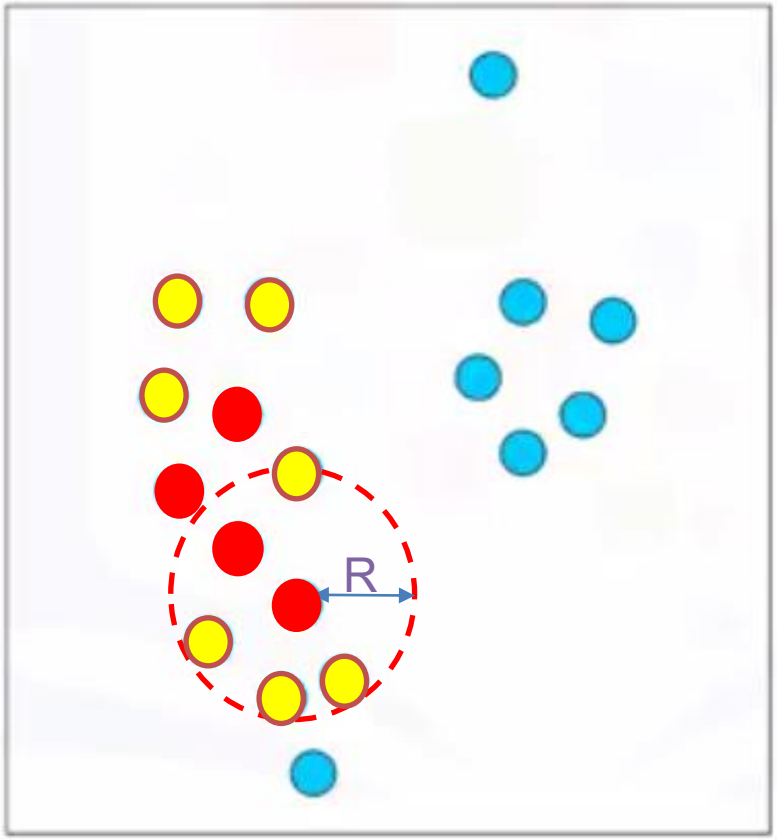
Ulangi langkah 1 dan 2 hingga semua poin sudah dikategorikan.

- Poin ketiga merupakan poin inti karena dalam radius R sebesar 2 unit, terdapat 7 poin (lebih dari M).

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



Langkah 3 :

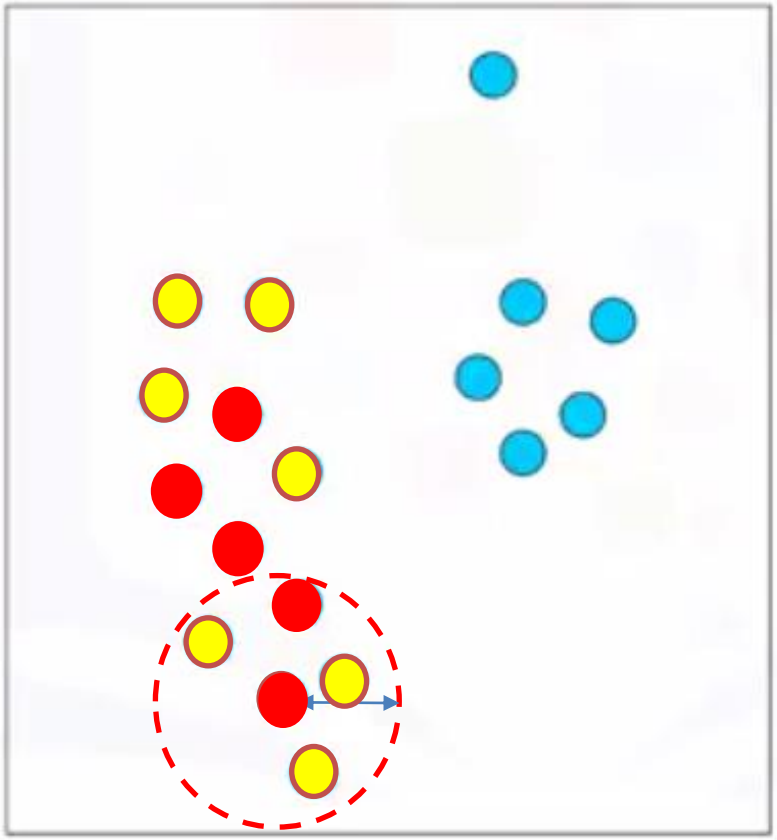
Ulangi langkah 1 dan 2 hingga semua poin sudah dikategorikan.

- Poin berikutnya merupakan poin inti karena dalam radius R sebesar 2 unit, terdapat 6 poin.

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



Langkah 3 :

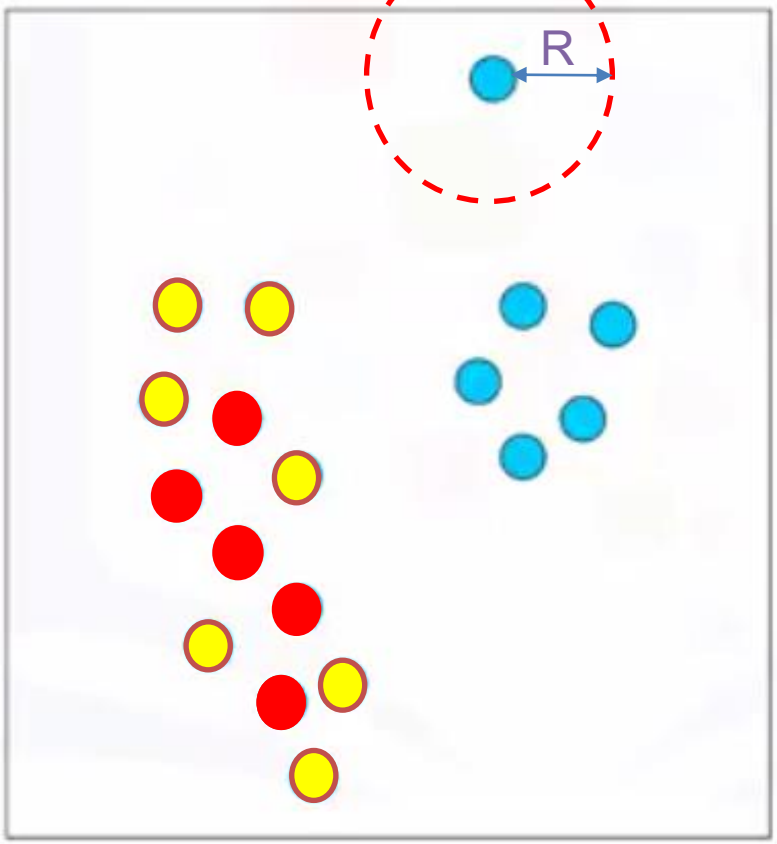
Ulangi langkah 1 dan 2 hingga semua poin sudah dikategorikan.

- Poin berikutnya merupakan poin inti karena dalam radius R sebesar 2 unit, terdapat 5 poin.

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



Langkah 3 :

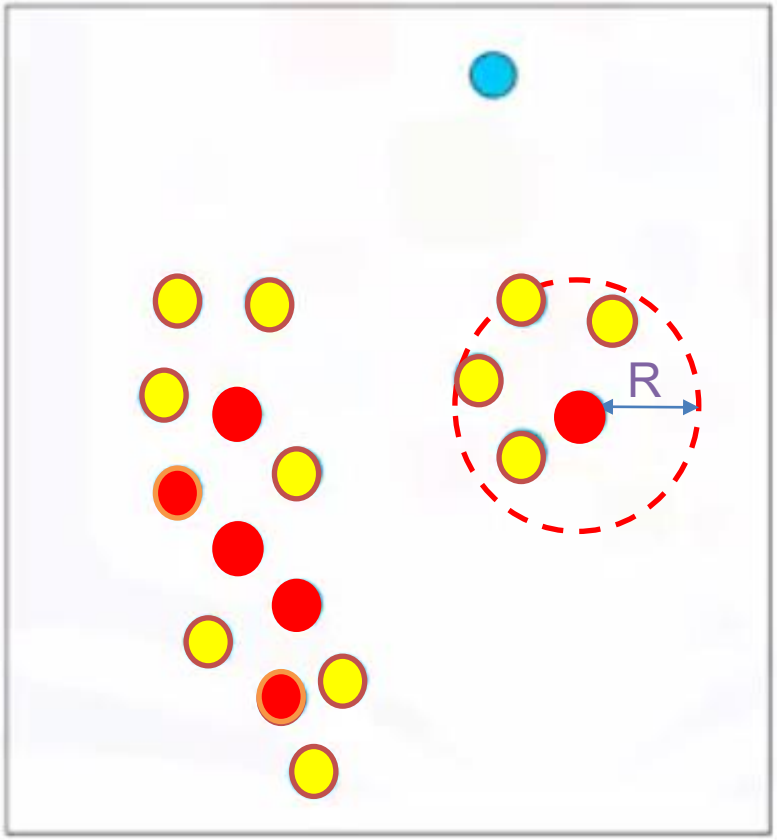
Ulangi langkah 1 dan 2 hingga semua poin sudah dikategorikan.

- Poin berikutnya merupakan poin pencilan karena dalam radius R sebesar 2 unit hanya terdiri dari poin itu sendiri (**tidak** memenuhi syarat poin inti).
- Poin tidak dapat menjangkau radius poin inti yang lain (**tidak** memenuhi syarat poin tepi).

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



Langkah 3 :

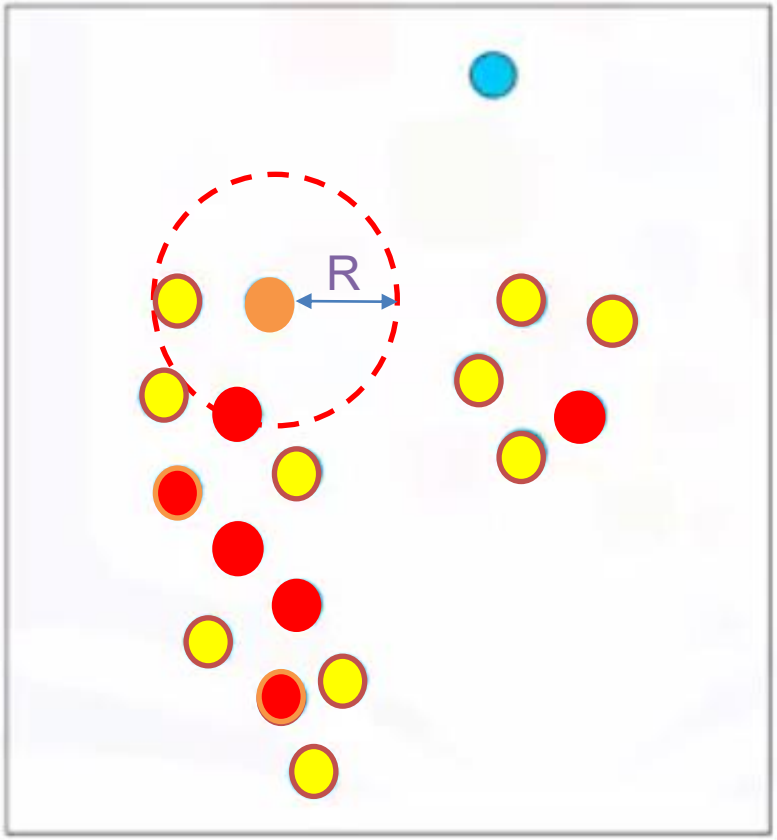
Ulangi langkah 1 dan 2 hingga semua poin sudah dikategorikan.

- Poin berikutnya merupakan poin inti karena dalam radius R sebesar 2 unit terdiri dari 5 poin.

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



Langkah 3 :

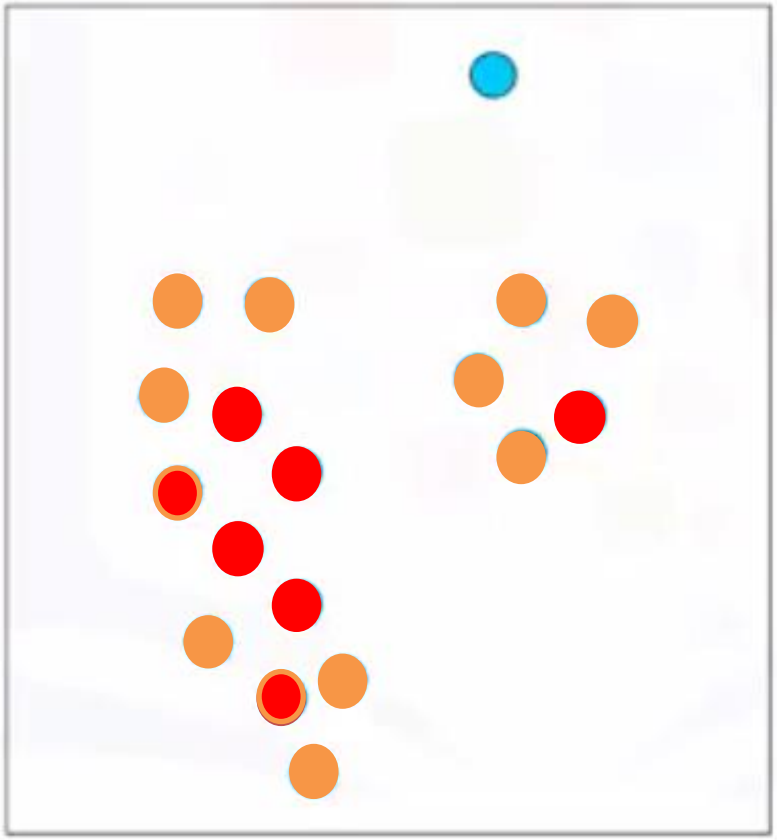
Ulangi langkah 1 dan 2 hingga semua poin sudah dikategorikan.

- Poin berikutnya merupakan poin tepi karena dalam radius R sebesar 2 unit terdiri dari 3 poin.

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



Langkah 3 :

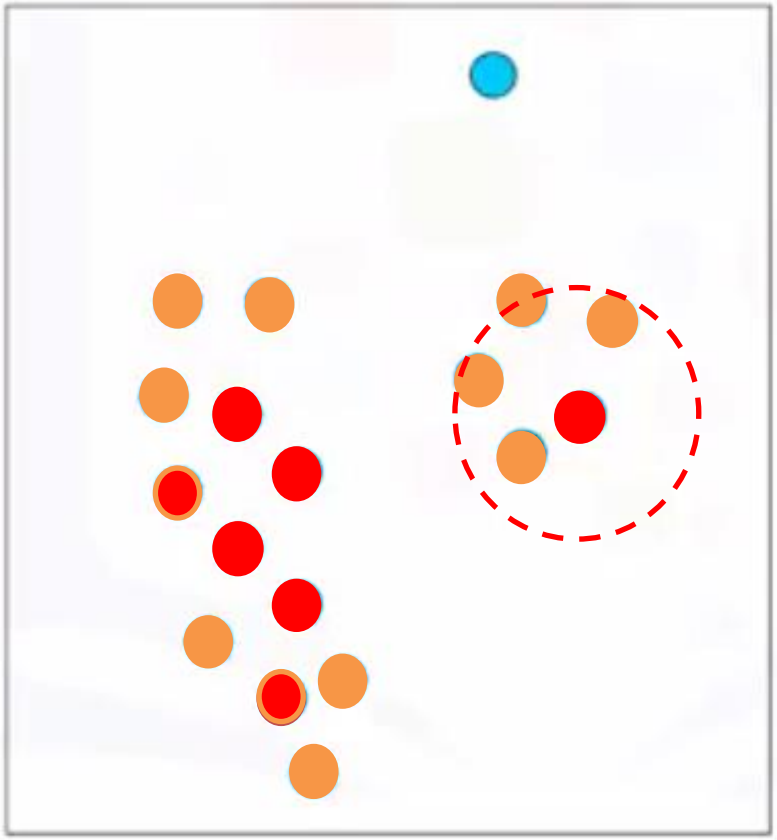
Ulangi langkah 1 dan 2 hingga semua poin sudah dikategorikan.

- Seluruh poin sudah dikategorikan.

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



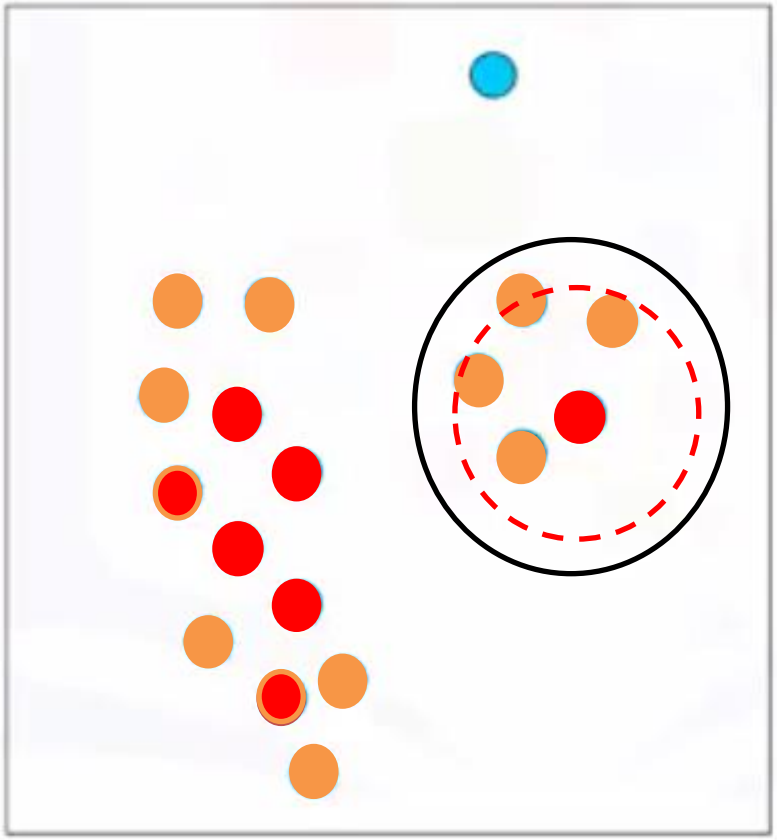
Langkah 4 :
Menentukan jumlah cluster.

- Cluster pertama karena di dalam jangkauan radius poin hanya memiliki satu poin inti.

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



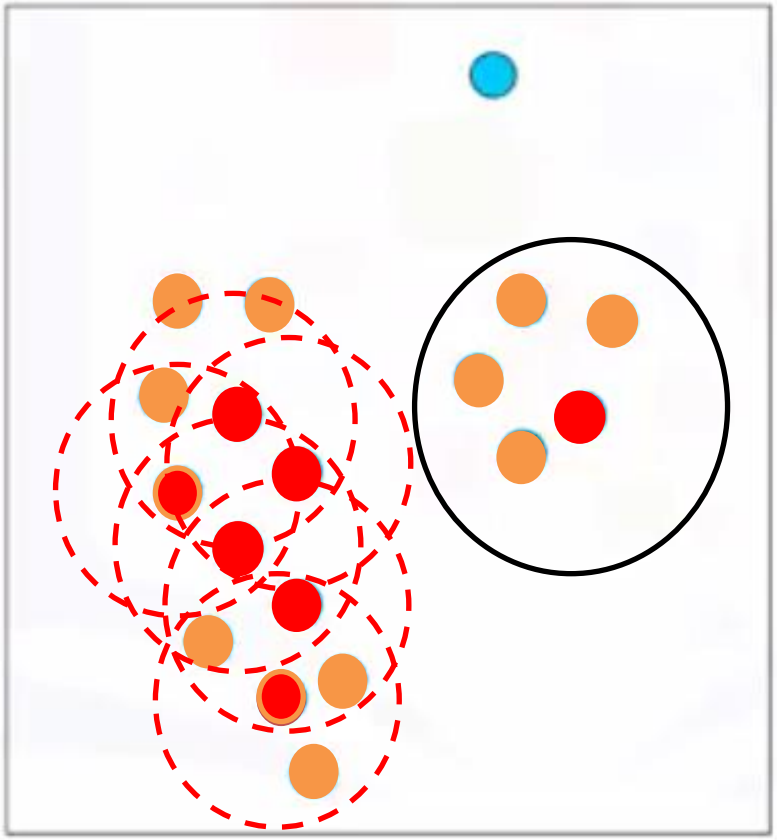
Langkah 4 :
Menentukan jumlah cluster.

- Cluster pertama karena di dalam jangkauan radius poin hanya memiliki satu poin inti.

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



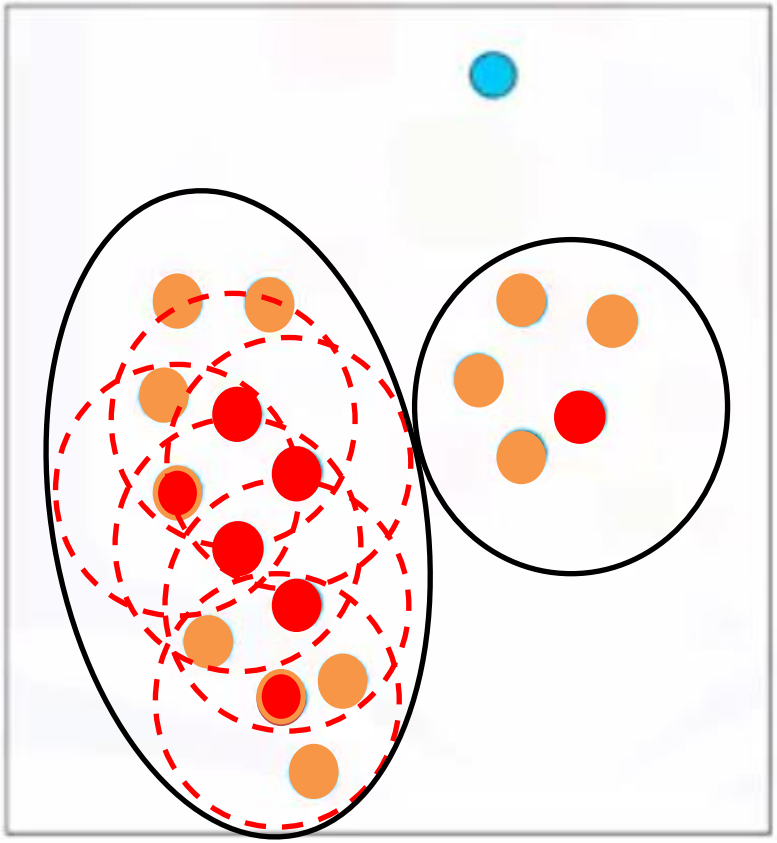
Langkah 4 :
Menentukan jumlah cluster.

- Cluster kedua karena di dalam jangkauan radius satu poin inti terdapat lebih dari satu poin inti yang berkesinambungan.

Algoritma DBSCAN

Parameter:

R = 2 unit dan M = 5



Langkah 4 :
Menentukan jumlah cluster.

- Cluster kedua karena di dalam jangkauan radius satu poin inti terdapat lebih dari satu poin inti yang berkesinambungan.

Kesimpulan DBSCAN

- DBSCAN memiliki kemampuan untuk mengklasifikasi seluruh dataset dengan bentuk sembarang (tidak selalu area berbentuk seperti lingkaran, dll).
- DBSCAN juga memiliki kemampuan untuk mengklasifikasikan data outlier.
- DBSCAN dapat diimplementasikan untuk kasus klasifikasi di dunia nyata dimana dataset yang diberikan merupakan raw data.

Pengelompokan Hierarki

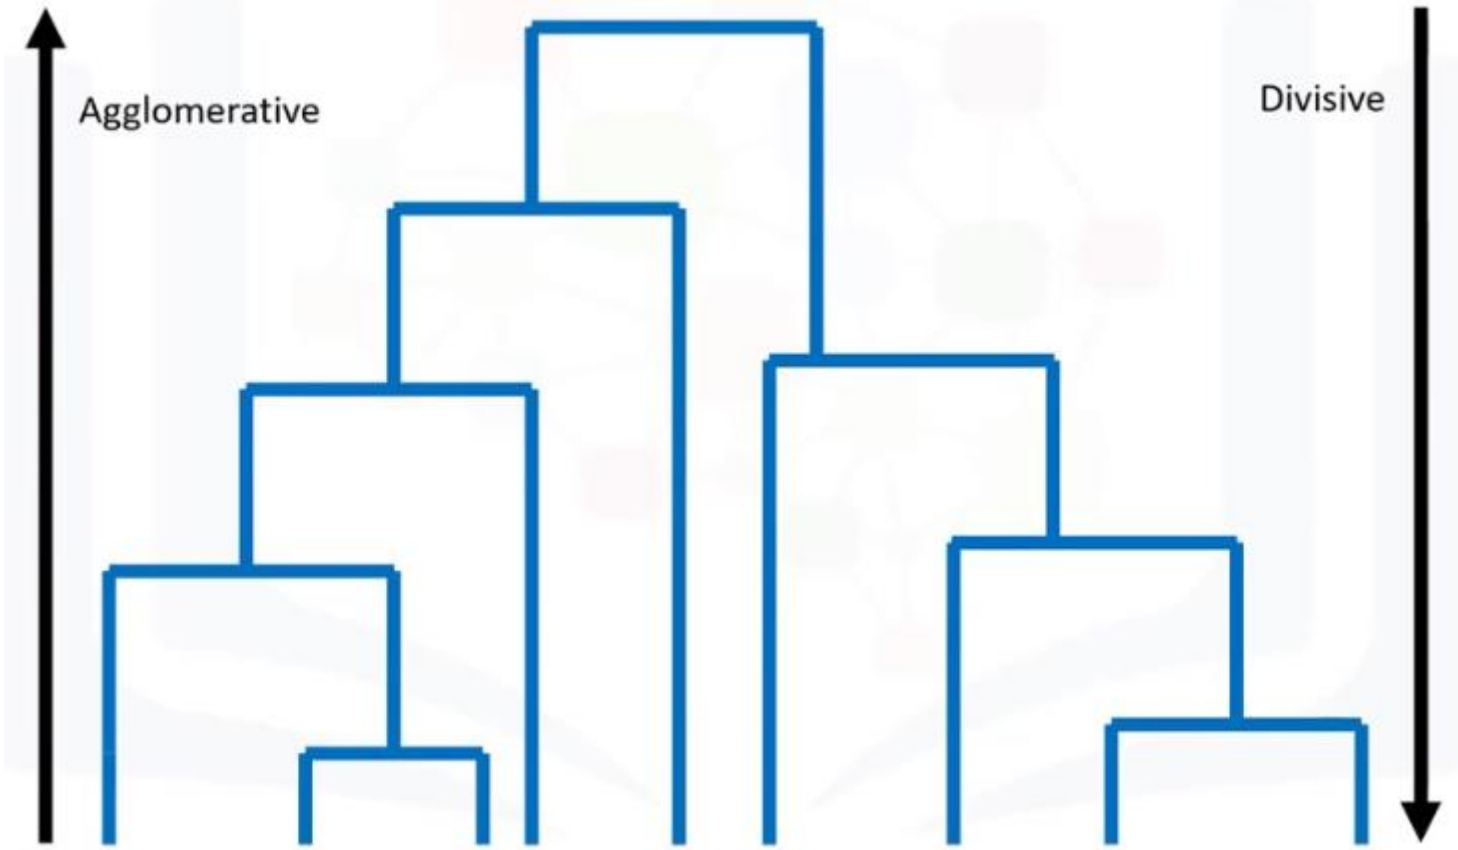
Bottom up = Agglomerative Clustering

- mulai dari cluster dengan instance tunggal
- pada setiap langkah, gabungkan 2 cluster terdekat

Top Down = Divise clustering

- mulai dengan 1 cluster universal
- temukan 2 cluster
- untuk tiap-tiap cluster, pisahkan menjadi 2 cluster

Pengelompokan Hierarki



Agglomerative Hierarchical Clustering

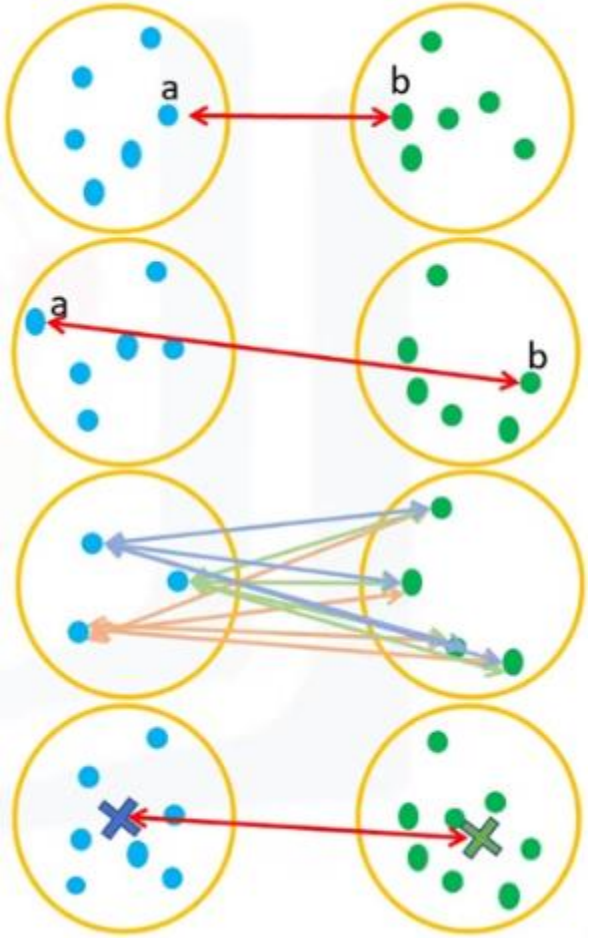
1. Hitung kedekatan jarak antar titik
2. Gabungkan 2 kelompok terdekat
3. Update kedekatan jarak yang menyatakan kedekatan antara kelompok yang baru dengan kelompok yang lama
4. Ulangi langkah 2 sampai terbentuk 1 cluster universal

Agglomerative Hierarchical Clustering

- Kunci operasi AHC adalah penggunaan ukuran kedekatan (proximity) diantara kelompok
- Ukuran kedekatan = ukuran yang membedakan kelompok- kelompok

Agglomerative Hierarchical Clustering

- 4 jenis kedekatan
  1. Single linkage (jarak terdekat)
  2. Complete linkage (jarak terjauh)
  3. Average linkage (jarak rata-rata)
  4. center linkage



Agglomerative Hierarchical Clustering

- Mengelompokkan kota berdasarkan jaraknya



j

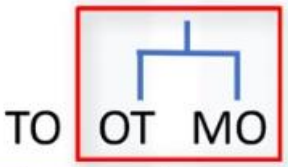
	TO	OT	VA	MO	WI	ED
TO		351	3363	505	1510	2699
OT			3543	167	1676	2840
VA				3690	1867	819
MO					1824	2976
WI						1195
ED						

i

dis(i,j)

Agglomerative Hierarchical Clustering

- Mencari kota terdekat (OT - MO)

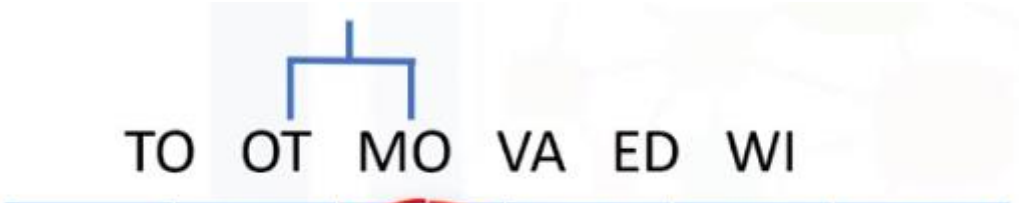




	TO	OT	VA	MO	WI	ED
TO		351	3363	505	1510	2699
OT			3543	167	1676	2840
VA				3690	1867	819
MO					1824	2976
WI						1195
ED						

Agglomerative Hierarchical Clustering

- MO dan OT di gabungkan



	TO	OT/MO	VA	WI	ED
TO		351	3363	1510	2699
OT/MO			3543	1676	2840
VA				1867	819
WI					1195
ED					

Agglomerative Hierarchical Clustering

- Mencari kota berikutnya yang dekat dengan OT/MO





	TO	OT/MO	VA	WI	ED
TO		351	3363	1510	2699
OT/MO			3543	1676	2840
VA				1867	819
WI					1195
ED					

Agglomerative Hierarchical Clustering

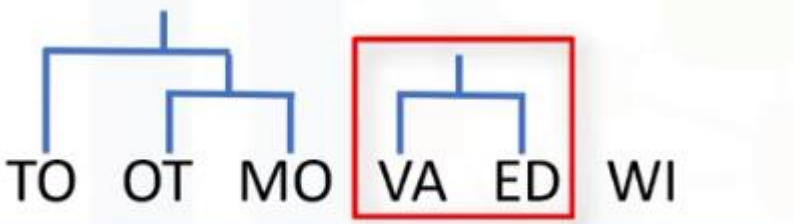
- Kota yang terdekat adalah TO.
- Hubungkan TO dengan cluster OT/MO
- Ketiga kota ini bisa membuat cluster baru



	TO	OT/MO	VA	WI	ED
TO		351	3363	1510	2699
OT/MO			3543	1676	2840
VA				1867	819
WI					1195
ED					

Agglomerative Hierarchical Clustering

- Kota VA dan ED memiliki jarak yg dekat, sehingga bisa membuat cluster baru

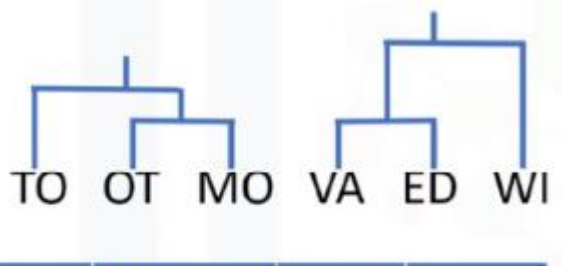


	TO/OT/MO	VA	WI	ED
TO/OT/MO		3543	1676	2840
VA			1867	819
WI				1195
ED				



Agglomerative Hierarchical Clustering

- Proses di ulang

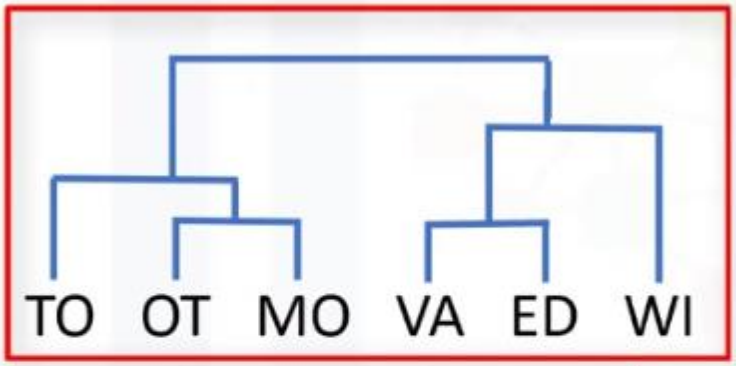


	TO/OT/MO	VA/ED	WI
TO/OT/MO		2840	1676
VA/ED			1667
WI			



Agglomerative Hierarchical Clustering

- Sampai semua kota masuk dalam cluster



	TO/OT/MO	VA/ED/WI
TO/OT/MO		1676
VA/ED/WI		



Agglomerative Hierarchical Clustering

Kelebihan (+)

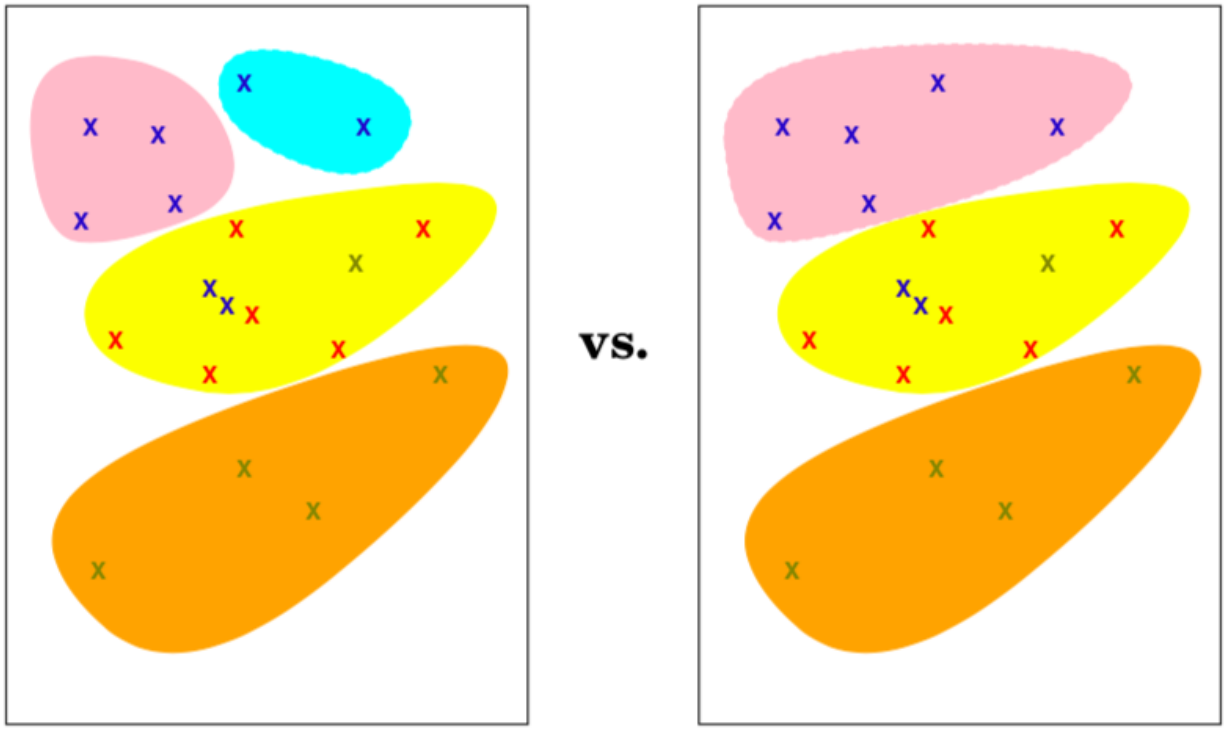
1. Tidak perlu menentukan jumlah cluster
2. Mudah diterapkan
3. Menghasilkan dendogram, mudah dipahami

Kekurangan (-)

1. Tidak bisa merubah step sebelumnya
2. Runtime lama
3. Kadang sulit menentukan jumlah cluster dari dendogram

Evaluasi clustering

- Manakah yang lebih baik



Evaluasi clustering

- Metode unsupervised banyak dievaluasi menggunakan konsep kohesi (seberapa mirip object dalam satu cluster dan seberapa berbeda antara cluster satu dengan lainnya)

Evaluasi clustering

- high **cluster cohesion**, i.e. instances in a given cluster should be closely related to each other

$$cohesion(C_i) = \frac{1}{\sum_{\mathbf{x},\mathbf{y} \in C_i} proximity(\mathbf{x}, \mathbf{y})}$$

- high **cluster separation**, i.e. instances in different clusters should be distinct from each other

$$separation(C_i, C_j) = \sum_{\mathbf{x} \in C_i, \mathbf{y} \in C_j} proximity(\mathbf{x}, \mathbf{y})$$

Evaluasi clustering

- Cluster compactness

  - One way of evaluating the quality of clusters (esp. for k-means), is via the **sum of squared errors** (SSE):

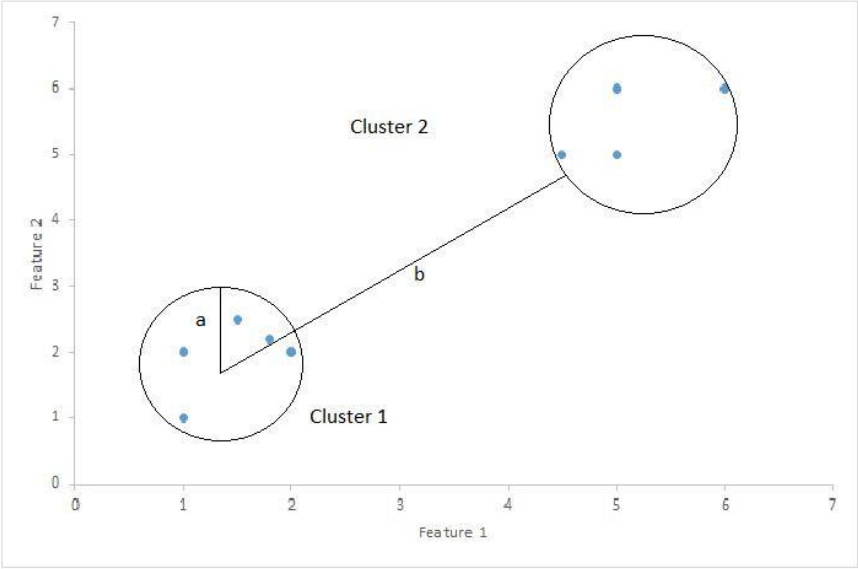
$$\mathrm{SSE} = \sum_{i=1}^{k} \sum_{\mathbf{x} \in C_i} proximity(\mathbf{x}, \mathbf{c_i})^2$$

    where $\mathbf{c_i}$ is the centroid of cluster C_i, and $proximity$ = Euclidean distance

Evaluasi clustering

- Silhouette Coefficient

$$s = \frac{b - a}{max(a, b)}$$



S : silhoette coefficient

a = jarak rata-rata sample dalam 1 cluster

B : jarak rata-rata sample dengan sample lain di cluster tetangganya

Range nilai antara -1 sampai 1

Davies Bouldin Index

- Hitung cluster dispersion (Si)
- Hitung cluster separation (Mi)
- Hitung kemiripan antar cluster i dengan cluster j (Rij)
- Cari cluster yang paling mirip dengan tiap cluster i (Ri)
- Hitung BDI nya

$$R_{ij} = \frac{S_i + S_j}{M_{ij}}$$

$$R_i \equiv maximum(R_{ij})$$

$$\bar{R} = \frac{1}{N} \sum_{i=1}^{N} R_i$$

Davies Bouldin Index

Davies Bouldin Index merepresentasikan rata-rata kemiripan cluster dengan cluster yang paling mirip dengan cluster tersebut

$$R_{ij} = \frac{S_i + S_j}{M_{ij}}$$

$$R_i \equiv maximum(R_{ij})$$

$$\bar{R} = \frac{1}{N} \sum_{i=1}^{N} R_i$$

Terima Kasih