CLASSIFICATION

Prof. Hindriyanto D. Purnomo, Ph.D

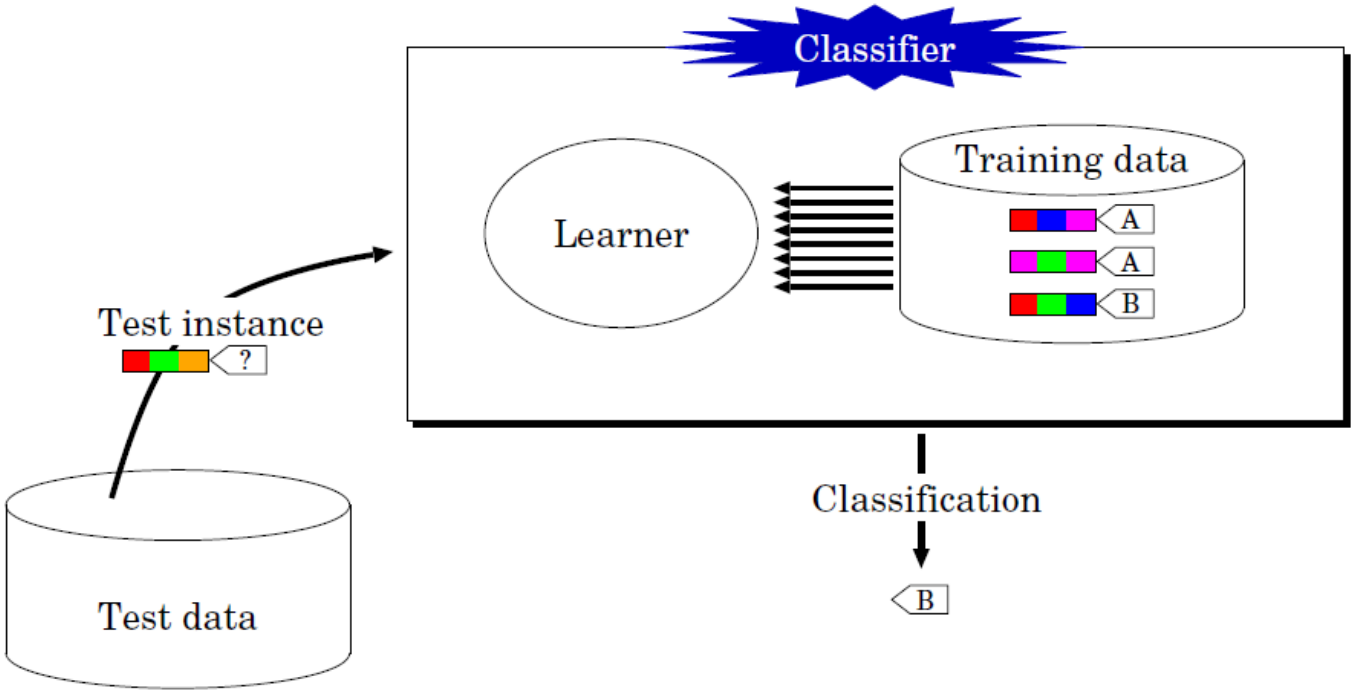
Outline

- Dasar-dasar klasifikasi
- K-NN
- Naïve Bayes
- Jaringan Saraf Tiruan
- Decision Tree
- Support Vector Machine

Dasar-dasar klasifikasi

- Klasifikasi berfungsi memasukkan objek data ke dalam kelas tertentu dari sejumlah kelas yang tersedia
- Ada dua unsur utama dalam klasifikasi
    1. Membangun model (learning phase)
    2. Menggunakan model tersebut untuk melakukan klasifikasi/pengenalan/prediksi
- Klasifikasi merupakan supervised learning

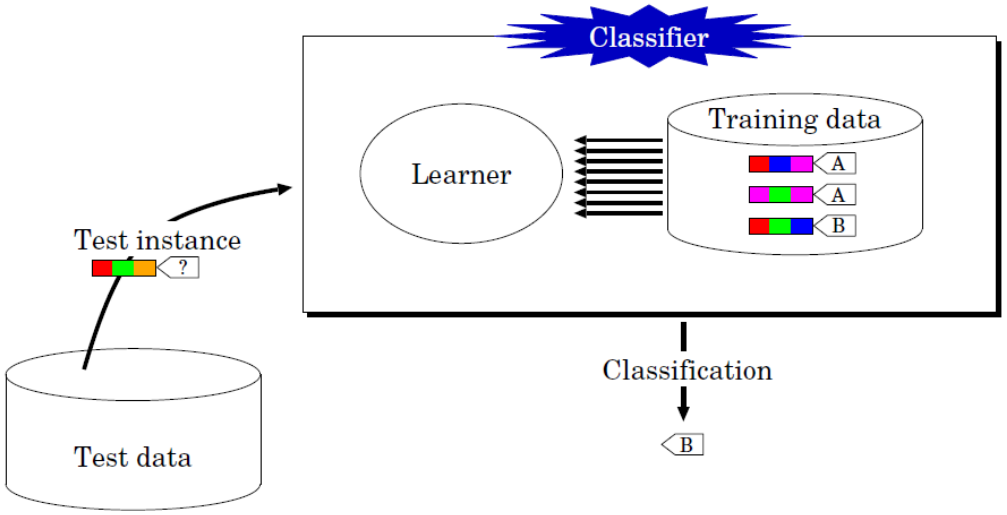
Dasar-dasar klasifikasi



Dasar-dasar klasifikasi

- Berdasarkan cara pelatihan, metode klasifikasi dapat dibagi menjadi
    1. lazy learner
    2. eager learner
- Lazy learner: sedikit/tidak melakukan pelatihan dan hanya menyimpan sebagian data latih, kemudian menggunakannya untuk prediksi
- Eager learner: melakukan pembelajaran secara intensif pada data latih dengan memetakan setiap vector input ke label kelas output sehingga pada akhir fase pembelajaran, model sudah dapat memetakan semua vector uji ke label kelas output dengan benar

Dasar-dasar klasifikasi



- Eager learner : mempelajari representasi struktural
- Lazy learner : melakukan mapping test instance ke training instance secara langsung

Dasar-dasar klasifikasi

Contoh :

1. lazy learner: K-nearest neighbor, regresi linear, Fuzzy k-nearest neighbor

2. eager learner : Jaringan saraf tiruan, decision tree, support vector machine, Bayesian

K-Nearest Neighbor (k-NN)

1. Mengklasifikasikan data berdasarkan kedekatan lokasi
2. Jarak antar data dapat dihitung, nilai jarak inilah yang dipakai sebagai nilai kedekatan/kemiripan
3. Menentukan nilai k sebagai jumlah tetangga yang harus diperhitungkan dalam klasifikasi

K-Nearest Neighbor (k-NN)

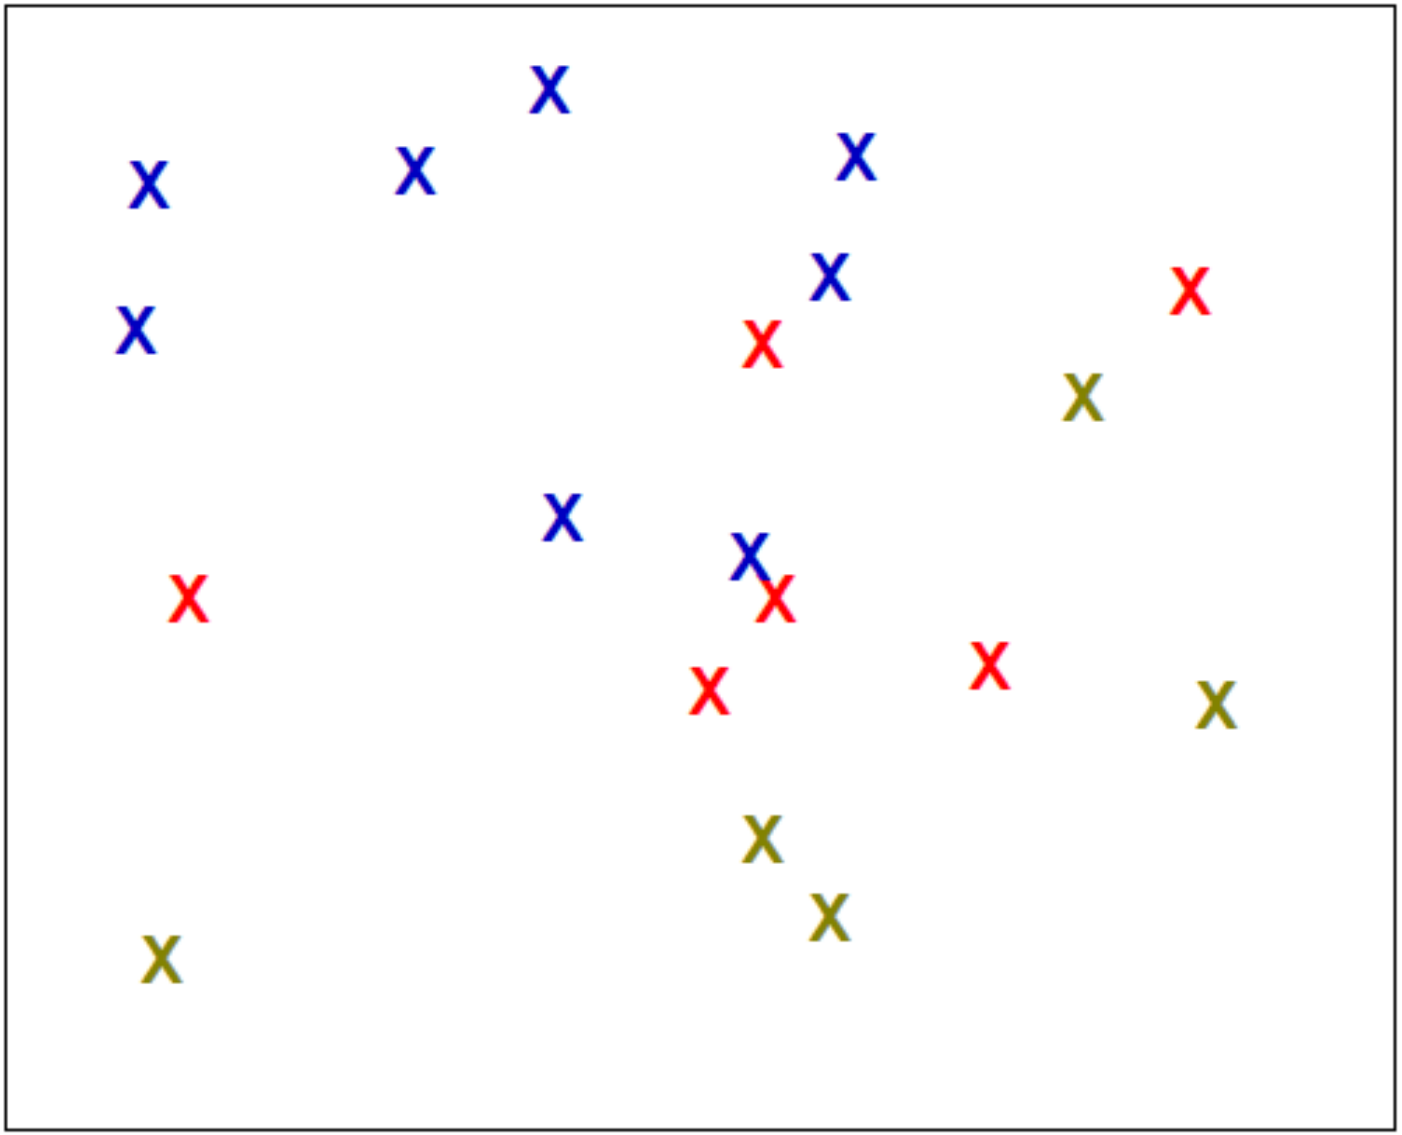
Prosedur dasar

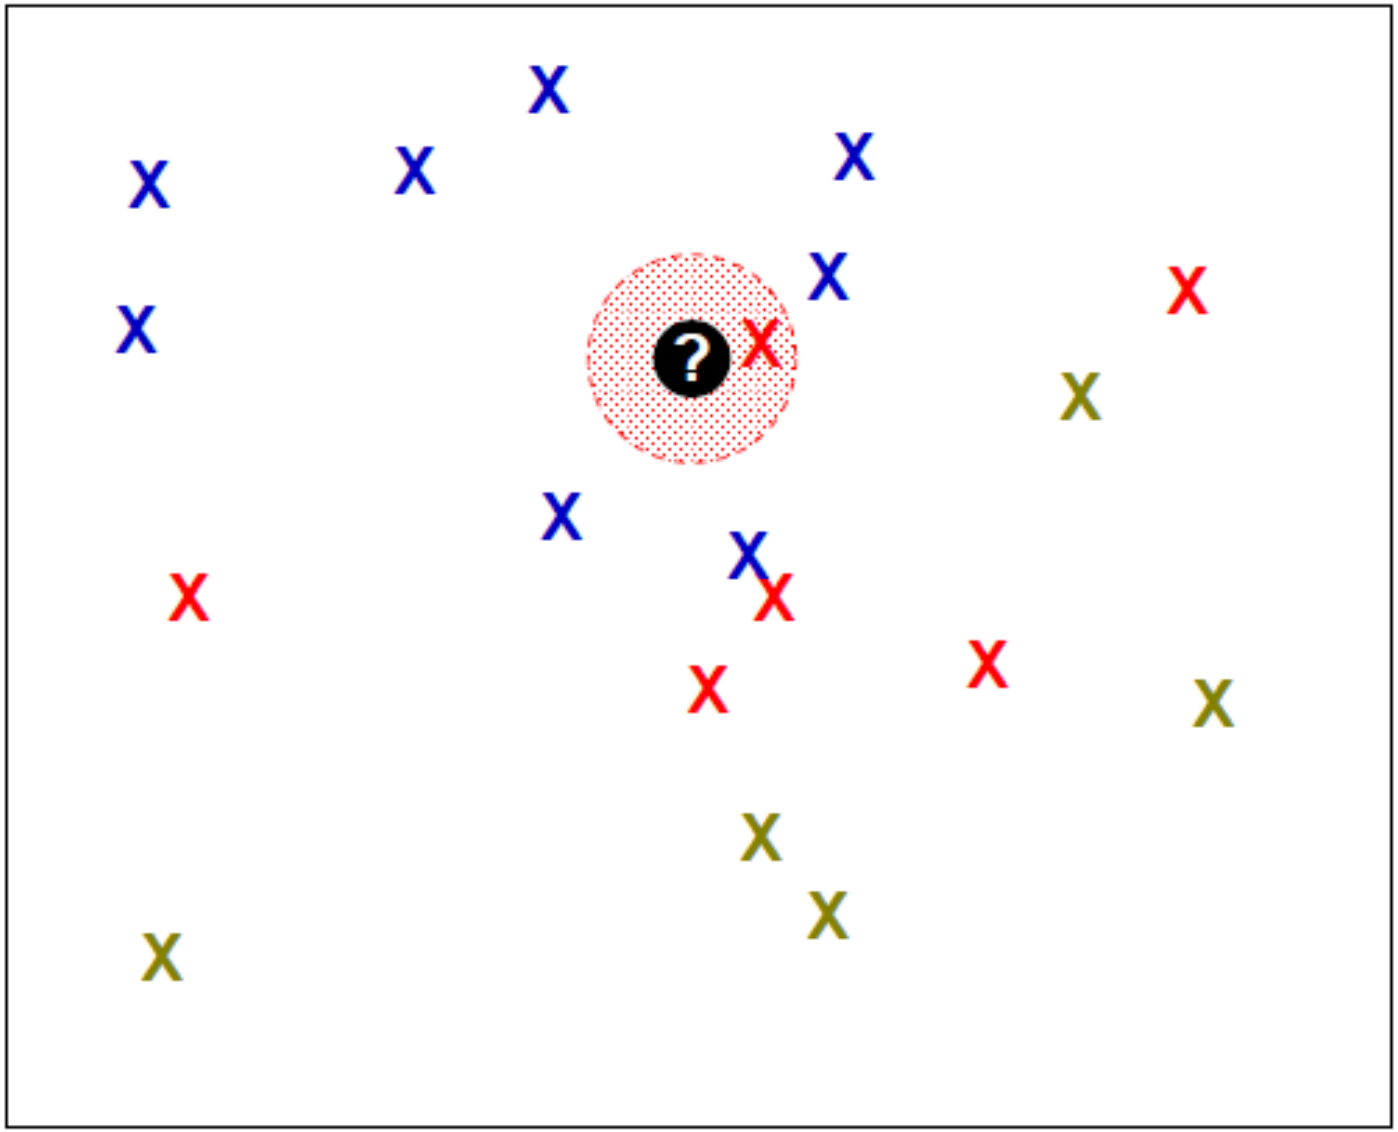
1. Hitung jarak antara data tes dengan data training
2. Prediksikan kelas dari data test berdasarkan distribusi dari *k* data yang paling sesuai

- Jika *k* = 1, ambil 1 tetangga terdekat dari data latih. Kelas dari data uji akan sama dengan kelas dari data latih terdekat

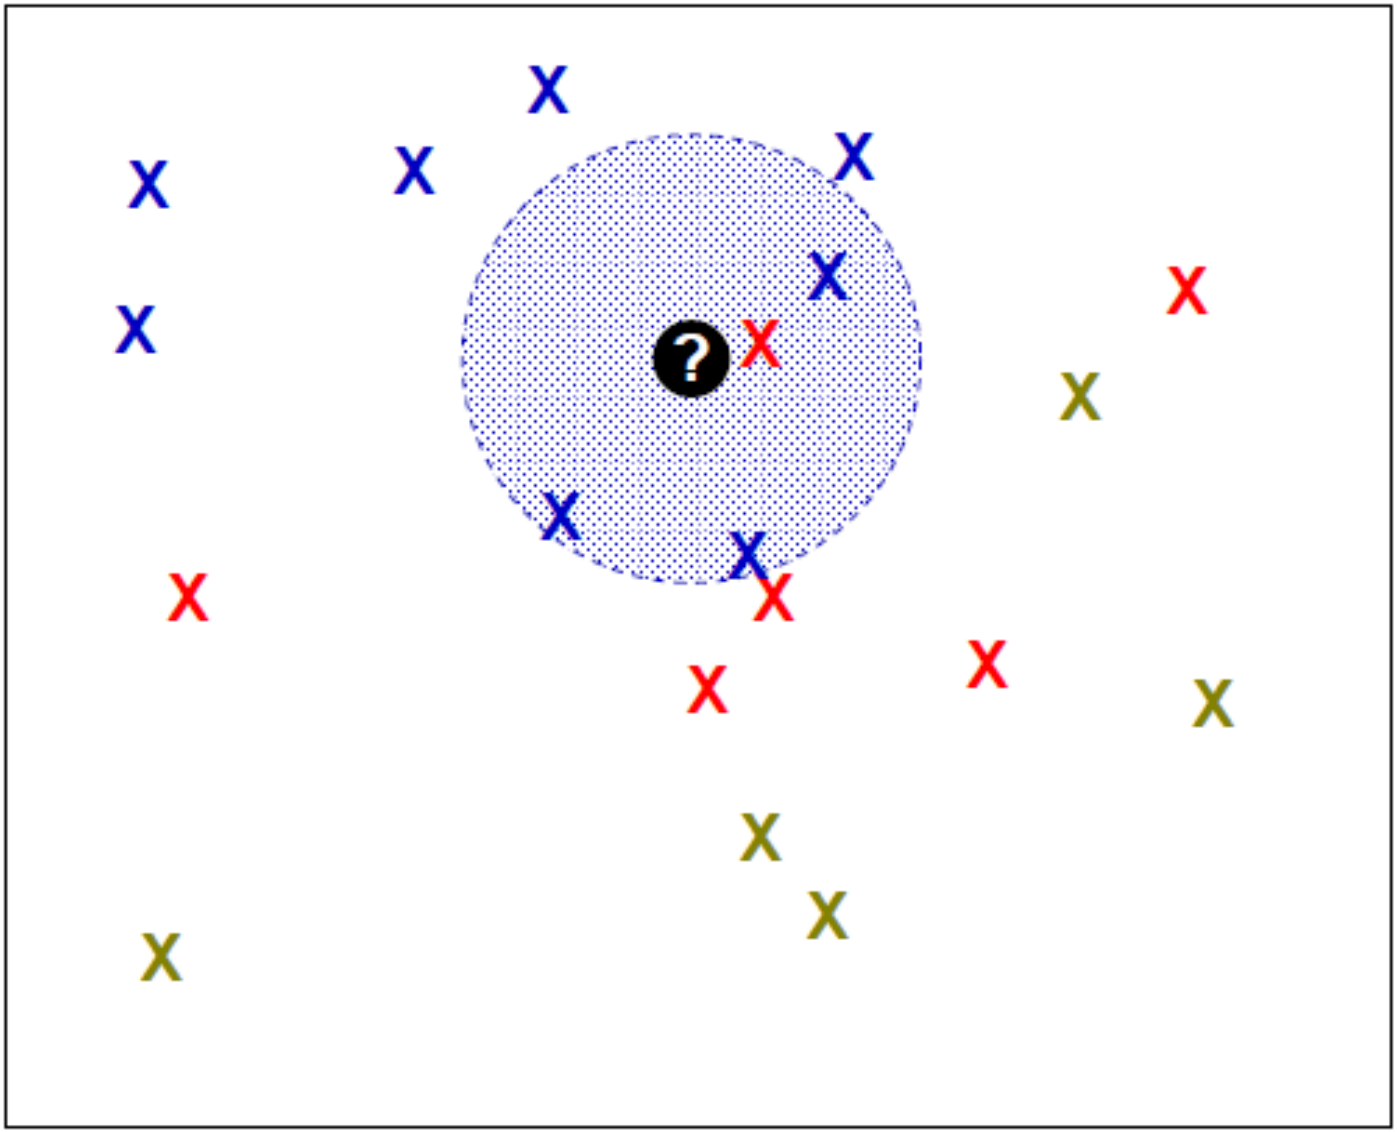
- Jika k = 2, ambil 2 tetangga terdekat.

Jika dalam k-tetangga terdekat ada dua kelas yang berbeda, maka kelas dari data uji akan sama dengan kelas dari mayoritas data latih





K = 1, kelas data uji = merah



K = 4,

kelas data uji = kelas dari mayoritas data latih = biru

Naïve Bayes

- Metode learning dan klasifikasi berdasarkan probabilitas
- Membangun sebuah model umum untuk mengetahui bagaimana data dihasilkan
- Menggunakan asumsi independensi yang kuat (naïve)
- Menggunakan model fitur independent

Naïve Bayes

Ide dasar dari Bayes adalah hasil dari hipotesis dapat diperkirakan berdasarkan beberapa bukti yang diamati

Ada beberapa hal penting dari aturan Bayes

1. Sebuah probabilitas awal H atau P(H) adalah probabilitas dari suatu hipotesis sebelum bukti diamati (evidence)
2. Sebuah probabilitas akhir H atau P(H|E) adalah probabilitas dari suatu hipotesis setelah bukti diamati

Naïve Bayes

Terorema Bayes

$$P(H|E) = \frac{P(E|H)xP(H)}{P(E)}$$

- P(H|E) = probabilitas akhir bersyarat suatu hipotesis H terjadi jika diberikan bukti E
- P(E|H) = probabilitas sebuah bukti E terjadi akan mempengaruhi hipotesis H
- P(H) = probabilitas awal hipotesis H terjadi tanpa memandang bukti apapun
- P(E) = probabilitas awal bukti E terjadi tanpa memandang hipotesis yang lain

Naïve Bayes

- Formulasi Naïve Bayes untuk klasifikasi dinyatakan sbb:

$$P(Y|X) = \frac{P(Y)\prod_{i=1}^{d} P(X_i|Y)}{P(X)}$$

- P(Y|X) = probabilitas data dengan vector X pada kelas Y
- P(Y) = probabilitas awal kelas Y
- $\prod_{i=1}^{q} P(X_i|Y)$ = probabilitas independent kelas Y dari semua fitur dalam vector X
- P(X) = nilainya selau tetap, sehingga dalam menghitung prediksi, yang dihitung adalah bagian , dimana nilai yang terbesar dipilih sebagai kelas hasil prediksi

Naïve Bayes

Outlook	Temperature	Humidity	Windy	Play
	TRAINING DATA			
sunny	hot	high	FALSE	no
sunny	hot	high	TRUE	no
overcast	hot	high	FALSE	yes
rainy	mild	high	FALSE	yes
rainy	cool	normal	FALSE	yes
rainy	cool	normal	TRUE	no
overcast	cool	normal	TRUE	yes
sunny	mild	high	FALSE	no
sunny	cool	normal	FALSE	yes
rainy	mild	normal	FALSE	yes
	TEST DATA			
sunny	mild	normal	TRUE	(yes)

- Priors:

  $P(\texttt{yes}) = \frac{7}{12}$

  $P(\texttt{no}) = \frac{5}{12}$

- Conditional probs:

  $P(\texttt{Outlook = sunny}|\texttt{yes}) = \frac{2}{9}$

  $P(\texttt{Outlook = o'cast}|\texttt{yes}) = \frac{3}{9}$

  $P(\texttt{Outlook = rainy}|\texttt{yes}) = \frac{4}{9}$

  $P(\texttt{Outlook = sunny}|\texttt{no}) = \frac{4}{7}$

  $P(\texttt{Outlook = o'cast}|\texttt{no}) = \frac{1}{7}$

  $P(\texttt{Outlook = rainy}|\texttt{no}) = \frac{2}{7}$

- Classification of test instance T:

  $P(\texttt{yes}|T) = \frac{7}{12} \times (\frac{2}{9} \times \frac{3}{9} \times \frac{5}{8} \times \frac{2}{8}) \approx 0.0068$

  $P(\texttt{no}|T) = \frac{5}{12} \times (\frac{4}{7} \times \frac{2}{7} \times \frac{2}{6} \times \frac{3}{6}) \approx 0.011$

Jaringan Saraf Tiruan

- Artificial Neural Network terinspirasi dari sistem saraf biologis
- Unit pemrosesan informasi terkecil dalam otak manusia adalah sel saraf, yang sering disebut juga neuron
- ada sekitar 10 milyar sel saraf dan sekitar 60 trilyun koneksi (sinap/synapse) antar sel saraf dalam otak manusia
- dengan menggunakan sel-sel saraf tersebut secara simultan, otak manusia dapat memproses informasi secara paralel dan cepat, bahkan lebih cepat dari komputer tercepat saat ini

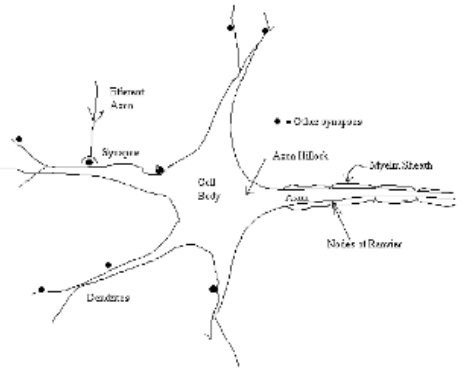
Jaringan Saraf Tiruan

sebuah sel saraf terdiri dari:

1. badan sel /soma
2. serangkaian sel yang menyalurkan informasi ke sel saraf (dendrit)
3. sel yang menyalurkan informasi keluar dari sel saraf (akson)

Jaringan Saraf Tiruan

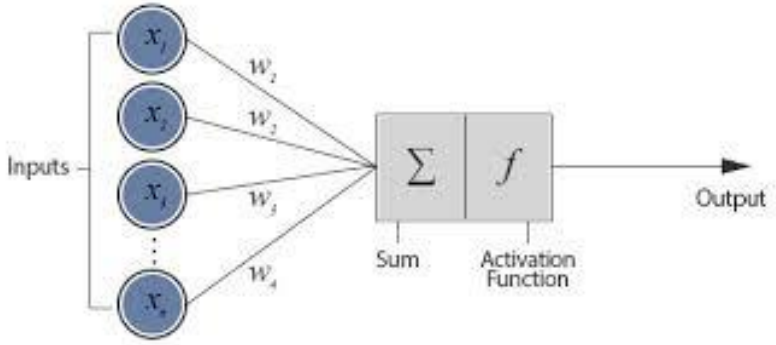
- sinyal yang diterima dendrit akan melewati sinaps untuk diteruskan ke sel saraf.
- sinyal ini diproses di dalam inti/badan sel (soma)
- hasil pengolahan sinyal akan dikeluarkan melalui akson untuk diteruskan ke neuron yang lain (atau hasil akhir pemrosesan di otak)



Jaringan Saraf Tiruan

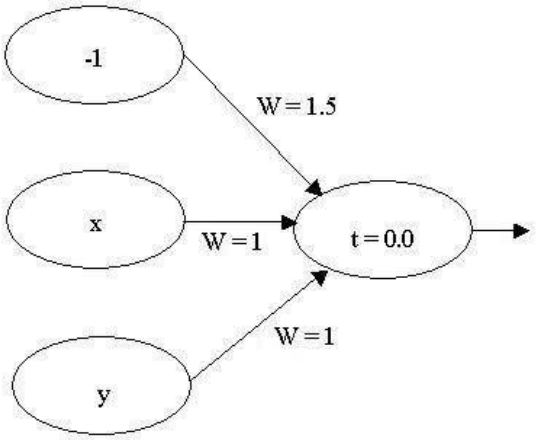
dengan analogi sistem kerja otak, Artificial Neural Network terdiri dari sebuah unit pemrosesan/neuron yang berisi:

1. adder,
2. fungsi aktivasi,
3. bobot (sinaps),
4. sejumlah input (dendrit)



Perceptron

- merupakan ANN berlayer tunggal
- feed forward
- perceptron sederhana menggunakan 1 neuron (hanya bisa membedakan 2 kelas)
- menggunakan fungsi aktivasi undak/step

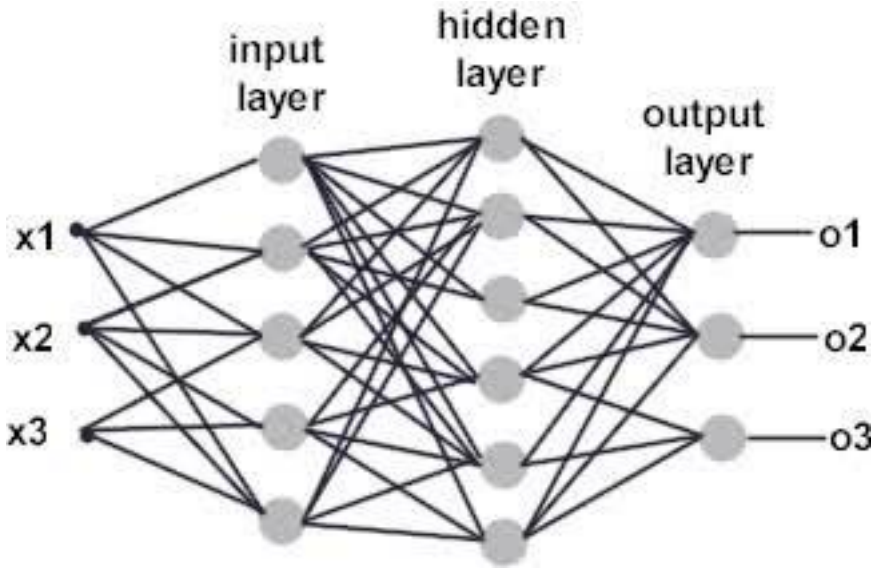


Perceptron

- bekerja dengan baik pada set data yang kelasnya dapat dipisahkan secara linear
- mampu menangani fitur redundan karena bobot identik akan dipelajari selama proses pelatihan
- sensitif terhadap noise
- pelatihan membutuhkan waktu yang lama
- hasil batas keputusan model yang didapatkan bisa berbeda pada setiap percobaan yang dilakukan.

Multi Layer Perceptron

- Untuk memperbaiki kinerja Perceptron yang tidak mampu bekerja dengan baik pada data yang kelasnya tidak bisa dipisahkan secara linear



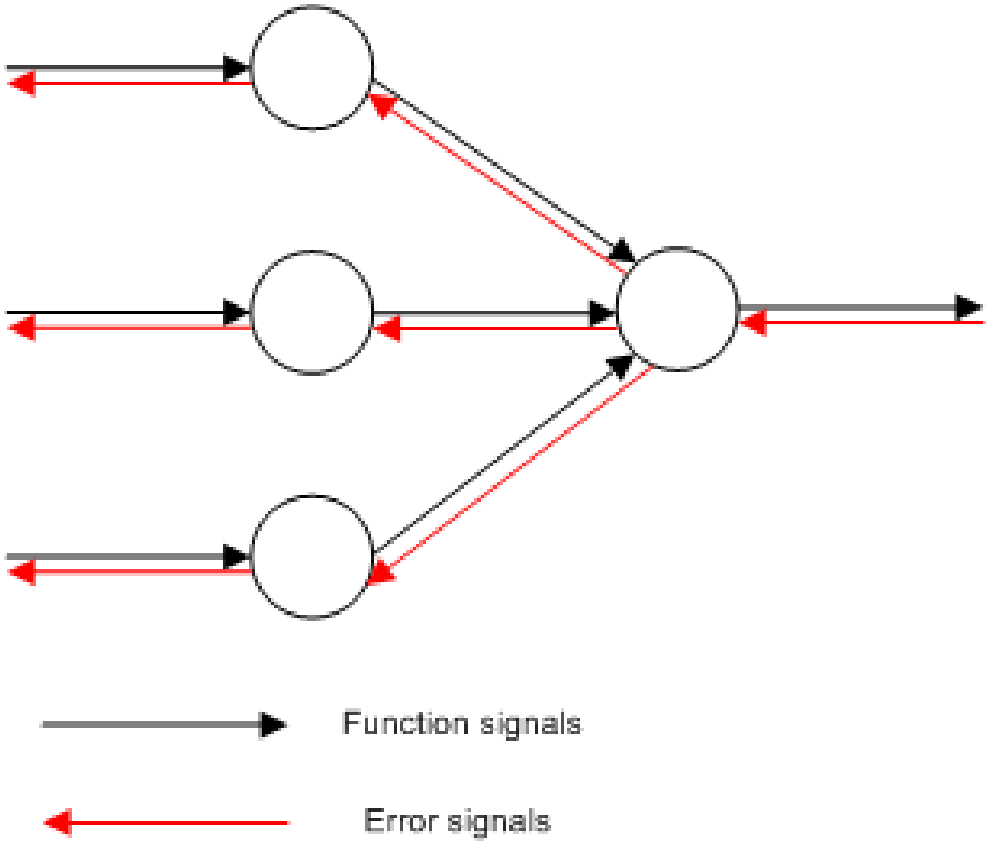
Multi Layer Perceptron

- ANN feedforward dengan satu atau lebih hidden layer
- sinyal input dirambatkan dengan arah maju pada layer per layer
- Metode pelatihan yang populer adalah backpropagation
- MLP Backpropagation memiliki 2 fase :

1. vektor masukan diberikan pada layer masukan. jaringan akan merambatkan pola masukan dari layer masukan ke hidden layer pertama, ke hidden layer kedua, dst, sampai nilai output dibangkitkan oleh layer keluaran

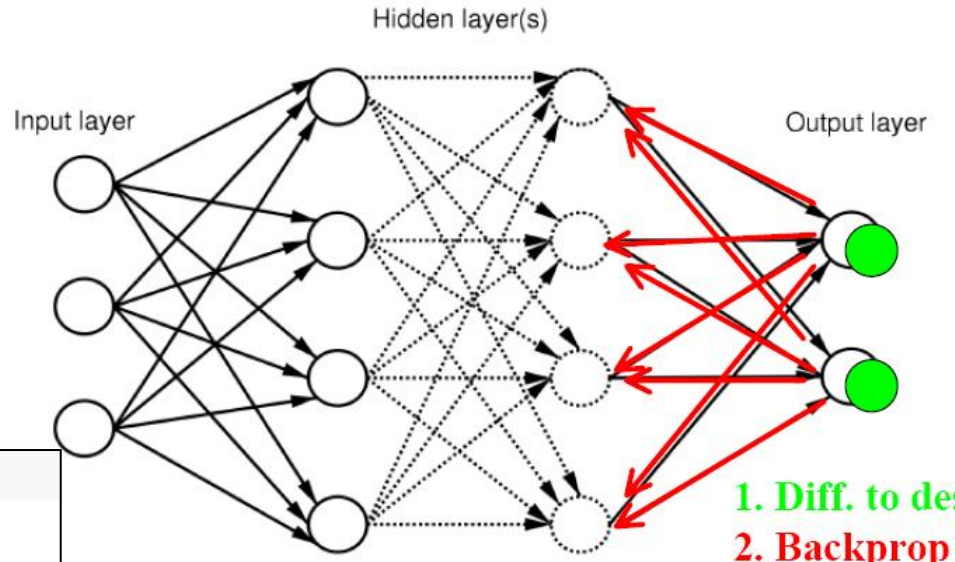
2. jika vektor nilai berbeda dengan yang diinginkan, error akan dihitung, kemudian dirambatkan balik ke dari layer keluaran s/d layer masukan. bobot akan dimodifikasi selama proses perambatan balik

Multi Layer Perceptron



Multi Layer Perceptron

Backpropagation Learning



Backpropagation Learning

$$E_{out\,i} = d_{out\,i} - out_i$$

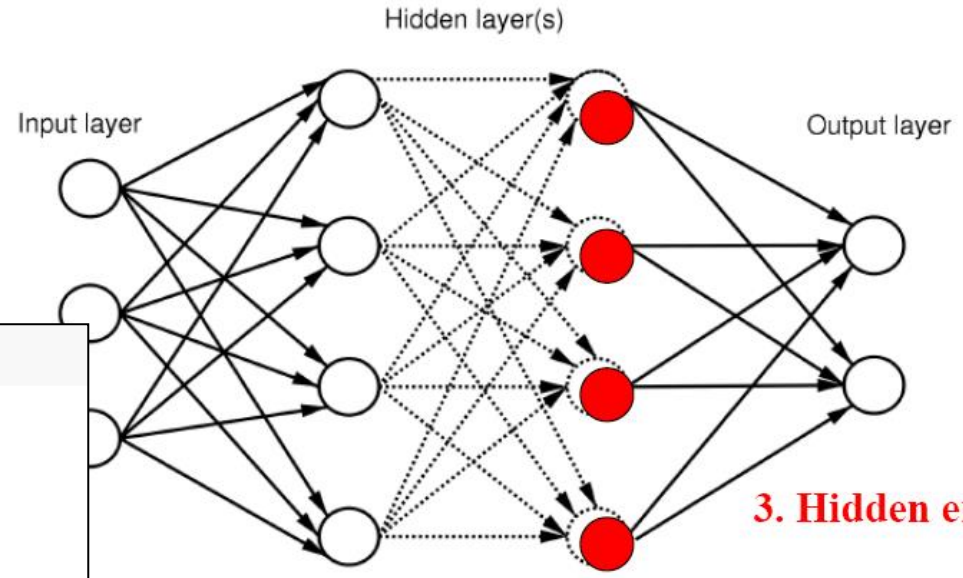
$$E_{total} = \sum_{i=0}^{num(n_{out})} E_{out\,i}^2$$

$$E_{hid\,i} = \sum_{k=1}^{num(n_{out})} E_{out\,k} \cdot w_{out\,i,k}$$

$$diff_{hid\,i} = E_{hid\,i} \cdot (1 - o(n_{hid\,i})) \cdot o(n_{hid\,i})$$

Multi Layer Perceptron

Backpropagation Learning



03

10

Backpropagation Learning

$$E_{out\ i} = d_{out\ i} - out_i$$

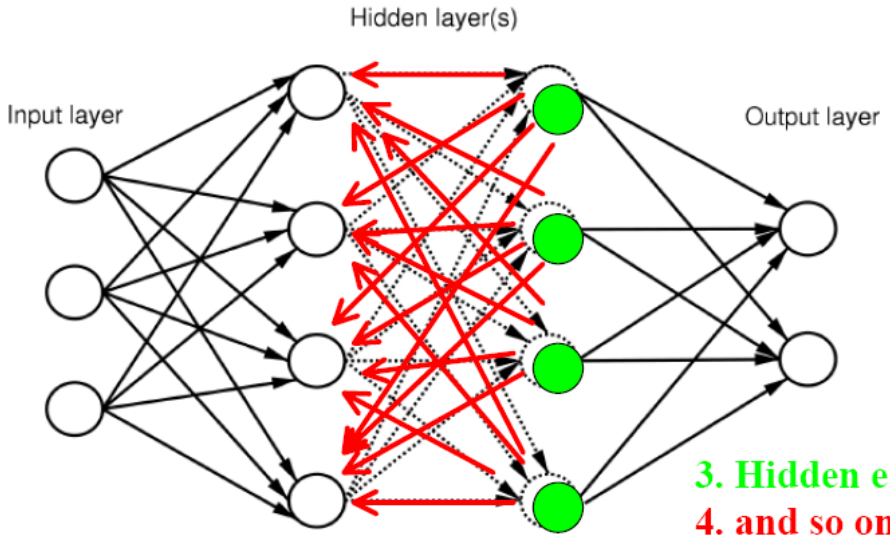
$$E_{total} = \sum_{i=0}^{num(n_{out})} E_{out\ i}^2$$

$$E_{hid\ i} = \sum_{k=1}^{num(n_{out})} E_{out\ k} \cdot w_{out\ i,k}$$

$$diff_{hid\ i} = E_{hid\ i} \cdot (1 - o(n_{hid\ i})) \cdot o(n_{hid\ i})$$

Multi Layer Perceptron

Backpropagation Learning



Bräunl 2003

11

Backpropagation Learni

$$E_{out\,i} = d_{out\,i} - out_i$$

$$E_{total} = \sum_{i=0}^{num(n_{out})} E_{out\,i}^2$$

$$E_{hid\,i} = \sum_{k=1}^{num(n_{out})} E_{out\,k} \cdot w_{out\,i,k}$$

$$diff_{hid\,i} = E_{hid\,i} \cdot (1 - o(n_{hid\,i})) \cdot o(n_{hid\,i})$$

Decision Tree

- Metode klasifikasi yang menggunakan struktur pohon untuk dalam representasi modelnya

- Decision tree mampu mem-*break down* proses pengambilan keputusan yang kompleks menjadi lebih simple, sehingga pengambil keputusan akan lebih menginterpretasikan solusi dari permasalahan

Decision Tree

Prosedur

1. Pilih sebuah attribut dalam dataset
2. Hitung significance dari attribut tersebut dalam menentukan output
3. Data dibagi berdasarkan nilai attribute terbaik
4. Ulangi proses 1 untuk setiap ‘cabang ‘ yang terbentuk

Decision Tree

Contoh :

- kita memiliki data dari pasien yang menderita penyakit yang sama
- Selama perawatan, ada dua jenis obat yang diberikan kepada para pasien tersebut (Obat A dan Obat B)
- Dari data tersebut kita ingin membangun model untuk mengetahui obat mana yang cocok untuk pasien tertentu

Decision Tree

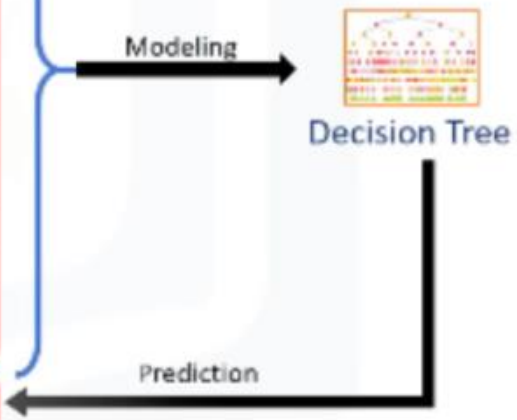
- Fitur input yang dikumpulkan : Age, Sex, Blood Pressure & cholestrol
- Targetnya : Drug A dan Drug B

Patient ID	Age	Sex	BP	Cholesterol	Drug
p1	Young	F	High	Normal	Drug A
p2	Young	F	High	High	Drug A
p3	Middle-age	F	Hiigh	Normal	Drug B
p4	Senior	F	Normal	Normal	Drug B
p5	Senior	M	Low	Normal	Drug B
p6	Senior	M	Low	High	Drug A
p7	Middle-age	M	Low	High	Drug B
p8	Young	F	Normal	Normal	Drug A
p9	Young	M	Low	Normal	Drug B
p10	Senior	M	Normal	Normal	Drug B
p11	Young	M	Normal	High	Drug B
p12	Middle-age	F	Normal	High	Drug B
p13	Middle-age	M	High	Normal	Drug B
p14	Senior	F	Normal	High	Drug A
p15	Middle-age	F	Low	Normal	?

Decision Tree

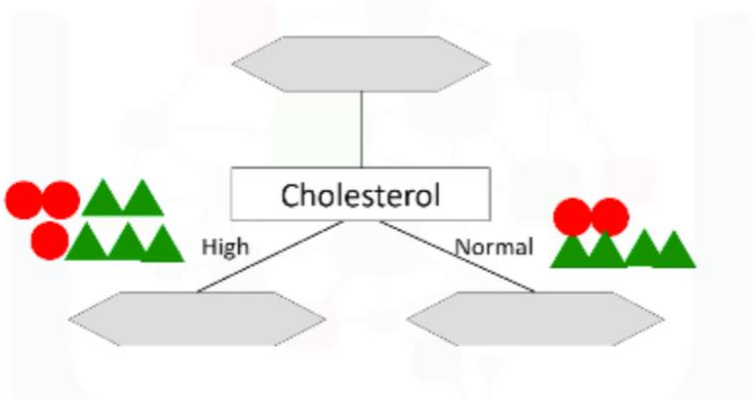
- Kita bisa membangun model Decision Tree untuk memprediksi obat yang cocok untuk pasien yang akan datang

Patient ID	Age	Sex	BP	Cholesterol	Drug
p1	Young	F	High	Normal	Drug A
p2	Young	F	High	High	Drug A
p3	Middle-age	F	Hiigh	Normal	Drug B
p4	Senior	F	Normal	Normal	Drug B
p5	Senior	M	Low	Normal	Drug B
p6	Senior	M	Low	High	Drug A
p7	Middle-age	M	Low	High	Drug B
p8	Young	F	Normal	Normal	Drug A
p9	Young	M	Low	Normal	Drug B
p10	Senior	M	Normal	Normal	Drug B
p11	Young	M	Normal	High	Drug B
p12	Middle-age	F	Normal	High	Drug B
p13	Middle-age	M	High	Normal	Drug B
p14	Senior	F	Normal	High	Drug A
p15	Middle-age	F	Low	Normal	?



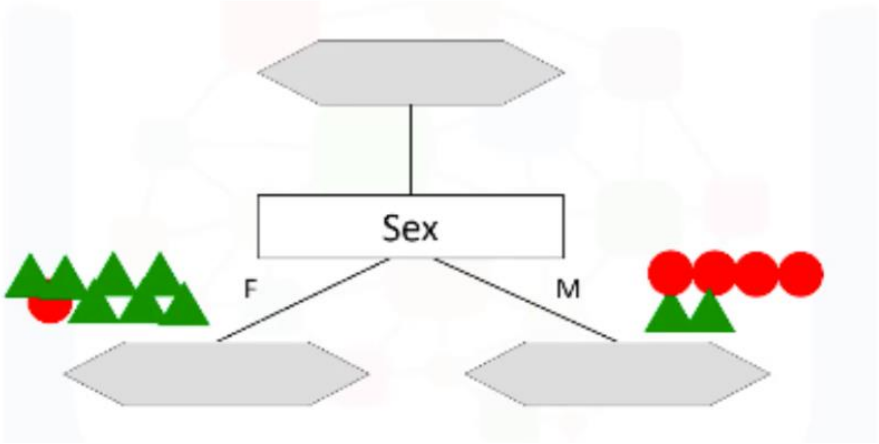
Decision Tree

- Kita bisa mulai melihat efek dari fitur input terhadap target
- Misal kita ambil fitur “cholesterol”, ada dua kategori cholesterol, ‘high’ dan ‘normal’
- High : 3 drug A dan 3 drug B
- Normal : 2 drug A dan 6 drug B



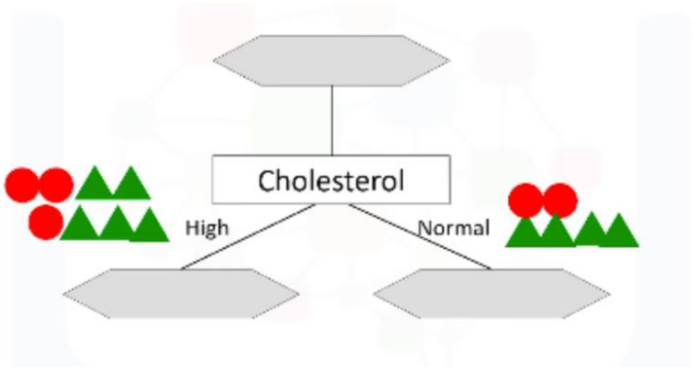
Decision Tree

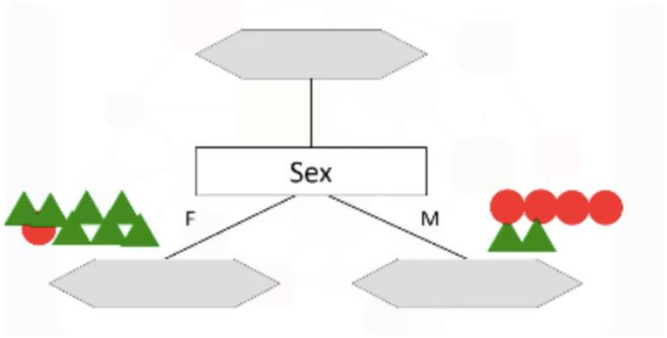
- Fitur : Sex
- male : 1 drug A , 6 drug B
- Female : 4 drug A dan 3 drug B
- Untuk pasien male, kita bisa lebih yakin untuk memberikan drug B, sedangkan untuk female, masih di butuhkan informasi tambahan



Decision Tree

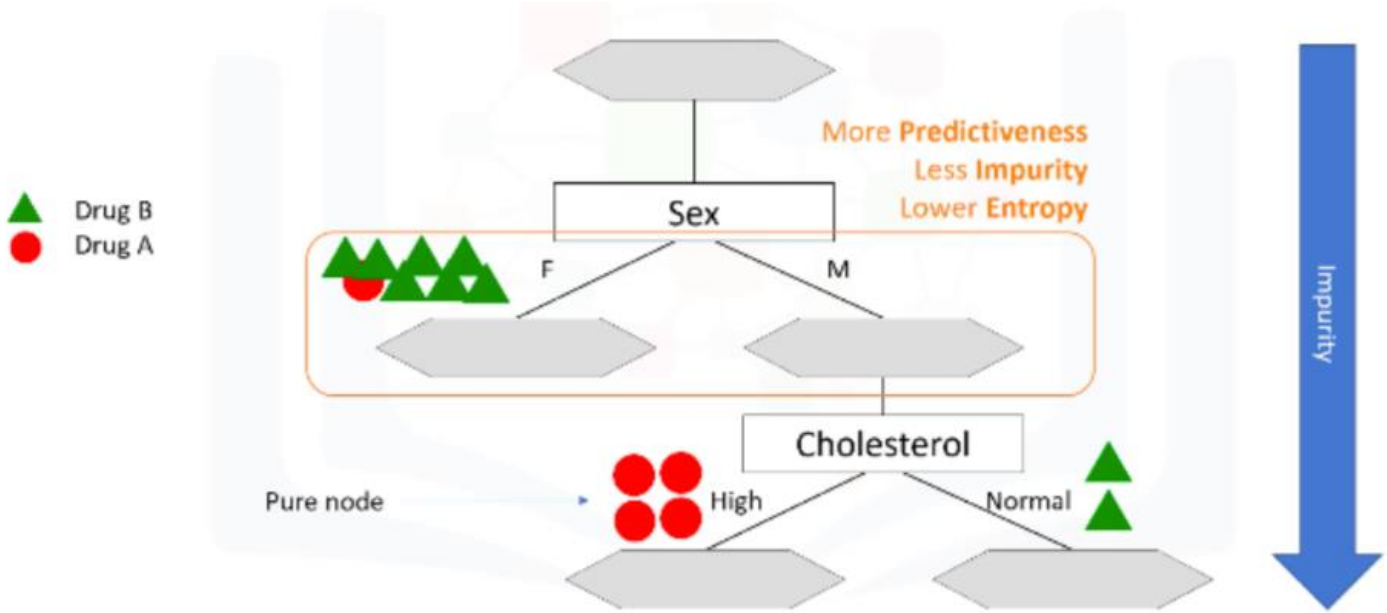
- Pada tahap ini, penggunaan fitur Sex lebih bagus dari pada cholesterol
- Fitur ‘Sex’ memberikan ‘purity’ yang lebih baik daripada fitur ‘cholesterol’
- Konsep purity/impurity ini yang dipakai untuk menentukan fitur mana yang paling baik dalam menentukan output





Decision Tree

- Untuk setiap cabang, fitur yang dipilih adalah yang menghasilkan imputiry minimal
- Impurity dihitung menggunakan ‘entropy’



Decision Tree

- Entropy adalah derajat ketidaktentuan atau derajat keacakan

$$\mathrm{H}(X) = -\sum_{i=1}^{n} \mathrm{P}(x_i) \log_b \mathrm{P}(x_i)$$



Entropy = - p(A)log(p(A)) - p(B)log(p(B))

Decision Tree

- Entropy data set

Patient ID	Age	Sex	BP	Cholesterol	Drug
p1	Young	F	High	Normal	Drug A
p2	Young	F	High	High	Drug A
p3	Middle-age	F	Hiigh	Normal	Drug B
p4	Senior	F	Normal	Normal	Drug B
p5	Senior	M	Low	Normal	Drug B
p6	Senior	M	Low	High	Drug A
p7	Middle-age	M	Low	High	Drug B
p8	Young	F	Normal	Normal	Drug A
p9	Young	M	Low	Normal	Drug B
p10	Senior	M	Normal	Normal	Drug B
p11	Young	M	Normal	High	Drug B
p12	Middle-age	F	Normal	High	Drug B
p13	Middle-age	M	High	Normal	Drug B
p14	Senior	F	Normal	High	Drug A

S: [9 B, 5 A]

$E = - p(B)\log(p(B)) - p(A)\log(p(A))$

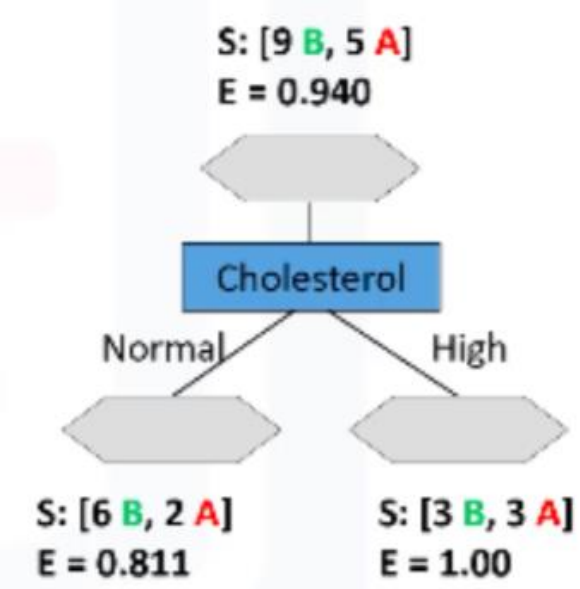
$E = - (9/14)\log(9/14) - (5/14)\log(5/14)$

$E = 0.940$

Decision Tree

- Entropy cholesterol

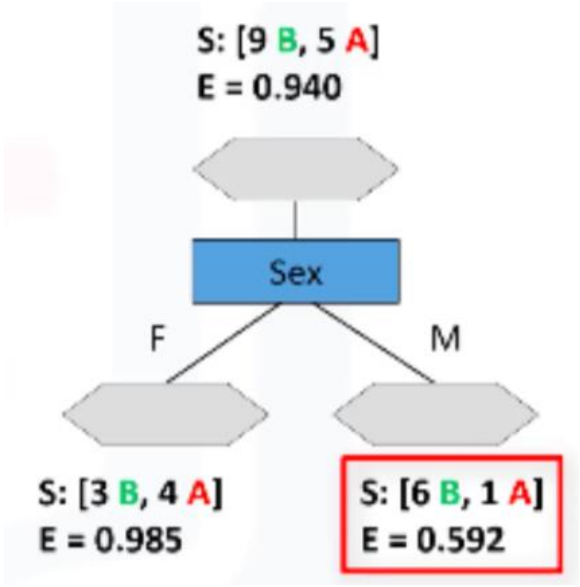
Patient ID	Age	Sex	BP	Cholesterol	Drug
p1	Young	F	High	Normal	Drug A
p2	Young	F	High	High	Drug A
p3	Middle-age	F	Hiigh	Normal	Drug B
p4	Senior	F	Normal	Normal	Drug B
p5	Senior	M	Low	Normal	Drug B
p6	Senior	M	Low	High	Drug A
p7	Middle-age	M	Low	High	Drug B
p8	Young	F	Normal	Normal	Drug A
p9	Young	M	Low	Normal	Drug B
p10	Senior	M	Normal	Normal	Drug B
p11	Young	M	Normal	High	Drug B
p12	Middle-age	F	Normal	High	Drug B
p13	Middle-age	M	High	Normal	Drug B
p14	Senior	F	Normal	High	Drug A



Decision Tree

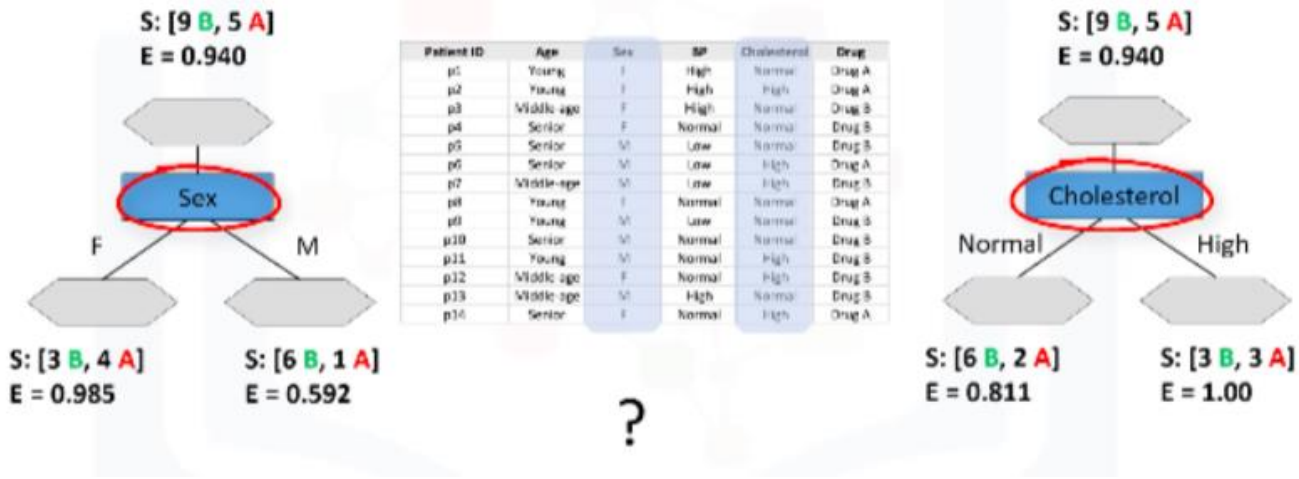
- Entropy Sex

Patient ID	Age	Sex	BP	Cholesterol	Drug
p1	Young	F	High	Normal	Drug A
p2	Young	F	High	High	Drug A
p3	Middle-age	F	Hiigh	Normal	Drug B
p4	Senior	F	Normal	Normal	Drug B
p5	Senior	M	Low	Normal	Drug B
p6	Senior	M	Low	High	Drug A
p7	Middle-age	M	Low	High	Drug B
p8	Young	F	Normal	Normal	Drug A
p9	Young	M	Low	Normal	Drug B
p10	Senior	M	Normal	Normal	Drug B
p11	Young	M	Normal	High	Drug B
p12	Middle-age	F	Normal	High	Drug B
p13	Middle-age	M	High	Normal	Drug B
p14	Senior	F	Normal	High	Drug A



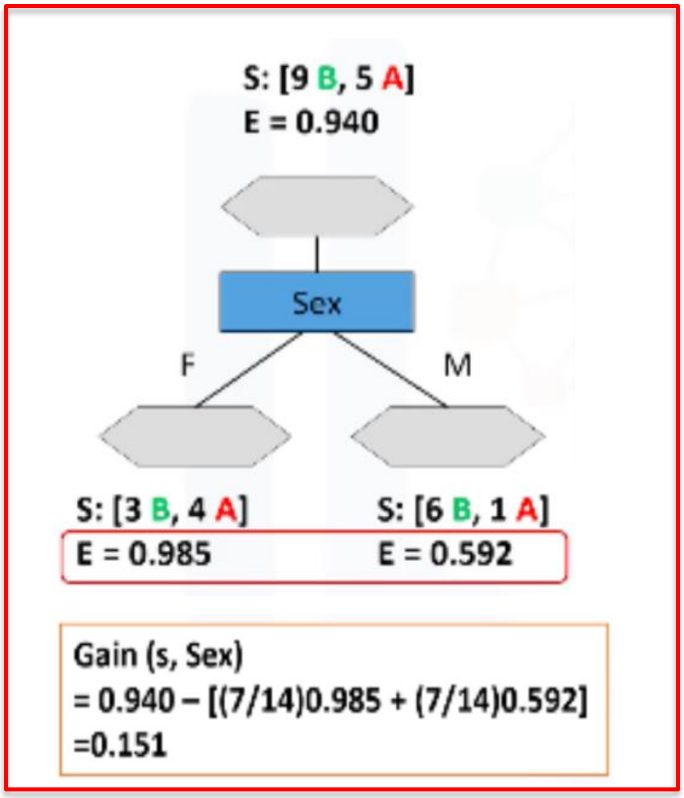
Decision Tree

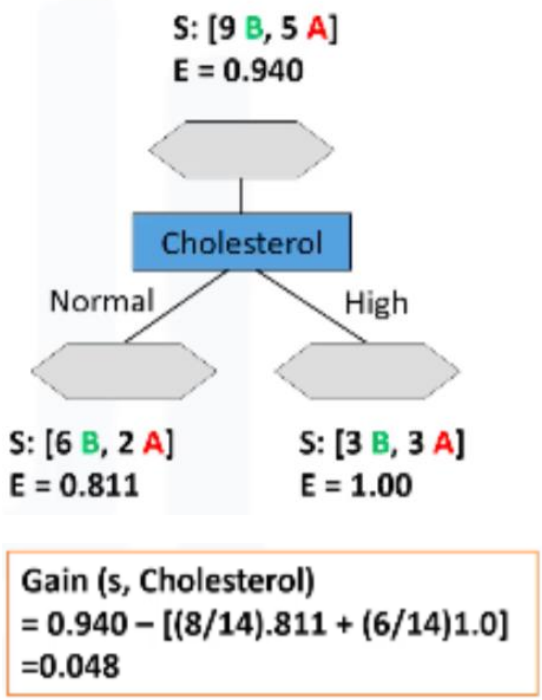
- Diantara cholesterol dan Sex, mana yang lebih baik sebagai atribut di cabang pertama?
- Attribut yang memberikan Gain Informasi lebih tinggi yang kana dipilih



Decision Tree

Information Gain = (Entropy before split) – (weighted entropy after split)





Support Vector Machine

- SVM : metode klasifikasi yang mentransformasikan data training ke dimensi yang lebih tinggi untuk mendapatkan batas class

Prosedur

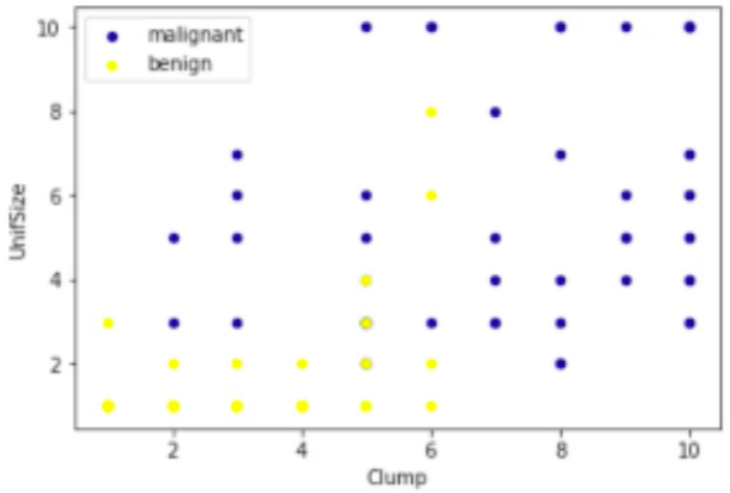
- Melakukan mapping data sehingga dimensi fitur spacenya lebih tinggi. Fitur space yang tinggi memungkinkan data dapat dikategorikan secara linear
- Menentukan pembatas antar kelas data

Support Vector Machine

Contoh :

Data tumor

Clump	UnifSize	UnifShape	MargAdh	SingEpiSize	BareNuc	BlandChrom	NormNucl	Mit	Class
5	1	1	1	2	1	3	1	1	benign
5	4	4	5	7	10	3	2	1	benign
3	1	1	1	2	2	3	1	1	malignant
6	8	8	1	3	4	3	7	1	benign
4	1	1	3	2	1	3	1	1	benign
8	10	10	8	7	10		7	1	malignant
1	1	1	1	2	10	3	1	1	benign
2	1	2	H	2	1	3	1	1	benign
2	1	1	1	2	1	1	1	5	benign
4	2	1	1	2	1	2	1	1	benign



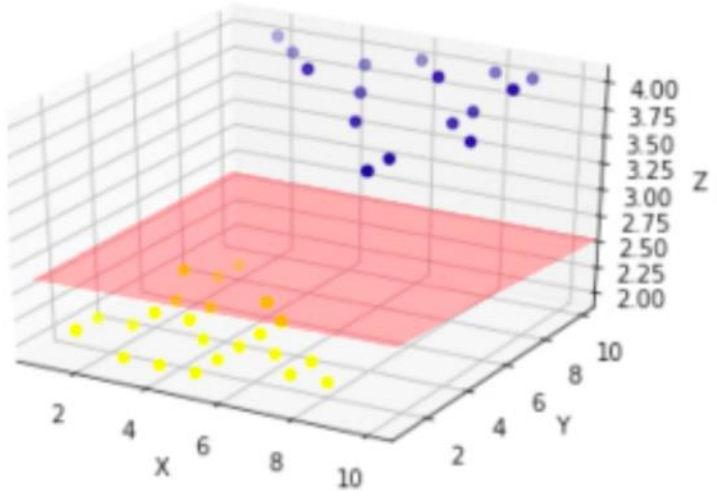
Sulit dipisahkan kelasnya

Support Vector Machine

Contoh :

Data tumor

Clump	UnifSize	UnifShape	MargAdh	SingEpiSize	BareNuc	BlandChrom	NormNucl	Mit	Class
5	1	1	1	2	1	3	1	1	benign
5	4	4	5	7	10	3	2	1	benign
3	1	1	1	2	2	3	1	1	malignant
6	8	8	1	3	4	3	7	1	benign
4	1	1	3	2	1	3	1	1	benign
8	10	10	8	7	10		7	1	malignant
1	1	1	1	2	10	3	1	1	benign
2	1	2	H	2	1	3	1	1	benign
2	1	1	1	2	1	1	1	5	benign
4	2	1	1	2	1	2	1	1	benign



Dipetakan ke dimensi yang lebih tinggi untuk memudahkan pengklasifikasian

Support Vector Machine

1. Bagaimana memetakan fitur data ke dimensi yang lebih tinggi?

2. Bagaimana menemukan pembatas terbaik (best hyperplane) dalam data yang sudah di transformasi tersebut?

Support Vector Machine

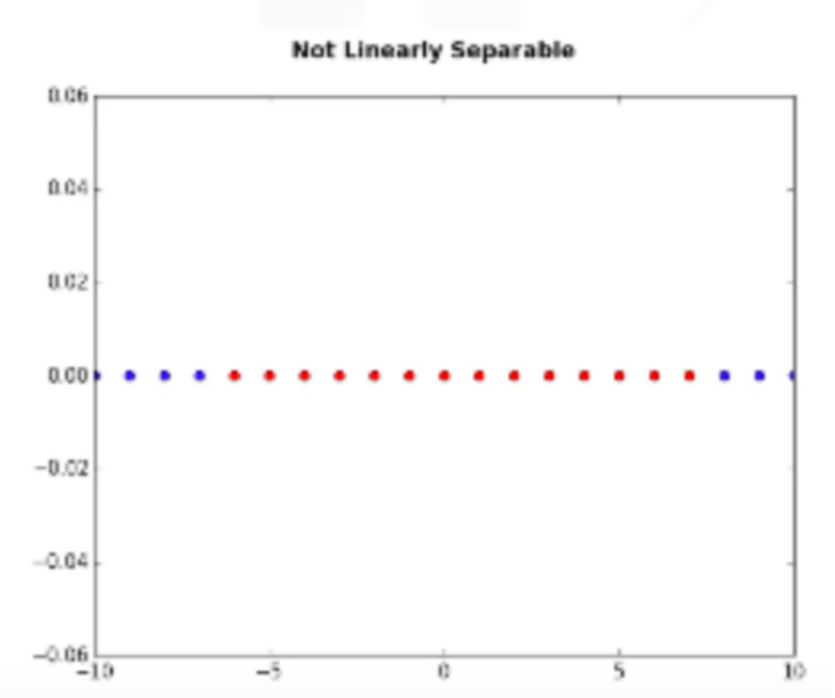
1. Bagaimana memetakan fitur data ke dimensi yang lebih tinggi?

- Menggunakan ‘kernelling’

Support Vector Machine

1. Bagaimana memetakan fitur data ke dimensi yang lebih tinggi?

Contoh :



Support Vector Machine

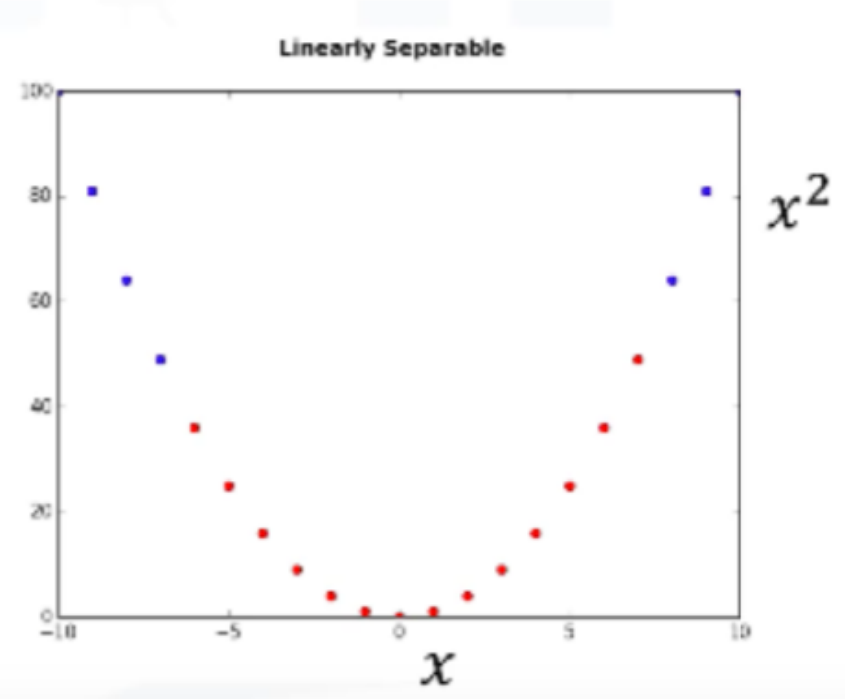
1. Bagaimana memetakan fitur data ke dimensi yang lebih tinggi?

Kita tingkatkan dimensi

Data dengan melakukan

mapping x ke dalam x-squared

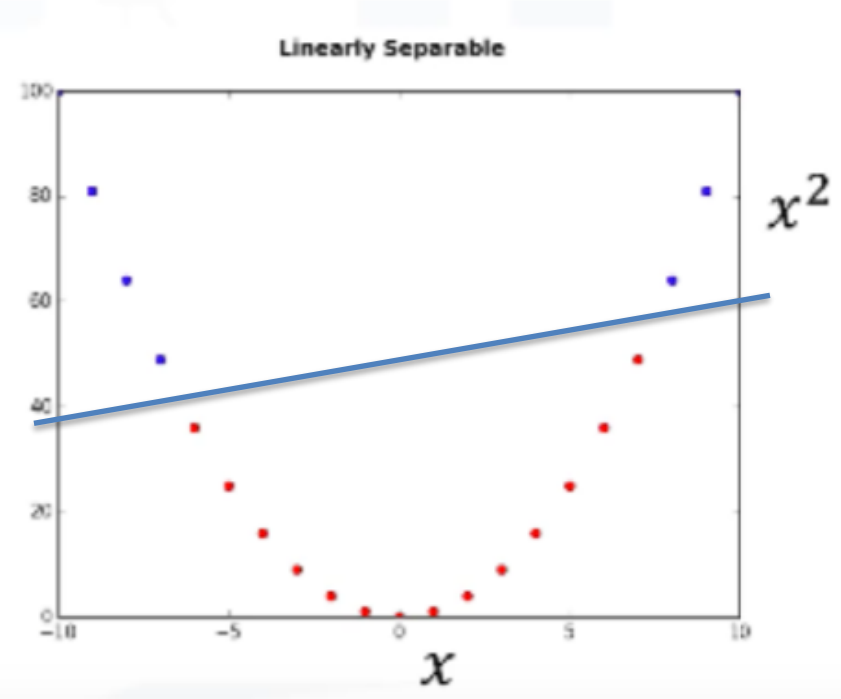
$$\phi(x) = [x, x^2]$$



Support Vector Machine

1. Bagaimana memetakan fitur data ke dimensi yang lebih tinggi?

Dimensi yang baru memungkinkan kita memisah data secara linear



Support Vector Machine

1. Bagaimana memetakan fitur data ke dimensi yang lebih tinggi?

Ada beberapa fungsi matematis yang dipakai untuk kernelling

a. Linear
b. Polynomial
c. Radial basis function (RBF)
d. Sigmoid

Support Vector Machine

1. Bagaimana memetakan fitur data ke dimensi yang lebih tinggi?

- Tiap fungsi memiliki karakteristik yang berbeda-beda
- Sulit untuk menentukan fungsi mana yang sesuai untuk suatu permasalahan / data set
- Membandingkan beberapa jenis fungsi untuk mendapatkan performa yang lebih baik

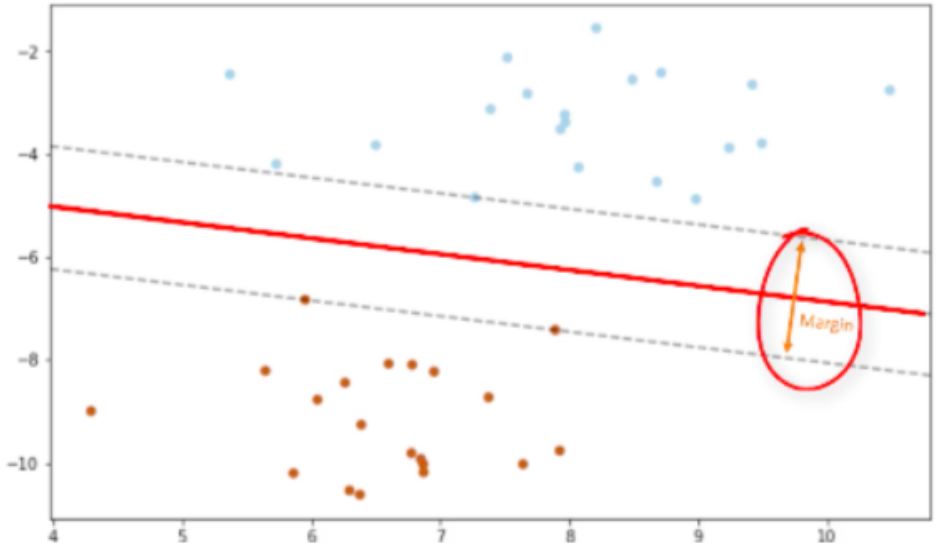
Support Vector Machine

2. Bagaimana menemukan pembatas terbaik (best hyperplane) dalam data yang sudah di transformasi tersebut?

Dengan mencari hyperplane terbaik yang bisa membagi data menjadi kelas-kelas

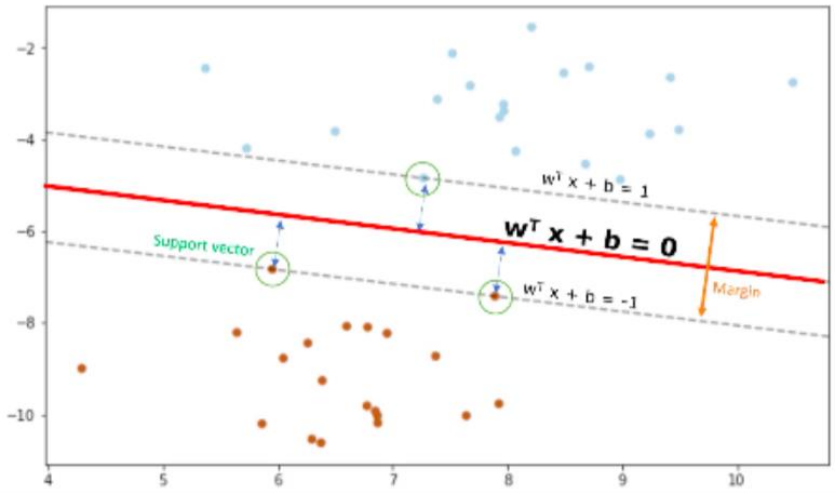
Support Vector Machine

- Misal data 2 dimensi, hyperplane dapat di ilustrasikan sebagai sebagai garis linear yang membagi data menjadi 2 kelas
- Hyperplane terbaik akan memiliki margin pemisah terbesar antara 2 kelas



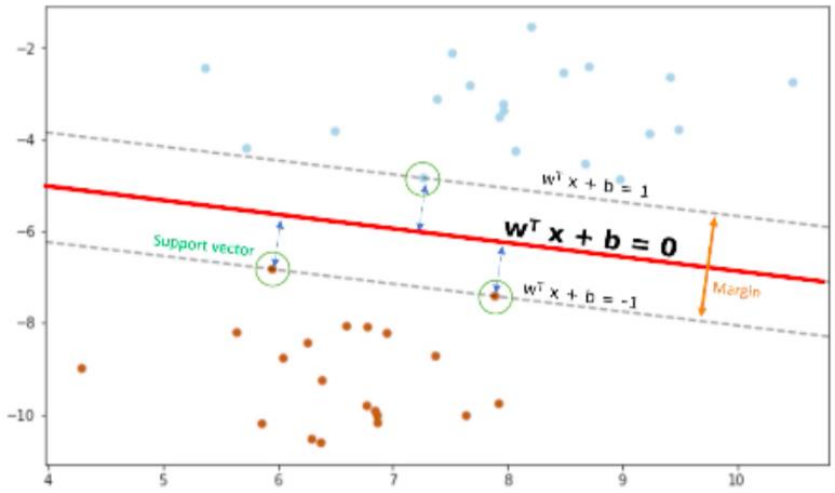
Support Vector Machine

- Hyperplane akan belajar dari training data untuk memaksimalkan margin pemisahnya
- Learning algorithm : gradient descent



Support Vector Machine

- Algoritma optimalisasi untuk mencari nilai ‘w’ dan ‘b’
- Setelah didapatkan nilai ‘w’ dan ‘b’, kita bisa menggunakan persamaan hyperplane untuk menentukan kelasnya. Jika hasil persamaan < 1, masuk kelas ‘merah’ dan jika > 1, masuk kelas ‘biru’



Support Vector Machine

Kelebihan (+)

- Akurat untuk dimensi tinggi
- efisien dalam penggunaan memori : Menggunakan subset training untuk menentukan ‘pembatas’ sehingga

Kekurangan (-)

- Rentan terhadap overfitting , terutama jika jumlah fiturnya lebih besar daripada jumlah data training
- Tidak efisien dari sisi computational cost untuk data set yang besar

Issues

- Data-related changes :
  - kualitas data
  - ketersediaan data
  - Bias Data
  - Privasi dan kepemilikan data

- Model
  - overfitting
  - kehandalan model
  - interpretability (explainable AI)

Issues

- Computational
  - komputasi yang sangat tinggi
  - implikasi lingkungan (panas, emisi karbon)

- Metode
  - reproduceability crisis : susah di reproduksi
  - benchmark overfitting
  - lack of theoretical understanding

Terima Kasih