Data Science



Hindriyanto Dwi Purnomo, Ph.D

Data Science Life Cycle

- Menerapkan Data Science bukanlah hal yang mudah
- Setidaknya ada 4 faktor yang dapat menyebabkan kegagalan dalam penerapan Data Science, yaitu :
  a. Ruang lingkup permasalahan
  b. Data
  c. Model
  d. Sumber Daya Manusia

a. Ruang Lingkup Pemasalahan :

- Permasalahan yang dihadapi tidak jelas
- Permasalahan yang dihadapi tidak bisa diselesaikan berbasis data

b. Data

- Data tidak tersedia
- Kualitas data rendah (tidak lengkap, tidak valid, terduplikasi)
- Bias

c. Model

- Tidak akurat
- Tidak dapat dipahami

d. Sumber daya manusia

- SDM yang dibutuhkan tidak tersedia
- SDM tidak memenuhi kualifikasi

- Untuk meningkatkan keberhasilan penerapan Data Science, diperlukan ’Data Science Life Cycle’ yang membantu Data Scientist dalam melakukan tahapan demi tahapan dalam project Data Science
- Data Science Life Cycle adalah serangkaian tahapan iteratif yang dilakukan untuk menyelesaikan project Data Science
- Data Science Life Cycle tidak bergantung pada teknologi atau tools yang dipakai

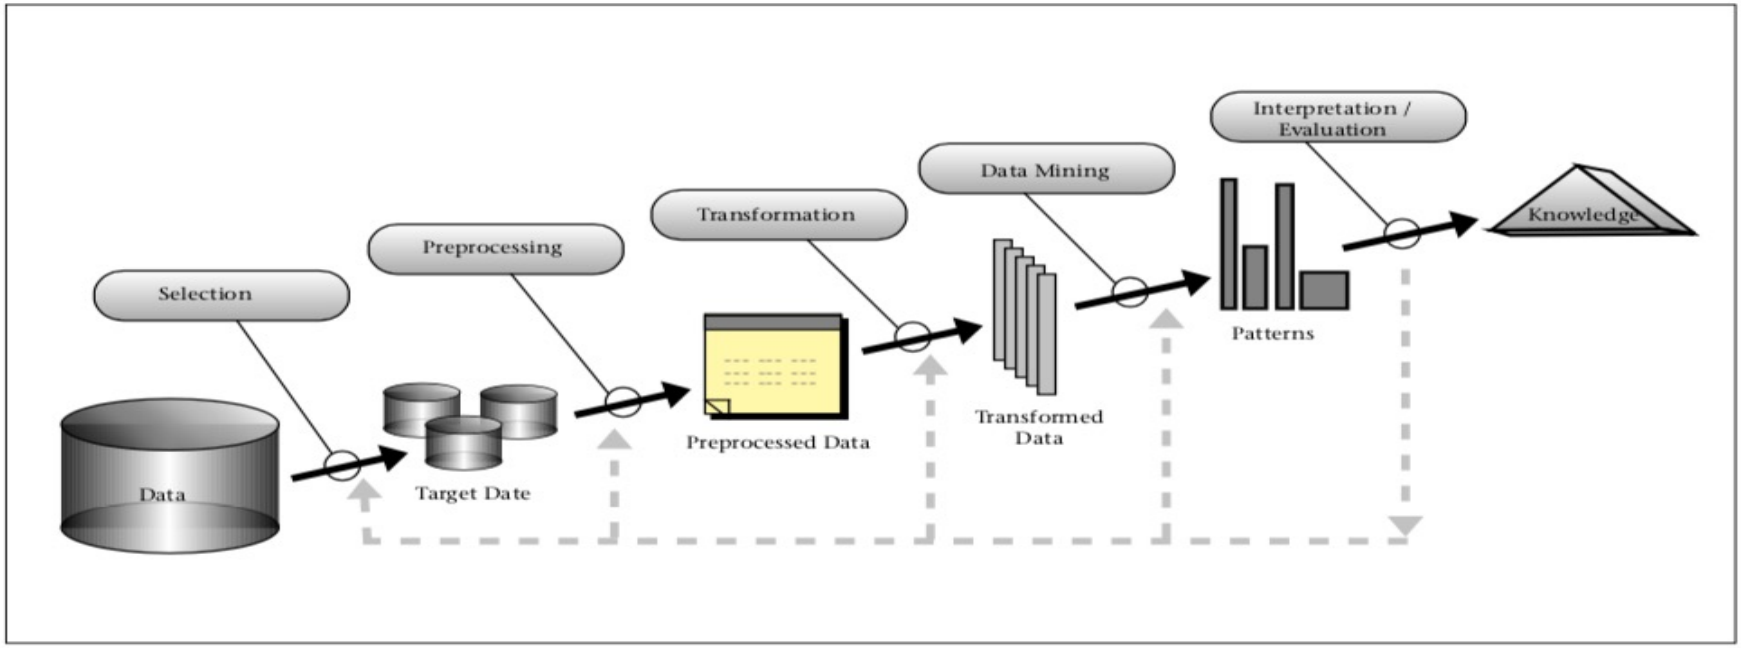
Data Science Life Cycle

Ada beberapa model Data Science Life Cycle yang umum dipakai, yaitu :

1. Knowledge Discovery in Database (KDD)
2. SEMMA
3. Cross Industry Standard Process for Data Mining (CRISP-DM)
4. IBM Data Science Methodology

Tahapan KDD

- KDD memiliki 5 tahap : Seleksi, preprocessing, transformation, data mining dan interpretasi/evaluasi



Fayyad, dkk, 1996

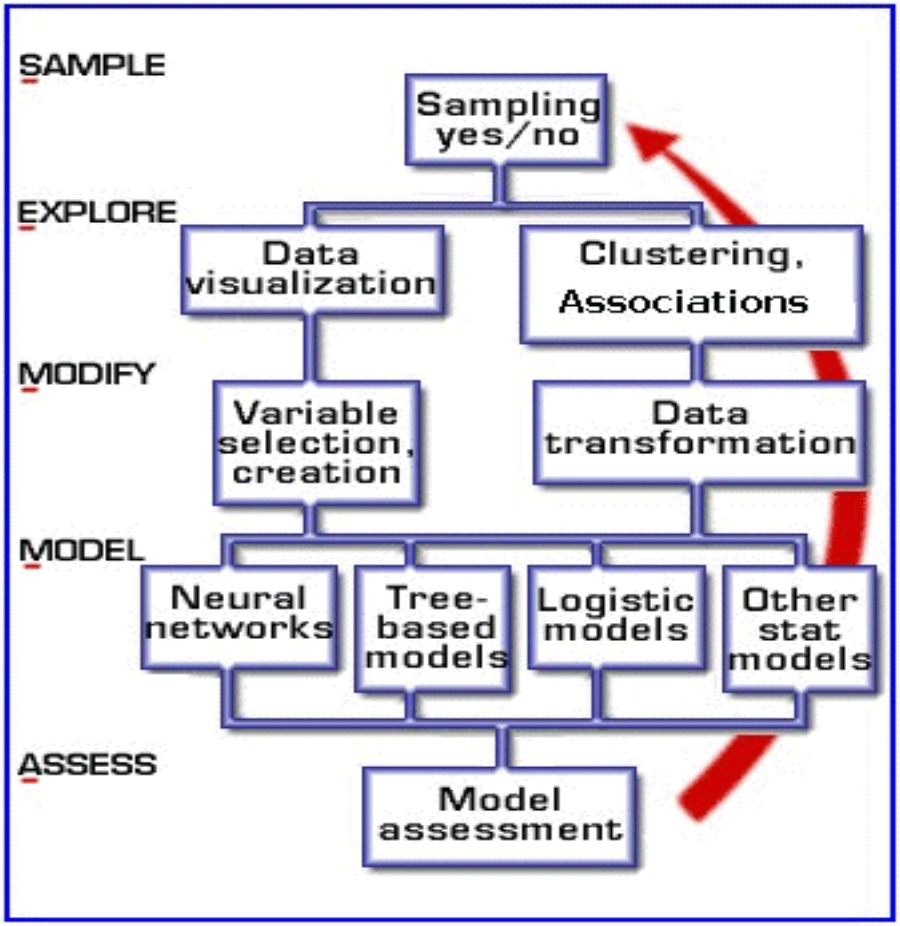
Tahapan KDD

1. **Seleksi :** memilih data yang akan menjadi sampel untuk tahapan selanjutnya
2. **Pre processing :** melengkapi data maupun menjaga konsistensi data
3. **Transformasi :** melakukan transformasi data supaya lebih mudah diolah dalam proses selanjutnya
4. **Data Mining :** mencari trend/pola atau informasi penting dalam data
5. **Interpretasi/Evaluasi** : melakukan interpretasi dan mengevaluasi trend/informasi yang didapatkan

SEMMA

- SEMMA merupakan akronim dari : Sample, Explore, Modify, Model dan Assess
- Tahapan awal SEMMA dimulai dari data yang kemudian diproses lebih lanjut untuk mendapatkan informasi penting

Tahapan SEMMA



SAS Institute (https://documentation.sas.com/doc/en/emref/14.3/n061bzurmej4j3n1jnj8bbjjm1a2.htm)

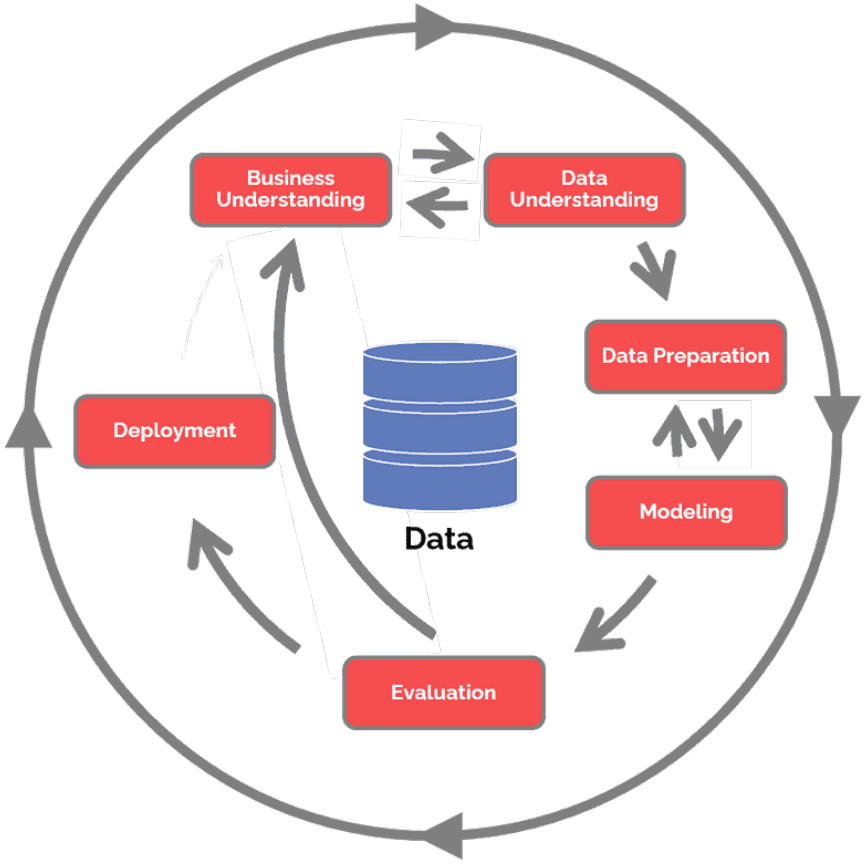
Tahapan SEMMA

1. Sample : Mengambil sample data dari sumber data
2. Explore : mengekplorasi data untuk meningkatkan pemahaman tentang data (misal : melihat relasi antar variabel, mendeteksi adanya anomali, melakukan visualisasi)
3. Modify : melakukan transformasi data dan pemilihan variabel yang lebih sesuai dengan proses berikutnya (pemodelan)
4. Model : melakukan pemodelan data untuk mencari kombinasi data yang menghasilkan prediksi yang tepat
5. Assesment : melalukan penilaian terkait kemanfaatan (usefulness) dan kehandalan (reliability) hasil yang diperoleh

Cross Industry Standard Process for Data Mining (CRISP-DM)

- CRISP-DM mulai dikembangkan sekitar tahun 1997
- Tahap awal CRISP-DM dimulai dari memahami permasalahan bisnis.
- CRISP-DM memiliki 6 tahap : Business Understanding, Data Understanding, Data Preparation, Modelling, Evaluation dan Deployment

Tahapan CRISP - DM



https://www.datascience-pm.com/crisp-dm-2/

Tahapan CRISP - DM

1. Business understanding : memahami proses bisnis dan mengidentifikasi permasalahan bisnis yang akan diselesaikan
2. Data understanding : mengidentifikasi data-data yang diperlukan, mengumpulkan data dan mengeksplorasi data yang sudah dikumpulkan
3. Data preparation : memperbaiki kualitas dan representasi data sehingga memudahkan dalam proses selanjutnya

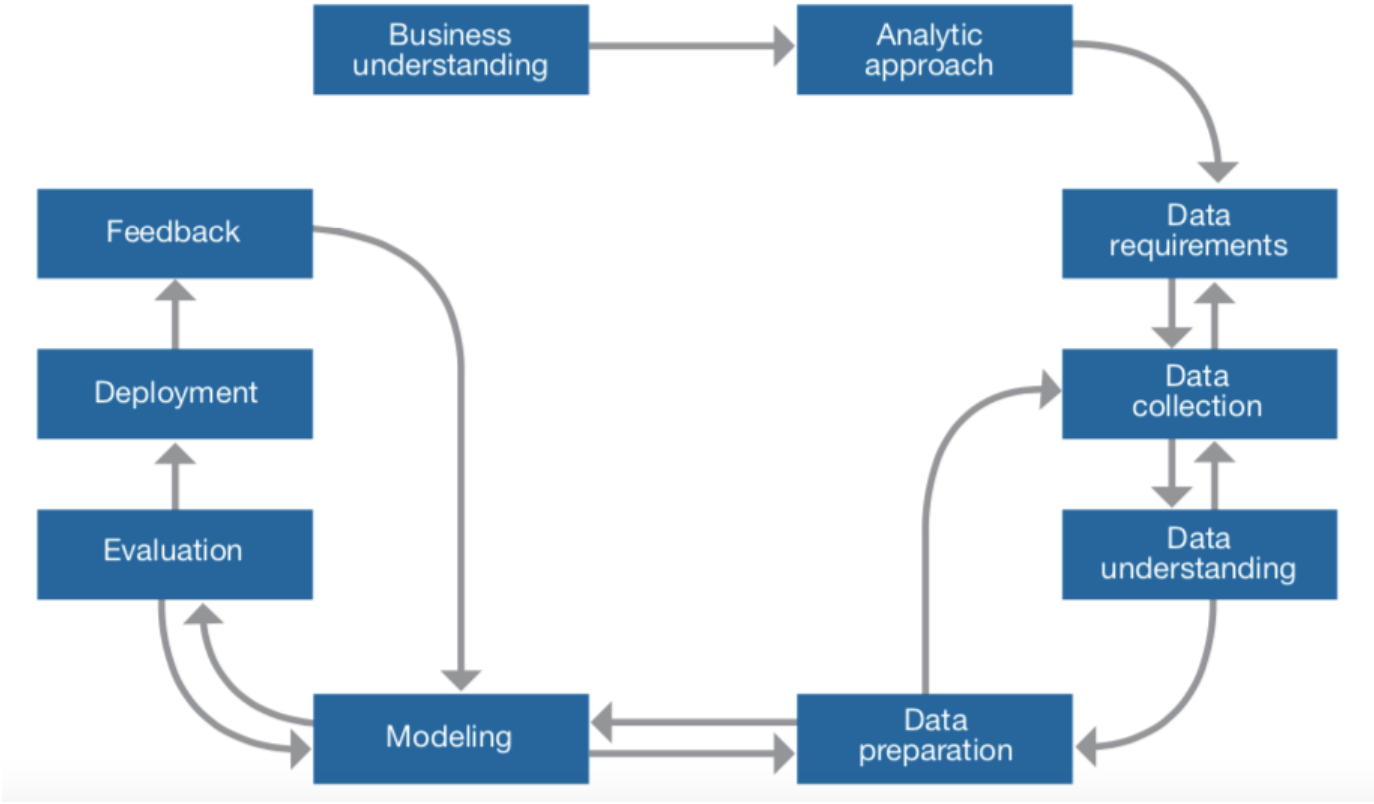
Tahapan CRISP - DM

4. Modeling : memilih teknik pemodelan yang sesuai dan menerapkannya pada data untuk mendapatkan model yang diinginkan
5. Evaluation : mengevaluasi model yang dihasilkan
6. Deployment : mengimplementasikan model supaya bisa dimanfaatkan oleh para pengguna

IBM Data Science Methodology

- IBM Data Science Methodology merupakan pengembangan CRISP – DM yang dilakukan oleh IBM
- IBM Data Science Methodology merupakan salah satu metodologi yang paling popular bagi Data Scientist
- Tahapa awal IBM Data Science methodology dimulai dari memahami permasalahan bisnis
- IBM Data Science Methodology memiliki 10 tahap

Tahapan IBM Methodology Data Science



IBM, Foundational Methodology for Data Science, 2015 , pg. 3

Tahapan IBM Methodology Data Science

1. Business understanding : memahami proses bisnis dan mengidentifikasi permasalahan bisnis yang akan diselesaikan
2. Analytics approach : menentukan pendekatan analitic yang akan dipergunakan untuk menyelesaikan permasalahan
3. Data requirement : mengidentifikasi data yang diperlukan, seperti format data, representasi data maupun isi data

Tahapan IBM Methodology Data Science

4. Data collection : mengumpulkan data-data yang diperlukan dari berbagai sumber yang ada
5. Data understanding : melakukan penilaian terhadap kuaitas data yang udah dikumpulkan, melakukan visualisasi dan statistika deskriptif untuk lebih memahami data
6. Data preparation : melakukan konstruksi data untuk mendapatkan representasi yang sesuai dengan tahap selanjutnya

Tahapan IBM Methodology Data Science

7. Modelling : membangun model berdasarkan data yang sudah dipersiapkan
8. Evaluation : melakukan evaluasi model untuk melihat kesesuaian dan reliabilitasnya
9. Deployment : mengimplementasikan model yang sudah dievaluasi ke dalam proses operasional supaya bisa dimanfaatkan pengguna (user)

Tahapan IBM Methodology Data Science

10. Feedback : melakukan evaluasi implementasi dari model untuk mendapatkan umpan balik dari pengguna. Umpan balik dapat berupa umpan balik terkait modelnya maupun implementasinya

Review

- 4 faktor yang dapat menyebabkan penerapan Data Science mengalami kegagalan:
  a. Ruang lingkup permasalahan
  b. Data
  c. Model
  d. Sumber Daya Manusia

Review

- Model Data Science Life Cycle
  a. Knowledge Discovery in Database
  b. SEMMA
  c. CRISP-DM
  d. IBM Data Science Methodology

Terima kasih