Metodologi Data Science



Prof. Hindriyanto D. Purnomo, Ph.D

Regression

Pendahuluan

- Uji regresi dipakai untuk memprediksi dan mengukur nilai dari pengaruh satu variabel (bebas/independent/ predictor) terhadap variabel lain (tak bebas/ dependent/ response)

- Analisis/uji regresi merupakan suatu kajian dari hubungan antara satu variabel, yaitu variabel yang diterangkan (the explained variabel) dengan satu atau lebih variabel, yaitu variabel yang menerangkan (the explanatory).

Pendahuluan

- Apabila variabel bebasnya hanya satu, maka analisis regresinya disebut dengan regresi linear sederhana.

- Apabila variabel bebasnya lebih dari satu, maka analisis regresinya dikenal dengan regresi linear berganda.
  - Dikatakan berganda karena terdapat beberapa variabel bebas yang mempengaruhi variabel tak bebas

Pendahuluan

- Analisis/uji regresi banyak digunakan dalam perhitungan hasil akhir untuk penulisan karya ilmiah/penelitian.

- Hasil perhitungan analisis/uji regresi akan dimuat dalam kesimpulan penelitian dan akan menentukan apakah penelitian yang sedang dilakukan berhasil atau tidak.

- Hasil dari analisis/ uji regresi berupa suatu persamaan regresi.
  - Persamaan regresi ini merupakan suatu fungsi prediksi variable yang mempengaruhi variabel lain

Tipe Regresi

Regresi sederhana

- Regresi linear sederhana
- Regresi nonlinear sederhana

Regresi Variabel Jamak

- Regresi variabel jamak linear
- Regresi variabel jamak non linear

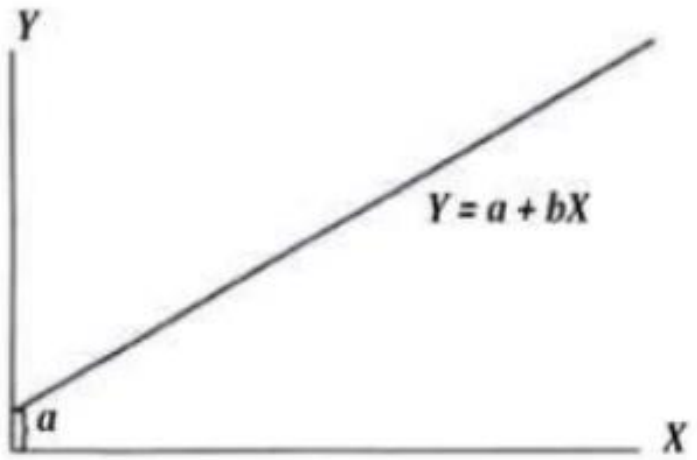
Algoritma Regresi

- Linear regression
- Polynomial regression
- Support vector regression
- Decision tree regression
- Random forest regression
- LASSO regression
- dll

Regresi Linear Sederhana

- Model Persamaan Regresi Linear Sederhana adalah seperti berikut ini :
  - **Y = a + bX**

- Dimana :
  - Y = Variabel Response atau Variabel Akibat (Dependent)
  - X = Variabel Predictor atau Variabel Faktor Penyebab (Independent)
  - a = konstanta
  - b = koefisien regresi (kemiringan/slope); besaran Response yang ditimbulkan oleh Predictor .



Regresi Linear Sederhana

- Besarnya konstanta **a** dan **b** dapat ditentukan menggunakan persamaan:

$$a = \frac{(\sum Y_i)(\sum X_i^2) - (\sum X_i)(\sum X_i Y_i)}{n\sum X_i^2 - (\sum X_i)^2}$$

$$b = \frac{n\ (\sum X_i Y_i) - (\sum X_i)(\sum Y_i)}{n\sum X_i^2 - (\sum X_i)^2}$$

yang mana n = jumlah data

Analisa Regresi Linear Sederhana

- Adapun langkah-langkah yang perlu dilakukan untuk melakukan analisis dan uji regresi linier sederhana adalah sebagai berikut:

1. Menentukan tujuan dari Analisis Regresi Linear Sederhana
2. Mengidentifikasi variabel predictor dan variabel response
3. Melakukan pengumpulan data dalam bentuk table
4. Menghitung X^2, Y^2, XY dan total dari masing-masingnya
5. Menghitung a dan b menggunakan rumus yang telah ditentukan
6. Membuat model Persamaan Garis Regresi
7. Melakukan prediksi terhadap variabel predictor atau response
8. Uji korelasi

Contoh

- “ **Terdapat suatu data penelitian tentang berat badan 10 mahasiswa yang diprediksi dipengaruhi oleh konsumsi jumlah kalori/hari**”.
- Bagaimana menganalisisnya?

1. Menentukan Tujuan : “Apakah konsumsi jumlah kalori/hari mempengaruhi berat badan mahasiswa?”
2. Mengidentifikasi variabel predictor dan variabel response

   X (variable bebas/ predictor) = jumlah kalori/hari

   Y (variable tak bebas/ response) = berat badan

3. Melakukan pengumpulan data dalam bentuk tabel

Nama Mahasiswa	Kalori/ hari (X)	Berat Badan (Y)
Adi	530	89
Rudi	300	48
Didi	358	56
Budi	510	72
Intan	302	54
Putu	300	42
Partadiyasa	387	60
Esti	527	85
Ike	415	63
Rojali	512	74

4. Menghitung X^2, Y^2, XY dan total dari masing-masingnya

	X	X^2	Y	Y^2	XY
	530	280900	89	7921	47170
	300	90000	48	2304	14400
	358	128164	56	3136	20048
	510	260100	72	5184	36720
	302	91204	54	2916	16308
	300	90000	42	1764	12600
	387	149769	60	3600	23220
	527	277729	85	7225	44795
	415	172225	63	3969	26145
	512	262144	74	5476	37888
∑	4141	1802235	643	43495	279294

5. Menghitung a dan b menggunakan rumus yang telah ditentukan

$$a = \frac{(\sum Y_i)(\sum X_i^2) - (\sum X_i)(\sum X_i Y_i)}{n \sum X_i^2 - (\sum X_i)^2}$$

$$= \frac{(643)(1802235) - (4141)(279294)}{10(1802235) - (4141)^2} = \frac{2280651}{874469} \cong 2{,}608$$

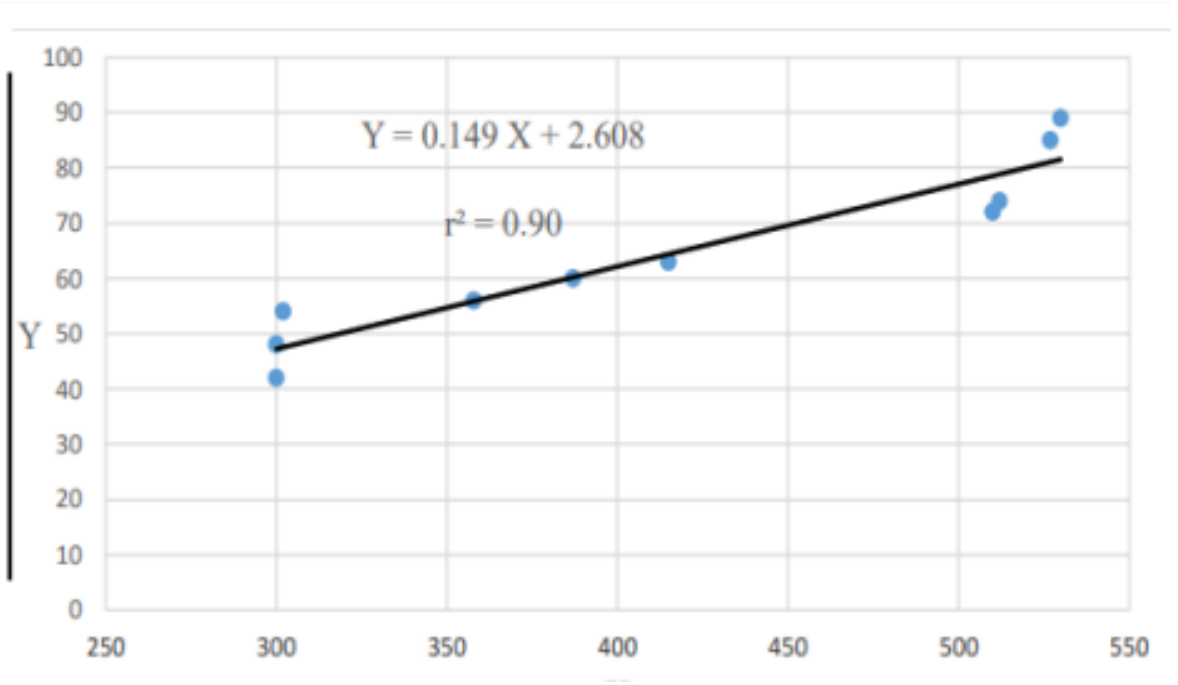
$$b = \frac{n (\sum X_i Y_i) - (\sum X_i)(\sum Y_i)}{n \sum X_i^2 - (\sum X_i)^2}$$

$$= \frac{10(279294) - (4141)(643)}{10(1802235) - (4141)^2} = \frac{130227}{874469} \cong 0{,}14892 \approx 0{,}149$$

- Membuat model Persamaan Garis Regresi

- Setelah didapat koefisien a dan b, maka persamaan garisnya adalah:

Y = 2,608 + 0,149 X



7. Melakukan prediksi terhadap variabel predictor atau response

- Prediksikan berat badan mahasiswa jika asupannya adalah 600 kalori/ hari:

$Y = 2{,}608 + 0{,}149\ X$

- Prediksi $Y = 2{,}608 + (0{,}149 * 600) = 92$ kilo gram

- Prediksikan asupan mahasiswa, jika berat badan mahasiswa adalah 40 kilo gram:

$40 = 2{,}608 + 0{,}149\ X$

$37{,}392 = 0{,}149X$

- Prediksi X = 250.59 kalori/ hari

Uji Korelasi

- Untuk mengukur kekuatan hubungan antar variable predictor X dan response Y, dilakukan analisis korelasi yang hasilnya dinyatakan oleh suatu bilangan yang dikenal dengan koefisien korelasi.
- Analisis regresi sering dilakukan bersama-sama dengan analisis korelasi. Persamaan koefisien korelasi (r) diekspresikan oleh:

$$r = \frac{n\sum_{i=1}^{n} Xi\,Yi - \left(\sum_{i=1}^{n} Xi\right)\left(\sum_{i=1}^{n} Yi\right)}{\sqrt{\left[n\sum_{i=1}^{n} X_i^2 - \left(\sum_{i=1}^{n} Xi\right)^2\right]\left[n\sum_{i=1}^{n} Y_i^2 - \left(\sum_{i=1}^{n} Yi\right)^2\right]}}$$

Uji Korelasi

- Berdasarkan data tabel, maka koefisien korelasinya adalah:

$$r = \frac{n\sum_{i=1}^{n} X_i Y_i - \left(\sum_{i=1}^{n} X_i\right)\left(\sum_{i=1}^{n} Y_i\right)}{\sqrt{\left[n\sum_{i=1}^{n} X_i^2 - \left(\sum_{i=1}^{n} X_i\right)^2\right]\left[n\sum_{i=1}^{n} Y_i^2 - \left(\sum_{i=1}^{n} Y_i\right)^2\right]}}$$

$$= \frac{10(279294) - (4141)(643)}{\sqrt{\left[10(1802235) - (4141)^2\right]\left[10(43495) - (643)^2\right]}}$$

$$= \frac{130277}{137120{,}2318} = 0{,}95$$

- Nilai ini memberi arti bahwa, hubungan variable bebas/ predictor X dengan variabel terikat/ response Y adalah sangat kuat, persentasenya 95%.
- Jadi, berat badan memang sangat dipengaruhi oleh konsumsi jumlah kalori/hari

Koefisien Determinasi (r^2)

- Koefisien determinasi dapat ditentukan dengan mengkuadratkan koefisien korelasi.
- Dari contoh kasus di atas, maka koefisien determinasinya adalah $r^2 = 0.95^2 = 0,90$
- Nilai ini berarti bahwa, 90% variabel bebas/ predictor X dapat menerangkan/ menjelaskan variabel tak bebas/ response Y dan 10% dijelaskan oleh variabel lainnya.

Regresi Linear Variabel Jamak

- Regresi variable jamak menggunakan lebih dari satu variabel bebas untuk memprediksi variabel tak bebas

X: Independent variable Y: Dependent variable

	ENGINESIZE	CYLINDERS	FUELCONSUMPTION_COMB	CO2EMISSIONS
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.5	6	10.0	230
6	3.5	6	10.1	232
7	3.7	6	11.1	255
8	3.7	6	11.6	267
9	2.4	4	9.2	?

$$Co2\ Em = \theta_0 + \theta_1 Engine\ size + \theta_2 Cylinders + \ ...$$

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \ ... + \theta_n x_n$$

$$\hat{y} = \theta^T X$$

$$\theta^T = [\theta_0, \theta_1, \theta_2, ...] \qquad X = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ ... \end{bmatrix}$$

Regresi Linear Variabel Jamak

- Contoh prediksi

	ENGINESIZE	CYLINDERS	FUELCONSUMPTION_COMB	CO2EMISSIONS
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.5	6	10.0	230
6	3.5	6	10.1	232
7	3.7	6	11.1	255
8	3.7	6	11.6	267
9	2.4	4	9.2	?

$\hat{y} = \theta^T X$

$\theta^T = [125, 6.2, 14, \dots]$

$\hat{y} = 125 + 6.2x_1 + 14x_2 +$

$Co2Em = 125 + 6.2EngSize + 14\ \text{Cylinders} + \dots$

$Co2Em = 125 + 6.2 \times 2.4 + 14 \times 4 + \dots$

$Co2Em = 214.1$

Regresi Linear Variabel Jamak

- Regresi variable jamak menggunakan Mean Square Error sebagai metrik kesalahan atau selisih antara hasil prediksi dengan nilai aktual variabel tak bebas

	ENGINESIZE	CYLINDERS	FUELCONSUMPTION_COMB	CO2EMISSIONS
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.5	6	10.0	230
6	3.5	6	10.1	232
7	3.7	6	11.1	255
8	3.7	6	11.6	267

$\hat{y} = \theta^T X$

$\hat{y}_i = 140$ the predicted emission of x_i

$y_i = 196$ actual value of x_i

$y_i - \hat{y}_i = 196 - 140 = 56$ residual error

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Regresi Linear Variabel Jamak

Estimasi parameter variabel jamak dilakukan dengan

- Least Squares

  - memerlukan waktu yang lama untuk data set yang besar

- Algoritma Optimalisasi

  - menggunakan metode optimasi berdasarkan gradient descent

  - sesuai untuk dataset yang besar

Regresi Non Linear

- Regresi Non-linier adalah pemodelan hubungan tidak linier antara variabel tak bebas dengan himpunan variabel bebas
- ŷ berupa fungsi non-linier dari parameter θ dan fitur x

$$\hat{y} = \theta_0 + \theta_2{}^2 x$$

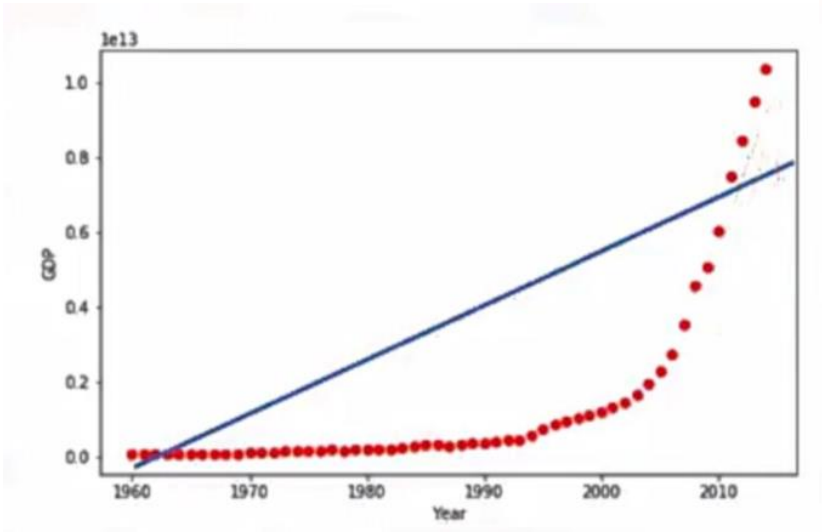
$$\hat{y} = \theta_0 + \theta_1 \theta_2{}^x$$

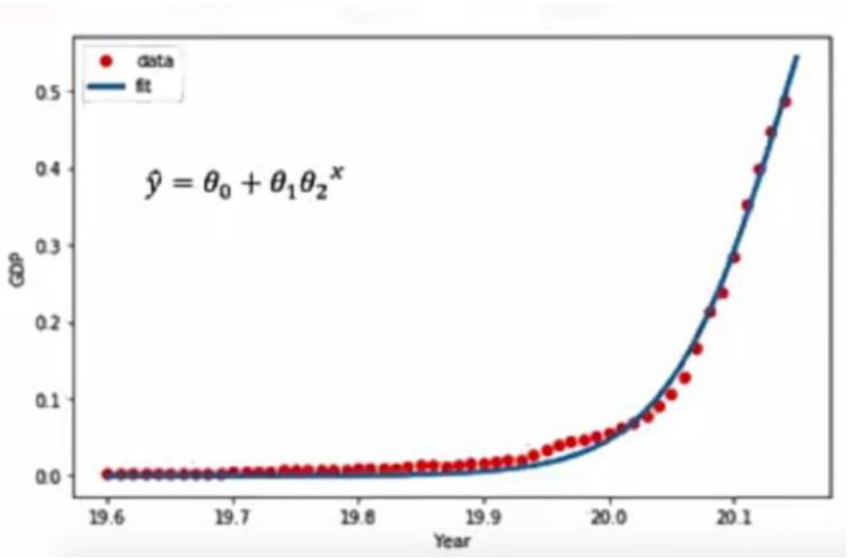
$$\hat{y} = \log(\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3)$$

$$\hat{y} = \frac{\theta_0}{1 + \theta_1{}^{(x-\theta_2)}}$$

Regresi Non Linear

Regresi non-linear diperlukan karena tidak setiap data menunjukkan hubungan linier sehingga error akan besar ketika dipaksakan menggunakan model linier

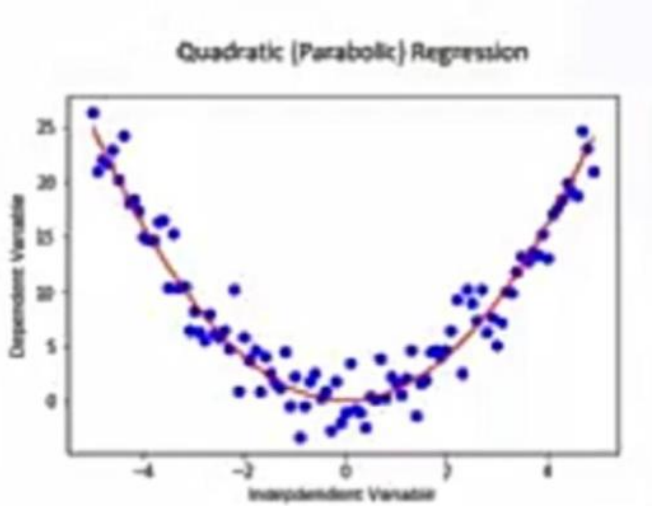


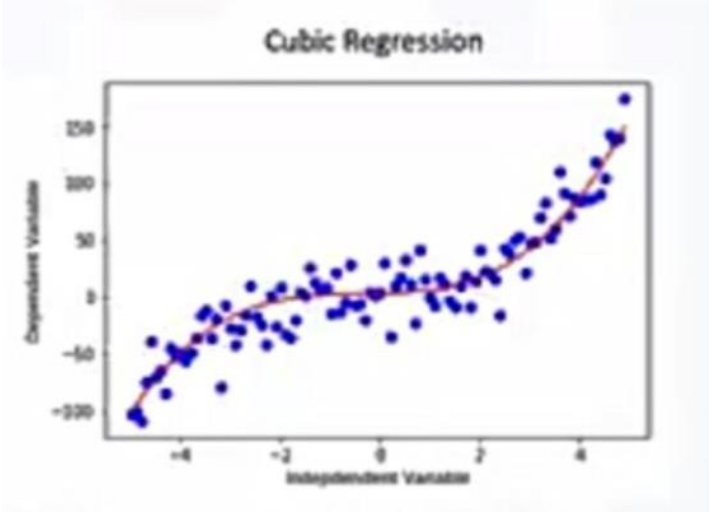


Regresi Non Linear

Tipe regresi non linear:

1. Regresi kuadratik
2. Regresi cubic
3. Regresi polinomial





$$\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3$$

Regresi Non Linear

Regresi polinomial dapat dibawa ke bentuk regresi linear

$$\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3$$

$$x_1 = x$$
$$x_2 = x^2$$
$$x_3 = x^3$$



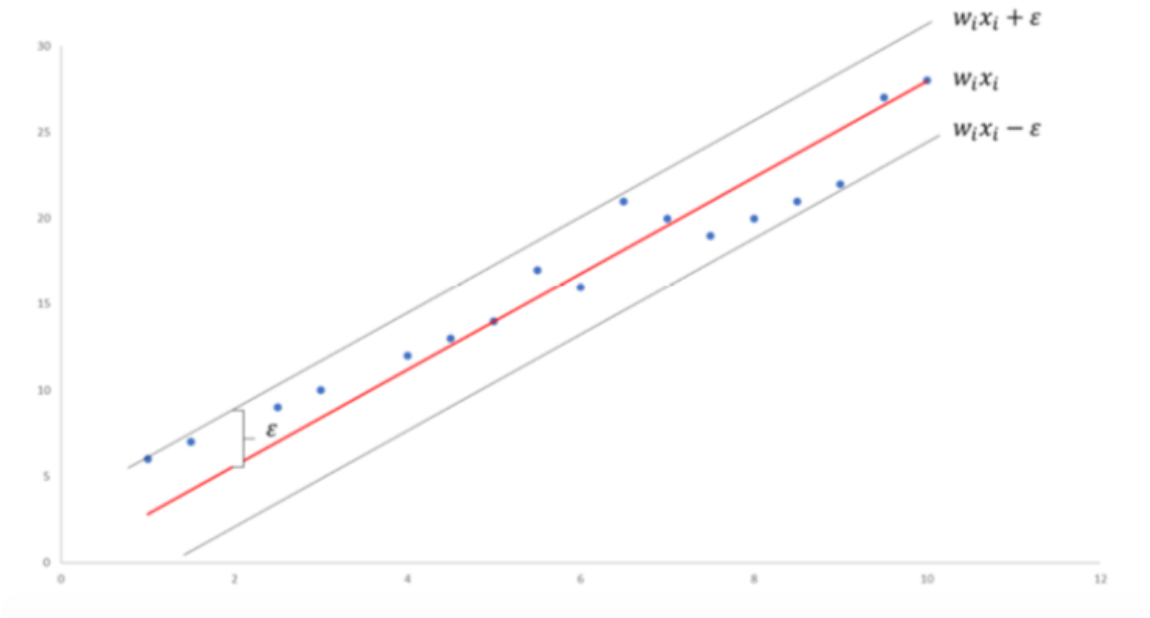
$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3$$

Support Vector Regression

- Support Vector Regression merupakan metode regresi yang memanfaatkan konsep Support Vector Machine
- SVR memberi fleksibilitas untuk menentukan seberapa besar kesalahan yang dapat diterima dalam model dan akan menemukan garis yang sesuai (atau hyperplane dalam dimensi yang lebih tinggi) agar sesuai dengan data.

Support Vector Regression

- Konsep SVR adalah dengan meminimalkan fungsi objektif yakni koefisien dengan konstrain margin



Minimize

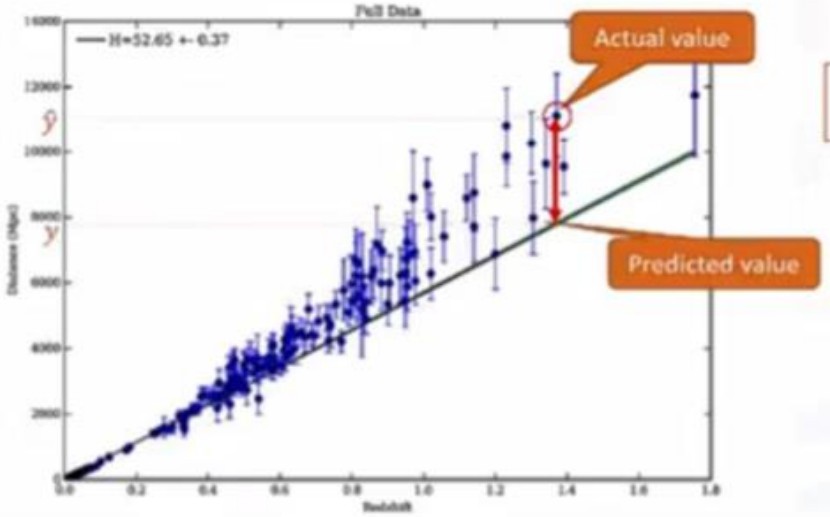
$$MIN\ \frac{1}{2}||\boldsymbol{w}||^2$$

Constraint

$$|y_i - w_i x_i| \leq \varepsilon$$

Evaluasi

Matrik evaluasi yang umum dipakai adalah error



Evaluasi

Matrik evaluasi yang umum dipakai adalah error

- Mean Absoute error
- Mean square error
- Root mean square error

$$MAE = \frac{1}{n}\sum_{j=1}^{n}|y_j - \hat{y}_j|$$

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{j=1}^{n}(y_j - \hat{y}_j)^2}$$

$$RAE = \frac{\sum_{j=1}^{n}|y_j - \hat{y}_j|}{\sum_{j=1}^{n}|y_j - \bar{y}|}$$

$$RSE = \frac{\sum_{j=1}^{n}(y_j - \hat{y}_j)^2}{\sum_{j=1}^{n}(y_j - \bar{y})^2}$$

Logistic Regression

- Logistic Regression merupakan salah satu teknik machine learning untuk melakukan klasifikasi record dari dataset.

	tenure	age	address	income	ed	employ	equip	callcard	wireless	churn
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	Yes
1	33.0	33.0	12.0	33.0	2.0	0.0	0.0	0.0	0.0	Yes
2	23.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	No
3	38.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	No
4	7.0	35.0	14.0	80.0	2.0	15.0	0.0	1.0	0.0	?

Logistic Regression

- Linear Regression

- Melakukan Prediksi
- Prediksi nilai kontinyu dari sebuah variable, seperti:
  - Harga rumah berdasarkan ciri
  - Tekanan darah berdasarkan symptom

- Logistic Regression

- Melakukan Klasifikasi
- Klasifikasi nilai biner, seperti:
  - Kelompok A atau B
  - Tetap berlangganan atau tidak.

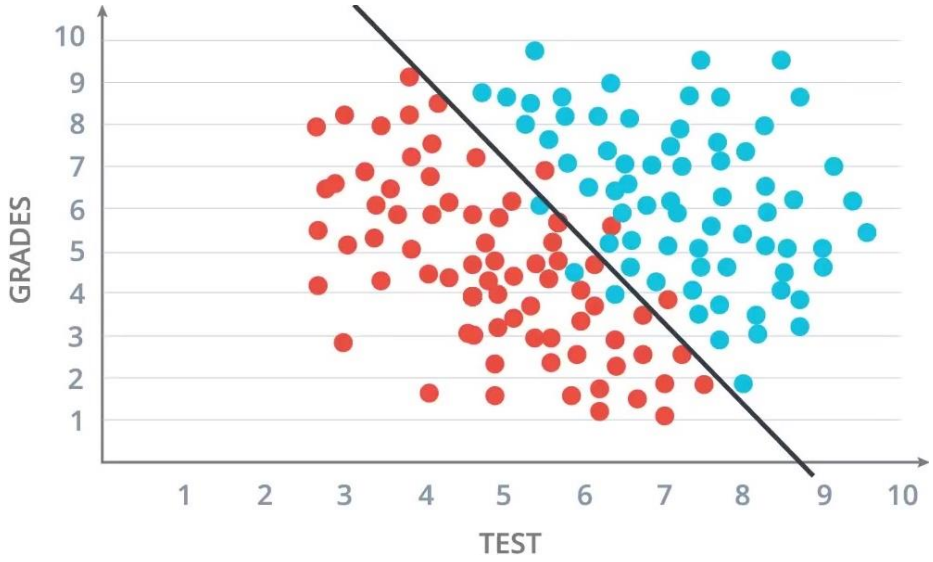
Logistic Regression

- Logistic Regression mewajibkan seluruh data dalam bentuk numerik
- Jika berkategori (Pria/Wanita, Ya/Tidak) harus diubah dalam bentuk angka.

Logistic Regression

Kapan perlu mempergunakan logistic regression

- Jika data berupa binary, seperti:
  - Kelompok A atau B
  - Lulus atau Tidak
  - Berlangganan atau Tidak



- Jika kita membutuhkan pengelompokkan dalam bentuk probabilitas

- Data bersifat "*linearly separable*"

Contoh

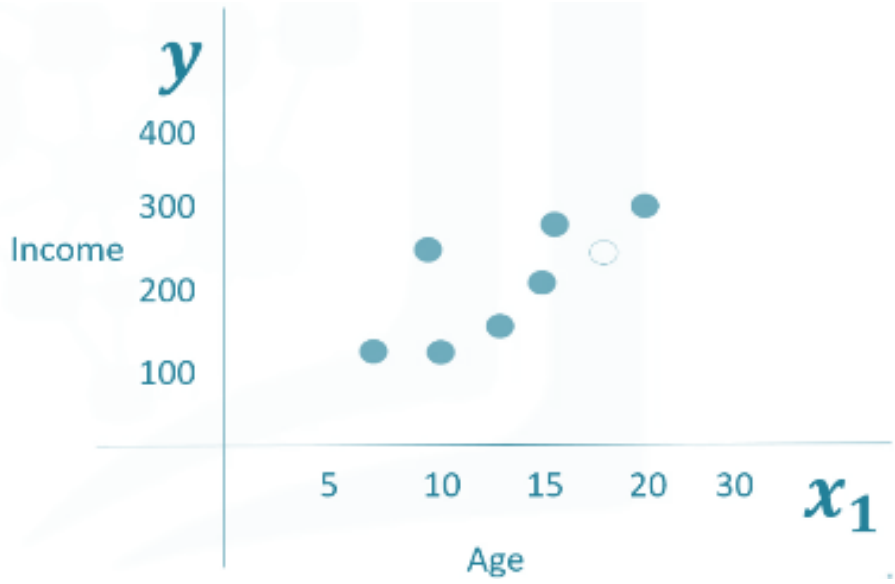
	tenure	age	address	income	ed	employ	equip	callcard	wireless	churn
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	1
1	33.0	33.0	12.0	33.0	2.0	0.0	0.0	0.0	0.0	1
2	23.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	0
3	38.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	0
4	7.0	35.0	14.0	80.0	2.0	15.0	0.0	1.0	0.0	0

- Misal : kita ingin melakukan prediksi pendapatannya pelanggan.
- Untuk simplisitas, kita hanya ambil *age* (umur) sebagai variable yang akan mempengaruhi *income*
- Independent variable () = Age
- Dependent variable () = Income.

Logistic Regression

	tenure	age	address	income	ed	employ	equip	callcard	wireless	churn
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	1
1	33.0	33.0	12.0	33.0	2.0	0.0	0.0	0.0	0.0	1
2	23.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	0
3	38.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	0
4	7.0	35.0	14.0	80.0	2.0	15.0	0.0	1.0	0.0	0

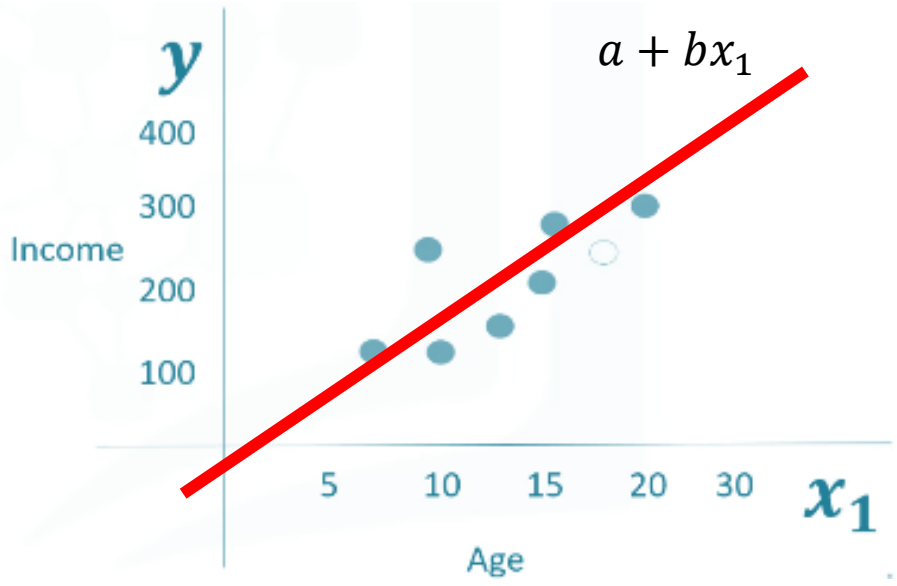
- Untuk memahami data, kita bisa lakukan plotting terlebih dahulu.
- Age, independent variable, sebagai sumbu x
- Income, dependent variable, sebagai sumbu y



Logistic Regression

	tenure	age	address	income	ed	employ	equip	callcard	wireless	churn
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	1
1	33.0	33.0	12.0	33.0	2.0	0.0	0.0	0.0	0.0	1
2	23.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	0
3	38.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	0
4	7.0	35.0	14.0	80.0	2.0	15.0	0.0	1.0	0.0	0

- Dengan Linear Regression kita dapat menyesuaikan sebuah garis yang merepresentasikan tren data.
- Kita dapat menemukan garis ini melalui training, atau menghitungnya secara matematis.
- Garis dapat diexpresikan dengan $a + bx_1$



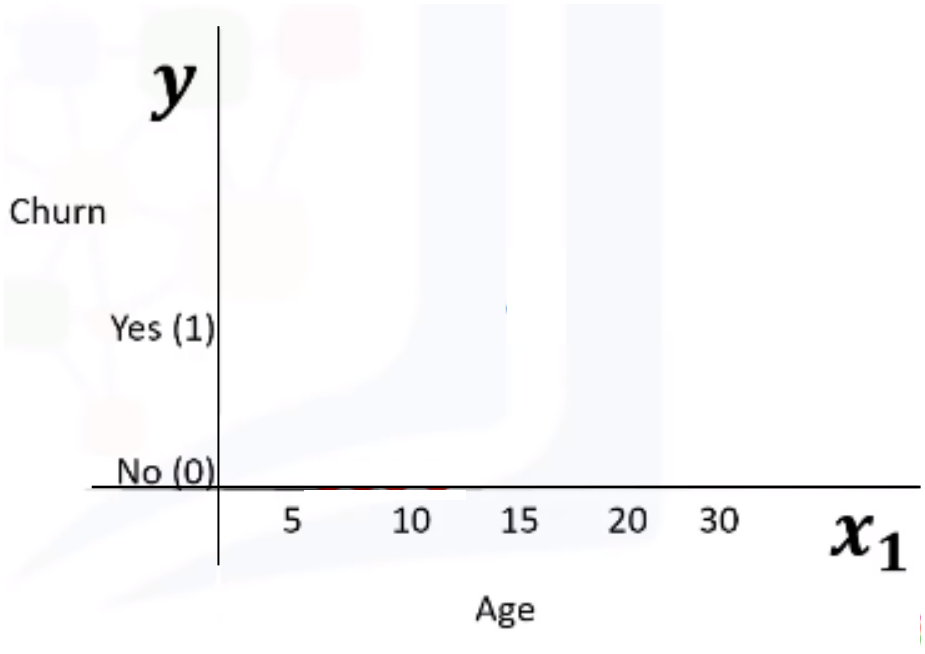
Logistic Regression

	tenure	age	address	income	ed	employ	equip	callcard	wireless	churn
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	1
1	33.0	33.0	12.0	33.0	2.0	0.0	0.0	0.0	0.0	1
2	23.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	0
3	38.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	0
4	7.0	35.0	14.0	80.0	2.0	15.0	0.0	1.0	0.0	0

- Sekarang mari kita ganti permasalahannya.
- Dengan teknik yang sama (linear regression), apakah kita bisa memprediksi kategori dari "*churn*"?
- Indepependent variable (x) = Age
- Dependent variable (y) = Churn.
- Mari kita diskusi bersama.

Logistic Regression

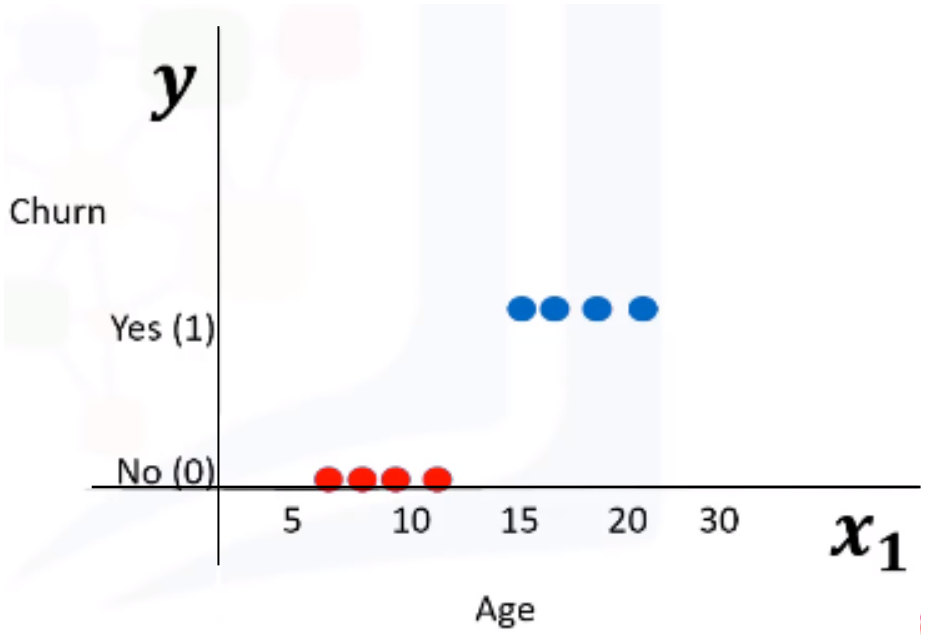
	tenure	age	address	income	ed	employ	equip	callcard	wireless	churn
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	1
1	33.0	33.0	12.0	33.0	2.0	0.0	0.0	0.0	0.0	1
2	23.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	0
3	38.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	0
4	7.0	35.0	14.0	80.0	2.0	15.0	0.0	1.0	0.0	0



- Untuk memahami data, kita bisa lakukan plotting terlebih dahulu.
- *Age*, independent variable, sebagai sumbu x
- *Churn*, dependent variable, sebagai sumbu y

Logistic Regression

	tenure	age	address	income	ed	employ	equip	callcard	wireless	churn
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	1
1	33.0	33.0	12.0	33.0	2.0	0.0	0.0	0.0	0.0	1
2	23.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	0
3	38.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	0
4	7.0	35.0	14.0	80.0	2.0	15.0	0.0	1.0	0.0	0

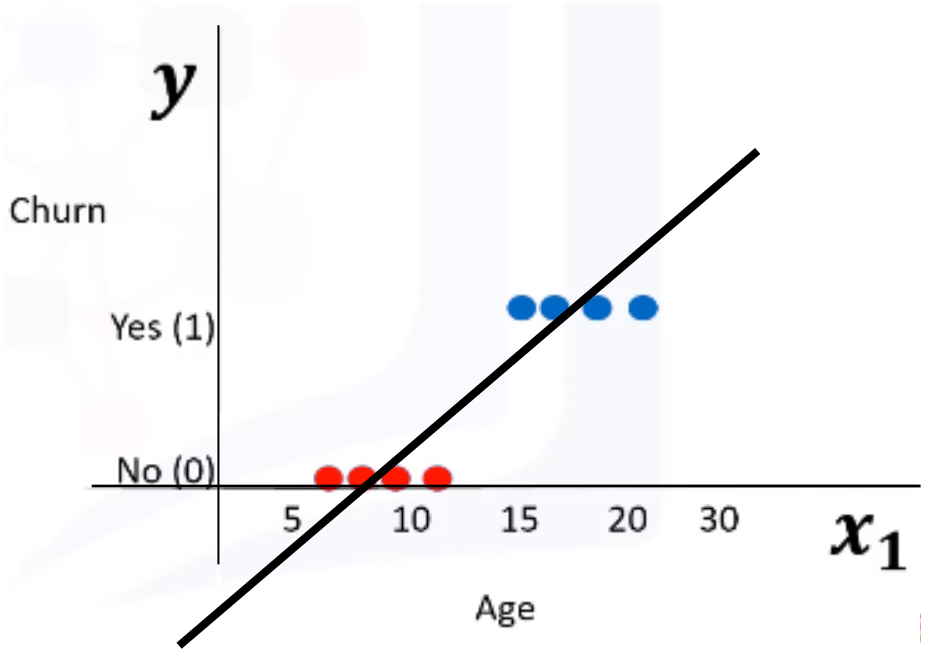


- Dapat kita lihat ada perbedaan mencolok dari plot yang kita buat.
- Sumbu y, *churn*, merupakan data berkategori.
  - Ya dan Tidak.
- Data tidak menjadi kontinyu

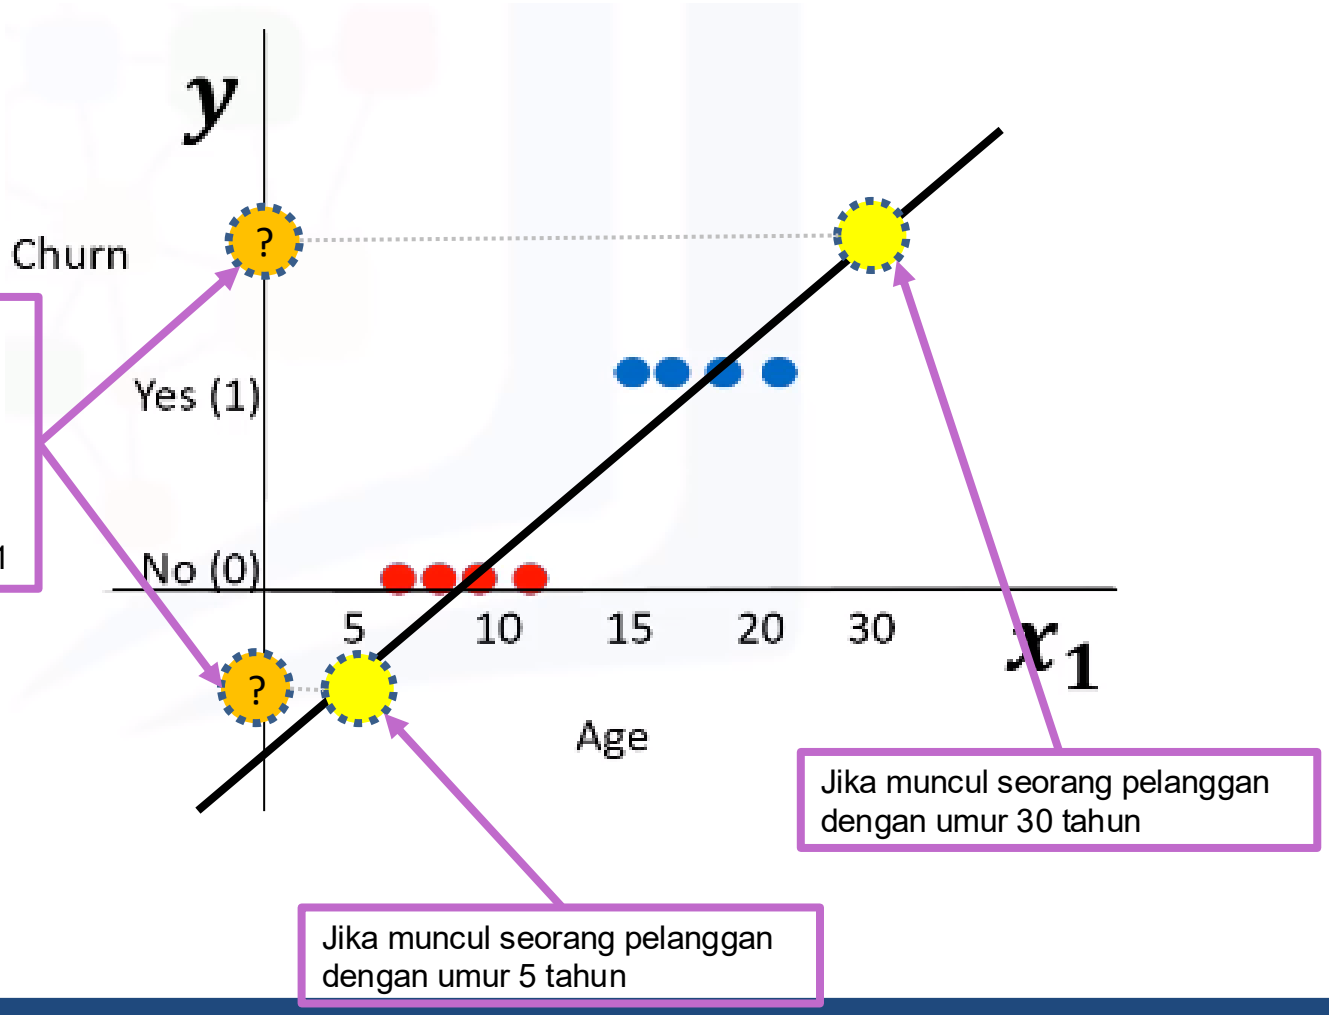
Logistic Regression

	tenure	age	address	income	ed	employ	equip	callcard	wireless	churn
0	11.0	33.0	7.0	136.0	5.0	5.0	0.0	1.0	1.0	1
1	33.0	33.0	12.0	33.0	2.0	0.0	0.0	0.0	0.0	1
2	23.0	30.0	9.0	30.0	1.0	2.0	0.0	0.0	0.0	0
3	38.0	35.0	5.0	76.0	2.0	10.0	1.0	1.0	1.0	0
4	7.0	35.0	14.0	80.0	2.0	15.0	0.0	1.0	0.0	0

- Kita dapat melihat bahwa persamaan garis menjadi tidak relevan.



Logistic Regression



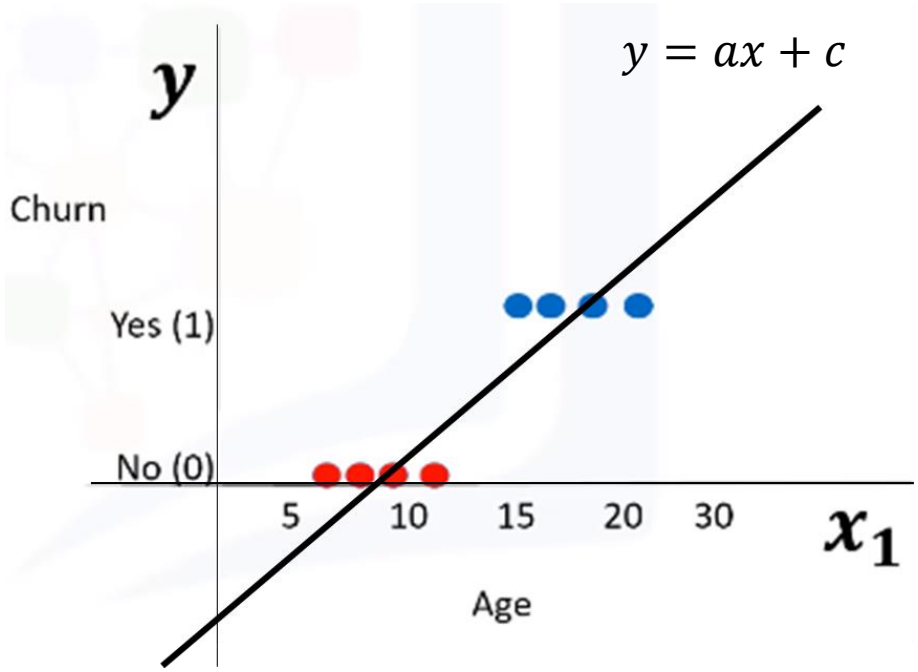
Logistic Regression

- Dari pemaparan sebelumnya, kita memahami bahwa meskipun kita memaksakan diri melakukan linear regression pada permasalahan kategorisasi, hasil yang didapat akan menjadi tidak relevan.

- Linear Regresion hanya untuk memprediksi! Bukan melakukan kategorisasi.

- Logistic Regresion sebaliknya, ditujukan untuk melakukan kategorisasi!

Logistic Regression



Persamaan Garis

$$y = ax + c$$

$$ax + by + c = 0$$

$$w_1 x_1 + w_2 x_2 + b = 0$$

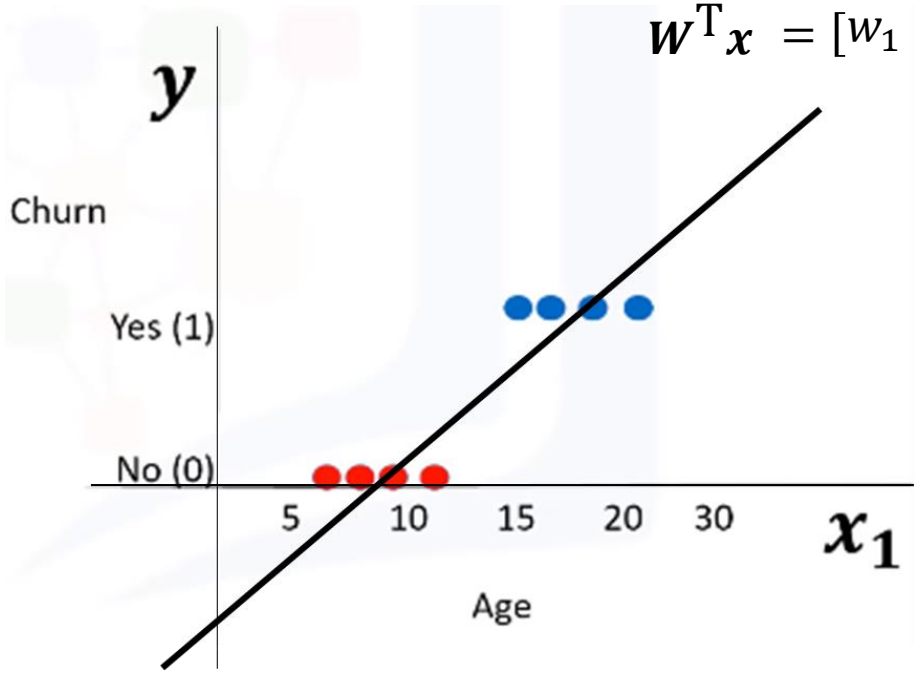
$$w_1 x_1 + w_2 x_2 + w_3 1 = 0$$

$$\boldsymbol{W}^{\mathrm{T}} \boldsymbol{x} = 0$$

dimana : $\boldsymbol{W} = [w_1 \quad w_2 \quad w_3]$

$$\boldsymbol{x} = \begin{bmatrix} x_1 \\ x_2 \\ 1 \end{bmatrix}$$

Logistic Regression



$$\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} = [w_1 \quad w_2 \quad w_3]\begin{bmatrix} x_1 \\ x_2 \\ 1 \end{bmatrix} = w_1x_1 + w_2x_2 + w_31$$

Contoh, diketahui parameter garis:

$$\boldsymbol{w}^{\mathrm{T}} = [0.1 \quad -1 \quad -1]$$

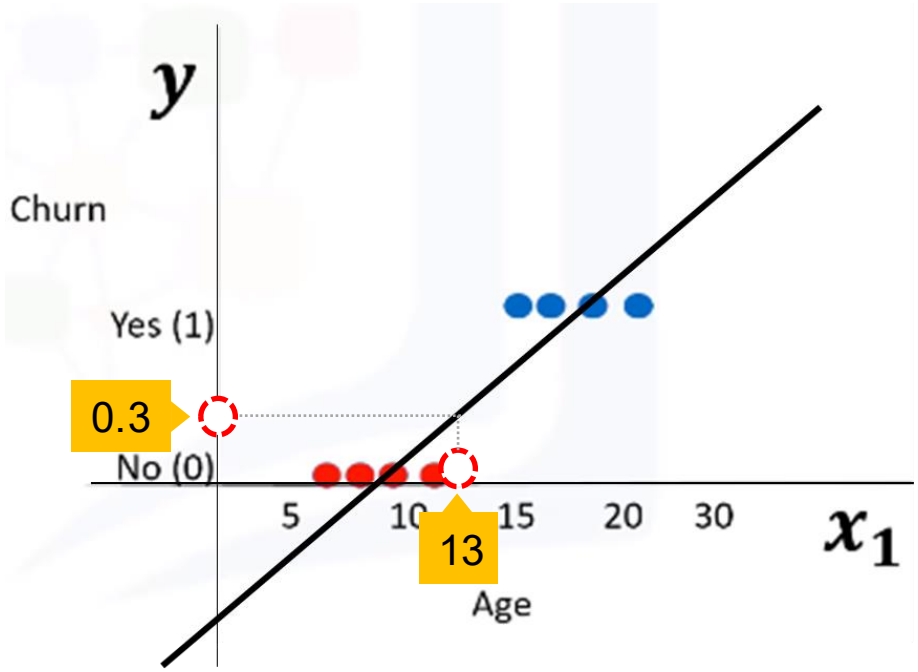
$$\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} = 0.1x_1 - 1x_2 - 1$$

Untuk mempermudah pemahaman

$$x_2 = 0.1x_1 - 1$$

$$y = 0.1x - 1$$

Logistic Regression



Sekarang, kita bisa menggunakan persamaan garis linear regression tersebut untuk melakukan kategorisasi churn berdasarkan umur.

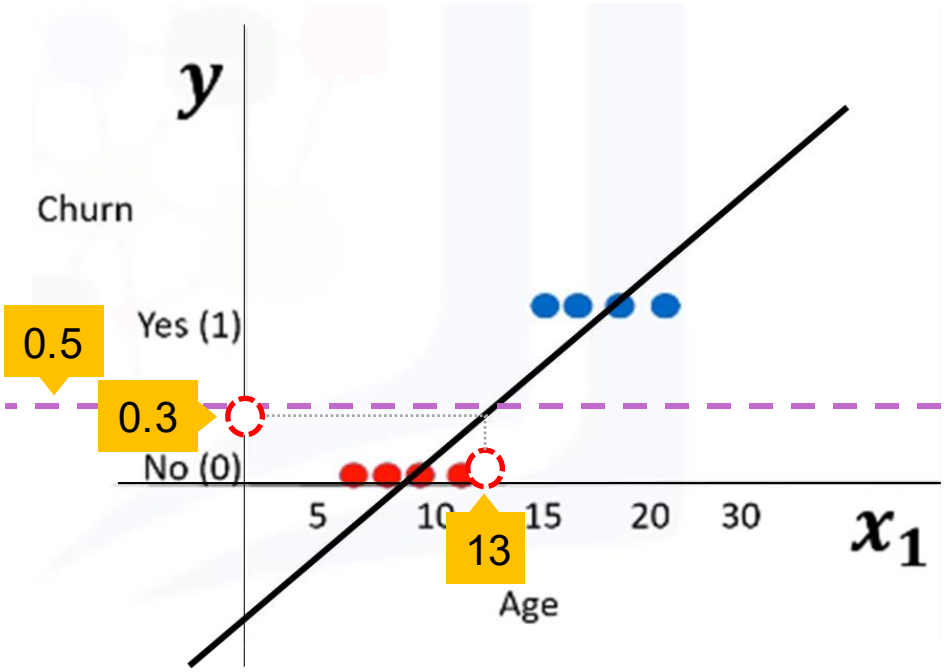
$$y = 0.1x - 1$$

Sebagai contoh, ada pelanggan berumur 13 tahun, maka:

$$y = 0.1(13) - 1$$

$$y = 0.3$$

Logistic Regression



Sekarang, mari kita buat sebuah aturan – thresholding:

$$\hat{y} = \begin{cases} 1, & \boldsymbol{Wx} \geq 0.5 \\ 0, & \boldsymbol{Wx} < 0.5 \end{cases}$$

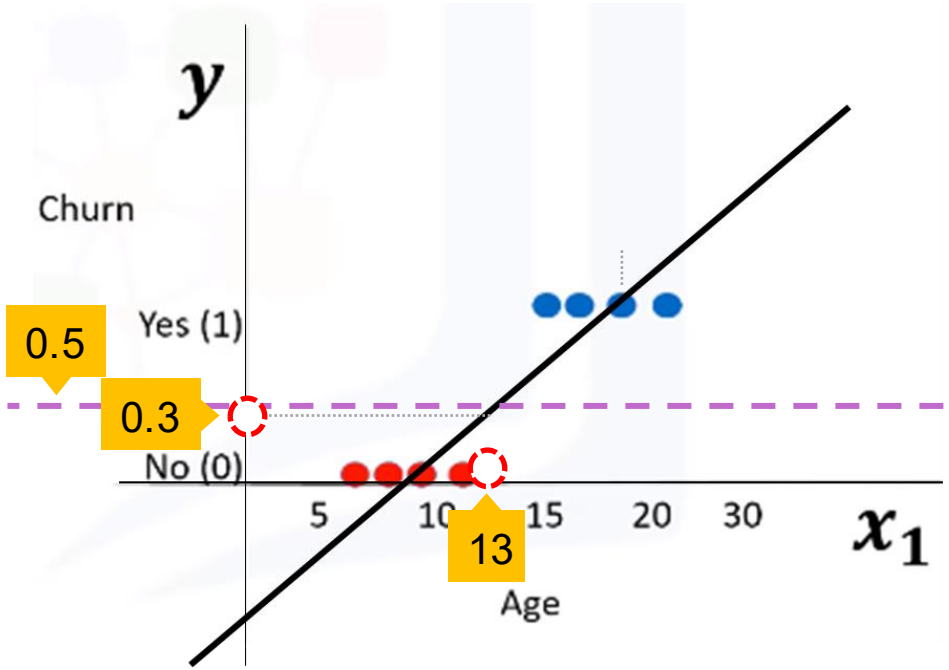
Karena

$$y = 0.3, \text{ dan } y < 0.5$$

Maka, $\hat{y}$ terkategorisasi ke class 0, tidak berlangganan.

$$\hat{y} = 0$$

Logistic Regression

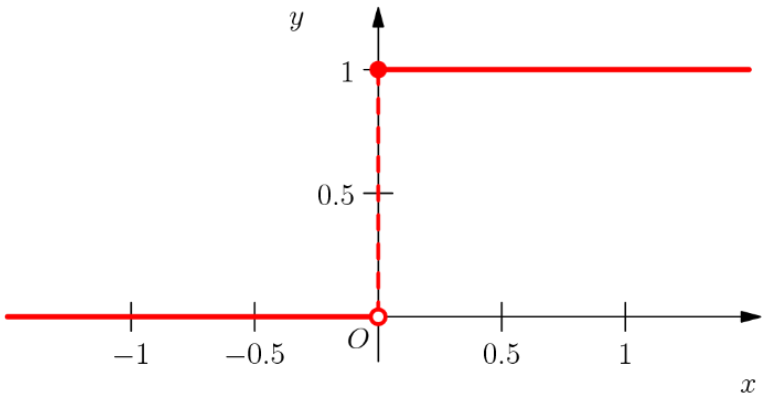


$$\hat{y} = \begin{cases} 1, & W^T x \geq 0.5 \\ 0, & W^T x < 0.5 \end{cases}$$

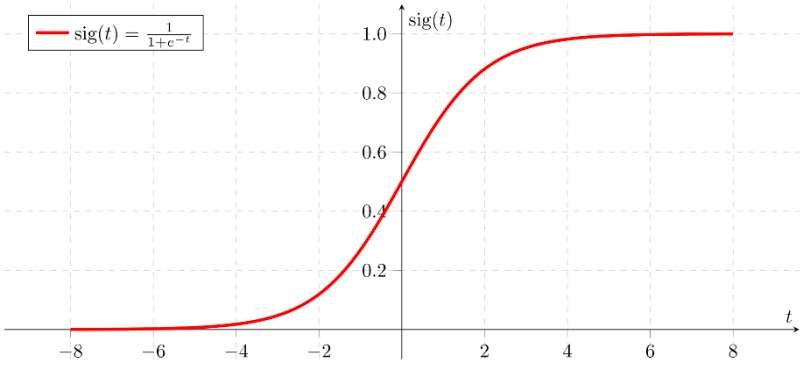
- Terdapat satu permasalahan yang masih belum disinggung.
- Rangkaian tahap ini tidak memberikan output berupa probabilitas.
- Berapa probabilitas pelanggan berumur 13 tahun berhenti berlangganan?

Logistic Regression

- Agar mengeluarkan output berupa probabilitas, Step Function harus diganti dengan sebuah fungsi yang lain, yang disebut dengan Logistic Function



Step Function



Logistic Function

$$\hat{y} = \begin{cases} 1, & \boldsymbol{W}^{\mathrm{T}}\boldsymbol{x} \geq \text{Threshold} \\ 0, & \boldsymbol{W}^{\mathrm{T}}\boldsymbol{x} < \text{Threshold} \end{cases}$$

$$\hat{y} = \sigma(W^{\mathrm{T}}\mathrm{x})$$

Logistic Regression

- Logistic Function juga umum disebut dengan Sigmoid Function.
- Didefinisikan sebagai

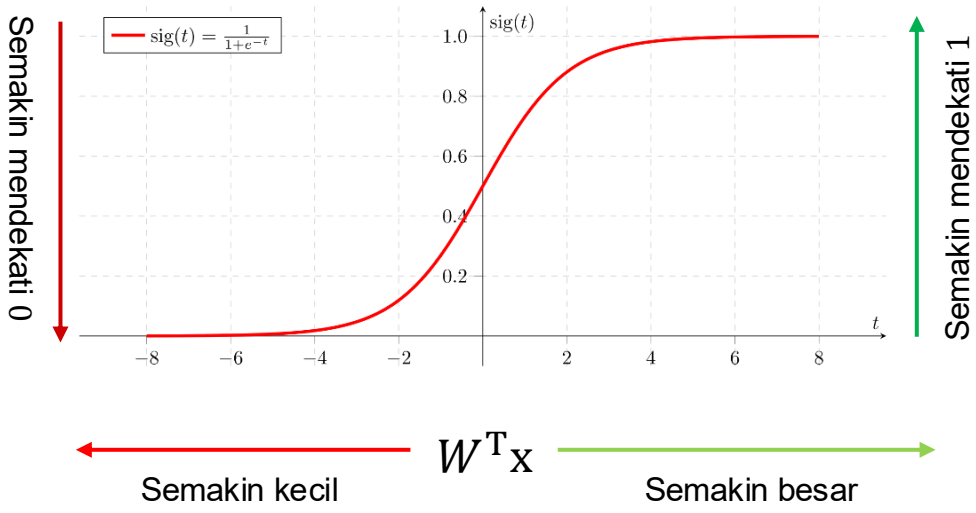
$$\sigma(\hat{y}) = \frac{1}{1 + e^{-\hat{y}}}$$

$\hat{y}$ bernilai besar,
$e^{-\hat{y}}$ mendekati 0
$\sigma(\hat{y}) \cong 1$

- Dimana

$\hat{y}$ bernilai kecil,
$e^{-\hat{y}}$ mendekati ∞
$\sigma(\hat{y}) \cong 0$

$$\hat{y} = W^{\mathrm{T}}\mathrm{x}$$
$$= w_1 x_1 + w_2 x_2 + w_3 1$$



Logistic Regression

- Berdasarkan pengamatan yang kita lakukan, kita melihat bahwa, diperlukan persamaan garis yang tepat agar kategorisasi data menjadi lebih akurat.

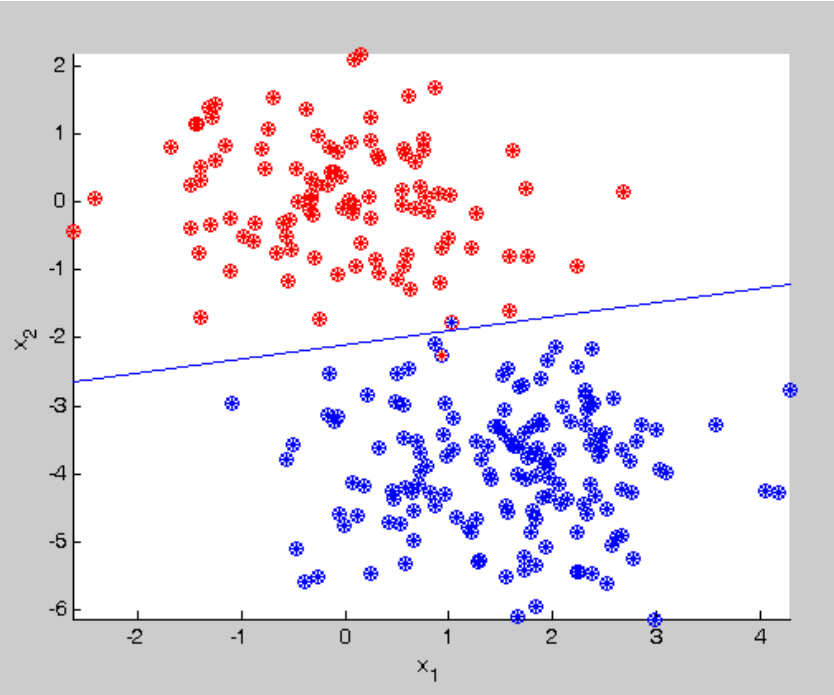
- Untuk menemukan persamaan garis yang tepat, sebuah proses yang disebut training, harus dilakukan!

- Training dilakukan untuk meminimalisasi error yang dibuat oleh persamaan garis.

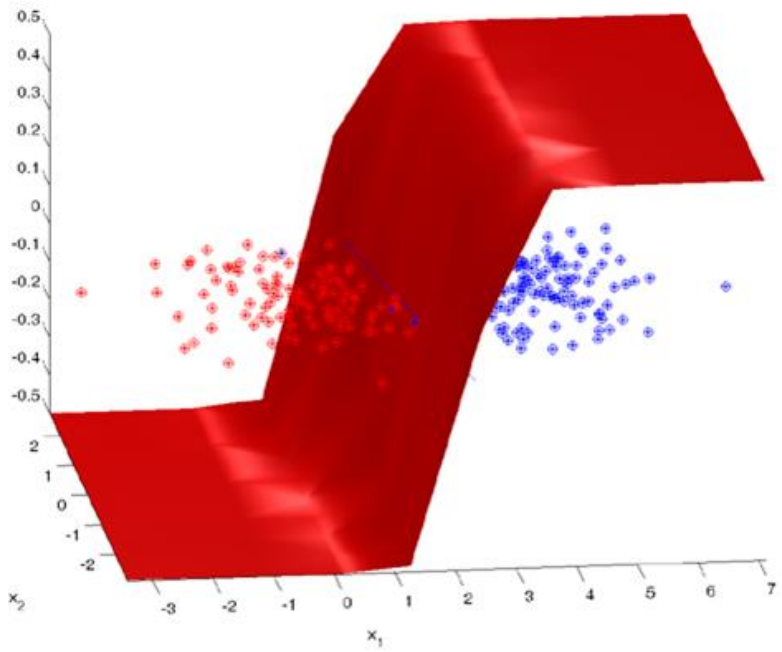
Training Logistic Regression

1. Inisialisasi $\boldsymbol{W}^{\mathrm{T}}$ secara acak untuk menentukan persamaan garis.
2. Hitung score, $\hat{y} = \boldsymbol{W}^{\mathrm{T}}\boldsymbol{x}$
3. Bandingkan hasil $\hat{y}$ dengan nilai label (dependent variable) yang sebenarnya, y
4. Hitung besar error (kesalahan) yang dilakukan oleh persamaan garis tersebut.
5. Ubah $\boldsymbol{W}^{\mathrm{T}}$ sedemikian rupa untuk mereduksi cost.
6. Kembali ke langkah 2.

Training Logistic Regression



Decision Boundary



Logistic Function in Action

Terima Kasih